**UNIVERSITAS INDONESIA**

# RANCANG BANGUN SISTEM PENGELOLAAN TUGAS AKHIR BERBASIS WEB UNTUK MAHASISWA TEKNIK KOMPUTER UNIVERSITAS INDONESIA

**SKRIPSI**

**JOHN DOE**
**2505250000**

**FAKULTAS TEKNIK**
**PROGRAM STUDI S1 TEKNIK KOMPUTER**
**DEPOK**
**2025**

**UNIVERSITAS INDONESIA**

# RANCANG BANGUN SISTEM PENGELOLAAN TUGAS AKHIR BERBASIS WEB UNTUK MAHASISWA TEKNIK KOMPUTER UNIVERSITAS INDONESIA

**SKRIPSI**
**Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Teknik**

**JOHN DOE**
**2505250000**

**FAKULTAS TEKNIK**
**PROGRAM STUDI S1 TEKNIK KOMPUTER**
**DEPOK**
**JULI 2025**

## HALAMAN PERNYATAAN ORISINALITAS

**Skripsi ini adalah hasil karya saya sendiri,**

**dan semua sumber baik yang dikutip maupun dirujuk**

**telah saya nyatakan dengan benar.**

| | | |
|---|---|---|
| **Nama** | : | **John Doe** |
| **NPM** | : | **2505250000** |
| **Tanda Tangan** | : | |
| | | |
| **Tanggal** | : | **25 Juli 2025** |

## HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL

**Saya menyatakan bahwa dalam penyusunan Tugas Akhir ini, saya menggunakan teknologi Keceradasan Buatan dengan platform Gemini dan ChatGPT untuk tujuan pemeriksaan dan perbaikan tata bahasa dan saya bertanggung jawab penuh atas keakuratan, orisinalitas, dan integritas seluruh isi Tugas Akhir ini.**

| | | |
|---|---|---|
| **Nama** | : | **John Doe** |
| **NPM** | : | **2505250000** |
| **Tanda Tangan** | : | |
| | | |
| **Tanggal** | : | **25 Juli 2025** |

## HALAMAN PENGESAHAN

| | | |
|---|---|---|
| Skripsi ini diajukan oleh | : | |
| Nama | : | John Doe |
| NPM | : | 2505250000 |
| Program Studi | : | S1 Teknik Komputer |
| Judul Skripsi | : | Rancang Bangun Sistem Pengelolaan Tugas Akhir Berbasis Web untuk Mahasiswa Teknik Komputer Universitas Indonesia |

**Telah berhasil dipertahankan di hadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Sarjana Teknik pada Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.**

## DEWAN PENGUJI

| | | | |
|---|---|---|---|
| Pembimbing | : | [Nama Dosen Pembimbing] | ( ) |
| Penguji | : | [Nama Dosen Penguji 1] | ( ) |
| Penguji | : | [Nama Dosen Penguji 2] | ( ) |
| Penguji | : | [Nama Dosen Penguji 3] | ( ) |

| | | |
|---|---|---|
| Ditetapkan di | : | Depok |
| Tanggal | : | 1 Agustus 2025 |

# KATA PENGANTAR

Puji dan syukur Penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan rahmat-Nya lah Penulis dapat menyelesaikan Skripsi dengan judul "Rancang Bangun Sistem Pengelolaan Tugas Akhir Berbasis Web untuk Mahasiswa Teknik Komputer Universitas Indonesia". Skripsi ini Penulis laksanakan sebagai salah satu syarat dalam memperoleh gelar Sarjana Teknik pada program studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.

Penulis juga ingin menyampaikan rasa terima kasihnya kepada:

1. [Nama Dosen Pembimbing], selaku Dosen Pembimbing SkripsiPenulis.
2. [Nama Ketua Departemen], selaku Ketua Departemen Teknik Elektro, Fakultas Teknik, Universitas Indonesia.
3. [Nama Ketua Prodi], selaku Kepala Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.
4. [Nama Dosen Pembimbing Akademis], selaku Pembimbing Akademis Penulis.
5. [Nama Dosen Penguji 1], [Nama Dosen Penguji 2] dan [Nama Dosen Penguji 3] selaku Dosen Penguji SkripsiP̃enulis.
6. Segenap dosen Departemen Teknik Elektro atas semua ilmu yang diberikan kepada Penulis.
7. Orang tua yang selalu memberikan dukungan serta doa, sehingga penulisan Skripsi dapat diselesaikan secara baik.
8. Teman-teman Teknik Komputer, selaku rekan penulis yang selalu membantu serta memberikan dukungan moril sepanjang proses kuliah serta penulisan proposal skripsi.

Penulis menyadari dan menerima bahwa Skripsi yang dibentuk ini masih jauh dari sempurna dan masih memiliki berbagai kekurangan serta kesalahan baik dari segi ilmu maupun pemahaman. Oleh karena itu, Penulis mengharapkan segala kritik dan saran yang diberikan agar ke depannya Penulis dapat menjadi lebih baik.

25 Juli 2025

John Doe

**HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS**

Sebagai sivitas akademik Universitas Indonesia, saya yang bertanda tangan di bawah ini:

| | | |
|---|---|---|
| **Nama** | : | John Doe |
| **NPM** | : | 2505250000 |
| **Program Studi** | : | S1 Teknik Komputer |
| **Fakultas** | : | Teknik |
| **Jenis Karya** | : | Skripsi |

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Indonesia **Hak Bebas Royalti Noneksklusif (*Non-exclusive Royalty Free Right*)** atas karya ilmiah saya yang berjudul:

Rancang Bangun Sistem Pengelolaan Tugas Akhir Berbasis Web untuk Mahasiswa Teknik Komputer Universitas Indonesia

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Universitas Indonesia berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyatan ini saya buat dengan sebenarnya.

Dibuat di : Depok

Pada tanggal : 25 Juli 2025

Yang menyatakan

(John Doe)

# ABSTRAK


| | | |
|---|---|---|
| Nama | : | John Doe |
| Program Studi | : | S1 Teknik Komputer |
| Judul | : | Rancang Bangun Sistem Pengelolaan Tugas Akhir Berbasis Web untuk Mahasiswa Teknik Komputer Universitas Indonesia |
| Pembimbing | : | [Nama Dosen Pembimbing] |



Proses pengerjaan Tugas Akhir di Program Studi Teknik Komputer Universitas Indonesia (PSTK UI) menghadapi tantangan ganda, yaitu inefisiensi pada alur kerja administrasi yang masih berjalan semi-manual serta rendahnya tingkat kepatuhan mahasiswa terhadap format penulisan yang baku. Penelitian ini bertujuan untuk merancang, membangun, dan mengevaluasi sebuah solusi terpadu bernama D'Office, yang terdiri dari sistem pengelolaan tugas akhir berbasis web dan sebuah templat penulisan berbasis LaTeX. Sebuah purwarupa fungsional dikembangkan dan dievaluasi melalui metodologi eksperimen campuran yang melibatkan 24 partisipan (mahasiswa dan dosen), dengan membandingkan kelompok kontrol (proses manual) dengan kelompok eksperimen (menggunakan solusi D'Office). Metrik kuantitatif yang diukur meliputi Waktu Pengerjaan Tugas (ToT), Tingkat Keberhasilan Tugas (TSR), Skor Kepatuhan Format, dan Skor Skala Kebergunaan Sistem (SUS), yang didukung oleh data kualitatif dari wawancara. Hasil pengujian menunjukkan bahwa sistem D'Office berhasil mengurangi ToT rata-rata sebesar 76% dan meningkatkan TSR hingga 100% pada tugas-tugas kunci. Penggunaan templat LaTeX meningkatkan Skor Kepatuhan Format secara signifikan dari 74.0 menjadi 97.5. Selain itu, sistem D'Office memperoleh skor SUS "*Excellent*" sebesar 85.5 dan umpan balik kualitatif yang sangat positif dari pengguna. Solusi terpadu D'Office terbukti efektif dalam meningkatkan efisiensi proses administrasi dan kualitas format penulisan tugas akhir, serta memberikan pengalaman pengguna yang sangat memuaskan.



Kata kunci: sistem informasi akademik, manajemen tugas akhir, templat LaTeX, evaluasi usabilitas, rekayasa perangkat lunak.

# ABSTRACT


| | | |
|---|---|---|
| Name | : | John Doe |
| Study Program | : | S1 Teknik Komputer |
| Title | : | Development of a Web-Based Thesis Management System for Computer Engineering Students at the University of Indonesia |
| Supervisor | : | [Nama Dosen Pembimbing] |



The thesis completion process at the Department of Computer Engineering, Universitas Indonesia, faces dual challenges: inefficiencies in the semi-manual administrative workflow and low student compliance with standardized writing formats. This research aims to design, build, and evaluate an integrated solution named D'Office, which consists of a web-based thesis management system and a LaTeX-based writing template. A functional prototype was developed and evaluated through a mixed-methods experiment involving 24 participants (students and lecturers), comparing a control group (manual process) with an experimental group (using the D'Office solution). Quantitative metrics, including Time on Task (ToT), Task Success Rate (TSR), Formatting Compliance Score, and System Usability Scale (SUS) score, were measured, supported by qualitative data from interviews. The results show that the D'Office system successfully reduced the average ToT by 76% and increased the TSR to 100% on key tasks. The use of the LaTeX template significantly improved the Formatting Compliance Score from 74.0 to 97.5. Furthermore, the D'Office system achieved an "Excellent" SUS score of 85.5 and received overwhelmingly positive qualitative feedback from users. The integrated D'Office solution is proven to be effective in enhancing the efficiency of the administrative process and the quality of thesis formatting, while providing a highly satisfactory user experience.



Keywords: academic information system, thesis management, LaTeX template, usability evaluation, software engineering.

## DAFTAR ISI

**HALAMAN JUDUL** . . . . . **i**

**HALAMAN PERNYATAAN ORISINALITAS** . . . . . **ii**

**HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL** . **iii**

**HALAMAN PENGESAHAN** . . . . . **iv**

**KATA PENGANTAR** . . . . . **v**

**HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI** . . . . . **vii**

**ABSTRAK** . . . . . **viii**

**ABSTRACT** . . . . . **ix**

**DAFTAR ISI** . . . . . **x**

**DAFTAR TABEL** . . . . . **xii**

**DAFTAR GAMBAR** . . . . . **xiii**

**DAFTAR PERSAMAAN** . . . . . **xiv**

**DAFTAR NOTASI** . . . . . **xv**

**DAFTAR KODE PROGRAM** . . . . . **xvi**

**DAFTAR SINGKATAN** . . . . . **xvii**

**1 PENDAHULUAN** . . . . . **1**

1.1 Latar Belakang . . . . . 1

1.2 Rumusan Masalah . . . . . 5

1.3 Tujuan Penelitian . . . . . 5

1.4 Manfaat Penelitian . . . . . 6

1.5 Ruang Lingkup Penelitian . . . . . 6

1.6 Sistematika Penulisan . . . . . 7

**2 TINJAUAN PUSTAKA** . . . . . **9**

2.1 Landasan Teori . . . . . 9

2.1.1 Sinyal EEG . . . . . 9

2.1.2 Akuisisi Sinyal EEG . . . . . 11

2.1.3 Prapemrosesan Sinyal EEG . . . . . 12

2.1.4 Feature Selection mRMR . . . . . 16

2.1.5 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG 17

2.1.6 Augmentasi Data EEG . . . . . 19
2.1.7 Variational Auto Encoder . . . . . 21
2.2 Penelitian Terdahulu . . . . . 23
2.2.1 Klasifikasi ASD Berbasis EEG Menggunakan mRMR dan XGBoost 23
2.2.2 Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder . . . . . 24
2.2.3 Dataset yang Digunakan . . . . . 25
2.2.4 Dataset yang Digunakan . . . . . 25
2.3 Fokus pada Celah Penelitian . . . . . 27

**DAFTAR REFERENSI . . . . . 28**

# DAFTAR TABEL

# DAFTAR GAMBAR

# DAFTAR PERSAMAAN

# DAFTAR NOTASI

| | |
|---|---|
| $g$ | Konstanta percepatan gravitasi (9.8 m/s$^2$) |
| $v_0$ | Kecepatan awal benda |
| $\alpha$ | Koefisien alpha |
| $\Sigma$ | Notasi untuk penjumlahan (sigma) |

# DAFTAR KODE PROGRAM

## DAFTAR SINGKATAN

| | |
|---|---|
| **API** | *Application Programming Interface* |
| **DTE** | Departemen Teknik Elektro |
| **HCI** | *Human Computer Interaction* |
| **IMK** | Interaksi Manusia dan Komputer |
| **ITB** | Institut Teknologi Bandung |
| **MVC** | *Model-View-Controller* |
| **ORM** | *Eloquent Object-Relational Mapper* |
| **PDF** | *Portable Document Format* |
| **PRG** | *Post/Redirect/Get* |
| **PSTK UI** | Program Studi Teknik Komputer, Universitas Indonesia |
| **SDLC** | *System Development Life Cycle* |
| **SIAK-NG** | Sistem Informasi Akademik *Next-Generation* |
| **SKS** | Satuan Kredit Semester |
| **SQL** | Structured Query Language |
| **SSD** | *Solid State Drive* |
| **SUS** | *System Usability Scale* |
| **TA** | Tugas Akhir |
| **ToT** | *Time on Task* |
| **TSR** | *Task Success Rate* |
| **TTFB** | *Time to First Byte* |
| **UGM** | Universitas Gadjah Mada |
| **UI** | Universitas Indonesia |
| **UI/UX** | *User Interface/Experience* |
| **UML** | *Unified Modeling Language* |
| **UX** | *User Experience* |

# BAB 1
# PENDAHULUAN

Autism Spectrum Disorder (ASD) merupakan gangguan perkembangan saraf yang memengaruhi kemampuan komunikasi sosial, interaksi sosial, serta pola perilaku individu. Proses identifikasi ASD secara dini masih menjadi tantangan karena metode diagnosis yang ada sering kali bergantung pada observasi klinis yang memerlukan waktu dan evaluasi yang mendalam. Dalam beberapa tahun terakhir, pemanfaatan sinyal electroencephalography (EEG) dan teknik machine learning mulai banyak dieksplorasi sebagai pendekatan alternatif untuk membantu proses identifikasi ASD secara lebih objektif. Meskipun demikian, penelitian berbasis EEG masih menghadapi berbagai kendala, seperti keterbatasan dataset dan tingginya variabilitas sinyal, yang dapat memengaruhi performa model klasifikasi. Oleh karena itu, teknik *data augmentation* mulai diteliti sebagai salah satu pendekatan untuk meningkatkan variasi data pelatihan serta membantu meningkatkan kemampuan generalisasi model.

Bab ini akan dimulai dengan penjelasan Latar Belakang yang memberikan konteks penting terkait penelitian ini, diikuti oleh Rumusan Masalah dan Tujuan Penelitian yang merinci fokus utama studi. Selanjutnya, akan dibahas Manfaat Penelitian dan Ruang Lingkup Penelitian untuk menjelaskan kontribusi serta batasan penelitian ini. Terakhir, Sistematika Penulisan akan menguraikan struktur keseluruhan laporan penelitian.

## 1.1 Latar Belakang

Autism Spectrum Disorder (ASD) merupakan gangguan perkembangan saraf yang ditandai oleh ketidakmampuan yang persisten dalam komunikasi sosial dan interaksi sosial, serta pola perilaku, minat, atau aktivitas yang terbatas dan berulang [1], [2]. Gejala umumnya muncul sejak masa anak-anak, dengan tingkat keparahan yang bervariasi sehingga menimbulkan karakteristik yang beragam pada setiap individu [1]. ASD memengaruhi berbagai aspek dari individu, diantaranya kemampuan sosial, akademik, dan okupasional, serta berlangsung seumur hidup [1]. Oleh karena itu, identifikasi dan intervensi

sejak dini menjadi faktor yang sangat penting untuk meminimalkan hambatan perkembangan jangka panjang dan memperbaiki kualitas hidup individu dengan ASD [1].

Saat ini di Indonesia, jumlah penyandang ASD diperkirakan berjumlah sebanyak 2,4 juta orang, dengan pertambahan sebanyak 500 penyandang baru per tahunnya[3]. Tingkat prevalensi Autism Spectrum Disorder (ASD) di Indonesia dilaporkan relatif lebih rendah dibandingkan dengan beberapa negara di kawasan Asia. Meskipun demikian, perbedaan angka prevalensi antarwilayah sering kali dipengaruhi oleh variasi dalam sistem diagnosis, pelaporan, serta tingkat kesadaran masyarakat, sehingga penguatan skrining dan intervensi dini, pengembangan sistem informasi kesehatan, serta pengurangan stigma sosial perlu menjadi prioritas untuk meningkatkan identifikasi dan penanganan ASD secara lebih efektif[4].

Diagnosa ASD yang akurat masih menjadi tantangan yang signifikan. Hal ini disebabkan oleh sifat heterogen dari ASD, dengan variasi gejala yang luas serta perbedaan tingkat keparahan pada setiap individu. Selain itu, proses diagnosis juga menjadi lebih sulit karena gejala ASD sering kali menyerupai atau muncul bersamaan dengan gangguan perkembangan lainnya, sehingga memerlukan evaluasi yang lebih menyeluruh dan instrumen penilaian yang tepat, serta prosedur diagnosis klinis yang umumnya memerlukan waktu yang cukup lama dan sering kali hanya dilakukan ketika terdapat indikasi kuat adanya perkembangan ASD[5][6]. Metode yang saat ini menjadi standar emas, Autism Diagnostic Observation Schedule, Second Edition (ADOS-2) masih memiliki beberapa kelemahan, seperti evaluasi yang subjektif dan ketidakmampuan membedakan varietas keterbatasan dalam membedakan tingkat keparahan gejala secara akurat, serta kemampuan deteksi dini yang masih kurang memadai karena metode ini pada umumnya menilai kondisi yang telah muncul pada anak[7]. Keterbatasan ini menuntut pengembangan metode yang lebih objektif dan konsisten, sehingga proses identifikasi dapat dilakukan dengan tingkat reliabilitas yang lebih tinggi

Untuk menjawab tantangan tersebut, berbagai penelitian mulai mengeksplorasi pendekatan berbasis data dalam proses identifikasi ASD. Penilaian ASD masih menghadapi berbagai kendala, di antaranya keterbatasan dataset pencitraan medis yang tersedia secara publik serta dominasi metode diagnosis konvensional yang bergantung pada observasi klinis, sehingga berpotensi menimbulkan variasi hasil diagnosis antar klinisi[7]. Oleh

karena itu, pendekatan berbasis biomarker mulai diteliti untuk meningkatkan objektivitas dalam proses identifikasi ASD. Sejumlah penelitian telah mengeksplorasi biomarker neurologis dan fisiologis seperti Magnetic Resonance Imaging (MRI), functional MRI (fMRI), functional near-infrared spectroscopy (fNIRS), serta biomarker genetik dan perilaku. Meskipun menunjukkan potensi dalam mengidentifikasi perbedaan struktur dan aktivitas otak pada individu dengan ASD, metode-metode tersebut masih memiliki keterbatasan, seperti biaya yang tinggi dan kebutuhan peralatan khusus. Oleh karena itu, electroencephalography (EEG) mulai banyak dieksplorasi sebagai biomarker alternatif karena bersifat non-invasif, relatif lebih murah, memiliki resolusi temporal yang tinggi, serta dapat digunakan secara luas dalam lingkungan klinis dan pada berbagai kelompok usia untuk memperoleh pengukuran aktivitas otak secara berulang [8], [9].

Perkembangan pesat dalam bidang machine learning telah membuka peluang baru dalam analisis sinyal neurofisiologis untuk membantu proses identifikasi gangguan neurologis, termasuk ASD. Teknik machine learning memungkinkan peneliti untuk mengekstraksi pola kompleks dari sinyal electroencephalography (EEG) yang sulit diidentifikasi melalui analisis konvensional. Pendekatan ini umumnya melibatkan beberapa tahapan pemrosesan, mulai dari akuisisi sinyal EEG, preprocessing, ekstraksi fitur, hingga proses klasifikasi menggunakan algoritma pembelajaran mesin seperti Support Vector Machine (SVM), k-Nearest Neighbor (kNN), dan Random Forest. Berbagai penelitian menunjukkan bahwa model machine learning yang diterapkan pada data EEG mampu mengidentifikasi perbedaan pola aktivitas otak antara individu dengan ASD dan individu dengan perkembangan tipikal, serta mencapai tingkat akurasi yang tinggi dalam proses klasifikasi.[10][11]. Draft penelitian [1x] mengusulkan pendekatan klasifikasi ASD berbasis EEG yang lebih optimal dan interpretable dengan mengombinasikan seleksi fitur minimum Redundancy Maximum Relevance (mRMR) dan algoritma XGBoost. Pendekatan yang diusulkan menunjukkan kinerja yang sangat baik, dengan tingkat akurasi yang tinggi dan konsisten pada berbagai skenario pengujian, sehingga dapat dikatakan mampu mencapai hasil klasifikasi yang baik untuk mendukung proses identifikasi ASD secara lebih andal.

Meskipun electroencephalography (EEG) menunjukkan potensi sebagai biomarker dalam identifikasi ASD, penelitian berbasis EEG masih menghadapi sejumlah tantan-

gan yang signifikan. Salah satu kendala utama yang ada adalah keterbatasan ketersediaan dataset EEG yang berlabel secara klinis dan dapat diakses secara publik[12]. Keterbatasan jumlah dan variasi partisipan pada dataset EEG dapat meningkatkan risiko overfitting dalam proses pelatihan model pembelajaran mesin, yang pada akhirnya dapat membatasi kemampuan model untuk melakukan generalisasi terhadap populasi yang lebih luas [13]. Variasi data EEG dapat berupa perbedaan protokol pengambilan data, seperti variasi jumlah kanal EEG, konfigurasi elektroda, perangkat perekaman, serta kondisi eksperimen, juga menyebabkan perbedaan karakteristik sinyal antar dataset[14]. Variabilitas sinyal EEG juga dapat berupa perbedaan antar individu, yang dipengaruhi oleh kondisi neurologis dan aktivitas yang dilakukan selama proses perekaman[15]. Data EEG juga rentan terhadap berbagai artefak yang dapat mengkontaminasi sinyal, seperti gerakan otot, kedipan mata, atau gangguan pada perangkat perekaman. Keberadaan artefak tersebut dapat memengaruhi kualitas sinyal yang diperoleh dan berpotensi menimbulkan pola yang tidak merepresentasikan aktivitas otak yang sebenarnya[16]. Kombinasi dari keterbatasan dataset, keberadaan artefak pada sinyal, serta tingginya variabilitas data menyebabkan pengembangan model yang mampu melakukan klasifikasi secara konsisten menjadi lebih sulit, terutama ketika model diharapkan dapat diterapkan secara lebih luas pada data EEG dari berbagai sumber dan kondisi perekaman yang berbeda.

Salah satu pendekatan yang mulai banyak diteliti untuk mengatasi keterbatasan dataset EEG adalah penggunaan teknik data augmentation. Teknik ini bertujuan untuk memperluas jumlah data pelatihan secara artifisial dengan menghasilkan variasi baru dari data yang sudah ada, sehingga model dapat mempelajari representasi fitur yang lebih beragam. Beberapa penelitian menunjukkan bahwa penerapan augmentasi data dapat membantu meningkatkan performa model klasifikasi EEG serta mengurangi risiko overfitting pada kondisi dataset yang terbatas [17]. Pendekatan augmentasi konvensional umumnya dilakukan melalui transformasi sederhana pada sinyal, seperti penambahan noise, pergeseran waktu, atau manipulasi amplitudo. Namun, metode tersebut sering kali memiliki keterbatasan dalam mempertahankan karakteristik kompleks dari sinyal EEG. Seiring dengan perkembangan metode deep learning, pendekatan berbasis model generatif seperti Variational Autoencoder (VAE) mulai banyak digunakan untuk menghasilkan data sintetis yang lebih representatif. Model ini mempelajari distribusi laten dari data EEG dan

memungkinkan proses generasi sampel baru yang mempertahankan karakteristik statistik dari data asli. Oleh karena itu, penggunaan data sintetis berbasis model generatif memiliki potensi yang lebih besar dalam meningkatkan kualitas dataset dibandingkan metode augmentasi konvensional[18]. Meskipun demikian, pemanfaatan data sintetis dalam analisis EEG, khususnya untuk klasifikasi Autism Spectrum Disorder (ASD), masih memerlukan kajian lebih lanjut untuk memahami dampaknya terhadap performa dan kemampuan generalisasi model. Oleh karena itu, penelitian ini bertujuan untuk mengeksplorasi penggunaan teknik augmentasi data berbasis model generatif dalam meningkatkan performa model klasifikasi EEG, serta mengevaluasi sejauh mana data sintetis yang dihasilkan dapat merepresentasikan karakteristik sinyal EEG yang relevan dengan kondisi ASD.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, permasalahan utama dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana teknik data augmentation pada sinyal EEG yang telah dikembangkan dalam penelitian sebelumnya dapat diidentifikasi dan dipilih untuk digunakan dalam klasifikasi EEG untuk klasifikasi ASD?

2. Bagaimana teknik data augmentation dapat diterapkan dalam pipeline pemrosesan data EEG, khususnya terkait tahap penerapannya terhadap proses preprocessing berdasarkan arsitektur yang diusulkan pada draft paper penelitian [1x]?

3. Sejauh mana penggunaan data augmentation memengaruhi performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD)?

## 1.3 Tujuan Penelitian

Selaras dengan rumusan masalah yang telah diuraikan, tujuan dari penelitian ini mencakup sebagai berikut:

1. Mengidentifikasi dan memilih teknik data augmentation pada sinyal EEG yang relevan berdasarkan penelitian yang telah ada untuk digunakan dalam proses klasifikasi

EEG untuk klasifikasi ASD.

2. Menerapkan teknik data augmentation dalam pipeline pemrosesan data EEG berdasarkan arsitektur draft penelitian rujukan [1x] serta mengevaluasi penerapannya terhadap tahapan preprocessing.

3. Menganaalisis pengaruh penggunaan data augmentation terhadap performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD).

## 1.4 Manfaat Penelitian

Berdasarkan latar belakang, rumusan masalah, dan tujuan penelitian yang telah diuraikan, penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. **Bagi Peneliti di Bidang Terkait:**
   Penelitian ini diharapkan dapat menjadi referensi bagi peneliti di bidang Artificial Intelligence dan analisis sinyal EEG, khususnya dalam pengembangan metode pembelajaran mesin untuk analisis data EEG pada studi Autism Spectrum Disorder (ASD). Hasil penelitian ini dapat digunakan sebagai dasar untuk penelitian lanjutan dalam pengembangan model analisis EEG yang lebih efektif.

2. **Bagi Tenaga Medis dan Profesional Kesehatan**
   Penelitian ini diharapkan dapat memberikan gambaran mengenai potensi pemanfaatan teknologi Artificial Intelligence dalam analisis data EEG pada studi Autism Spectrum Disorder (ASD), sehingga dapat mendukung penelitian lanjutan maupun pengembangan alat bantu yang dapat membantu proses evaluasi klinis.

## 1.5 Ruang Lingkup Penelitian

Agar penelitian ini tetap terfokus, maka ditetapkan beberapa batasan masalah sebagai berikut:

1. **Arsitektur Dasar dan Implementasi Model:** Penelitian ini akan merekonstruksi pendekatan analisis EEG yang diusulkan pada penelitian rujukan[1x], yaitu metode

analisis EEG yang memanfaatkan seleksi fitur *mRMR* serta model klasifikasi *XGBoost*. Penelitian ini bertujuan untuk mengimplementasikan kembali pendekatan tersebut sebagai dasar eksperimen.

2. **Dataset dan Variasi Data:** Penelitian ini menggunakan dataset EEG yang sama dengan penelitian rujukan. Variasi dalam penelitian ini terletak pada keterlibatan teknik *data augmentasi* yang dihasilkan berdasarkan data asli yang akan digunakan dan dianalisis pengaruhnya terhadap performa model dalam proses klasifikasi.

3. **Proses Training Model Augmentasi:** Model augmentasi akan dilatih menggunakan metode VAE dengan mengacu pada pendekatan pada penelitian rujukan[], disertai penyesuaian arsitektur model untuk mengakomodasi perubahan dimensi data yang digunakan untuk proses training model.

4. **Proses Training Model Klasifikasi:** Model klasifikasi akan dilatih menggunakan prosedur pelatihan berdasarkan penilitan rujukan [1x] tanpa melakukan modifikasi terhadap struktur model maupun proses *fine-tuning* tambahan di luar skenario eksperimen yang dirancang.

5. **Evaluasi dan Analisis Hasil:** Evaluasi penelitian difokuskan pada perbandingan performa model yang dilatih dengan dan tanpa penerapan *data augmentasi*. Analisis akan mencakup pengamatan terhadap metrik performa klasifikasi untuk menilai pengaruh variasi data terhadap hasil model.

6. **Platform Eksekusi:** Seluruh proses pelatihan, pengujian, dan analisis model akan dijalankan menggunakan komputasi klasik dengan memanfaatkan CPU dan/atau GPU.

## 1.6 Sistematika Penulisan

Laporan tesis ini disusun secara sistematis ke dalam lima bab utama, dengan rincian sebagai berikut:

1. **Bab 1: Pendahuluan.** Bab ini menyajikan gambaran umum penelitian, meliputi latar belakang yang menjelaskan pentingnya analisis sinyal EEG dalam mendukung

identifikasi Autism Spectrum Disorder (ASD), rumusan masalah yang menjadi dasar penelitian, tujuan yang ingin dicapai, manfaat penelitian, ruang lingkup penelitian, serta sistematika penulisan laporan ini.

2. **Bab 2: Tinjauan Pustaka.** Bab ini menguraikan landasan teoretis yang mendukung penelitian, meliputi konsep dasar sinyal EEG, metode ekstraksi dan seleksi fitur pada data EEG, metode *Minimum Redundancy Maximum Relevance* (mRMR), algoritma klasifikasi *XGBoost*, serta kajian terhadap penelitian-penelitian sebelumnya yang relevan.

3. **Bab 3: Metodologi Penelitian.** Bab ini menjelaskan metode yang digunakan dalam penelitian, mencakup deskripsi dataset EEG yang digunakan, tahapan prapemrosesan data, penerapan teknik *data augmentasi*, proses seleksi fitur menggunakan metode *mRMR*, serta proses pelatihan model klasifikasi menggunakan *XGBoost*.

4. **Bab 4: Hasil dan Analisis.** Bab ini memaparkan hasil eksperimen yang diperoleh dari proses pelatihan dan pengujian model. Analisis dilakukan untuk membandingkan performa model pada skenario dengan dan tanpa penerapan *data augmentasi*, serta mengevaluasi pengaruhnya terhadap kemampuan model dalam melakukan klasifikasi data EEG.

5. **Bab 5: Penutup.** Bab terakhir ini berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran untuk pengembangan penelitian selanjutnya terkait analisis dan klasifikasi data EEG menggunakan metode pembelajaran mesin.

# BAB 2
# TINJAUAN PUSTAKA

Bab ini menjelaskan konteks dan landasan teoretis yang mendasari penelitian mengenai analisis sinyal EEG untuk klasifikasi Autism Spectrum Disorder (ASD) menggunakan metode machine learning. Penjelasan diawali dengan pemaparan landasan teori yang mencakup konsep dasar sinyal EEG, tahapan pemrosesan dan analisis data EEG, serta metode klasifikasi yang digunakan dalam penelitian ini. Selanjutnya, bab ini membahas penelitian-penelitian terdahulu yang relevan dengan analisis EEG dan penerapan teknik data augmentation. Bab ini kemudian diakhiri dengan pembahasan mengenai celah penelitian yang menjadi dasar dilakukannya penelitian ini.

## 2.1 Landasan Teori

Bagian ini menguraikan konsep-konsep teoretis yang menjadi dasar dalam penelitian analisis sinyal EEG untuk klasifikasi Autism Spectrum Disorder (ASD). Landasan teori ini mencakup konsep dasar EEG, tahapan pemrosesan sinyal EEG, metode *machine learning* untuk klasifikasi, serta teknik seleksi fitur dan *data augmentation* yang digunakan dalam penelitian ini.

### 2.1.1 Sinyal EEG

Sinyal electroencephalogram (EEG) dihasilkan oleh aktivitas listrik neuron di dalam otak. Neuron saling berkomunikasi melalui proses transmisi sinaptik yang menghasilkan impuls listrik kecil yang menyebar melalui jaringan otak. Ketika sekelompok besar neuron mengalami aktivasi secara sinkron, potensial listrik yang dihasilkan dapat dideteksi pada permukaan kulit kepala menggunakan elektroda. Sinyal EEG direkam sebagai perubahan tegangan terhadap waktu dengan rentang frekuensi yang umumnya berada pada kisaran 0,5 hingga 100 Hz. Aktivitas yang terekam pada sinyal EEG dipengaruhi oleh berbagai proses aktivitas otak, seperti proses kognitif, fungsi motorik, serta kondisi emosional, sehingga EEG banyak dimanfaatkan sebagai alat untuk mempelajari fungsi otak maupun

berbagai gangguan neurologis.[19]

Sinyal EEG memiliki amplitudo yang relatif kecil, umumnya berada pada kisaran sekitar 10 hingga 100 mikrovolt. Amplitudo yang rendah ini menyebabkan sinyal EEG sangat sensitif terhadap berbagai sumber gangguan selama proses perekaman. Gangguan tersebut dapat berasal dari aktivitas fisiologis tubuh maupun dari lingkungan sekitar. Artefak fisiologis yang sering muncul antara lain disebabkan oleh pergerakan mata (electrooculogram atau EOG), aktivitas otot wajah dan kepala (electromyogram atau EMG), serta kedipan mata. Selain itu, interferensi listrik dari perangkat elektronik atau jaringan listrik juga dapat mempengaruhi kualitas sinyal yang direkam. Oleh karena itu, data EEG umumnya memerlukan tahapan prapemrosesan seperti penyaringan sinyal dan penghapusan artefak untuk meningkatkan kualitas sinyal sebelum dilakukan analisis lebih lanjut. [20]

Sinyal EEG juga bersifat tidak stasioner (non-stationary), yang berarti bahwa karakteristik statistiknya dapat berubah terhadap waktu. Perubahan ini dipengaruhi oleh berbagai faktor, termasuk kondisi fisiologis individu, tingkat kesadaran, serta aktivitas kognitif yang sedang berlangsung. Variasi tersebut menyebabkan pola amplitudo maupun distribusi frekuensi sinyal EEG dapat berubah secara dinamis selama proses perekaman. Sifat non-stationary ini menjadikan analisis sinyal EEG lebih kompleks dibandingkan sinyal yang bersifat stasioner, sehingga dalam banyak penelitian diperlukan metode analisis yang mampu menangkap perubahan karakteristik sinyal dari waktu ke waktu.[20]

Dalam penelitian EEG, pengumpulan data umumnya dilakukan menggunakan desain eksperimen atau protokol stimulasi yang terstandarisasi untuk mengamati aktivitas listrik otak pada berbagai kondisi. Secara umum, pembangkitan sinyal EEG dalam penelitian dapat diklasifikasikan menjadi dua jenis utama berdasarkan sumber aktivasinya, yaitu stimulus eksogen dan aktivasi endogen. Stimulus eksogen berasal dari rangsangan eksternal dari lingkungan, seperti rangsangan visual, auditori, atau taktil, yang diterima oleh sistem sensorik dan memicu respons saraf yang kemudian terekam sebagai aktivitas listrik pada EEG. Sebaliknya, aktivasi endogen tidak bergantung pada rangsangan eksternal, melainkan muncul dari proses mental internal individu, seperti imajinasi gerakan (motor imagery), respons emosional, pemusatan perhatian, atau aktivitas kognitif lainnya yang menghasilkan sinyal EEG secara spontan.[19][21]

### 2.1.2 Akuisisi Sinyal EEG

EEG biasanya direkam dalam bentuk sinyal multikanal yang diperoleh dari sejumlah elektroda yang ditempatkan pada berbagai lokasi di permukaan kulit kepala. Dalam konteks ini, setiap kanal merepresentasikan satu jalur perekaman sinyal yang berasal dari pasangan elektroda atau dari elektroda terhadap referensi tertentu. Setiap elektroda menangkap aktivitas listrik dari wilayah otak yang berbeda, sehingga setiap kanal mengandung informasi yang merefleksikan aktivitas saraf pada lokasi spesifik. Oleh karena itu, data multikanal yang dihasilkan mampu merepresentasikan distribusi spasial aktivitas otak pada berbagai area korteks. Representasi ini memungkinkan peneliti untuk melakukan analisis spasial maupun spatio-temporal terhadap aktivitas otak, serta mengidentifikasi pola aktivitas yang muncul pada wilayah tertentu atau hubungan aktivitas antar wilayah otak.[20]

Untuk memastikan konsistensi dan keterbandingan data antar penelitian, penempatan elektroda EEG umumnya mengikuti sistem standar yang dikenal sebagai International 10–20 System. Sistem ini merupakan protokol penempatan elektroda yang distandarisasi oleh International Federation of Clinical Neurophysiology (IFCN) untuk menentukan posisi elektroda pada kulit kepala secara sistematis. Dalam sistem ini, penentuan posisi elektroda didasarkan pada pengukuran jarak antara beberapa titik anatomi utama pada kepala, yaitu nasion, inion, serta titik preauricular pada kedua sisi kepala. Berdasarkan titik-titik referensi tersebut, permukaan kepala dibagi menjadi beberapa posisi proporsional untuk memastikan cakupan perekaman yang memadai terhadap berbagai wilayah otak. Setiap elektroda dalam sistem ini diberi nama yang terdiri dari huruf dan angka, di mana huruf menunjukkan wilayah anatomi relatif pada kulit kepala, seperti frontal (F), central (C), temporal (T), parietal (P), dan occipital (O), sedangkan angka menunjukkan hemisfer otak, dengan angka ganjil untuk hemisfer kiri dan angka genap untuk hemisfer kanan. Selain itu, angka yang lebih kecil menunjukkan posisi yang lebih dekat dengan garis tengah kepala, sedangkan angka yang lebih besar menunjukkan posisi yang lebih lateral. Elektroda yang terletak tepat pada garis tengah kepala ditandai dengan huruf "z" (*zero*), seperti Fz, Cz, dan Pz. Standarisasi ini memungkinkan proses perekaman EEG dilakukan secara konsisten sehingga distribusi aktivitas listrik otak dapat dibandingkan secara lebih sistematis antar subjek maupun antar studi penelitian. [22][23]

–GAMBAR 10-20 System–

Selain konfigurasi dan penempatan elektroda, proses akuisisi sinyal EEG juga melibatkan tahapan konversi sinyal analog menjadi sinyal digital agar dapat diproses oleh sistem komputer. Aktivitas listrik otak yang direkam oleh elektroda pada awalnya berupa sinyal analog dengan perubahan tegangan yang berlangsung secara kontinu terhadap waktu. Untuk memungkinkan penyimpanan dan analisis secara digital, sinyal analog tersebut dikonversi menjadi serangkaian nilai numerik melalui proses digitalisasi menggunakan konverter analog-ke-digital (*analog-to-digital converter* atau ADC). Dalam proses ini, tegangan sinyal pada setiap kanal EEG diukur secara berkala dalam interval waktu yang sangat singkat yang dikenal sebagai *time-frame* atau sampel, kemudian nilai tersebut disimpan sebagai data digital.[23]

Frekuensi pengambilan sampel atau *sampling frequency* menentukan seberapa sering tegangan sinyal diukur dalam satu detik. Resolusi temporal dari sinyal EEG yang direkam sangat bergantung pada frekuensi sampling yang digunakan. Berdasarkan prinsip teorema Nyquist, frekuensi sampling harus setidaknya dua kali lebih besar dari frekuensi tertinggi dari sinyal yang ingin direkam agar bentuk sinyal dapat direpresentasikan secara akurat. Dalam praktik klinis, aktivitas listrik otak yang relevan untuk interpretasi EEG umumnya berada pada rentang frekuensi sekitar 0,1 hingga 70 Hz. Oleh karena itu, standar minimal frekuensi sampling yang direkomendasikan untuk perekaman EEG klinis adalah sekitar 128 Hz. Meskipun demikian, penggunaan frekuensi sampling yang lebih tinggi seringkali lebih disukai karena dapat memberikan resolusi temporal yang lebih baik serta memungkinkan representasi sinyal yang lebih akurat. Perangkat EEG modern umumnya mampu melakukan perekaman dengan frekuensi sampling sebesar 256 Hz atau lebih tinggi.[23]

### 2.1.3 Prapemrosesan Sinyal EEG

Dalam analisis sinyal EEG, aktivitas listrik otak yang terekam dapat dianalisis melalui beberapa pendekatan yang berbeda. Secara umum, analisis EEG dilakukan dalam dua domain utama, yaitu domain waktu (time domain) dan domain frekuensi (frequency domain). Analisis dalam domain waktu dilakukan dengan mengamati karakteristik sinyal terhadap waktu, seperti amplitudo puncak, latensi, serta perbedaan latensi antar komponen sinyal yang muncul pada kondisi tertentu. Sementara itu, analisis dalam domain frekuensi bertujuan untuk mengidentifikasi kandungan spektral sinyal dengan memeriksa

distribusi energi atau daya pada berbagai rentang frekuensi menggunakan metode transformasi spektral, seperti Fast Fourier Transform (FFT) maupun teknik estimasi Power Spectral Density (PSD). Melalui analisis spektral tersebut, pola osilasi aktivitas otak pada rentang frekuensi tertentu dapat diidentifikasi.[21]

Dalam praktik analisis spektral EEG, sinyal yang telah direkam biasanya terlebih dahulu dibagi ke dalam beberapa segmen waktu atau epoch sebelum dilakukan perhitungan spektrum. Setiap epoch kemudian dianalisis untuk memperoleh nilai Power Spectral Density (PSD) yang menggambarkan distribusi daya sinyal pada setiap frekuensi. Nilai PSD yang dihasilkan dari seluruh epoch umumnya dirata-ratakan untuk setiap kanal dan subjek sehingga diperoleh representasi spektral yang lebih stabil. Setelah distribusi spektrum sinyal diperoleh, analisis selanjutnya umumnya dilakukan dengan membagi rentang frekuensi EEG ke dalam beberapa pita frekuensi tertentu (*frequency bands*). Pembagian ini bertujuan untuk mempermudah interpretasi aktivitas listrik otak karena setiap rentang frekuensi diketahui berkaitan dengan kondisi fisiologis dan kognitif yang berbeda. Secara umum, sinyal EEG diklasifikasikan ke dalam lima pita frekuensi utama sebagai berikut[20]:

- **Delta (±0,5–4 Hz)**: Pita frekuensi delta umumnya muncul secara dominan pada kondisi tidur nyenyak (*deep sleep*) atau keadaan tidak sadar. Aktivitas delta sering dikaitkan dengan proses pemulihan fisiologis dan regulasi fungsi tubuh selama fase tidur dalam.

- **Theta (±4–8 Hz)**: Aktivitas theta biasanya muncul pada kondisi mengantuk, tahap awal tidur, serta pada beberapa aktivitas mental tertentu seperti meditasi dan proses pembentukan memori. Gelombang theta juga sering dikaitkan dengan aktivitas pada sistem limbik dan hipokampus.

- **Alpha (±8–13 Hz)**: Gelombang alpha umumnya terlihat ketika individu berada dalam keadaan rileks namun tetap terjaga, terutama ketika mata tertutup dan rangsangan visual berkurang. Aktivitas alpha sering ditemukan pada wilayah oksipital dan dianggap berkaitan dengan kondisi relaksasi serta pengolahan informasi sensorik yang minimal.

- **Beta (±13–30 Hz)**: Pita frekuensi beta umumnya berkaitan dengan kondisi kewaspadaan, aktivitas kognitif aktif, pemecahan masalah, serta aktivitas motorik. Gelombang beta sering meningkat ketika individu sedang berpikir secara intens atau melakukan aktivitas yang memerlukan konsentrasi.

- **Gamma (>±30 Hz)**: Aktivitas gamma berada pada rentang frekuensi tinggi dan sering dikaitkan dengan proses kognitif tingkat lanjut, seperti perhatian, integrasi informasi sensorik, serta proses memori dan persepsi.

Melalui analisis distribusi daya pada setiap pita frekuensi tersebut, peneliti dapat mengidentifikasi pola aktivitas otak yang khas serta membandingkan karakteristik sinyal EEG pada berbagai kondisi fisiologis maupun gangguan neurologis tertentu. Oleh karena itu, representasi pita frekuensi EEG sering digunakan sebagai dasar dalam proses ekstraksi fitur pada analisis sinyal EEG, misalnya melalui perhitungan *band power*, estimasi *power spectral density* (PSD), maupun metode analisis spektral lainnya.

–FOTO RENTANG FREKUENSI PSD–

Sebelum dilakukan proses ekstraksi fitur maupun klasifikasi, sinyal EEG umumnya melalui beberapa tahapan prapemrosesan (*preprocessing*). Tahapan ini bertujuan untuk meningkatkan kualitas sinyal dengan mengurangi komponen gangguan yang tidak relevan serta menyiapkan data agar lebih sesuai untuk proses analisis komputasional. Dalam praktik analisis EEG, berbagai teknik prapemrosesan telah dikembangkan untuk memperbaiki kualitas sinyal yang direkam. Secara umum, teknik-teknik tersebut meliputi penyaringan sinyal (*filtering*), penghapusan artefak (*artifact removal*), koreksi baseline (*baseline correction*), serta normalisasi atau standarisasi data. Setiap teknik memiliki tujuan yang berbeda dalam meningkatkan kualitas dan konsistensi data EEG sebelum dilakukan analisis lebih lanjut.[20]

Salah satu tahap prapemrosesan yang paling umum diterapkan adalah penyaringan sinyal (*filtering*). Proses ini bertujuan untuk menghilangkan komponen frekuensi yang tidak berkaitan dengan aktivitas saraf serta mengurangi pengaruh gangguan dari lingkungan sekitar. Sinyal EEG yang direkam sering mengandung berbagai jenis gangguan, seperti *DC offset*, drift frekuensi rendah, maupun interferensi listrik dari jaringan listrik. Oleh karena itu, proses penyaringan biasanya dilakukan dengan membatasi rentang

frekuensi sinyal yang dianalisis menggunakan filter tertentu. Dalam banyak penelitian, *band-pass filter* digunakan untuk mempertahankan komponen frekuensi yang berkaitan dengan aktivitas otak, biasanya pada rentang sekitar 0,5 hingga 70 Hz. Selain itu, *notch filter* sering diterapkan pada frekuensi 50 Hz atau 60 Hz untuk menekan interferensi dari jaringan listrik. Filter tambahan seperti *high-pass filter* juga dapat digunakan untuk menghilangkan drift sinyal berfrekuensi sangat rendah, sedangkan *low-pass filter* digunakan untuk mereduksi komponen noise berfrekuensi tinggi. Perancangan filter perlu dilakukan secara hati-hati karena konfigurasi filter yang tidak tepat dapat menyebabkan distorsi sinyal atau pergeseran fase, terutama pada analisis yang berfokus pada karakteristik temporal sinyal.[20]

Selain gangguan frekuensi, sinyal EEG juga sering terkontaminasi oleh artefak non-neural yang berasal dari aktivitas fisiologis maupun faktor eksternal. Artefak tersebut dapat disebabkan oleh kedipan mata, pergerakan bola mata, aktivitas otot wajah dan kepala, serta pergerakan tubuh selama proses perekaman. Keberadaan artefak dapat mempengaruhi kualitas sinyal dan berpotensi menurunkan akurasi analisis maupun kinerja sistem klasifikasi. Oleh karena itu, berbagai metode telah dikembangkan untuk mengidentifikasi dan mengurangi pengaruh artefak pada data EEG. Salah satu pendekatan yang banyak digunakan adalah metode *Blind Source Separation* (BSS), seperti *Independent Component Analysis* (ICA), yang memisahkan sinyal EEG menjadi beberapa komponen yang secara statistik independen sehingga komponen yang berkaitan dengan artefak dapat diidentifikasi dan dipisahkan dari komponen yang merepresentasikan aktivitas saraf. Metode lain yang juga banyak diterapkan adalah pendekatan berbasis transformasi wavelet, yang memungkinkan analisis sinyal secara simultan pada domain waktu dan frekuensi sehingga memudahkan identifikasi artefak yang bersifat temporer maupun berfrekuensi tinggi[20].

Selain itu, dalam analisis EEG berbasis *machine learning*, normalisasi atau standarisasi data sering diterapkan untuk mengurangi variasi antar kanal maupun antar subjek. Variasi tersebut dapat menyebabkan perbedaan skala pada fitur yang diekstraksi dari sinyal EEG sehingga dapat mempengaruhi proses pembelajaran model. Oleh karena itu, proses normalisasi digunakan untuk menyesuaikan skala fitur agar berada dalam rentang yang lebih seragam. Salah satu metode yang umum digunakan adalah *z-score normalization*, yaitu dengan mengurangkan nilai rata-rata dan membaginya dengan standar deviasi

sehingga data memiliki rata-rata nol dan variansi satu. Metode lain yang juga sering digunakan adalah *min-max normalization*, yang menskalakan nilai fitur ke dalam rentang tertentu, biasanya antara 0 dan 1. Penerapan normalisasi atau standarisasi membantu memastikan bahwa setiap fitur memiliki kontribusi yang lebih seimbang dalam proses pembelajaran model serta dapat meningkatkan stabilitas dan kinerja algoritma klasifikasi yang digunakan[20].

### 2.1.4 Feature Selection mRMR

Dalam banyak aplikasi klasifikasi, identifikasi fitur-fitur yang paling merepresentasikan data observasi, atau yang dikenal sebagai proses *feature selection*, merupakan langkah yang krusial untuk meminimalkan kesalahan klasifikasi. Diberikan suatu dataset $D$ yang terdiri dari $N$ sampel dan $M$ fitur $X = \{x_i \mid i = 1, 2, \ldots, M\}$, serta variabel target klasifikasi $c$, maka permasalahan seleksi fitur adalah menentukan subset fitur berdimensi lebih rendah $R^m \subset R^M$ dengan $m < M$ yang mampu merepresentasikan karakteristik variabel target secara optimal.

Secara umum, tujuan *feature selection* dapat diformulasikan sebagai proses optimasi untuk mencari himpunan fitur $S \subseteq X$ dengan $|S| = m$ yang memaksimalkan ketergantungan terhadap kelas target. Ketergantungan ini sering diukur menggunakan *mutual information* $I(S;c)$, sehingga permasalahan dapat dinyatakan sebagai:

$$\max_{S \subseteq X, |S|=m} I(S;c) \tag{2.1}$$

Namun, penggunaan seluruh fitur yang tersedia tidak selalu menghasilkan performa yang optimal karena adanya redundansi informasi antar fitur. Fitur-fitur yang memiliki korelasi tinggi cenderung memberikan informasi yang berulang dan tidak menambah kontribusi signifikan dalam proses klasifikasi. Oleh karena itu, diperlukan metode *feature selection* yang tidak hanya mempertimbangkan relevansi terhadap target, tetapi juga meminimalkan redundansi antar fitur[24].

Keberadaan fitur-fitur yang bersifat tidak relevan maupun destruktif terhadap proses klasifikasi merupakan permasalahan umum dalam pengolahan data. Oleh karena itu, algoritma *feature selection* menjadi komponen penting dalam aplikasi klasifikasi dan pembe-

lajaran mesin untuk mengeliminasi fitur-fitur tersebut. Selain itu, karakteristik data berdimensi tinggi, seperti pada analisis domain frekuensi sinyal EEG, proses seleksi fitur yang tepat mampu mencegah peningkatan kompleksitas, *overfitting*, serta penurunan kemampuan generalisasi dari model klasifikasi. Oleh karena itu, metode *minimum Redundancy Maximum Relevance* (mRMR) digunakan untuk menghilangkan fitur yang tidak relevan sekaligus memilih subset fitur yang optimal dan efisien [25].

### 2.1.5 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG

Dalam *machine learning*, klasifikasi merupakan proses pemetaan data masukan ke dalam kategori atau kelas tertentu berdasarkan pola yang dipelajari dari data pelatihan. Pada analisis EEG, proses klasifikasi umumnya dilakukan dengan menggunakan fitur-fitur yang diekstraksi dari sinyal EEG, seperti fitur dalam domain waktu, domain frekuensi, maupun domain waktu-frekuensi. Fitur-fitur tersebut merepresentasikan karakteristik aktivitas listrik otak yang relevan terhadap kondisi fisiologis atau kognitif tertentu. Melalui proses klasifikasi, model diharapkan mampu mengidentifikasi pola tersebut secara akurat pada data baru.

Sinyal EEG telah banyak digunakan dalam berbagai tugas klasifikasi untuk mengidentifikasi kondisi kognitif dan neurologis berdasarkan pola aktivitas otak, diantaranya dalam tugas motorik, deteksi kejang epilepsi, dan penerapan dalam sistem *brain–computer interface* (BCI) [26]. Berkaitan dengan gangguan perkembangan saraf, sinyal EEG juga dimanfaatkan untuk mengidentifikasi pola aktivitas otak yang berkaitan dengan *Autism Spectrum Disorder* (ASD). Perbedaan karakteristik aktivitas neurofisiologis antara individu dengan ASD dan individu dengan perkembangan tipikal memungkinkan penggunaan EEG sebagai data dalam proses klasifikasi kondisi tersebut[10].

Salah satu pendekatan yang banyak digunakan dalam tugas klasifikasi adalah analisis dalam domain frekuensi. Analisis dalam domain frekuensi merupakan pendekatan yang umum digunakan dalam studi EEG untuk mengkaji gangguan *Autism Spectrum Disorder* (ASD), karena aktivitas otak dapat direpresentasikan sebagai pola osilasi yang terdistribusi pada pita frekuensi tertentu. Pita frekuensi EEG diketahui memiliki keterkaitan erat dengan berbagai proses kognitif dan fungsi neural, sehingga analisis spektral menjadi pendekatan yang informatif dalam mengungkap karakteristik aktivitas neurofisiolo-

gis. Pendekatan ini juga memungkinkan pengukuran kuantitatif terhadap distribusi daya sinyal pada masing-masing pita frekuensi, baik dalam bentuk *absolute power* maupun *relative power*, yang memberikan informasi mengenai aktivitas neural secara lebih terstruktur dan terukur.

Dalam konteks ASD, studi EEG berbasis analisis spektral menunjukkan adanya pola abnormalitas yang relatif konsisten pada berbagai pita frekuensi. Individu dengan ASD cenderung menunjukkan peningkatan daya pada pita frekuensi rendah (delta dan theta) serta frekuensi tinggi (beta dan gamma), disertai dengan penurunan daya pada pita frekuensi menengah (alpha). Pola ini membentuk karakteristik profil spektral berbentuk U (*U-shaped profile*) yang mencerminkan adanya gangguan dalam mekanisme neurofisiologis yang mendasari aktivitas otak. Oleh karena itu, representasi dalam domain frekuensi menjadi relevan dalam analisis dan klasifikasi ASD, karena mampu menyoroti perbedaan distribusi aktivitas neural yang tidak mudah diamati dalam domain waktu [26].

Berdasarkan representasi fitur yang diperoleh, proses klasifikasi selanjutnya dilakukan menggunakan algoritma *machine learning* untuk membangun model prediksi. Berbagai metode klasifikasi, seperti *support vector machine* (SVM), *k-nearest neighbor* (KNN), dan *random forest*, telah banyak digunakan dalam analisis sinyal EEG dan menunjukkan kinerja yang baik dalam mengidentifikasi pola aktivitas neural yang kompleks[10]. Meskipun pendekatan *deep learning* juga berkembang pesat dalam beberapa tahun terakhir, metode *machine learning* konvensional tetap menjadi pilihan yang efektif, khususnya pada kondisi data yang terbatas dan kebutuhan interpretabilitas model[27].

Lebih lanjut, pendekatan berbasis algoritma *ensemble* seperti *Extreme Gradient Boosting* (XGBoost) telah menunjukkan performa yang handal dalam tugas klasifikasi sinyal EEG, terutama pada skenario yang memanfaatkan representasi fitur dalam domain frekuensi. Berdasarkan penelitian [1x], penerapan algoritma XGBoost dalam klasifikasi ASD menghasilkan performa yang cukup handal, dengan kemampuan dalam menangkap hubungan non-linear serta meningkatkan akurasi klasifikasi melalui mekanisme pembelajaran berbasis *boosting*. Hal ini menunjukkan bahwa pemilihan algoritma yang tepat, khususnya yang mampu mengelola kompleksitas data dan redundansi fitur, memiliki peran penting dalam meningkatkan kinerja sistem klasifikasi berbasis EEG.

### 2.1.6 Augmentasi Data EEG

Dalam penelitian berbasis *machine learning*, ketersediaan data dalam jumlah yang memadai merupakan faktor penting dalam proses pelatihan model. Namun demikian, pada analisis sinyal EEG, pengumpulan dataset berskala besar seringkali menjadi tantangan. Proses perekaman EEG memerlukan perangkat khusus, prosedur eksperimen yang terkontrol, serta partisipasi subjek manusia, sehingga proses akuisisi data menjadi relatif mahal dan memakan waktu. Selain itu, sinyal EEG juga memiliki tingkat variabilitas yang tinggi antar individu maupun antar sesi perekaman. Variasi ini dapat disebabkan oleh berbagai faktor, seperti perbedaan konfigurasi perangkat EEG, jumlah kanal yang digunakan, kondisi eksperimen, serta keberadaan artefak yang berasal dari aktivitas non-neural seperti gerakan otot, kedipan mata, maupun gangguan lingkungan. Variabilitas tersebut menyebabkan distribusi data EEG menjadi kompleks dan seringkali tidak konsisten antar dataset[14].

Keterbatasan jumlah data serta kompleksitas karakteristik sinyal EEG dapat menyebabkan model *machine learning* mengalami masalah *overfitting*, di mana model mampu mempelajari pola yang sangat spesifik terhadap data pelatihan namun memiliki kemampuan generalisasi yang rendah terhadap data baru. Oleh karena itu, berbagai penelitian mengusulkan penggunaan teknik *data augmentation* untuk meningkatkan jumlah dan keragaman data pelatihan tanpa harus melakukan perekaman EEG tambahan. Secara umum, *data augmentation* bertujuan untuk menghasilkan sampel data baru yang memiliki karakteristik statistik yang serupa dengan data asli, sehingga model *machine learning* dapat mempelajari representasi pola yang lebih robust[17].

Untuk sinyal EEG, teknik augmentasi data dapat dilakukan melalui berbagai pendekatan. Beberapa metode sederhana meliputi manipulasi sinyal dalam domain waktu atau frekuensi, seperti penambahan derau (*noise injection*), pergeseran waktu (*time shifting*), maupun transformasi spektral. Pendekatan-pendekatan ini umumnya dilakukan dengan mentransformasikan data asli untuk menghasilkan sampel baru yang memiliki distribusi yang serupa dengan data awal. Namun demikian, metode augmentasi konvensional tersebut memiliki keterbatasan ketika diterapkan pada sinyal EEG. Berbeda dengan data citra, sinyal EEG merupakan data deret waktu yang tidak dapat secara langsung dikenai transformasi geometris seperti translasi, rotasi, maupun refleksi tanpa meng-

ubah makna fisiologisnya. Selain itu, penambahan derau pada sinyal EEG berpotensi mengubah amplitudo serta distribusi data asli, sehingga dapat mengganggu representasi karakteristik sinyal. Beberapa penelitian juga menunjukkan bahwa augmentasi sederhana, seperti penambahan derau Gaussian pada fitur EEG, tidak selalu meningkatkan performa model klasifikasi, bahkan dalam beberapa kasus dapat menyebabkan penurunan kinerja. Oleh karena itu, pendekatan berbasis model generatif mulai banyak dikembangkan untuk menghasilkan data EEG sintetis yang lebih mampu mempertahankan karakteristik kompleks sinyal, termasuk dependensi spasial dan temporal pada data multikanal, sehingga menghasilkan representasi data yang lebih realistis dan informatif [29].

Model generatif berbasis *deep learning*, seperti *Generative Adversarial Networks* (GAN) dan *Variational Autoencoders* (VAE), telah banyak digunakan untuk menghasilkan sinyal EEG sintetis yang mengikuti distribusi statistik dari data asli. Pendekatan ini memungkinkan model untuk mempelajari struktur laten dari sinyal EEG dan kemudian menghasilkan sampel baru yang memiliki karakteristik yang serupa dengan data pelatihan. Beberapa penelitian menunjukkan bahwa penggunaan data sintetis yang dihasilkan oleh model generatif dapat meningkatkan performa model klasifikasi EEG, terutama pada kondisi di mana jumlah data pelatihan terbatas[29].

Salah satu penelitian yang memanfaatkan pendekatan generatif untuk augmentasi data EEG menunjukkan bahwa data sintetis yang dihasilkan oleh model generatif dapat meningkatkan performa sistem klasifikasi berbasis EEG secara signifikan. Dalam penelitian tersebut, model generatif digunakan untuk mempelajari distribusi sinyal EEG dan menghasilkan sampel sintetis yang kemudian digunakan sebagai tambahan data pelatihan untuk model klasifikasi .Hasil eksperimen menunjukkan bahwa penggunaan data hasil augmentasi mampu meningkatkan akurasi klasifikasi dibandingkan dengan model yang hanya dilatih menggunakan data asli[28].

Dalam penelitian ini, pendekatan augmentasi data dilakukan dengan memanfaatkan model *Variational Autoencoder* (VAE) untuk menghasilkan sinyal EEG sintetis. Model VAE dilatih untuk mempelajari representasi laten dari sinyal EEG sehingga mampu menghasilkan sampel baru yang memiliki karakteristik serupa dengan data asli. Data sintetis yang dihasilkan kemudian digunakan sebagai tambahan data pelatihan dalam proses klasifikasi sinyal EEG.

### 2.1.7 Variational Auto Encoder

*Variational Autoencoder* (VAE) merupakan salah satu model generatif berbasis *deep learning* yang banyak digunakan untuk mempelajari representasi laten dari suatu dataset dan menghasilkan sampel data baru yang memiliki karakteristik statistik yang serupa dengan data asli. Model ini pertama kali diperkenalkan oleh Kingma dan Welling sebagai pendekatan probabilistik terhadap arsitektur *autoencoder* tradisional. Berbeda dengan *autoencoder* konvensional yang hanya bertujuan untuk melakukan kompresi dan rekonstruksi data, VAE dirancang untuk mempelajari distribusi probabilistik dari data sehingga memungkinkan proses generasi data baru melalui ruang laten (*latent space*) yang dipelajari oleh model[30].

Secara umum, arsitektur VAE terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*. Bagian *encoder* bertugas memetakan data masukan $x$ ke dalam representasi laten $z$ yang memiliki dimensi lebih rendah. Namun berbeda dengan *autoencoder* biasa yang menghasilkan representasi deterministik, VAE memodelkan representasi laten tersebut sebagai distribusi probabilistik, yang umumnya diasumsikan mengikuti distribusi normal multivariat. Oleh karena itu, *encoder* tidak hanya menghasilkan satu vektor representasi laten, tetapi juga dua parameter distribusi, yaitu nilai rata-rata ($\mu$) dan variansi ($\sigma$), yang mendeskripsikan distribusi probabilistik dari variabel laten tersebut[30].

Setelah distribusi laten diperoleh, proses berikutnya adalah melakukan *sampling* dari distribusi tersebut untuk menghasilkan vektor laten $z$ yang kemudian diberikan sebagai masukan kepada bagian *decoder*. Decoder berfungsi untuk merekonstruksi kembali data dari representasi laten tersebut sehingga menghasilkan data keluaran $\hat{x}$ yang diharapkan memiliki karakteristik yang serupa dengan data asli $x$. Dengan mekanisme ini, model tidak hanya mempelajari bagaimana merekonstruksi data, tetapi juga mempelajari struktur distribusi laten dari dataset yang digunakan[30].

Proses pelatihan VAE dilakukan dengan memaksimalkan fungsi objektif yang dikenal sebagai *Evidence Lower Bound* (ELBO). Fungsi ini terdiri dari dua komponen utama, yaitu *reconstruction loss* dan *regularization loss*. *Reconstruction loss* mengukur sejauh mana data hasil rekonstruksi $\hat{x}$ mendekati data asli $x$, sehingga model terdorong untuk mempertahankan informasi penting dari data masukan. Sementara itu, komponen regularisasi diukur menggunakan *Kullback–Leibler Divergence* (KL Divergence), yang bertu-

juan untuk memastikan bahwa distribusi laten yang dipelajari oleh model tetap mendekati distribusi prior yang telah ditentukan, biasanya distribusi normal standar.

Secara matematis, fungsi objektif VAE dapat dinyatakan sebagai berikut:

$$\mathcal{L}(\theta,\phi;x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) \parallel p(z))$$

di mana $q_\phi(z|x)$ merepresentasikan distribusi laten yang dihasilkan oleh *encoder*, $p_\theta(x|z)$ merepresentasikan proses rekonstruksi oleh *decoder*, dan $p(z)$ merupakan distribusi prior pada ruang laten. Komponen pertama pada persamaan tersebut merepresentasikan kualitas rekonstruksi data, sedangkan komponen kedua berfungsi sebagai regularisasi untuk menjaga struktur distribusi laten[30].

Dalam implementasinya, proses *sampling* pada ruang laten tidak dapat dilakukan secara langsung dalam proses pelatihan menggunakan metode *backpropagation*. Oleh karena itu, VAE menggunakan teknik yang dikenal sebagai *reparameterization trick*. Melalui teknik ini, variabel laten $z$ dinyatakan sebagai:

$$z = \mu + \sigma \cdot \varepsilon$$

di mana $\varepsilon$ merupakan variabel acak yang diambil dari distribusi normal standar $\mathcal{N}(0,1)$. Dengan pendekatan ini, proses *sampling* dapat ditransformasikan menjadi operasi deterministik yang memungkinkan gradien tetap dapat dihitung selama proses pelatihan neural network[30].

Kemampuan VAE dalam mempelajari representasi laten dari data menjadikannya sangat sesuai untuk digunakan sebagai model generatif dalam berbagai aplikasi, termasuk augmentasi data. Dengan mempelajari distribusi laten dari dataset pelatihan, model dapat menghasilkan sampel sintetis baru yang memiliki karakteristik statistik yang serupa dengan data asli. Hal ini sangat bermanfaat pada dataset yang memiliki jumlah sampel terbatas, seperti pada penelitian berbasis sinyal EEG, di mana proses akuisisi data seringkali memerlukan prosedur eksperimen yang kompleks.

Dalam konteks analisis sinyal EEG, penggunaan VAE memungkinkan model untuk mempelajari pola spasial dan temporal dari sinyal EEG secara lebih komprehensif. Setelah model dilatih menggunakan dataset EEG yang tersedia, representasi laten yang di-

hasilkan dapat digunakan untuk menghasilkan sinyal EEG sintetis yang tetap mempertahankan karakteristik distribusi dari data asli.Model VAE menjadi salah satu pendekatan yang banyak digunakan dalam penelitian augmentasi data EEG untuk meningkatkan performa sistem klasifikasi berbasis *machine learning*[17].

## 2.2 Penelitian Terdahulu

Selain membahas konsep-konsep dasar yang relevan dengan penelitian ini, penting juga untuk meninjau beberapa penelitian terdahulu yang berkaitan dengan klasifikasi Autism Spectrum Disorder (ASD) berbasis sinyal EEG. Seiring dengan berkembangnya pendekatan machine learning dalam analisis sinyal EEG, berbagai metode telah diusulkan untuk mengidentifikasi pola aktivitas neural yang berkaitan dengan ASD. Salah satu pendekatan yang cukup menonjol adalah penggunaan kombinasi teknik seleksi fitur dan algoritma klasifikasi berbasis ensemble learning.

Selain membahas pendekatan klasifikasi berbasis EEG, penting juga untuk meninjau metode data augmentation sebagai solusi terhadap keterbatasan jumlah data. Dalam analisis sinyal EEG, teknik augmentasi umumnya terbagi menjadi metode konvensional, seperti penambahan derau dan transformasi sinyal, serta pendekatan berbasis model generatif. Meskipun metode konvensional mudah diterapkan, pendekatan ini seringkali kurang mampu mempertahankan karakteristik kompleks sinyal EEG. Oleh karena itu, metode berbasis model generatif dinilai lebih unggul karena mampu mempelajari distribusi data secara lebih mendalam dan menghasilkan data sintetis yang lebih representatif.

Kedua pendekatan ini menjadi landasan penting dalam pengembangan metode augmentasi data yang lebih efektif untuk meningkatkan performa model klasifikasi EEG.

### 2.2.1 Klasifikasi ASD Berbasis EEG Menggunakan mRMR dan XGBoost

Pada draft penelitian oleh [XX], dilakukan analisis klasifikasi *Autism Spectrum Disorder* (ASD) menggunakan sinyal EEG dengan memanfaatkan teknik seleksi fitur dan algoritma *machine learning*. Selain membangun model klasifikasi, penelitian ini juga mengembangkan model deskriptif untuk mengidentifikasi dan memahami karakteristik pola aktiv-

itas neural yang membedakan individu dengan ASD dan individu dengan perkembangan tipikal. Penelitian ini berfokus pada pemanfaatan fitur berbasis domain frekuensi untuk merepresentasikan karakteristik aktivitas neural yang relevan dengan kondisi ASD, serta menekankan pentingnya pemilihan fitur yang optimal untuk meningkatkan performa dan interpretabilitas model klasifikasi.

Penelitian menggunakan pendekatan seleksi fitur berbasis *minimum Redundancy Maximum Relevance* (mRMR) untuk mengidentifikasi fitur yang paling informatif sekaligus meminimalkan redundansi antar fitur. Sebelum proses seleksi fitur, sinyal EEG melalui tahap prapemrosesan yang meliputi segmentasi, (*filtering*), serta dekomposisi ke dalam pita frekuensi untuk menghasilkan representasi fitur yang lebih stabil dan terstruktur. Fitur yang telah diseleksi kemudian digunakan sebagai masukan bagi model klasifikasi berbasis *ensemble*, yaitu XGBoost, di mana pendekatan ini dibandingkan dengan metode dasar berbasis *Discrete Wavelet Transform* (DWT), ekstraksi fitur *Shannon entropy*, dan klasifikasi menggunakan *Artificial Neural Network* (ANN).

Hasil eksperimen menunjukkan bahwa pendekatan yang diusulkan mampu menghasilkan performa klasifikasi yang cukup baik dalam membedakan individu dengan ASD dan individu dengan perkembangan tipikal. Penggunaan mRMR terbukti dapat meningkatkan kualitas fitur yang digunakan, sementara XGBoost memberikan kemampuan klasifikasi yang robust terhadap kompleksitas data EEG. Temuan ini menunjukkan bahwa kombinasi seleksi fitur dan algoritma *ensemble* memiliki potensi yang signifikan dalam meningkatkan akurasi serta kemampuan generalisasi model dalam klasifikasi ASD berbasis sinyal EEG.

### 2.2.2 Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder

Pada penelitian oleh [XX], diusulkan pendekatan augmentasi data untuk sinyal EEG menggunakan model generatif berbasis *Variational Autoencoder* (VAE). Implementasi yang digunakan dalam penelitian ini mengadaptasi metode yang diperkenalkan dalam studi sebelumnya [XX], yang memanfaatkan VAE untuk mempelajari distribusi laten dari sinyal EEG dan menghasilkan sampel sintetis yang menyerupai data asli. Pendekatan ini juga dikombinasikan dengan representasi berbasis citra sehingga memungkinkan pemanfaatan arsitektur *2D Convolutional Neural Network* (2D CNN) dalam proses klasifikasi.

Tujuan utama dari pendekatan ini adalah untuk mengatasi keterbatasan jumlah data pelatihan pada analisis EEG serta meningkatkan kualitas representasi data dalam tugas klasifikasi.

Dari sisi arsitektur, model yang digunakan terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*, yang dilatih secara end-to-end untuk merekonstruksi sinyal EEG melalui representasi laten berdimensi rendah. *Encoder* memetakan sinyal EEG ke dalam distribusi probabilistik yang direpresentasikan oleh parameter mean dan variansi, sementara *decoder* menghasilkan kembali sinyal berdasarkan sampel dari ruang laten tersebut melalui mekanisme *reparameterization*. Selain itu, dalam tahap evaluasi, digunakan arsitektur *EEGNet* sebagai model klasifikasi berbasis CNN yang dirancang khusus untuk sinyal EEG. Dua model EEGNet dilatih secara terpisah menggunakan data asli dan data hasil augmentasi untuk membandingkan pengaruh penggunaan data sintetis terhadap performa klasifikasi.

Hasil penelitian menunjukkan bahwa penggunaan data sintetis yang dihasilkan oleh VAE mampu meningkatkan performa model klasifikasi secara signifikan. Model yang dilatih menggunakan data asli memperoleh akurasi sebesar 0.73, sedangkan model yang dilatih menggunakan data hasil augmentasi mencapai akurasi sebesar 0.88. Peningkatan ini juga tercermin pada metrik *precision*, *recall*, dan *f1-score* pada sebagian besar kelas, yang menunjukkan bahwa data sintetis mampu memperkaya variasi data pelatihan dan membantu model dalam menangkap pola yang lebih representatif. Temuan ini menunjukkan bahwa pendekatan generatif berbasis VAE memiliki potensi yang signifikan dalam meningkatkan kinerja sistem klasifikasi berbasis sinyal EEG.

### 2.2.3 Dataset yang Digunakan

### 2.2.4 Dataset yang Digunakan

Dataset yang digunakan dalam penelitian ini terdiri dari sinyal *electroencephalogram* (EEG), yaitu metode non-invasif yang digunakan untuk merekam aktivitas listrik otak serta mengamati pola osilasi neural. EEG banyak dimanfaatkan dalam studi kognitif dan klinis, termasuk dalam penelitian *Autism Spectrum Disorder* (ASD), karena kemampuannya dalam mengidentifikasi abnormalitas aktivitas neural yang tidak mudah diamati se-

cara langsung.

Data EEG dikumpulkan dari sepuluh partisipan yang terdiri dari lima anak dengan diagnosis ASD berusia 6–10 tahun serta lima subjek kontrol sehat berusia di atas 17 tahun. Proses akuisisi dilakukan menggunakan 16 kanal EEG yang ditempatkan berdasarkan sistem standar *International 10–20 System*, yaitu pada posisi Fp1, Fp2, F3, F4, F7, F8, C3, C4, T3, T4, T5, T6, P3, P4, O1, dan O2. Perekaman dilakukan dalam kondisi terkontrol untuk memastikan kenyamanan partisipan, pada rentang waktu 09.00–12.00 guna menjaga kondisi subjek tetap sadar dan rileks. Setiap sesi perekaman berlangsung sekitar 15 menit untuk delapan kanal dan diulang hingga mencakup seluruh 16 kanal, sehingga total durasi perekaman mencapai sekitar 40 menit, dengan tambahan waktu sekitar 10 menit untuk pemasangan elektroda.

Akuisisi data dilakukan menggunakan perangkat *OpenBCI Cyton Biosensing Board*, yang mendukung perekaman hingga delapan kanal EEG per sesi. Sistem ini dilengkapi dengan *USB dongle* untuk transmisi data secara nirkabel ke komputer, serta menggunakan baterai 3.7V sebagai sumber daya. Elektroda ditempatkan menggunakan *EEG cap* dengan bantuan gel konduktif untuk meningkatkan kualitas kontak dan meminimalkan gangguan sinyal. Perangkat ini memiliki rasio *signal-to-noise ratio* (SNR) sebesar 121 dB serta resolusi tegangan sebesar 0.298 $\mu V$, sehingga mampu merekam sinyal EEG dengan tingkat presisi yang tinggi. Data yang diperoleh divisualisasikan dan direkam menggunakan perangkat lunak *OpenBCI GUI* serta pustaka *BrainFlow* untuk keperluan pemrosesan lebih lanjut.

Lingkungan perekaman juga dirancang untuk meminimalkan gangguan eksternal, dengan konfigurasi ruangan yang mengarahkan partisipan menghadap dinding kosong guna mengurangi distraksi visual. Setelah proses akuisisi, sinyal EEG melalui tahap prapemrosesan untuk meningkatkan kualitas data. Dalam penelitian terkait [XX], beberapa metode seperti *Butterworth filtering*, *Discrete Wavelet Transform* (DWT), dan *Independent Component Analysis* (ICA) digunakan untuk mengurangi artefak dan meningkatkan kejernihan sinyal. Di antara metode tersebut, ICA menunjukkan performa yang paling efektif dalam meningkatkan kualitas sinyal, khususnya dalam meningkatkan nilai SNR serta mempertahankan karakteristik penting sinyal EEG yang relevan untuk analisis lebih lanjut.

Selanjutnya, sinyal EEG yang telah diproses digunakan dalam tahap segmentasi dan ekstraksi fitur, khususnya melalui dekomposisi ke dalam pita frekuensi utama (delta, theta, alpha, beta, dan gamma). Karakteristik dataset yang memiliki dimensi fitur tinggi serta jumlah sampel yang terbatas menjadikannya representatif untuk menguji model klasifikasi yang digunakan.

## 2.3 Fokus pada Celah Penelitian

Berdasarkan tinjauan pustaka yang telah dilakukan, terdapat celah penelitian dalam pemanfaatan teknik augmentasi data berbasis *Variational Autoencoder* (VAE) untuk analisis sinyal EEG. Beberapa penelitian sebelumnya telah menerapkan VAE untuk menghasilkan data EEG sintetis, khususnya dalam konteks tugas klasifikasi berbasis *motor imagery* menggunakan arsitektur seperti *2D Convolutional Neural Network* (CNN). Pendekatan tersebut menunjukkan bahwa data sintetis mampu meningkatkan performa model klasifikasi dengan memperkaya variasi data pelatihan. Namun demikian, fokus penelitian masih terbatas pada representasi sinyal dalam domain waktu atau spasial, tanpa mengeksplorasi secara mendalam karakteristik sinyal dalam domain frekuensi.

Di sisi lain, analisis berbasis domain frekuensi memiliki peran penting dalam studi EEG, terutama dalam mengidentifikasi pola osilasi neural yang berkaitan dengan kondisi neurologis seperti *Autism Spectrum Disorder* (ASD). Meskipun demikian, pemanfaatan data sintetis berbasis VAE pada representasi fitur frekuensi masih relatif terbatas, dan belum banyak dikaji bagaimana augmentasi tersebut memengaruhi kualitas fitur serta performa model klasifikasi berbasis *machine learning* konvensional.

Oleh karena itu, penelitian ini mengusulkan pendekatan yang mengintegrasikan teknik augmentasi data berbasis VAE dengan ekstraksi fitur domain frekuensi, serta memanfaatkan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) dan algoritma klasifikasi *XGBoost*. Pendekatan ini bertujuan untuk mengeksplorasi bagaimana data sintetis yang dihasilkan pada domain frekuensi dapat meningkatkan kualitas representasi fitur serta performa klasifikasi ASD. Dengan mengisi celah ini, diharapkan penelitian ini dapat memberikan kontribusi dalam pengembangan metode klasifikasi EEG yang lebih robust dan akurat, khususnya pada kondisi dataset yang terbatas.

# DAFTAR REFERENSI