



**UNIVERSITAS INDONESIA**

**ANALISIS AUGMENTASI DATA BERBASIS VARIATIONAL  
AUTOENCODER UNTUK KLASIFIKASI AUTISM SPECTRUM  
DISORDER MENGGUNAKAN SINYAL EEG**

**SKRIPSI**

**WENDY DHARMAWAN  
2206059591**

**FAKULTAS TEKNIK  
PROGRAM STUDI S1 TEKNIK KOMPUTER  
DEPOK  
2025**



**UNIVERSITAS INDONESIA**

**ANALISIS AUGMENTASI DATA BERBASIS VARIATIONAL  
AUTOENCODER UNTUK KLASIFIKASI AUTISM SPECTRUM  
DISORDER MENGGUNAKAN SINYAL EEG**

**SKRIPSI**

**Diajukan sebagai salah satu syarat untuk memperoleh gelar  
Sarjana Teknik**

**WENDY DHARMAWAN  
2206059591**

**FAKULTAS TEKNIK  
PROGRAM STUDI S1 TEKNIK KOMPUTER  
DEPOK  
JULI 2025**

## **HALAMAN PERNYATAAN ORISINALITAS**

**Skripsi ini adalah hasil karya saya sendiri,  
dan semua sumber baik yang dikutip maupun dirujuk  
telah saya nyatakan dengan benar.**

**Nama : Wendy Dharmawan**

**NPM : 2206059591**

**Tanda Tangan :**

**Tanggal : 25 Juli 2025**

## **HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL**

**Saya menyatakan bahwa dalam penyusunan Tugas Akhir ini, saya menggunakan teknologi Kecerdasan Buatan dengan platform Gemini dan ChatGPT untuk tujuan pemeriksaan dan perbaikan tata bahasa dan saya bertanggung jawab penuh atas keakuratan, orisinalitas, dan integritas seluruh isi Tugas Akhir ini.**

**Nama : Wendy Dharmawan**

**NPM : 2206059591**

**Tanda Tangan :**

**Tanggal : 25 Juli 2025**

## HALAMAN PENGESAHAN

Skripsi ini diajukan oleh :  
Nama : Wendy Dharmawan  
NPM : 2206059591  
Program Studi : S1 Teknik Komputer  
Judul Skripsi : Analisis Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG

**Telah berhasil dipertahankan di hadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Sarjana Teknik pada Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.**

## DEWAN PENGUJI

Pembimbing : [Nama Dosen Pembimbing] ( )  
Penguji : [Nama Dosen Penguji 1] ( )  
Penguji : [Nama Dosen Penguji 2] ( )  
Penguji : [Nama Dosen Penguji 3] ( )

Ditetapkan di : Depok  
Tanggal : 1 Agustus 2025

## KATA PENGANTAR

Puji dan syukur Penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan rahmat-Nya lah Penulis dapat menyelesaikan Skripsi dengan judul “Analisis Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG”. Skripsi ini Penulis laksanakan sebagai salah satu syarat dalam memperoleh gelar Sarjana Teknik pada program studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.

Penulis juga ingin menyampaikan rasa terima kasihnya kepada:

1. [Nama Dosen Pembimbing], selaku Dosen Pembimbing Skripsi Penulis.
2. [Nama Ketua Departemen], selaku Ketua Departemen Teknik Elektro, Fakultas Teknik, Universitas Indonesia.
3. [Nama Ketua Prodi], selaku Kepala Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.
4. [Nama Dosen Pembimbing Akademis], selaku Pembimbing Akademis Penulis.
5. [Nama Dosen Penguji 1], [Nama Dosen Penguji 2] dan [Nama Dosen Penguji 3] selaku Dosen Penguji Skripsi Penulis.
6. Segenap dosen Departemen Teknik Elektro atas semua ilmu yang diberikan kepada Penulis.
7. Orang tua yang selalu memberikan dukungan serta doa, sehingga penulisan Skripsi dapat diselesaikan secara baik.
8. Teman-teman Teknik Komputer, selaku rekan penulis yang selalu membantu serta memberikan dukungan moril sepanjang proses kuliah serta penulisan proposal skripsi.

Penulis menyadari dan menerima bahwa Skripsi yang dibentuk ini masih jauh dari sempurna dan masih memiliki berbagai kekurangan serta kesalahan baik dari segi ilmu maupun pemahaman. Oleh karena itu, Penulis mengharapkan segala kritik dan saran yang diberikan agar ke depannya Penulis dapat menjadi lebih baik.

25 Juli 2025

Wendy Dharmawan

## HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas akademik Universitas Indonesia, saya yang bertanda tangan di bawah ini:

**Nama** : Wendy Dharmawan  
**NPM** : 2206059591  
**Program Studi** : S1 Teknik Komputer  
**Fakultas** : Teknik  
**Jenis Karya** : Skripsi

demikian pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Indonesia **Hak Bebas Royalti Noneksklusif (*Non-exclusive Royalty Free Right*)** atas karya ilmiah saya yang berjudul:

Analisis Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Universitas Indonesia berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Depok  
Pada tanggal : 25 Juli 2025  
Yang menyatakan

(Wendy Dharmawan)  
vii



## **ABSTRAK**

Nama : Wendy Dharmawan  
Program Studi : S1 Teknik Komputer  
Judul : Analisis Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG  
Pembimbing : [Nama Dosen Pembimbing]

Kata kunci: sistem informasi akademik, manajemen tugas akhir, templat  $\text{\LaTeX}$ , evaluasi usabilitas, rekayasa perangkat lunak.

## **ABSTRACT**

Name : Wendy Dharmawan  
Study Program : S1 Teknik Komputer  
Title : Analysis of Data Augmentation Using Variational Autoencoder for EEG-Based Autism Spectrum Disorder Classification  
Supervisor : [Nama Dosen Pembimbing]

Keywords: academic information system, thesis management, L<sup>A</sup>T<sub>E</sub>X template, usability evaluation, software engineering.

## DAFTAR ISI

|                                                                     |             |
|---------------------------------------------------------------------|-------------|
| <b>HALAMAN JUDUL</b>                                                | <b>i</b>    |
| <b>HALAMAN PERNYATAAN ORISINALITAS</b>                              | <b>ii</b>   |
| <b>HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL</b>          | <b>iii</b>  |
| <b>HALAMAN PENGESAHAN</b>                                           | <b>iv</b>   |
| <b>KATA PENGANTAR</b>                                               | <b>v</b>    |
| <b>HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI</b>                     | <b>vii</b>  |
| <b>ABSTRAK</b>                                                      | <b>viii</b> |
| <b>ABSTRACT</b>                                                     | <b>ix</b>   |
| <b>DAFTAR ISI</b>                                                   | <b>x</b>    |
| <b>DAFTAR TABEL</b>                                                 | <b>xii</b>  |
| <b>DAFTAR GAMBAR</b>                                                | <b>xiii</b> |
| <b>DAFTAR KODE PROGRAM</b>                                          | <b>xiv</b>  |
| <b>DAFTAR SINGKATAN</b>                                             | <b>xiv</b>  |
| <b>1 PENDAHULUAN</b>                                                | <b>1</b>    |
| 1.1 Latar Belakang                                                  | 1           |
| 1.2 Rumusan Masalah                                                 | 3           |
| 1.3 Tujuan Penelitian                                               | 4           |
| 1.4 Manfaat Penelitian                                              | 4           |
| 1.5 Ruang Lingkup Penelitian                                        | 5           |
| 1.6 Sistematika Penulisan                                           | 6           |
| <b>2 TINJAUAN PUSTAKA</b>                                           | <b>8</b>    |
| 2.1 Landasan Teori                                                  | 8           |
| 2.1.1 Sinyal EEG                                                    | 8           |
| 2.1.2 Feature Selection mRMR                                        | 13          |
| 2.1.3 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG | 15          |
| 2.1.4 Generative Machine Learning                                   | 16          |
| 2.1.5 Metode Evaluasi Data Sintetis Sinyal EEG                      | 16          |
| 2.1.6 Augmentasi Data EEG                                           | 17          |
| 2.1.7 Variational Auto Encoder                                      | 18          |
| 2.2 Penelitian Terdahulu                                            | 20          |

|          |                                                                                      |           |
|----------|--------------------------------------------------------------------------------------|-----------|
| 2.2.1    | Klasifikasi ASD Berbasis EEG Menggunakan mRMR dan XGBoost                            | 21        |
| 2.2.2    | Metode Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder . . . . . | 22        |
| 2.2.3    | Dataset EEG yang Digunakan . . . . .                                                 | 23        |
| 2.3      | Fokus pada Celah Penelitian . . . . .                                                | 24        |
| <b>3</b> | <b>PERANCANGAN DAN IMPLEMENTASI SISTEM . . . . .</b>                                 | <b>26</b> |
| 3.1      | Analisis Kebutuhan Sistem . . . . .                                                  | 27        |
| 3.2      | Perancangan Arsitektur Sistem . . . . .                                              | 28        |
| 3.2.1    | Pra-Pemrosesan Dataset . . . . .                                                     | 30        |
| 3.2.2    | Arsitektur Model VAE untuk Augmentasi Data . . . . .                                 | 31        |
| 3.2.3    | Arsitektur Model Klasifikasi . . . . .                                               | 34        |
| 3.3      | Detail Implementasi dan Teknologi . . . . .                                          | 36        |
| 3.3.1    | Teknologi dan Library . . . . .                                                      | 36        |
| 3.3.2    | Implementasi Model Generatif Variational Autoencoder (VAE) . .                       | 37        |
| 3.3.3    | Implementasi Model Klasifikasi . . . . .                                             | 42        |
| <b>4</b> | <b>PENUTUP . . . . .</b>                                                             | <b>43</b> |
| 4.1      | Kesimpulan . . . . .                                                                 | 43        |
| 4.2      | Pengembangan Lanjutan . . . . .                                                      | 45        |
|          | <b>DAFTAR PUSTAKA . . . . .</b>                                                      | <b>47</b> |
|          | <b>DAFTAR PUSTAKA . . . . .</b>                                                      | <b>47</b> |

## DAFTAR TABEL

|                  |                                                   |    |
|------------------|---------------------------------------------------|----|
| <b>Tabel 2.1</b> | Pita frekuensi EEG dan karakteristiknya . . . . . | 10 |
| <b>Tabel 3.1</b> | Konfigurasi Parameter <i>XGBoost</i> . . . . .    | 42 |

## DAFTAR GAMBAR

|                   |                                                                                                |    |
|-------------------|------------------------------------------------------------------------------------------------|----|
| <b>Gambar 2.1</b> | Sistem Internasional 10–20 untuk Penempatan Elektroda EEG                                      | 9  |
| <b>Gambar 2.2</b> | Pita Frekuensi EEG pada Rentang Frekuensi Tinggi dan Rendah                                    | 11 |
| <b>Gambar 2.3</b> | Ilustrasi pengaruh berbagai jenis filter terhadap sinyal EEG                                   | 12 |
| <b>Gambar 2.4</b> | Bentuk-Bentuk Artefak pada Sinyal EEG . . . . .                                                | 12 |
| <b>Gambar 3.1</b> | Diagram aliran data pada sistem . . . . .                                                      | 29 |
| <b>Gambar 3.2</b> | Diagram aliran proses prapemrosesan sistem . . . . .                                           | 30 |
| <b>Gambar 3.3</b> | Diagram Model VAE untuk Augmentasi EEG . . . . .                                               | 32 |
| <b>Gambar 3.4</b> | Diagram Model Klasifikasi . . . . .                                                            | 35 |
| <b>Gambar 3.5</b> | Diagram Aliran Layer <i>Encoder</i> pada Model VAE . . . . .                                   | 37 |
| <b>Gambar 3.6</b> | Diagram aliran Reparameterization Layer . . . . .                                              | 38 |
| <b>Gambar 3.7</b> | Diagram aliran Decoder Layer . . . . .                                                         | 40 |
| <b>Gambar 4.1</b> | Perbandingan sampel sinyal EEG asli dan sintetis pada channel Fp1 dalam domain waktu . . . . . | 45 |
| <b>Gambar 4.2</b> | Perbandingan PSD antara sampel sinyal asli dan sintetis pada channel Fp1 . . . . .             | 45 |

## DAFTAR SINGKATAN

|             |                                                 |
|-------------|-------------------------------------------------|
| <b>ASD</b>  | <i>Autism Spectrum Disorder</i>                 |
| <b>BCI</b>  | <i>Brain–Computer Interface</i>                 |
| <b>CNN</b>  | <i>Convolutional Neural Network</i>             |
| <b>DWT</b>  | <i>Discrete Wavelet Transform</i>               |
| <b>EEG</b>  | <i>Electroencephalography</i>                   |
| <b>ELBO</b> | <i>Evidence Lower Bound</i>                     |
| <b>EMG</b>  | <i>Electromyogram</i>                           |
| <b>EOG</b>  | <i>Electrooculogram</i>                         |
| <b>FFT</b>  | <i>Fast Fourier Transform</i>                   |
| <b>GAN</b>  | <i>Generative Adversarial Network</i>           |
| <b>ICA</b>  | <i>Independent Component Analysis</i>           |
| <b>kNN</b>  | <i>k-Nearest Neighbor</i>                       |
| <b>KL</b>   | <i>Kullback–Leibler</i>                         |
| <b>mRMR</b> | <i>Minimum Redundancy Maximum<br/>Relevance</i> |
| <b>PSD</b>  | <i>Power Spectral Density</i>                   |
| <b>SNR</b>  | <i>Signal-to-Noise Ratio</i>                    |
| <b>SVM</b>  | <i>Support Vector Machine</i>                   |
| <b>VAE</b>  | <i>Variational Autoencoder</i>                  |

## **BAB 1**

### **PENDAHULUAN**

Autism Spectrum Disorder (ASD) merupakan gangguan neurologis yang memengaruhi komunikasi, interaksi sosial, dan perilaku individu, sehingga proses identifikasi dini memiliki peranan penting dalam penanganannya. Analisis sinyal electroencephalography (EEG) menggunakan metode machine learning mulai banyak diteliti sebagai pendekatan dalam proses klasifikasi ASD secara lebih objektif. Meskipun demikian, pengembangan model klasifikasi berbasis EEG masih menghadapi tantangan berupa keterbatasan dataset EEG yang tersedia dan tingginya variabilitas sinyal antar individu maupun antar sesi perekaman. Karakteristik tersebut menyebabkan terhambatnya proses pengembangan model klasifikasi EEG yang mampu memberikan performa secara konsisten pada data dengan karakteristik yang berbeda. Salah satu pendekatan yang mulai banyak digunakan untuk mengatasi permasalahan tersebut adalah teknik *data augmentation*, yaitu proses penambahan variasi data *training* secara artifisial, sehingga diharapkan dapat meningkatkan performa dan kemampuan generalisasi model.

Bab ini akan dimulai dengan penjelasan Latar Belakang yang memberikan konteks penting terkait penelitian ini, diikuti oleh Rumusan Masalah dan Tujuan Penelitian yang merinci fokus utama studi. Selanjutnya, akan dibahas Manfaat Penelitian dan Ruang Lingkup Penelitian untuk menjelaskan kontribusi serta batasan penelitian ini. Terakhir, Sistematika Penulisan akan menguraikan struktur keseluruhan laporan penelitian.

#### **1.1 Latar Belakang**

Autism Spectrum Disorder (ASD) merupakan gangguan neurologis yang ditandai oleh hambatan dalam komunikasi dan interaksi sosial, serta pola perilaku yang terbatas dan berulang [1], [2]. Identifikasi dan intervensi dini menjadi faktor penting dalam membantu perkembangan individu dengan ASD, namun proses diagnosis masih menghadapi berbagai tantangan karena karakteristik gejala yang heterogen dan sering kali menyerupai gangguan perkembangan lainnya [3] [4]. Kondisi tersebut mendorong berkembangnya



pendekatan diagnosis berbasis biomarker yang lebih objektif dan konsisten.

Salah satu pendekatan yang banyak diteliti adalah analisis electroencephalography (EEG) menggunakan metode machine learning. Dibandingkan dengan metode lainnya, EEG memiliki keunggulan karena bersifat non-invasif, relatif lebih murah, dan memiliki resolusi temporal yang tinggi [5] [6]. Berbagai penelitian menunjukkan bahwa model machine learning mampu mengidentifikasi pola aktivitas otak yang berkaitan dengan ASD melalui sinyal EEG dengan performa klasifikasi yang cukup baik [7]. Penelitian rujukan [8] mengusulkan pendekatan klasifikasi ASD berbasis EEG menggunakan kombinasi seleksi fitur minimum Redundancy Maximum Relevance (mRMR) dan algoritma XGBoost yang menunjukkan performa klasifikasi yang baik dan konsisten.

Meskipun demikian, pengembangan model klasifikasi EEG masih menghadapi berbagai tantangan, terutama terkait keterbatasan dataset EEG yang tersedia secara publik dan telah memiliki label klinis [9]. Proses akuisisi dan pelabelan data EEG umumnya membutuhkan biaya, waktu, serta keterlibatan tenaga ahli, sehingga jumlah data yang tersedia sering kali terbatas. Keterbatasan dataset ini dapat meningkatkan risiko overfitting pada proses training model machine learning dan membatasi kemampuan model dalam melakukan generalisasi terhadap data baru [10]. Selain itu, sinyal EEG juga rentan terhadap berbagai artefak, seperti gerakan otot, kedipan mata, maupun gangguan pada perangkat perekaman yang dapat memengaruhi kualitas sinyal [11]. Keberadaan artefak tersebut menyebabkan proses analisis EEG menjadi lebih sulit karena sinyal yang diperoleh tidak selalu merepresentasikan aktivitas otak yang sebenarnya.

Salah satu pendekatan yang mulai banyak diteliti untuk mengatasi keterbatasan dataset EEG adalah penggunaan teknik data augmentation. Teknik ini bertujuan untuk meningkatkan jumlah dan variasi data training secara artifisial sehingga model dapat mempelajari representasi fitur yang lebih beragam. Beberapa penelitian menunjukkan bahwa penerapan data augmentation pada data EEG dapat membantu meningkatkan performa model klasifikasi dan mengurangi risiko overfitting pada kondisi dataset yang terbatas [12].

Penerapan augmentasi pada data EEG memiliki tantangan tersendiri karena sinyal EEG merupakan data *time series* multikanal yang bersifat non-stasioner dan memiliki rasio *signal-to-noise* yang rendah [13]. Berbeda dengan berbagai jenis data multimedia

lain seperti citra, audio, atau video yang umumnya memiliki pola representasi yang lebih stabil, manipulasi pada data EEG perlu dilakukan secara hati-hati karena perubahan pada sinyal dapat memengaruhi representasi aktivitas otak yang dianalisis. Pendekatan augmentasi data konvensional pada data *time series* umumnya dilakukan melalui transformasi sederhana seperti penambahan *noise*, pergeseran waktu, atau manipulasi amplitudo. Namun, pada data EEG, transformasi tersebut berpotensi mengubah karakteristik temporal dan spasial yang digunakan dalam proses analisis maupun klasifikasi sinyal [14].

Seiring dengan perkembangan deep learning, pendekatan berbasis model generatif seperti Variational Autoencoder (VAE) mulai digunakan untuk menghasilkan data EEG sintetis yang lebih representatif. Model VAE mempelajari distribusi laten dari data EEG sehingga mampu menghasilkan sampel baru yang berbeda namun tetap mempertahankan karakteristik statistik dari data asli. Pendekatan generatif memiliki potensi untuk menghasilkan variasi data yang lebih realistis dibandingkan metode augmentasi konvensional [14]. Meskipun demikian, pemanfaatan data sintetis berbasis model generatif pada klasifikasi EEG, khususnya dalam konteks Autism Spectrum Disorder (ASD), masih memerlukan kajian lebih lanjut untuk memahami pengaruhnya terhadap performa dan kemampuan generalisasi model klasifikasi.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk mengeksplorasi penggunaan teknik data augmentation berbasis Variational Autoencoder (VAE) untuk menghasilkan data EEG sintetis dan menganalisis pengaruhnya terhadap performa model klasifikasi ASD berbasis EEG. Penelitian dilakukan dengan mengimplementasikan pendekatan klasifikasi EEG menggunakan seleksi fitur mRMR dan algoritma XGBoost berdasarkan penelitian rujukan [8], kemudian mengevaluasi perbedaan performa model sebelum dan sesudah penerapan data augmentasi.

## 1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, permasalahan utama dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana pendekatan yang dapat digunakan untuk mengatasi keterbatasan jumlah dan variasi data pada sinyal EEG dalam konteks klasifikasi Autism Spectrum

Disorder (ASD)?

2. Bagaimana pendekatan tersebut dapat dirancang dan diintegrasikan ke dalam pipeline pemrosesan data EEG untuk mendukung proses klasifikasi?
3. Bagaimana pengaruh penambahan atau peningkatan variasi data terhadap performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD)?

### 1.3 Tujuan Penelitian

Selaras dengan rumusan masalah yang telah diuraikan, tujuan dari penelitian ini mencakup sebagai berikut:

1. Mengidentifikasi dan mengeksplorasi pendekatan yang dapat digunakan untuk mengatasi keterbatasan jumlah dan variasi data pada sinyal EEG dalam klasifikasi Autism Spectrum Disorder (ASD).
2. Merancang dan mengintegrasikan pendekatan tersebut ke dalam pipeline pemrosesan data EEG untuk mendukung proses klasifikasi.
3. Menganalisis pengaruh penambahan atau peningkatan variasi data terhadap performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD).

### 1.4 Manfaat Penelitian

Berdasarkan latar belakang, rumusan masalah, dan tujuan penelitian yang telah diuraikan, penelitian ini diharapkan memberikan manfaat sebagai berikut:

#### 1. Bagi Peneliti dan Pengembangan Metode:

Penelitian ini diharapkan dapat menjadi referensi dalam pengembangan dan pemanfaatan teknik *data augmentation* pada sinyal EEG, serta membuka peluang bagi pengembangan metode klasifikasi dan diagnosis di masa depan yang mampu memanfaatkan data dalam jumlah yang lebih besar dan beragam, sehingga meningkatkan robustness dan kemampuan generalisasi model.

## 2. Bagi Tenaga Medis dan Profesional Kesehatan:

Penelitian ini diharapkan dapat memberikan gambaran mengenai potensi pemanfaatan *machine learning* dalam analisis data EEG pada studi Autism Spectrum Disorder (ASD), maupun untuk sehingga dapat mendukung pemahaman dan penelitian lanjutan terkait pendekatan berbasis data dalam konteks klinis.

### 1.5 Ruang Lingkup Penelitian

Agar penelitian ini tetap terfokus, maka ruang lingkup penelitian ditetapkan sebagai berikut:

1. **Dataset Penelitian:** Penelitian ini menggunakan dataset EEG yang sama dengan dataset pada penelitian rujukan [8][6]. Dataset tersebut digunakan sebagai dasar dalam proses pelatihan model augmentasi maupun model klasifikasi sehingga hasil penelitian dapat dibandingkan secara relevan dengan penelitian sebelumnya.
2. **Metode Preprocessing Data:** Tahapan *preprocessing* data EEG mengikuti prosedur yang digunakan pada penelitian rujukan [8]. Proses ini mencakup tahapan pengolahan data yang diperlukan sebelum proses seleksi fitur, augmentasi data, dan klasifikasi dilakukan.
3. **Metode Augmentasi dan Klasifikasi:** Penelitian ini menerapkan metode *data augmentation* berbasis *Variational Autoencoder* (VAE) untuk menghasilkan data EEG sintetis. Selanjutnya, proses klasifikasi dilakukan menggunakan pendekatan yang mengacu pada penelitian rujukan [8], yaitu kombinasi seleksi fitur *mRMR* dan model klasifikasi *XGBoost*.
4. **Metode Evaluasi:** Evaluasi penelitian dilakukan dengan membandingkan performa model klasifikasi pada data tanpa augmentasi dan dengan augmentasi. Penilaian kualitas data sintetis serta performa klasifikasi mengacu pada metode evaluasi yang digunakan dalam penelitian rujukan [15].
5. **Hasil Akhir Penelitian:** Penelitian ini menghasilkan model *data augmentation* EEG berbasis *Variational Autoencoder* (VAE) yang dapat digunakan untuk meng-

hasilkan data EEG sintetis guna mendukung peningkatan performa model klasifikasi.

6. **Batasan Penelitian:** Penelitian difokuskan pada analisis pengaruh penerapan *data augmentation* EEG terhadap kualitas performa model klasifikasi. Penelitian ini tidak membahas aspek perangkat keras EEG, proses akuisisi data asli, maupun tahapan penghilangan *noise* dan *artifact removal* di luar prosedur *preprocessing* yang telah ditetapkan pada penelitian rujukan.

## 1.6 Sistematika Penulisan

Laporan tesis ini disusun secara sistematis ke dalam lima bab utama, dengan rincian sebagai berikut:

1. **Bab 1: Pendahuluan.** Bab ini menyajikan gambaran umum penelitian, meliputi latar belakang yang menjelaskan pentingnya analisis sinyal EEG dalam mendukung identifikasi Autism Spectrum Disorder (ASD), rumusan masalah yang menjadi dasar penelitian, tujuan yang ingin dicapai, manfaat penelitian, ruang lingkup penelitian, serta sistematika penulisan laporan ini.
2. **Bab 2: Tinjauan Pustaka.** Bab ini menguraikan landasan teoretis yang mendukung penelitian, meliputi konsep dasar sinyal EEG, metode ekstraksi dan seleksi fitur pada data EEG, metode *Minimum Redundancy Maximum Relevance* (mRMR), implementasi *machine learning* dalam klasifikasi berdasarkan EEG, metode augmentasi data EEG, model *Variational AutoEncoder*, serta kajian terhadap penelitian-penelitian sebelumnya yang bersifat relevan.
3. **Bab 3: Metodologi Penelitian.** Bab ini menjelaskan metode yang digunakan dalam penelitian, mencakup deskripsi dataset EEG yang digunakan, tahapan pra-pemrosesan data, penerapan teknik *data augmentation*, proses seleksi fitur menggunakan metode *mRMR*, arsitektur model augmentasi berbasis *VAE*, serta konfigurasi *training* model klasifikasi menggunakan *XGBoost*.
4. **Bab 4: Hasil dan Analisis.** Bab ini memaparkan hasil eksperimen yang diperoleh dari proses *training* dan pengujian model. Analisis dilakukan untuk membanding-

kan performa model pada skenario dengan dan tanpa penerapan *data augmentasi*, serta mengevaluasi pengaruhnya terhadap kemampuan model dalam melakukan klasifikasi data EEG.

5. **Bab 5: Penutup.** Bab terakhir ini berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran untuk pengembangan penelitian selanjutnya terkait analisis dan klasifikasi data EEG menggunakan metode *machine learning* .

## **BAB 2**

### **TINJAUAN PUSTAKA**

Bab ini menjelaskan konteks dan landasan teoretis yang mendasari penelitian mengenai analisis sinyal EEG untuk klasifikasi *Autism Spectrum Disorder* (ASD) menggunakan metode *machine learning*. Penjelasan diawali dengan pemaparan landasan teori, dilanjutkan dengan pembahasan penelitian terdahulu yang relevan, dan diakhiri dengan pembahasan mengenai celah penelitian yang menjadi dasar penelitian ini.

#### **2.1 Landasan Teori**


Bagian ini menguraikan konsep-konsep teoretis yang menjadi dasar dalam penelitian analisis sinyal EEG untuk klasifikasi Autism Spectrum Disorder (ASD). Landasan teori ini mencakup konsep dasar EEG, tahapan pemrosesan sinyal EEG, teknik seleksi fitur dalam pemrosesan, metode *machine learning* untuk klasifikasi, serta metode *data augmentation* yang digunakan dalam penelitian ini.

##### **2.1.1 Sinyal EEG**

Sinyal *electroencephalogram* (EEG) dihasilkan oleh aktivitas listrik neuron di otak yang muncul akibat aktivitas sinaptik antar neuron, sehingga potensial listrik yang dihasilkan dapat dideteksi pada permukaan kepala menggunakan elektroda. Sinyal EEG direkam sebagai perubahan tegangan terhadap waktu dengan rentang frekuensi sekitar 0,5 hingga 100 Hz dan amplitudo yang relatif rendah, umumnya berada pada kisaran 10 hingga 100 mikrovolt. Selain memiliki resolusi temporal yang tinggi, sinyal EEG juga bersifat *non-stationary*, sehingga karakteristik amplitudo dan distribusi frekuensinya dapat berubah secara dinamis seiring waktu akibat pengaruh kondisi fisiologis, tingkat kesadaran, maupun aktivitas kognitif. Aktivitas yang terekam mencerminkan berbagai proses otak, seperti fungsi kognitif, motorik, dan emosional, sehingga EEG banyak digunakan untuk mempelajari fungsi otak dan gangguan neurologis [16].

EEG biasanya direkam dalam bentuk sinyal multikanal yang diperoleh dari sejumlah

lah elektroda yang ditempatkan pada berbagai lokasi di permukaan kulit kepala. Setiap kanal merepresentasikan satu jalur perekaman sinyal yang berasal dari pasangan elektroda atau dari elektroda terhadap referensi tertentu. Setiap elektroda menangkap aktivitas listrik dari wilayah otak yang berbeda, sehingga setiap kanal mengandung informasi yang merepresentasikan aktivitas saraf pada lokasi tertentu.[13].



**Gambar 2.1.** Sistem Internasional 10–20 untuk Penempatan Elektroda EEG

Penempatan elektroda EEG umumnya mengikuti standar International *10–20 System*, yaitu protokol yang distandarisasi oleh *International Federation of Clinical Neurophysiology* (IFCN) untuk menentukan posisi elektroda pada permukaan kepala berdasarkan titik anatomi seperti nasion, inion, dan titik preauricular. Dalam sistem ini, setiap elektroda diberi kode huruf dan angka yang menunjukkan wilayah otak dan hemisfer terkait, seperti frontal (F), central (C), temporal (T), parietal (P), dan occipital (O), dengan angka ganjil untuk hemisfer kiri, angka genap untuk hemisfer kanan, serta “z” untuk posisi garis tengah kepala. Standarisasi ini memungkinkan perekaman EEG dilakukan secara konsisten dan dapat dibandingkan antar subjek maupun antar penelitian[17].

Dalam analisis sinyal EEG, aktivitas listrik otak yang terekam dapat dianalisis melalui dua domain utama, yaitu domain waktu dan domain frekuensi. Analisis dalam domain waktu dilakukan dengan mengamati karakteristik sinyal terhadap waktu, seperti amplitudo puncak, dan latensi. Sedangkan analisis dalam domain frekuensi bertujuan untuk




mengidentifikasi kandungan spektral sinyal dengan memeriksa distribusi energi atau daya pada berbagai rentang frekuensi menggunakan metode transformasi spektral, seperti *Fast Fourier Transform* (FFT) maupun teknik estimasi *Power Spectral Density* (PSD) untuk mengidentifikasi aktivitas otak pada rentang frekuensi tertentu [18].

Dalam analisis spektral EEG, sinyal umumnya dibagi ke dalam beberapa segmen waktu (*epoch*) sebelum dihitung nilai *Power Spectral Density* (PSD) untuk menggambarkan distribusi daya pada setiap frekuensi. Berdasarkan karakteristik fisiologis dan kognitifnya, sinyal EEG kemudian diklasifikasikan ke dalam beberapa pita frekuensi utama sebagai berikut.

**Tabel 2.1.** Pita frekuensi EEG dan karakteristiknya

| Pita  | Frekuensi (Hz) | Karakteristik                                                                                                                                              |
|-------|----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Delta | 0,5–4          | Dominan pada kondisi <i>deep sleep</i> dan berperan dalam proses pemulihan fisiologis serta regulasi fungsi tubuh selama tidur.                            |
| Theta | 4–8            | Berkaitan dengan proses pembentukan memori dan aktivitas pada sistem limbik serta hipokampus, serta muncul pada kondisi mengantuk atau relaksasi mendalam. |
| Alpha | 8–13           | Muncul pada kondisi rileks saat mata tertutup, dengan dominasi pada wilayah oksipital dan berhubungan dengan penurunan aktivitas pemrosesan sensorik.      |
| Beta  | 13–30          | Berkaitan dengan aktivitas kognitif aktif seperti konsentrasi, pemecahan masalah, serta aktivitas motorik.                                                 |
| Gamma | >30            | Berhubungan dengan proses kognitif tingkat tinggi, termasuk perhatian, integrasi informasi sensorik, dan persepsi.                                         |


Melalui analisis distribusi daya pada pita frekuensi, dapat dilakukan identifikasi pola aktivitas otak yang khas serta membandingkan karakteristik sinyal EEG pada berbagai kondisi fisiologis maupun gangguan neurologis tertentu. Representasi pita frekuensi EEG sering digunakan sebagai dasar dalam proses ekstraksi fitur pada analisis sinyal EEG, misalnya melalui perhitungan *band power*, estimasi *power spectral density* (PSD), maupun metode analisis spektral lainnya [13].



**Gambar 2.2.** Pita Frekuensi EEG pada Rentang Frekuensi Tinggi dan Rendah


Sebelum dilakukan ekstraksi fitur dan klasifikasi, sinyal EEG umumnya melalui tahap *preprocessing* untuk meningkatkan kualitas sinyal dan mengurangi gangguan yang tidak relevan. Tahapan ini biasanya meliputi *filtering*, *artifact removal*, *baseline correction*, serta normalisasi atau standarisasi data [13].

*Filtering* adalah proses penyaringan sinyal untuk menghilangkan komponen frekuensi yang tidak berkaitan dengan aktivitas saraf serta mengurangi gangguan dari lingkungan seperti interferensi listrik serta gangguan yang muncul akibat pergerakan elektroda dan perubahan impedansi kulit. *Filtering* dilakukan dengan membatasi rentang frekuensi sinyal menggunakan filter tertentu. Umumnya, *band-pass filter* digunakan untuk mempertahankan frekuensi aktivitas otak, serta *notch filter* untuk mereduksi interferensi jaringan listrik. Filter tambahan seperti *high-pass filter* juga dapat digunakan untuk menghilangkan *drift* sinyal berfrekuensi sangat rendah, sedangkan *low-pass filter* digunakan untuk mereduksi komponen *noise* berfrekuensi tinggi. Pemilihan filter perlu dilakukan secara hati-hati untuk menghindari distorsi sinyal atau pergeseran fase sinyal [13]. Pengaruh penggunaan filter terhadap sinyal EEG dapat dilihat pada ilustrasi berikut.



**Gambar 2.3.** Ilustrasi pengaruh berbagai jenis filter terhadap sinyal EEG

Sinyal EEG dapat terkontaminasi oleh artefak non-neural yang berasal dari aktivitas fisiologis maupun faktor eksternal. Artefak fisiologis umumnya disebabkan oleh kedipan mata dan pergerakan bola mata (*electrooculogram*), aktivitas otot wajah dan kepala (*electromyogram*), serta pergerakan tubuh selama proses perekaman, sedangkan artefak eksternal dapat berasal dari interferensi perangkat elektronik dan jaringan listrik. Keberadaan artefak dapat mempengaruhi kualitas sinyal dan berpotensi menurunkan akurasi analisis maupun kinerja sistem klasifikasi. Berbagai metode digunakan untuk mengurangi artefak pada sinyal EEG, seperti *Blind Source Separation* (BSS), *Independent Component Analysis* (ICA), serta transformasi wavelet yang memungkinkan analisis pada domain waktu dan frekuensi untuk mendeteksi artefak [13].



**Gambar 2.4.** Bentuk-Bentuk Artefak pada Sinyal EEG

Dalam analisis EEG berbasis *machine learning*, normalisasi atau standarisasi digunakan untuk mengurangi variasi antar kanal maupun antar subjek yang menyebabkan perbedaan skala fitur dan mempengaruhi proses *training*. Proses normalisasi digunakan untuk menyesuaikan skala fitur agar berada dalam rentang yang lebih seragam. Salah satu metode yang umum digunakan adalah *Z-score normalization*, yaitu mengurangi nilai rata-rata dan membaginya dengan standar deviasi sehingga data memiliki rata-rata nol dan variansi satu, sedangkan *min-max normalization* juga dapat dilakukan dengan men-skalakan nilai fitur ke dalam rentang tertentu, umumnya antara 0 dan 1. Proses ini memastikan kontribusi fitur lebih seimbang serta meningkatkan stabilitas dan kinerja model [13].

### 2.1.2 Feature Selection mRMR

Dalam aplikasi klasifikasi *machine learning*, *feature selection* merupakan langkah krusial untuk meminimalkan kesalahan klasifikasi. Secara formal, diberikan dataset  $D$  yang terdiri dari  $N$  sampel dan  $M$  fitur  $X = \{x_i \mid i = 1, 2, \dots, M\}$ , serta variabel target  $c$ , maka seleksi fitur bertujuan menentukan subset berdimensi lebih rendah  $R^m \subset R^M$  dengan  $m < M$  yang mampu merepresentasikan target secara optimal[19].

Secara umum, tujuan *feature selection* dapat diformulasikan sebagai proses optimasi untuk mencari himpunan fitur  $S \subseteq X$  dengan  $|S| = m$  yang memaksimalkan ketergantungan terhadap kelas target. Ketergantungan ini seringkali diukur menggunakan *mutual information*  $I(S; c)$ , sehingga permasalahan dapat dinyatakan sebagai:

$$\max_{S \subseteq X, |S|=m} I(S; c) \quad (2.1)$$

Penggunaan seluruh fitur tidak selalu menghasilkan performa optimal karena adanya redundansi antar fitur. Fitur dengan korelasi tinggi cenderung memberikan informasi yang berulang, sehingga diperlukan metode *feature selection* yang mempertimbangkan relevansi terhadap target sekaligus meminimalkan redundansi.

*Minimum Redundancy Maximum Relevance* (mRMR) merupakan teknik seleksi fitur berbasis teori informasi yang memilih subset fitur dengan relevansi tinggi terhadap target dan redundansi rendah antar fitur. Pendekatan ini efektif dalam mengurangi dimensi data tanpa mengorbankan informasi penting, sehingga meningkatkan efisiensi komputasi dan

kemampuan generalisasi model [20][21]. Proses pemilihan fitur pada metode mRMR dilakukan secara iteratif dengan mengevaluasi keseimbangan antara relevansi fitur terhadap kelas target dan redundansi antar fitur yang telah dipilih sebelumnya.

**Listing 2.1.** Pseudocode algoritma mRMR untuk seleksi fitur.

```

1  # mRMR Feature Selection Algorithm
2
3  def mrmr_feature_selection(X, c, m):
4
5      S = []                # selected features
6      F = X                # candidate features
7
8      # Select feature with maximum relevance
9      for xi in F:
10         relevance[xi] = MI(xi, c)
11
12     x_best = argmax(relevance)
13
14     S.append(x_best)
15     F.remove(x_best)
16
17     # Iterative feature selection
18     while len(S) < m:
19
20         for xj in F:
21
22             rel = MI(xj, c)
23
24             red = 0
25             for xs in S:
26                 red += MI(xj, xs)
27
28             red = red / len(S)
29
30             score[xj] = rel - red
31
32         x_best = argmax(score)
33
34         S.append(x_best)
35         F.remove(x_best)
36
37     return S

```

Kode 2.1 menjelaskan proses seleksi fitur menggunakan metode *Minimum Redundancy Maximum Relevance* (mRMR). Algoritma dimulai dengan memilih fitur yang memiliki nilai *mutual information* tertinggi terhadap kelas target sebagai fitur awal. Selanjutnya, fitur lain dipilih secara iteratif berdasarkan nilai *mRMR score*, yaitu selisih antara relevansi fitur terhadap target dan redundansinya terhadap fitur yang dipilih sebelumnya. Proses ini dilakukan hingga jumlah fitur terpilih mencapai jumlah yang diinginkan.

### 2.1.3 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG

Dalam *machine learning*, klasifikasi merupakan proses pemetaan data ke dalam kategori atau kelas tertentu berdasarkan pola yang dipelajari dari data *training*. Pada analisis EEG, proses klasifikasi umumnya dilakukan dengan menggunakan fitur-fitur yang diekstraksi dari sinyal EEG, seperti fitur dalam domain waktu, domain frekuensi, maupun domain waktu-frekuensi. Fitur-fitur tersebut merepresentasikan karakteristik aktivitas otak yang relevan terhadap kondisi fisiologis atau kognitif tertentu. Melalui proses klasifikasi, model diharapkan mampu mengidentifikasi pola tersebut secara akurat pada data baru. Sinyal EEG digunakan dalam berbagai tugas klasifikasi untuk mengidentifikasi kondisi kognitif dan neurologis, seperti tugas motorik, deteksi kejang epilepsi, dan sistem *brain-computer interface* (BCI) [22]. EEG juga dimanfaatkan untuk mengidentifikasi pola aktivitas otak pada Autism Spectrum Disorder (ASD), karena perbedaan karakteristik neurofisiologis antara individu ASD dan individu dengan perkembangan tipikal [23].

Sinyal EEG digunakan dalam berbagai tugas klasifikasi untuk mengidentifikasi kondisi kognitif dan neurologis, seperti tugas motorik, deteksi kejang epilepsi, dan sistem *brain-computer interface* (BCI) [22]. EEG juga dimanfaatkan untuk mengidentifikasi pola aktivitas otak pada Autism Spectrum Disorder (ASD), dengan memanfaatkan perbedaan karakteristik neurofisiologis antara individu ASD dan individu dengan perkembangan tipikal [23].

Analisis sinyal EEG dalam domain frekuensi merupakan pendekatan yang umum digunakan dalam studi EEG untuk mengkaji gangguan *Autism Spectrum Disorder* (ASD), karena aktivitas otak dapat direpresentasikan sebagai pola osilasi yang terdistribusi pada pita frekuensi tertentu. Pita frekuensi EEG diketahui memiliki keterkaitan dengan proses kognitif dan fungsi neural, sehingga analisis spektral menjadi pendekatan yang informatif dalam mengungkap karakteristik aktivitas neurofisiologis secara terstruktur [24].

Pada kasus ASD, studi EEG berbasis analisis spektral menunjukkan adanya pola abnormalitas yang relatif konsisten pada berbagai pita frekuensi. Individu dengan ASD cenderung menunjukkan peningkatan daya pada pita frekuensi rendah (delta dan theta) serta frekuensi tinggi (beta dan gamma), disertai dengan penurunan daya pada pita frekuensi menengah (alpha). Pola ini membentuk karakteristik profil spektral berbentuk U (*U-shaped profile*) yang mencerminkan adanya gangguan dalam mekanisme neurofisiolo-

gis yang mendasari aktivitas otak. Representasi ini relevan dalam analisis ASD karena mampu menyoroti perbedaan distribusi aktivitas neural yang tidak mudah diamati dalam domain waktu [22].

Berdasarkan representasi fitur yang diperoleh, proses klasifikasi selanjutnya dilakukan menggunakan algoritma *machine learning* untuk membangun model prediksi. Berbagai metode klasifikasi, seperti *support vector machine* (SVM), *k-nearest neighbor* (KNN), dan *random forest*, telah banyak digunakan dalam analisis sinyal EEG dan menunjukkan kinerja yang baik dalam mengidentifikasi pola aktivitas neural yang kompleks[23]. Meskipun pendekatan *deep learning* juga berkembang pesat dalam beberapa tahun terakhir, metode *machine learning* konvensional tetap menjadi pilihan yang efektif, khususnya pada kondisi data yang terbatas dan kebutuhan interpretabilitas model[25].

#### 2.1.4 Generative Machine Learning

#### 2.1.5 Metode Evaluasi Data Sintetis Sinyal EEG

Dalam penelitian referensi [15], evaluasi kualitas data sintetis dilakukan untuk menilai kesamaan distribusi dan keberagaman sampel yang dihasilkan oleh model generatif. Pendekatan yang digunakan dalam penelitian memanfaatkan beberapa metrik kuantitatif yang umum digunakan dalam evaluasi model generatif, yaitu *Inception Score* (IS), *Frechet Inception Distance* (FID), *Euclidean Distance* (ED), dan *Sliced Wasserstein Distance* (SWD).

Dalam implementasinya, *Inception Score* dihitung dengan menggunakan model klasifikasi EEG yang telah dilatih sebelumnya sebagai pengganti model *Inception* pada domain citra. Metrik ini digunakan untuk mengevaluasi kualitas dan keberagaman sinyal sintetis berdasarkan distribusi prediksi model, di mana distribusi yang tajam dan beragam menunjukkan kualitas generasi yang baik.

Selanjutnya, *Frechet Inception Distance* digunakan untuk mengukur kesamaan distribusi antara data EEG asli dan sintetis pada ruang fitur yang diperoleh dari lapisan representasi model klasifikasi. Berbeda dengan IS, metrik ini mempertimbangkan statistik distribusi secara langsung, sehingga lebih sensitif terhadap perbedaan struktur data dan variasi sampel.

Untuk mengevaluasi kemiripan secara langsung antara sampel, digunakan *Euclidean Distance* dengan membandingkan jarak minimum antara data sintetis dan data asli. Pendekatan ini bertujuan untuk mengidentifikasi apakah model hanya mereplikasi data pelatihan atau mampu menghasilkan variasi baru yang tetap realistis.

Selain itu, *Sliced Wasserstein Distance* digunakan untuk membandingkan distribusi global antara data asli dan sintetis melalui proyeksi satu dimensi. Metrik ini memberikan estimasi kesamaan distribusi secara efisien dan sensitif terhadap perbedaan bentuk distribusi.

Hasil evaluasi pada penelitian referensi menunjukkan bahwa kombinasi metrik tersebut mampu memberikan penilaian yang lebih komprehensif terhadap kualitas data sintetis, mencakup aspek kesamaan distribusi, keberagaman sampel, serta kemampuan model dalam menghasilkan data yang tidak hanya meniru data pelatihan. Oleh karena itu, pendekatan evaluasi ini digunakan sebagai acuan dalam menilai kualitas sinyal EEG sintetis yang dihasilkan pada penelitian ini.

### 2.1.6 Augmentasi Data EEG

Dalam penelitian *machine learning*, ketersediaan data yang memadai penting untuk proses *training*, namun pada analisis EEG hal ini sering menjadi kendala. Perekaman EEG relatif mahal, memakan waktu, dan menghasilkan data dengan variabilitas tinggi antar individu maupun sesi, akibat perbedaan perangkat, konfigurasi kanal, kondisi eksperimen, serta artefak non-neural. Variabilitas ini menyebabkan distribusi data menjadi kompleks dan tidak konsisten antar dataset [26]. Keterbatasan ini serta kompleksitas karakteristik sinyal EEG dapat menyebabkan model *machine learning* mengalami masalah *overfitting*, di mana model mampu mempelajari pola yang sangat spesifik terhadap data *training* namun memiliki kemampuan generalisasi yang rendah terhadap data baru. Berbagai penelitian mengusulkan penggunaan teknik *data augmentation* sebagai solusi untuk meningkatkan jumlah dan keragaman data *training* tanpa harus melakukan perekaman sinyal EEG tambahan.

Secara umum, *data augmentation* bertujuan untuk menghasilkan sampel data baru yang memiliki karakteristik statistik yang serupa dengan data asli, sehingga model *machine learning* dapat mempelajari representasi pola yang lebih stabil [12]. Untuk sinyal



EEG, teknik *data augmentation* dapat dilakukan melalui berbagai pendekatan. Beberapa metode sederhana meliputi manipulasi sinyal dalam domain waktu atau frekuensi, seperti *noise injection*, *time shifting*, maupun transformasi spektral. Pendekatan-pendekatan ini umumnya dilakukan dengan mentransformasikan data asli untuk menghasilkan sampel baru yang memiliki distribusi yang serupa dengan data awal.

Metode augmentasi konvensional memiliki keterbatasan pada sinyal EEG. Penambahan *noise* dapat mengubah amplitudo dan distribusi data, sedangkan *time shifting* berpotensi mengganggu informasi temporal yang berkaitan dengan aktivitas fisiologis. Beberapa penelitian juga menunjukkan bahwa augmentasi sederhana tidak selalu meningkatkan performa model, bahkan dapat menurunkannya. Oleh karena itu, pendekatan berbasis model generatif digunakan untuk menghasilkan data sintetis yang lebih mampu mempertahankan karakteristik kompleks sinyal, termasuk dependensi spasial dan temporal, sehingga menghasilkan representasi yang lebih realistis dan informatif [14].

Model generatif berbasis *deep learning*, seperti *Generative Adversarial Networks* (GAN) dan *Variational Autoencoders* (VAE), telah banyak digunakan untuk menghasilkan sinyal EEG sintetis yang mengikuti distribusi statistik dari data asli. Pendekatan ini memungkinkan model untuk mempelajari struktur laten dari sinyal EEG dan kemudian menghasilkan sampel baru yang memiliki karakteristik yang serupa dengan data *training*. Beberapa penelitian menunjukkan bahwa penggunaan data sintetis yang dihasilkan oleh model generatif dapat meningkatkan performa model klasifikasi EEG, terutama pada kondisi di mana jumlah data *training* terbatas [14].

Salah satu model yang dapat digunakan adalah *Variational Autoencoder* (VAE), yang merupakan model generatif probabilistik yang mampu memodelkan distribusi laten dan menghasilkan sampel data secara terkontrol. Pendekatan ini memungkinkan pembelajaran representasi laten yang kontinu dan terstruktur, sehingga sesuai untuk data berdimensi tinggi seperti sinyal EEG serta mampu mempertahankan karakteristik statistik data untuk keperluan augmentasi dan peningkatan kualitas data *training* [27].

### 2.1.7 Variational Auto Encoder

*Variational Autoencoder* (VAE) merupakan salah satu model generatif berbasis *deep learning* yang banyak digunakan untuk mempelajari representasi laten dari suatu dataset

dan menghasilkan sampel data baru yang memiliki karakteristik statistik yang serupa dengan data asli. Model ini merupakan pengembangan dari *autoencoder* tradisional dengan pendekatan probabilistik, di mana representasi laten dimodelkan sebagai distribusi probabilitas sehingga memungkinkan proses generasi data baru melalui ruang laten (*latent space*) yang dipelajari oleh model, berbeda dengan *autoencoder* konvensional yang berfokus pada kompresi dan rekonstruksi data [28].

Secara umum, arsitektur VAE terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*. Bagian *encoder* bertugas memetakan data input  $x$  ke dalam representasi laten  $z$  yang memiliki dimensi lebih rendah. VAE memodelkan representasi laten tersebut sebagai distribusi probabilistik, yang mengikuti distribusi normal multivariat. *Encoder* tidak hanya menghasilkan satu vektor representasi laten, tetapi juga dua parameter distribusi, yaitu nilai rata-rata ( $\mu$ ) dan variansi ( $\sigma$ ), yang mendeskripsikan distribusi probabilistik dari variabel laten tersebut [28].

Setelah distribusi laten diperoleh, proses berikutnya adalah melakukan *sampling* dari distribusi tersebut untuk menghasilkan vektor laten  $z$  yang menjadi input *decoder*. *Decoder* berfungsi untuk merekonstruksi kembali data dari representasi laten tersebut sehingga menghasilkan data keluaran  $\hat{x}$  yang diharapkan memiliki karakteristik yang serupa dengan data asli  $x$  [28].

Proses *training* VAE dilakukan dengan memaksimalkan fungsi objektif yang dikenal sebagai *Evidence Lower Bound* (ELBO). Fungsi ini terdiri dari dua komponen utama, yaitu *reconstruction loss* dan *regularization loss*. *Reconstruction loss* mengukur sejauh mana data hasil rekonstruksi  $\hat{x}$  mendekati data asli  $x$ , sehingga model terdorong untuk mempertahankan informasi penting dari data input. Sementara itu, komponen regularisasi diukur menggunakan *Kullback–Leibler Divergence* (KL Divergence), yang bertujuan untuk memastikan bahwa distribusi laten yang dipelajari oleh model tetap mendekati distribusi yang telah ditentukan sebelumnya, biasanya berupa distribusi normal standar.

Secara matematis, fungsi objektif VAE dapat dinyatakan sebagai berikut:

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)] - D_{KL}(q_{\phi}(z|x) \parallel p(z))$$

di mana  $q_{\phi}(z|x)$  merepresentasikan distribusi laten yang dihasilkan oleh *encoder*,  $p_{\theta}(x|z)$  merepresentasikan proses rekonstruksi oleh *decoder*, dan  $p(z)$  merupakan dis-

tribusi prior pada ruang laten. Komponen pertama pada persamaan tersebut merepresentasikan kualitas rekonstruksi data, sedangkan komponen kedua berfungsi sebagai regularisasi untuk menjaga struktur distribusi laten[28].

Proses *sampling* pada ruang laten tidak dapat dilakukan secara langsung dalam proses *training* menggunakan metode *backpropagation*. Oleh karena itu, VAE menggunakan teknik yang dikenal sebagai *reparameterization trick*. Melalui teknik ini, variabel laten  $z$  dinyatakan sebagai:

$$z = \mu + \sigma \cdot \epsilon$$

di mana  $\epsilon$  merupakan variabel acak yang diambil dari distribusi normal standar  $\mathcal{N}(0, 1)$ . Dengan pendekatan ini, proses *sampling* dapat ditransformasikan menjadi operasi deterministik yang memungkinkan gradien tetap dapat dihitung selama proses *training* neural network [28].

Kemampuan VAE dalam mempelajari representasi laten dari data menjadikannya sesuai dalam tugas augmentasi data. Penggunaan VAE pada EEG memungkinkan model untuk mempelajari pola spasial dan temporal dari sinyal EEG secara lebih komprehensif sehingga dapat digunakan untuk menghasilkan sinyal EEG sintetis yang tetap mempertahankan karakteristik distribusi dari data asli. Model VAE menjadi salah satu pendekatan yang banyak digunakan dalam penelitian augmentasi data EEG untuk meningkatkan performa sistem klasifikasi berbasis *machine learning*[12].

## 2.2 Penelitian Terdahulu

Selain membahas konsep-konsep dasar yang relevan dengan penelitian ini, penting juga untuk meninjau beberapa penelitian terdahulu yang berkaitan dengan klasifikasi Autism Spectrum Disorder (ASD) berbasis sinyal EEG. Seiring dengan berkembangnya pendekatan machine learning dalam analisis sinyal EEG, berbagai metode telah diusulkan untuk mengidentifikasi pola aktivitas neural yang berkaitan dengan ASD.

Selain membahas pendekatan klasifikasi berbasis EEG, perlu juga dilakukan tinjauan terhadap penerapan augmentasi data dalam penelitian terdahulu sebagai upaya mengatasi keterbatasan jumlah data. Sejumlah penelitian menunjukkan bahwa augmentasi data

dapat meningkatkan performa model klasifikasi. Namun, efektivitas teknik augmentasi sangat bergantung pada metode yang digunakan dan kesesuaiannya dengan karakteristik sinyal EEG.

Kedua pendekatan ini menjadi landasan penting dalam pengembangan metode augmentasi data yang lebih efektif untuk meningkatkan performa model klasifikasi EEG.

### 2.2.1 Klasifikasi ASD Berbasis EEG Menggunakan mRMR dan XGBoost

Pada penelitian rujukan[8], dilakukan analisis klasifikasi *Autism Spectrum Disorder* (ASD) menggunakan sinyal EEG dengan memanfaatkan teknik seleksi fitur dan algoritma *machine learning*. Selain membangun model klasifikasi, penelitian ini juga mengembangkan model deskriptif untuk mengidentifikasi dan memahami karakteristik pola aktivitas neural yang membedakan individu dengan ASD dan individu dengan perkembangan tipikal. Penelitian ini berfokus pada pemanfaatan fitur berbasis domain frekuensi untuk merepresentasikan karakteristik aktivitas neural yang relevan dengan kondisi ASD, serta menekankan pentingnya pemilihan fitur yang optimal untuk meningkatkan performa dan interpretabilitas model klasifikasi.

Penelitian menggunakan pendekatan seleksi fitur berbasis *minimum Redundancy Maximum Relevance* (mRMR) untuk mengidentifikasi fitur yang paling informatif sekaligus meminimalkan redundansi antar fitur. Sebelum proses seleksi fitur, sinyal EEG melalui tahap prapemrosesan yang meliputi segmentasi, (*filtering*), serta dekomposisi ke dalam pita frekuensi untuk menghasilkan representasi fitur yang lebih stabil dan terstruktur. Fitur yang telah diseleksi kemudian digunakan sebagai masukan bagi model klasifikasi berbasis *ensemble*, yaitu XGBoost. Pendekatan ini dibandingkan dengan metode dasar berbasis *Discrete Wavelet Transform* (DWT), ekstraksi fitur *Shannon entropy*, dan klasifikasi menggunakan *Artificial Neural Network* (ANN).

Hasil eksperimen menunjukkan bahwa pendekatan yang diusulkan mampu menghasilkan performa klasifikasi yang cukup baik dalam membedakan individu dengan ASD dan individu dengan perkembangan tipikal. Penggunaan mRMR terbukti dapat meningkatkan kualitas fitur yang digunakan, sementara XGBoost memberikan kemampuan klasifikasi yang robust terhadap kompleksitas data EEG. Temuan ini menunjukkan bahwa kombinasi seleksi fitur dan algoritma *ensemble* memiliki potensi yang signifikan

dalam meningkatkan akurasi serta kemampuan generalisasi model dalam klasifikasi ASD berbasis sinyal EEG.

### 2.2.2 Metode Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder

Pada penelitian referensi [14], diusulkan pendekatan augmentasi data untuk sinyal EEG menggunakan model generatif berbasis *Variational Autoencoder* (VAE). Implementasi yang digunakan dalam penelitian ini mengadaptasi metode yang diperkenalkan dalam studi referensi [29], yang memanfaatkan VAE untuk mempelajari distribusi laten dari sinyal EEG dan menghasilkan sampel sintetis yang menyerupai data asli. Dataset yang digunakan berasal dari BCI Competition IV Dataset 2a, yang terdiri dari data EEG 22 kanal dari 9 subjek dengan empat kelas tugas *motor imagery*, sehingga digunakan dalam tugas klasifikasi *motor imagery*. Dalam implementasinya, data EEG diolah dalam bentuk yang sesuai untuk pemanfaatan arsitektur *2D Convolutional Neural Network* (2D CNN), sehingga direpresentasikan dalam bentuk matriks dua dimensi.

Dari sisi arsitektur, model yang digunakan terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*, yang dilatih secara end-to-end untuk merekonstruksi sinyal EEG melalui representasi laten berdimensi rendah. *Encoder* memetakan sinyal EEG ke dalam distribusi probabilistik yang direpresentasikan oleh parameter *mean* dan variansi, sementara *decoder* menghasilkan kembali sinyal berdasarkan sampel dari ruang laten tersebut melalui mekanisme *reparameterization*. Selain itu, dalam tahap evaluasi, digunakan arsitektur *EEGNet* sebagai model klasifikasi berbasis CNN yang dirancang khusus untuk sinyal EEG. Dua model EEGNet dilatih secara terpisah menggunakan data asli dan data hasil augmentasi untuk membandingkan pengaruh penggunaan data sintetis terhadap performa klasifikasi.

Hasil penelitian menunjukkan bahwa penggunaan data sintetis yang dihasilkan oleh VAE mampu meningkatkan performa model klasifikasi *motor imagery* secara signifikan. Model yang dilatih menggunakan data asli memperoleh akurasi sebesar 0.73, sedangkan model yang dilatih menggunakan data hasil augmentasi mencapai akurasi sebesar 0.88. Peningkatan ini juga tercermin pada metrik *precision*, *recall*, dan *f1-score* pada sebagian besar kelas, yang menunjukkan bahwa data sintetis mampu memperkaya variasi data

*training* dan membantu model dalam menangkap pola yang lebih representatif. Temuan ini menunjukkan bahwa pendekatan generatif berbasis VAE memiliki potensi yang signifikan dalam meningkatkan kinerja sistem klasifikasi berbasis sinyal EEG, yang dalam kasus ini berfokus pada klasifikasi *motor imagery*.

### 2.2.3 Dataset EEG yang Digunakan

Dataset yang digunakan dalam penelitian ini berupa sinyal *electroencephalogram* (EEG) yang diperoleh dari studi rujukan [6], berupa data subjek dengan dan tanpa diagnosis *Autism Spectrum Disorder* (ASD). Data ini dipilih karena mampu merepresentasikan aktivitas neural yang berkaitan dengan kondisi ASD, sehingga relevan untuk digunakan dalam pengembangan dan evaluasi model klasifikasi berbasis *machine learning*.

Data EEG dikumpulkan dari sepuluh partisipan yang terdiri dari lima anak dengan diagnosis ASD berusia 6–10 tahun serta lima subjek kontrol sehat berusia di atas 17 tahun. Proses akuisisi dilakukan menggunakan 16 kanal EEG yang ditempatkan berdasarkan sistem standar *International 10–20 System*, yaitu pada posisi Fp1, Fp2, F3, F4, F7, F8, C3, C4, T3, T4, T5, T6, P3, P4, O1, dan O2. Setiap sesi perekaman berlangsung sekitar 15 menit untuk delapan kanal dan diulang hingga mencakup seluruh 16 kanal, sehingga total durasi perekaman mencapai sekitar 40 menit. Perekaman dilakukan tanpa adanya stimulan eksternal dan dengan upaya meminimalkan distraksi partisipan.

Akuisisi data dilakukan menggunakan perangkat *OpenBCI Cyton Biosensing Board*, yang mendukung perekaman hingga delapan kanal EEG per sesi. Elektroda yang digunakan ditempatkan menggunakan *EEG cap* dengan bantuan gel konduktif untuk meningkatkan kualitas kontak dan meminimalkan gangguan sinyal. Perangkat ini memiliki rasio *signal-to-noise ratio* (SNR) sebesar 121 dB serta resolusi tegangan sebesar 0.298  $\mu V$ , sehingga mampu merekam sinyal EEG dengan tingkat presisi yang tinggi. Data yang diperoleh divisualisasikan dan direkam menggunakan perangkat lunak *OpenBCI GUI* serta *library BrainFlow* untuk keperluan pemrosesan lebih lanjut.

Setelah proses akuisisi, sinyal EEG melalui tahap prapemrosesan untuk meningkatkan kualitas data. Dalam penelitian terkait [8], beberapa metode seperti *Butterworth filtering*, *Discrete Wavelet Transform* (DWT), dan *Independent Component Analysis* (ICA) digunakan untuk mengurangi artefak dan meningkatkan kejernihan sinyal. Di antara metode

tersebut, ICA menunjukkan performa yang paling efektif dalam meningkatkan kualitas sinyal, khususnya dalam meningkatkan nilai SNR serta mempertahankan karakteristik penting sinyal EEG yang relevan untuk analisis lebih lanjut.

Selanjutnya, sinyal EEG yang telah diproses digunakan dalam tahap segmentasi dan ekstraksi fitur, khususnya melalui dekomposisi ke dalam pita frekuensi utama (delta, theta, alpha, beta, dan gamma). Karakteristik dataset yang memiliki dimensi fitur tinggi serta jumlah sampel yang relatif terbatas menjadikannya menantang dalam proses pemodelan, sehingga sesuai untuk mengevaluasi kinerja metode klasifikasi serta efektivitas pendekatan augmentasi data yang digunakan dalam penelitian ini.

### 2.3 Fokus pada Celah Penelitian

Berdasarkan tinjauan pustaka yang telah dilakukan, terdapat celah penelitian dalam pemanfaatan teknik augmentasi data berbasis *Variational Autoencoder* (VAE) untuk analisis sinyal EEG. Beberapa penelitian sebelumnya telah menerapkan VAE untuk menghasilkan data EEG sintetis, khususnya dalam konteks tugas klasifikasi berbasis *motor imagery* menggunakan arsitektur seperti *2D Convolutional Neural Network* (CNN). Pendekatan tersebut menunjukkan bahwa data sintetis mampu meningkatkan performa model klasifikasi dengan memperkaya variasi data *training*. Meskipun demikian, fokus penelitian masih terbatas pada representasi sinyal dalam domain waktu atau spasial, tanpa mengeksplorasi secara mendalam karakteristik sinyal dalam domain frekuensi.

Di sisi lain, analisis berbasis domain frekuensi memiliki peran penting dalam studi EEG, terutama dalam mengidentifikasi pola osilasi neural yang berkaitan dengan kondisi neurologis seperti *Autism Spectrum Disorder* (ASD). Pemanfaatan data sintetis berbasis VAE pada representasi fitur frekuensi masih relatif terbatas, dan belum banyak dilakukan pengkajian terkait pengaruh augmentasi sinyal EEG terhadap kualitas fitur dan performa model klasifikasi berbasis *machine learning* konvensional.

Oleh karena itu, penelitian ini mengusulkan pendekatan yang mengintegrasikan teknik augmentasi data berbasis VAE dengan ekstraksi fitur domain frekuensi, serta memanfaatkan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) dan algoritma klasifikasi *XGBoost*. Pendekatan ini bertujuan untuk mengeksplorasi bagaimana data sintetis yang dihasilkan pada domain frekuensi dapat meningkatkan kualitas repre-

sentasi fitur serta performa klasifikasi ASD. Dengan mengisi celah ini, diharapkan penelitian ini dapat memberikan kontribusi dalam pengembangan metode klasifikasi EEG yang lebih robust dan akurat, khususnya pada kondisi dataset yang terbatas.



### BAB 3

## PERANCANGAN DAN IMPLEMENTASI SISTEM

Bab ini menyajikan metodologi penelitian serta perancangan teknis yang dilakukan untuk mengembangkan dan mengevaluasi sistem klasifikasi *Autism Spectrum Disorder* (ASD) berbasis sinyal EEG. Sistem yang dikembangkan dalam penelitian ini difokuskan sebagai sebuah lingkungan uji (*testbed*) yang terkontrol untuk mengevaluasi efektivitas pendekatan yang diusulkan, khususnya integrasi antara augmentasi data berbasis *Variational Autoencoder* (VAE), seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR), dan algoritma klasifikasi *XGBoost*.

Pembahasan pada bab ini diawali dengan Analisis Kebutuhan yang bertujuan untuk mendefinisikan batasan masalah serta spesifikasi sistem. Fokus utama bab ini terletak pada Perancangan Arsitektur dan Alur Kerja Sistem, yang menguraikan tahapan pengolahan sinyal EEG secara menyeluruh. Proses dimulai dari tahap prapemrosesan sinyal, dilanjutkan dengan dekomposisi frekuensi dan ekstraksi fitur statistik, kemudian dilakukan augmentasi data menggunakan model VAE. Model VAE yang digunakan diimplementasikan dalam bentuk *Encoder-Decoder neural network* yang dilatih untuk merekonstruksi sinyal EEG melalui representasi laten, sehingga mampu menghasilkan data sintetis yang mempertahankan karakteristik distribusi data asli. Data hasil augmentasi selanjutnya digabungkan dengan data asli sebelum dilakukan seleksi fitur menggunakan mRMR dan klasifikasi menggunakan XGBoost. Alur ini divisualisasikan menggunakan diagram arsitektur dan flowchart untuk memberikan gambaran sistem secara komprehensif.

Selanjutnya, bagian Detail Implementasi dan Teknologi menjelaskan realisasi arsitektur ke dalam bentuk implementasi kode. Model VAE dikembangkan menggunakan *library deep learning* (seperti TensorFlow atau PyTorch) dengan mekanisme *reparameterization trick* untuk memungkinkan proses *training* berbasis *backpropagation*. Selain itu, digunakan *library* seperti *NumPy* dan *SciPy* untuk pengolahan sinyal, serta *scikit-learn* dan *XGBoost* untuk proses seleksi fitur dan klasifikasi.

### 3.1 Analisis Kebutuhan Sistem

Sebelum memulai perancangan arsitektur, tahap pertama yang perlu dilakukan adalah menganalisis kebutuhan sistem. Untuk menjaga fokus penelitian dan tidak memperluas pembahasan, analisis kebutuhan ini difokuskan pada kebutuhan fungsional yang berkaitan dengan perancangan arsitektur sistem serta tujuan utama penelitian. Berbeda dengan penelitian yang berfokus pada pengembangan model klasifikasi, penelitian ini menitikberatkan pada integrasi proses augmentasi data ke dalam *pipeline* klasifikasi yang telah ada.

Secara khusus, sistem yang dirancang harus mampu mengakomodasi alur pemrosesan data EEG secara terstruktur, mulai dari tahap preprocessing hingga sintesis data baru menggunakan model generatif, serta memastikan bahwa data yang dihasilkan tetap kompatibel dengan *pipeline* klasifikasi. Oleh karena itu, kebutuhan fungsional yang didefinisikan berfokus pada integrasi antar komponen dalam *pipeline*, bukan pada perancangan model klasifikasi itu sendiri.

Berdasarkan penjabaran tersebut, didefinisikan beberapa kebutuhan fungsional utama yang harus dipenuhi dalam perancangan arsitektur sistem pada penelitian ini:

#### 1. Arsitektur *pipeline* Augmentasi EEG

Sistem harus dirancang sebagai *pipeline* terstruktur yang mencakup tahapan preprocessing sinyal EEG dan ekstraksi fitur sebagai representasi data. Tahapan ini harus mampu menghasilkan representasi data yang terstandarisasi dan siap digunakan sebagai masukan bagi modul augmentasi, sehingga proses *training* distribusi data dapat dilakukan secara optimal.

#### 2. Karakteristik dan Mekanisme Model Generatif (VAE)

Keseluruhan sistem harus mengimplementasikan modul augmentasi berbasis model generatif berupa *Variational Autoencoder* (VAE) yang mampu mempelajari distribusi laten dari data EEG. Model ini harus mampu menghasilkan sampel data sintetis baru yang diharapkan tetap mempertahankan karakteristik penting dari data asli. Modul augmentasi ini harus dirancang secara modular sehingga dapat diintegrasikan maupun dilepas dari *pipeline* klasifikasi tanpa memerlukan perubahan signifikan pada struktur sistem utama.

### 3. Kesesuaian dan Konsistensi dengan *pipeline* Klasifikasi

Sistem dan proses augmentasi harus mempertahankan kompatibilitas dengan *pipeline* klasifikasi yang digunakan, yaitu seleksi fitur berbasis *minimum Redundancy Maximum Relevance* (mRMR) dan model klasifikasi XGBoost. Data asli dan data sintetis harus memiliki format serta representasi fitur yang konsisten setelah melalui tahapan preprocessing dan ekstraksi fitur, sehingga keduanya dapat diproses secara langsung tanpa memerlukan perubahan pada struktur arsitektur utama.


## 3.2 Perancangan Arsitektur Sistem

Setelah kebutuhan fungsional sistem diuraikan, tahap selanjutnya adalah merancang arsitektur sistem sebagai representasi konseptual dari alur pemrosesan data yang akan diimplementasikan. Perancangan ini bertujuan untuk menggambarkan integrasi antar komponen dalam *pipeline*, khususnya dalam menggabungkan proses augmentasi data berbasis *Variational Autoencoder* (VAE) dengan *pipeline* klasifikasi yang telah ditentukan.

Secara umum, arsitektur sistem yang dirancang mencakup keseluruhan alur pemrosesan sinyal EEG, mulai dari tahap prapemrosesan hingga klasifikasi. Untuk mempermudah pemahaman, sistem dibagi menjadi tiga komponen utama, yaitu tahap prapemrosesan dan ekstraksi fitur, model augmentasi data berbasis VAE, serta tahap klasifikasi.

Pendekatan yang digunakan dalam penelitian ini mengadaptasi model *EEG Data Augmentation using Variational Autoencoder* [30], yaitu suatu model generatif berbasis VAE yang dirancang untuk menghasilkan data EEG sintetis yang menyerupai karakteristik data asli. Model ini pada dasarnya terdiri dari komponen *encoder* dan *decoder* yang dilatih secara end-to-end untuk merekonstruksi sinyal melalui representasi laten probabilistik.

Dalam implementasinya, arsitektur awal model tersebut mengalami penyesuaian untuk menyesuaikan dengan kebutuhan penelitian. Secara khusus, dimensi data dan struktur jaringan dimodifikasi dari pendekatan awal menjadi berbasis *1D Convolutional Neural Network* (1D CNN). Ketetapan didasarkan pada penelitian referensi [8] yang memproses sinyal EEG sebagai kanal terpisah dalam domain satu dimensi, sehingga lebih sesuai dengan karakteristik data serta kompatibel dengan *pipeline* klasifikasi yang digunakan. Dengan demikian, arsitektur yang diusulkan tetap mempertahankan prinsip dasar VAE, namun diadaptasi agar selaras dengan representasi data yang digunakan.




**Gambar 3.1.** Diagram aliran data pada sistem

Gambar 3.1 menunjukkan alur pemrosesan data pada sistem yang dikembangkan dalam penelitian ini. Proses dimulai dari data input berupa sinyal EEG yang terlebih dahulu melalui tahap pra-pemrosesan dan ekstraksi fitur yang kemudian diproses pada tahap augmentasi menggunakan model *Variational Autoencoder* (VAE), dengan tujuan untuk menghasilkan data sintetis yang memiliki karakteristik serupa dengan data asli.

Hasil tahap tersebut digunakan dalam dua skenario klasifikasi yang berbeda. Pada skenario pertama, proses klasifikasi dilakukan hanya menggunakan data asli, sedangkan pada skenario kedua, proses klasifikasi memanfaatkan kombinasi data asli dan data hasil augmentasi. Kedua skenario tersebut menggunakan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) serta algoritma klasifikasi XGBoost berdasarkan referensi penelitian sebelumnya [8]. Perbandingan antara kedua skenario ini bertujuan untuk mengevaluasi pengaruh penggunaan data sintetis terhadap performa model klasifikasi yang dihasilkan.

### 3.2.1 Pra-Pemrosesan Dataset

Tahap pra-pemrosesan dalam pengolahan sinyal EEG untuk memastikan bahwa data yang digunakan berada dalam kondisi yang representatif dan siap diproses oleh model. Tahap ini bertujuan untuk meningkatkan kualitas sinyal serta menyiapkan data dalam bentuk yang terstruktur untuk tahap selanjutnya.



**Gambar 3.2.** Diagram aliran proses prapemrosesan sistem

Selanjutnya, secara lebih rinci, Gambar 3.2 menggambarkan alur proses pada tahap pra-pemrosesan data. Sinyal EEG mentah terlebih dahulu dibersihkan dari nilai yang hilang. Selanjutnya, sinyal dibagi ke dalam segmen-segmen dengan durasi tertentu menggunakan pendekatan *sliding window* dengan overlap, sehingga memungkinkan penangkapan karakteristik temporal dari aktivitas neural. Setiap segmen kemudian diproses menggu-


nakan *bandpass filter* berbasis Butterworth untuk mempertahankan komponen frekuensi yang relevan serta mengurangi gangguan seperti *low-frequency drift* dan *high-frequency noise*.

Setelah proses penyaringan, dilakukan tahap seleksi segmen untuk mengidentifikasi dan mengeliminasi artefak berdasarkan kriteria amplitudo dan distribusi statistik, seperti nilai *peak-to-peak* dan *z-score*. Tahap ini bertujuan untuk memastikan bahwa hanya segmen sinyal yang berkualitas baik yang digunakan dalam proses selanjutnya.

Selanjutnya, dilakukan proses normalisasi terhadap setiap segmen sinyal menggunakan metode *z-score normalization*, yaitu dengan mengurangi nilai rata-rata dan membaginya dengan simpangan baku pada masing-masing sampel. Proses ini bertujuan untuk menyeragamkan distribusi data, mengurangi variasi antar sampel, serta meningkatkan stabilitas dalam proses *training* model, khususnya pada tahap augmentasi menggunakan VAE. Data yang telah dinormalisasi kemudian dipisahkan menjadi data *training* dan validasi, serta disusun ulang ke dalam bentuk tensor tiga dimensi agar sesuai dengan kebutuhan arsitektur *1D Convolutional Neural Network*.

### 3.2.2 Arsitektur Model VAE untuk Augmentasi Data

Model *Variational Autoencoder* (VAE) digunakan untuk melakukan augmentasi data sinyal EEG. Pada penelitian referensi [30], arsitektur VAE yang digunakan berbasis *2D Convolutional Neural Network*, yaitu data EEG direpresentasikan dalam bentuk dua dimensi dengan mempertimbangkan hubungan spasial antar kanal. Namun demikian, dalam penelitian ini dilakukan penyesuaian arsitektur menjadi berbasis *1D Convolutional Neural Network* (1D CNN). Perubahan ini dilakukan untuk menyesuaikan dengan pendekatan klasifikasi yang digunakan, di mana sinyal EEG diproses sebagai deret waktu satu dimensi pada setiap kanal secara terpisah. Selain itu, dimensi ruang laten juga ditingkatkan untuk meningkatkan kapasitas model dalam menangkap variasi pola sinyal EEG.



**Gambar 3.3.** Diagram Model VAE untuk Augmentasi EEG

Pada prosesnya, data input berupa segmen sinyal EEG satu dimensi terlebih dahulu diproses oleh bagian *encoder*. Bagian ini terdiri dari beberapa lapisan *convolutional* satu dimensi yang diikuti oleh *batch normalization* dan fungsi aktivasi *LeakyReLU*. Setiap lapisan *convolutional* menggunakan *stride* tertentu untuk melakukan reduksi dimensi secara progresif, sehingga menghasilkan representasi fitur berdimensi lebih rendah. Representasi ini kemudian diratakan (*flatten*) dan dipetakan ke dalam dua parameter distribusi laten, yaitu *mean* ( $z_{\text{mean}}$ ) dan variansi logaritmik ( $z_{\text{log\_var}}$ ) menggunakan lapisan *dense*. Selanjutnya, dilakukan proses *reparameterization*, di mana vektor laten  $z$  dihasilkan dengan mengombinasikan kedua parameter tersebut dengan variabel acak yang mengikuti distribusi normal standar. Mekanisme ini memungkinkan proses *training* model tetap dapat dilakukan melalui *backpropagation* secara *end-to-end*.

Vektor laten yang dihasilkan kemudian menjadi input bagi bagian *decoder*, yang bertugas untuk merekonstruksi kembali sinyal EEG. Proses rekonstruksi diawali dengan lapisan *dense* yang diikuti dengan proses *reshape* untuk membentuk kembali struktur data. Selanjutnya, digunakan serangkaian operasi *upsampling* yang dikombinasikan dengan lapisan *convolutional* satu dimensi dan fungsi aktivasi untuk meningkatkan dimensi data secara bertahap. Lapisan akhir berupa *convolutional* satu dimensi menghasilkan sinyal output yang memiliki dimensi yang sama dengan input awal.

Model yang telah melalui tahap *training* juga dimanfaatkan untuk menghasilkan data sintesis baru. Proses ini dilakukan dengan melakukan sampling secara acak pada ruang laten menggunakan distribusi normal standar, yang kemudian diberikan sebagai input ke bagian *decoder*. Melalui mekanisme ini, *decoder* dapat menghasilkan sinyal EEG sintesis yang memiliki karakteristik statistik yang menyerupai data asli, sehingga dapat digunakan sebagai data tambahan dalam proses augmentasi.

Dalam proses *training*, model VAE dioptimalkan menggunakan *loss function* gabungan yang terdiri dari dua komponen utama, yaitu *reconstruction loss* dan *Kullback-Leibler* (KL) divergence. *Reconstruction loss* mengukur perbedaan antara sinyal input dan hasil rekonstruksi, sedangkan KL divergence mengatur distribusi laten agar mendekati distribusi normal standar. Kedua komponen ini dihitung berdasarkan output dari *decoder* serta parameter distribusi laten ( $z_{\text{mean}}$  dan  $z_{\text{log\_var}}$ ), kemudian digabungkan untuk menghasilkan total *loss* yang digunakan dalam proses optimasi model.



### 3.2.3 Arsitektur Model Klasifikasi


*Pipeline* klasifikasi yang digunakan terdiri dari beberapa tahapan utama, yaitu dekomposisi frekuensi, standardisasi data, ekstraksi fitur statistik, seleksi fitur, serta klasifikasi. Tahapan awal dilakukan dengan memisahkan sinyal EEG ke dalam lima pita frekuensi utama, yaitu delta, theta, alpha, beta, dan gamma. Pemisahan ini bertujuan untuk menangkap karakteristik aktivitas otak pada rentang frekuensi yang berbeda, sehingga informasi yang diperoleh menjadi lebih representatif terhadap kondisi neurologis yang diamati dan lebih mudah dianalisis pada tahap selanjutnya.

Setelah proses dekomposisi, setiap pita frekuensi distandardisasi menggunakan transformasi *z-score*. Tahapan ini bertujuan untuk menormalkan distribusi data sehingga memiliki skala yang sebanding antar pita frekuensi, serta mencegah dominasi fitur tertentu dalam proses pembelajaran model sehingga setiap pita frekuensi dapat berkontribusi secara proporsional dalam pembentukan fitur.

Tahap berikutnya adalah ekstraksi fitur statistik, yang bertujuan untuk mengubah sinyal EEG yang bersifat kontinu menjadi representasi numerik yang terstruktur. Fitur yang dihasilkan mencerminkan karakteristik distribusi, variabilitas, dan kompleksitas sinyal pada masing-masing pita frekuensi. Proses ini menghasilkan himpunan fitur berdimensi tinggi yang mampu merepresentasikan pola sinyal secara komprehensif, sehingga menjadi dasar penting dalam proses klasifikasi.

Seleksi fitur dilakukan menggunakan metode *minimum Redundancy Maximum Relevance* (mRMR), yang bertujuan untuk memilih fitur yang paling relevan terhadap label kelas sekaligus meminimalkan redundansi antar fitur. Pendekatan ini menghasilkan subset fitur yang lebih ringkas, efisien, dan tetap informatif untuk digunakan pada tahap klasifikasi.

Tahap akhir dari *pipeline* adalah proses klasifikasi menggunakan algoritma XGBoost. Model ini membangun ensemble pohon keputusan secara bertahap untuk menangkap hubungan non-linear antar fitur secara efektif. Dalam penelitian ini, proses klasifikasi dilakukan dalam dua skenario, yaitu menggunakan data asli serta menggunakan kombinasi data asli dan data sintetis yang diperoleh dari model augmentasi. Kedua skenario diproses menggunakan *pipeline* yang sama, sehingga perbedaan performa yang dihasilkan dapat secara langsung dianalisis sebagai dampak dari penggunaan data hasil augmentasi.



**Gambar 3.4.** Diagram Model Klasifikasi

### 3.3 Detail Implementasi dan Teknologi

Bagian ini menjelaskan bagaimana perancangan sistem yang telah dijabarkan sebelumnya diterapkan ke dalam kode serta teknologi yang digunakan untuk mengimplementasikannya. Penjelasan pada bagian ini mencakup teknologi dan *library* yang digunakan, serta gambaran umum implementasi dari komponen utama dalam *pipeline*, termasuk pemrosesan sinyal EEG, ekstraksi dan seleksi fitur, modul augmentasi berbasis *Variational Autoencoder* (VAE), serta model klasifikasi.

#### 3.3.1 Teknologi dan Library

Dalam penelitian ini, seluruh proses pengolahan data, *training*, dan evaluasi model dilakukan menggunakan bahasa pemrograman Python. Pemilihan Python didasarkan pada ekosistem *library* yang luas serta kemampuannya dalam mendukung pengembangan sistem berbasis *machine learning* dan pemrosesan sinyal secara efisien. Untuk mempercepat komputasi, sistem ini memanfaatkan akselerasi GPU dengan bantuan CUDA Toolkit dari NVIDIA, sehingga operasi numerik berskala besar seperti *training* model dan komputasi matriks dapat dilakukan dengan lebih efisien.

Library utama yang digunakan dalam pengembangan sistem ini meliputi NumPy, Pandas, SciPy, dan scikit-learn. NumPy berperan sebagai backend komputasi numerik untuk operasi berbasis array dan matriks, sementara Pandas digunakan untuk pengelolaan dan manipulasi dataset. SciPy menyediakan fungsi *signal processing* yang mendukung proses pemrosesan sinyal EEG, sedangkan scikit-learn digunakan untuk kebutuhan preprocessing data, ekstraksi fitur, serta evaluasi model melalui berbagai metrik yang tersedia.

Untuk tahap pemodelan, digunakan XGBoost sebagai algoritma klasifikasi berbasis *gradient boosting* yang efisien dan mampu menangani data berdimensi tinggi serta hubungan non-linear. Selain itu, PyTorch digunakan sebagai framework *deep learning* untuk membangun model generatif berbasis Variational Autoencoder (VAE), yang memungkinkan proses augmentasi data dilakukan secara fleksibel dengan dukungan akselerasi GPU.

Dalam implementasi *pipeline* klasifikasi, beberapa *library* juga berperan dalam tahap ekstraksi dan pemrosesan fitur. SciPy digunakan untuk pemrosesan sinyal dan dekomposisi frekuensi, sementara NumPy dan Pandas mendukung perhitungan serta pengelo-


laan fitur statistik. Untuk seleksi fitur, digunakan scikit-learn sebagai dasar implementasi metode mRMR, sebelum fitur terpilih digunakan dalam proses pelatihan dan prediksi menggunakan XGBoost.

### 3.3.2 Implementasi Model Generatif Variational Autoencoder (VAE)

Perancangan model generatif pada penelitian ini dilakukan menggunakan pendekatan *Variational Autoencoder* (VAE) yang bertujuan untuk mempelajari distribusi laten dari sinyal EEG serta menghasilkan data sintetis yang menyerupai data asli. Arsitektur model secara umum terdiri dari dua bagian utama, yaitu *encoder* dan *decoder*.

Model menerima input berupa sinyal EEG satu dimensi dengan panjang 512 sampel dan satu kanal, sehingga berbentuk  $(512, 1)$ . Panjang sinyal ini diperoleh dari proses segmentasi dengan durasi 4 detik pada frekuensi sampling 128 Hz.

**Arsitektur Layer *Encoder*** dirancang menggunakan beberapa lapisan *Conv1D* untuk mengekstraksi pola temporal dari sinyal EEG. Setiap lapisan menggunakan *stride* sebesar 2 untuk melakukan downsampling secara bertahap.



**Gambar 3.5.** Diagram Aliran Layer *Encoder* pada Model VAE


*Encoder* menggunakan tiga blok konvolusi dengan jumlah filter 32, 64, dan 128. Ukuran kernel yang relatif besar (15–25) dipilih untuk menangkap pola temporal EEG yang memiliki karakteristik frekuensi rendah hingga menengah. Proses downsampling dilakukan melalui stride pada setiap lapisan konvolusi, sehingga menghasilkan reduksi dimensi bertahap dari 512 menjadi 64, yang membuat representasi semakin ringkas dan informatif.

Setiap blok konvolusi diikuti oleh Batch Normalization untuk menstabilkan distribusi aktivasi selama pelatihan, mempercepat konvergensi, serta mengurangi masalah internal covariate shift. Setelah normalisasi, digunakan fungsi aktivasi LeakyReLU dengan parameter 0.2, yang berarti gradien kecil sebesar 0.2 tetap dipertahankan untuk nilai negatif, sehingga mencegah masalah “dying ReLU” dan menjaga aliran gradien tetap stabil.

Padding yang digunakan adalah “same”, yang menjaga ukuran temporal output tetap proporsional dengan input sebelum proses downsampling oleh stride dilakukan, sehingga informasi di tepi sinyal tetap dipertahankan secara optimal.

Dimensi laten ditetapkan sebesar 16 sebagai kompromi antara kapasitas representasi dan stabilitas pelatihan, sehingga model mampu menangkap struktur penting data tanpa menyebabkan overfitting atau kehilangan informasi yang signifikan.

**Reparameterization Layer** digunakan untuk memungkinkan proses pelatihan berbasis gradien.



**Gambar 3.6.** Diagram alirán Reparameterization Layer

Lapisan Sampling menghasilkan vektor laten  $z$  dengan menggabungkan dua parameter yang dipelajari oleh *encoder*, yaitu  $z_{\text{mean}}$  dan  $z_{\text{log var}}$ . Proses ini digunakan untuk membuat representasi laten bersifat probabilistik, sehingga model tidak hanya menghasilkan satu

nilai tetap, tetapi sebuah distribusi.

Pada tahap ini digunakan variabel acak  $\epsilon$  (epsilon), yang diambil dari distribusi normal standar dengan mean 0 dan variansi 1. Noise ini berfungsi untuk memperkenalkan unsur stochastic dalam proses sampling, sehingga setiap forward pass dapat menghasilkan representasi  $z$  yang sedikit berbeda meskipun input sama.

Nilai  $z$  dihitung menggunakan teknik reparameterization trick, yaitu:  $z = z_{\text{mean}} + \exp(0.5 \cdot z_{\log \text{var}}) \cdot \epsilon$

Faktor  $\exp(0.5 \cdot z_{\log \text{var}})$  merepresentasikan standar deviasi dari distribusi yang dipelajari, sehingga noise  $\epsilon$  diskalakan sesuai dengan tingkat ketidakpastian data. Pendekatan ini memungkinkan proses sampling tetap dapat dioptimalkan menggunakan backpropagation, karena operasi acak dipisahkan dari parameter yang dipelajari.

**Arsitektur Decoder** menggunakan tiga tahap *upsampling* dengan jumlah filter 128, 64, dan 32. Ukuran kernel yang relatif besar (15–25) dipilih untuk mempertahankan pola temporal EEG yang memiliki karakteristik frekuensi rendah hingga menengah. Proses *upsampling* dilakukan pada setiap tahap untuk meningkatkan dimensi sinyal secara bertahap dari 64 menjadi 512, sehingga memungkinkan rekonstruksi struktur temporal secara progresif.


Setiap tahap *upsampling* diikuti oleh lapisan konvolusi yang berfungsi untuk memperhalus dan membentuk kembali fitur hasil interpolasi, sehingga informasi yang dihasilkan tidak bersifat kasar atau terdistorsi. Struktur jumlah filter disusun secara terbalik dari encoder, sehingga representasi fitur secara bertahap dikurangi kompleksitasnya seiring dengan peningkatan resolusi sinyal.

Setiap lapisan konvolusi diikuti oleh Batch Normalization untuk menstabilkan distribusi aktivasi selama proses rekonstruksi, membantu menjaga konsistensi output, serta mengurangi potensi ketidakstabilan selama propagasi. Setelah normalisasi, digunakan fungsi aktivasi ReLU yang memberikan non-linearitas yang cukup untuk memodelkan hubungan kompleks tanpa menghambat proses generasi sinyal.

Padding yang digunakan adalah “same”, yang menjaga ukuran temporal output tetap proporsional setelah setiap operasi konvolusi, sehingga perubahan dimensi hanya dipengaruhi oleh proses *upsampling*. Hal ini memastikan bahwa informasi pada bagian tepi

sinyal tetap dipertahankan selama proses rekonstruksi.

Lapisan akhir menggunakan konvolusi dengan satu filter untuk menghasilkan sinyal output dengan jumlah kanal yang sesuai dengan data asli, sehingga hasil rekonstruksi dapat langsung dibandingkan dengan input awal dalam proses pembelajaran.



**Gambar 3.7.** Diagram alir Decoder Layer

**Fungsi Loss dan Proses Training** didasarkan pada kombinasi *reconstruction loss* dan *Kullback-Leibler (KL) divergence*, yang merupakan komponen utama dalam *Variational Autoencoder (VAE)*.

*Reconstruction loss* dihitung menggunakan *Mean Squared Error (MSE)* antara input dan output rekonstruksi. Sebelum perhitungan, kedua tensor diubah menjadi vektor satu

dimensi (*flatten*) untuk menyederhanakan komputasi. Nilai loss kemudian dikalikan dengan faktor 512 untuk menyesuaikan skala kontribusinya terhadap total loss, sehingga model lebih fokus dalam mempertahankan kemiripan antara data asli dan hasil rekonstruksi.

*KL divergence* digunakan untuk mengukur perbedaan antara distribusi laten yang dipelajari dengan distribusi normal standar  $\mathcal{N}(0, 1)$ . Perhitungan dilakukan menggunakan parameter  $\mu$  ( $z\_mean$ ) dan  $\log \sigma^2$  ( $z\_log\_var$ ), kemudian dijumlahkan pada setiap dimensi laten dan dikalikan dengan faktor  $-0.5$ . Komponen ini berfungsi sebagai regularisasi agar ruang laten tetap terstruktur dan tidak menyimpang.

Total loss diperoleh dengan menjumlahkan kedua komponen tersebut, kemudian dirata-ratakan terhadap batch dan ditambahkan sebagai *custom loss* pada model.

Pelatihan dilakukan menggunakan optimizer Adam dengan *learning rate* 0.001, *batch size* 32, dan maksimum 1000 epoch.

**Generasi Data Sintetis** dilakukan melalui proses sampling pada ruang laten. Secara prinsip, karena distribusi laten telah dipaksa mendekati distribusi normal standar selama training, maka sampling dapat dilakukan dengan menghasilkan vektor acak dari distribusi Gaussian  $\mathcal{N}(0, 1)$  dengan dimensi yang sesuai (misalnya 16 dimensi laten).

Vektor laten acak ini kemudian diberikan sebagai input ke bagian *decoder* dari model. Decoder akan memetakan representasi laten tersebut kembali ke ruang data asli, sehingga menghasilkan sampel baru yang secara statistik menyerupai data pelatihan. Proses ini memungkinkan model untuk menghasilkan variasi data yang tidak identik dengan data asli, namun tetap mempertahankan karakteristik distribusinya.

Data sintetis yang dihasilkan selanjutnya digunakan sebagai bentuk *data augmentation* dalam pipeline klasifikasi. Dengan menambahkan sampel sintetis ke dalam data pelatihan, diharapkan model klasifikasi dapat meningkatkan kemampuan generalisasi, terutama dalam kondisi keterbatasan jumlah data asli.



### 3.3.3 Implementasi Model Klasifikasi

**Minimum Redundancy Maximum Relevance (mRMR)** diimplementasikan melalui *library feature\_engine.selection* melalui kelas *MRMR*. Label kelas terlebih dahulu dikonversi ke bentuk numerik menggunakan *LabelEncoder* dari *sklearn.preprocessing* melalui operasi *fit\_transform*, sehingga menghasilkan representasi biner yang dapat digunakan dalam proses seleksi fitur.

Fitur yang digunakan berasal dari kombinasi kanal EEG dan jenis fitur hasil ekstraksi *Discrete Wavelet Transform (DWT)*. Penamaan kolom dibentuk secara eksplisit melalui iterasi terhadap daftar kanal (*ch\_names*) dan jenis fitur (*DWT\_FEAT*), sehingga setiap fitur memiliki format *channel\_feature*. Seluruh fitur kemudian dikonversi ke dalam struktur *pandas DataFrame (dfX)* untuk memastikan kompatibilitas dengan metode *MRMR*.

**Tabel 3.1.** Konfigurasi Parameter *XGBoost*

| Parameter         | Nilai   |
|-------------------|---------|
| use_label_encoder | False   |
| eval_metric       | logloss |
| n_estimators      | 100     |
| learning_rate     | 0.3     |
| max_depth         | 6       |
| subsample         | 1.0     |
| colsample_bylevel | 1.0     |
| reg_alpha         | 0       |
| reg_lambda        | 1       |

**Model XGBoost** Model *XGBoost* pada penelitian ini menggunakan konfigurasi parameter sebagaimana ditunjukkan pada Tabel di atas. Parameter tersebut digunakan dalam proses *training* model untuk menghasilkan prediksi pada data uji.

Pembagian data dilakukan menggunakan *train\_test\_split* dengan parameter *test\_size=0.2*, *stratify=y\_enc*, dan *random\_state=42*. Model kemudian dilakukan *training* menggunakan data *training* dan digunakan untuk menghasilkan prediksi label serta probabilitas pada data *testing*. Hasil prediksi selanjutnya dievaluasi menggunakan *confusion matrix*, *classification report*, serta *ROC curve* dan *AUC score*.

## BAB 4

### PENUTUP

#### 4.1 Kesimpulan

Berdasarkan pemaparan teori serta perancangan metode yang telah dilakukan, dapat ditarik beberapa kesimpulan terkait konsep, pendekatan, dan arsitektur sistem yang diusulkan dalam penelitian ini. Kesimpulan yang diperoleh mencakup hasil analisis terhadap pendekatan yang diusulkan dalam meningkatkan representasi data EEG untuk mendukung proses klasifikasi ASD, sebagai berikut:


1. Diagnosis dini *Autism Spectrum Disorder* (ASD) merupakan aspek penting dalam mendukung intervensi yang lebih efektif. Analisis sinyal EEG sebagai metode non-invasif menjadi pendekatan yang menjanjikan dan terus berkembang untuk analisis aktivitas otak dalam konteks ASD, baik dalam domain waktu maupun frekuensi.
2. Representasi sinyal EEG pada domain frekuensi, seperti distribusi daya pada pita frekuensi dapat dimanfaatkan untuk merepresentasikan pola aktivitas otak yang relevan, yang kemudian dimodelkan menggunakan pendekatan *machine learning*. Pada penelitian ini, digunakan model *Extreme Gradient Boosting* (XGBoost) dengan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) berdasarkan penelitian rujukan untuk memperoleh fitur yang informatif dan meminimalkan redundansi.
3. Ketersediaan dataset pada analisis EEG masih menjadi tantangan utama dalam penerapan *machine learning* karena proses akuisisi yang mahal dan kompleks, serta tingginya variabilitas data. Variabilitas ini muncul akibat perbedaan antar subjek, kondisi perekaman, konfigurasi perangkat, jumlah kanal, serta keberadaan artefak seperti gerakan otot dan kedipan mata, yang menyebabkan distribusi data menjadi tidak konsisten dan menyulitkan proses generalisasi model.
4. Metode augmentasi data, yaitu metode membuat data dengan representasi statistik yang serupa berdasarkan data yang sudah ada dapat digunakan untuk mengatasi

masalah overfitting model karena keterbatasan dataset. Metode augmentasi yang digunakan dalam penelitian ini adalah *Variational Autoencoder* (VAE), yang dipilih karena mampu memodelkan distribusi laten data secara probabilistik dan menghasilkan sampel sintetis yang menyerupai data asli, sehingga lebih sesuai dibandingkan metode augmentasi konvensional yang berpotensi mengganggu karakteristik sinyal EEG.


5. Pipeline penelitian ini mencakup tahapan prapemrosesan, augmentasi data, seleksi fitur menggunakan mRMR, dan klasifikasi dengan XGBoost. Augmentasi dilakukan menggunakan VAE untuk menghasilkan data sintetis yang kemudian digabungkan dengan data asli. Pelatihan model dilakukan dalam dua skenario, yaitu menggunakan data asli saja dan menggunakan kombinasi data asli dan hasil augmentasi, sehingga perbandingan kinerja model dapat dilakukan untuk mengevaluasi pengaruh augmentasi sinyal EEG.
6. Evaluasi kualitas data sintetis mengacu pada metrik kuantitatif yang umum digunakan pada model generatif, yaitu *Inception Score* (IS), *Frechet Inception Distance* (FID), *Euclidean Distance* (ED), dan *Sliced Wasserstein Distance* (SWD). Metrik-metrik ini digunakan untuk menilai kesamaan distribusi, keberagaman sampel, serta kemampuan model dalam menghasilkan data yang tidak hanya mereplikasi data pelatihan, sehingga memberikan evaluasi yang lebih komprehensif terhadap kualitas sinyal EEG sintetis.
7. Penelitian ini secara khusus mengisi celah penelitian melalui integrasi augmentasi data berbasis VAE dengan representasi fitur domain frekuensi yang berbeda dengan pendekatan yang berfokus pada domain waktu atau spasial pada penelitian yang ada. Metode yang diusulkan memanfaatkan karakteristik frekuensi sinyal EEG sebagai dasar pembelajaran distribusi laten, sehingga data sintetis yang dihasilkan tetap mempertahankan pola osilasi neural yang relevan. Pendekatan yang diusulkan dapat meningkatkan variabilitas data *training* sehingga berpotensi menghasilkan model klasifikasi ASD yang lebih robust, khususnya pada kondisi dataset yang terbatas dan memiliki variabilitas tinggi.

## 4.2 Pengembangan Lanjutan

Pada tahap saat ini, model generatif yang dikembangkan telah mampu menghasilkan data sintetis dengan tingkat kesesuaian yang baik terhadap data asli. Hal ini ditunjukkan melalui hasil evaluasi menggunakan metrik yang telah dibahas sebelumnya, yaitu *Inception Score* (IS), *Frechet Inception Distance* (FID), *Euclidean Distance* (ED), dan *Sliced Wasserstein Distance* (SWD), di mana nilai yang diperoleh menunjukkan kualitas distribusi dan keberagaman sampel yang memadai.



**Gambar 4.1.** Perbandingan sampel sinyal EEG asli dan sintetis pada channel Fp1 dalam domain waktu



**Gambar 4.2.** Perbandingan PSD antara sampel sinyal asli dan sintetis pada channel Fp1

Meskipun demikian, pengembangan lebih lanjut masih diperlukan, khususnya dalam mengintegrasikan hasil augmentasi secara optimal ke dalam pipeline klasifikasi serta melakukan evaluasi eksperimental terhadap peningkatan performa model. Selain itu, eksplorasi terhadap variasi arsitektur model generatif, tuning hiperparameter, serta pengujian pada dataset yang lebih beragam dapat dilakukan untuk meningkatkan kualitas data sintetis dan stabilitas model secara keseluruhan.

## DAFTAR PUSTAKA

- [1] National Center for Biotechnology Information, “Autism spectrum disorder,” [Online]. Available: <https://www.ncbi.nlm.nih.gov/books/NBK525976/>, 2023.
- [2] American Psychiatric Association, *Diagnostic and Statistical Manual of Mental Disorders (DSM-5)*, 5th ed. Arlington, VA, USA: American Psychiatric Association, 2013, [Online]. Available: <https://www.psychiatry.org/psychiatrists/practice/dsm>.
- [3] Y. Hus and O. Segal, “Challenges surrounding the diagnosis of autism in children,” 2021, [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8654688/>.
- [4] S. Bose and P. Seth, “Screening of autism spectrum disorder using machine learning approach in accordance with dsm-5,” in *2023 7th International Conference on Electronics, Materials Engineering & Nano-Technology (IEMENTech)*, 2023, [Online]. Available: <https://doi.org/10.1109/IEMENTech60402.2023.10423494>.
- [5] C. Clairmont, J. Wang, S. Tariq, H. T. Sherman, M. Zhao, and X.-J. Kong, “The value of brain imaging and electrophysiological testing for early screening of autism spectrum disorder: A systematic review,” 2022, [Online]. Available: <https://doi.org/10.3389/fnins.2021.812946>.
- [6] M. Melinda, P. D. Purnamasari, F. Fahmi, E. P. Sinulingga, M. Mulyadi, Y. Away, Y. Yunidar, and F. H. Juwono, “A comprehensive eeg dataset and performance assessment for autism spectrum disorder,” 2025, [Online]. Available: <https://doi.org/10.1038/s41598-025-34981>.
- [7] O. Gurau, W. J. Bosl, and C. R. Newton, “How useful is electroencephalography in the diagnosis of autism spectrum disorders and the delineation of subtypes: A systematic review,” 2017, [Online]. Available: <https://doi.org/10.3389/fpsyt.2017.00121>.

- [8] P. D. Purnamasari, A. A. P. Ratna, M. Melinda, F. Fahmi, F. H. Juwono, Y. Away, N. Li, R. Yan, and S. Gazali, "Enhancing clinical transparency in asd detection: An eeg analysis approach with mrmr and xgboost," 2025, under review.
- [9] R. Lyu, "Deep learning approaches for eeg-based healthcare applications: A comprehensive review," 2026, [Online]. Available: <https://doi.org/10.3389/fnhum.2025.1689073>.
- [10] M. Tabejamaat, H. Mohammadzade, F. Negin, and F. Bremond, "Eeg classification with limited data: A deep clustering approach," 2025, [Online]. Available: <https://doi.org/10.1016/j.patcog.2024.110934>.
- [11] X. Jiang, G. B. Bian, and Z. Tian, "Removal of artifacts from eeg signals: A review," 2019, [Online]. Available: <https://doi.org/10.3390/s19050987>.
- [12] C. Rommel, J. Paillard, T. Moreau, and A. Gramfort, "Data augmentation for learning predictive models on eeg: A systematic comparison," 2022, [Online]. Available: <https://doi.org/10.48550/arXiv.2206.14483>.
- [13] S. Savadi, "A comprehensive review of feature extraction and classification techniques in eeg signal analysis," 2025, [Online]. Available: <http://www.ijceronline.com/>.
- [14] G. Bao, B. Yan, L. Tong, J. Shu, L. Wang, K. Yang, and Y. Zeng, "Data augmentation for eeg-based emotion recognition using generative adversarial networks," 2021, [Online]. Available: <https://doi.org/10.3389/fncom.2021.723843>.
- [15] K. G. Hartmann, R. T. Schirrmeister, and T. Ball, "Eeg-gan: Generative adversarial networks for electroencephalographic (eeg) brain signals," 2018, [Online]. Available: <https://doi.org/10.48550/arXiv.1806.01875>.
- [16] W. Kong and X. Jin, "Basics of eeg signals," in *Brain Fingerprint Identification*. Springer, Singapore, 2025, [Online]. Available: [https://doi.org/10.1007/978-981-96-4512-1\\_2](https://doi.org/10.1007/978-981-96-4512-1_2).

- [17] S. Beniczky and D. L. Schomer, "Electroencephalography: Basic biophysical and technological aspects important for clinical applications," 2020, [Online]. Available: <https://doi.org/10.1684/epd.2020.1217>.
- [18] E. Ignatious, S. Azam, M. Jonkman, and F. D. Boer, "Frequency and time domain analysis of eeg-based auditory evoked potentials to detect binaural hearing in noise," 2023, [Online]. Available: <https://doi.org/10.3390/jcm12134487>.
- [19] H. Peng, F. Long, and C. Ding, "Feature selection based on mutual information criteria of max-dependency, max-relevance, and min-redundancy," 2005, [Online]. Available: <https://doi.org/10.1109/TPAMI.2005.159>.
- [20] B. Gholami, M. H. Behboudi, M. G. Mahjani, and A. Khadem, "Diagnosis of sleep apnea syndrome from eeg signals using different entropy measures," in *2021 7th International Conference on Signal Processing and Intelligent Systems (ICSPIS)*, 2021, [Online]. Available: <https://doi.org/10.1109/ICSPIS54653.2021.9729367>.
- [21] C.-T. Hsieh and Y.-H. Huang, "Tsmrmr feature selection method for detecting sleep apnea episodes based on eeg signals," in *2024 IEEE-EMBS Conference on Biomedical Engineering and Sciences (IECBES)*, 2024, [Online]. Available: <https://doi.org/10.1109/IECBES61011.2024.10991314>.
- [22] J. Wang, J. Barstein, L. E. Ethridge, M. W. Mosconi, Y. Takarae, and J. A. Sweeney, "Resting-state eeg abnormalities in autism spectrum disorders," 2013, [Online]. Available: <https://doi.org/10.1186/1866-1955-5-24>.
- [23] A. D. Giacomo, R. Palmieri, E. F. Russo, I. Pizzolorusso, R. Brandi, F. Magistro, M. G. D. Cesare, S. Quattrocelli, D. Cardone, D. Perpetuini, and A. Merla, "Machine learning and deep learning applied to eeg and fnirs for early autism spectrum disorder diagnosis: A systematic review," 2026, [Online]. Available: <https://doi.org/10.3389/fpsy.2026.1668914>.
- [24] L. B. Ribeiro and M. da Silva Filho, "Systematic review on eeg analysis to diagnose and treat autism by evaluating functional connectivity and spectral power," 2023, [Online]. Available: <https://doi.org/10.2147/NDT.S394363>.



- [25] F. J. Ramírez-Arias, E. E. García-Guerrero, E. Tlelo-Cuautle, J. M. Colores-Vargas, E. García-Canseco, O. R. López-Bonilla, G. M. Galindo-Aldana, and E. Inzunza-González, “Evaluation of machine learning algorithms for classification of eeg signals,” 2022, [Online]. Available: <https://doi.org/10.3390/technologies10040079>.
- [26] L. Xu, M. Xu, Y. Ke, X. An, S. Liu, and D. Ming, “Cross-dataset variability problem in eeg decoding with deep learning,” 2020, [Online]. Available: <https://doi.org/10.3389/fnhum.2020.00103>.
- [27] Y. Yao, X. Wang, X. Hao, H. Sun, R. Dong, and Y. Li, “Trans-cvae-gan: Transformer-based cvae-gan for high-fidelity eeg signal generation,” 2025, [Online]. Available: <https://doi.org/10.3390/bioengineering12101028>.
- [28] D. P. Kingma and M. Welling, “Auto-encoding variational bayes,” 2014, [Online]. Available: <https://doi.org/10.48550/arXiv.1312.6114>.
- [29] C. Ahuja and D. Sethia, “Harnessing few-shot learning for eeg signal classification: A survey of state-of-the-art techniques and future directions,” 2024, [Online]. Available: <https://doi.org/10.3389/fnhum.2024.1421922>.
- [30] A. Vasarkar, “Eeg data augmentation using variational autoencoder,” [Online]. Available: <https://github.com/arkanivasarkar/EEG-Data-Augmentation-using-Variational-Autoencoder>.
- [31] D. T. Kertapati, “Anak-anak luar biasa,” 2023, [Online]. Available: [https://kemkes.go.id/app\\_asset/file\\_content\\_download/171090786265fa61d67ff2e9.83516065.pdf](https://kemkes.go.id/app_asset/file_content_download/171090786265fa61d67ff2e9.83516065.pdf).
- [32] “Burden and inequality of autism spectrum disorders in global, east asian, and south-east asian regions, 1990–2021,” 2021, [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/40819035/>.
- [33] A. Adhikary, “Identification of novel diagnostic neuroimaging biomarkers for autism spectrum disorder through convolutional neural network-based analysis of functional, structural, and diffusion tensor imaging data towards enhanced autism diagnosis,” 2024, [Online]. Available: <https://doi.org/10.48550/arXiv.2305.18841>.

- [34] S. Saha and M. Baumert, “Intra- and inter-subject variability in eeg-based sensorimotor brain computer interface: A review,” 2020, [Online]. Available: <https://doi.org/10.3389/fncom.2019.00087>.
- [35] G. M. Rojas, C. Alvarez, C. E. Montoya, M. de la Iglesia-Vayá, J. E. Cisternas, and M. Gálvez, “Study of resting-state functional connectivity networks using eeg electrodes position as seed,” 2018, [Online]. Available: <https://doi.org/10.3389/fnins.2018.00235>.