



UNIVERSITAS INDONESIA

**IMPLEMENTASI AUGMENTASI DATA BERBASIS VARIATIONAL
AUTOENCODER UNTUK KLASIFIKASI AUTISM SPECTRUM
DISORDER MENGGUNAKAN SINYAL EEG**

SKRIPSI

**WENDY DHARMAWAN
2206059591**

**FAKULTAS TEKNIK
PROGRAM STUDI S1 TEKNIK KOMPUTER
DEPOK
2026**



UNIVERSITAS INDONESIA

**IMPLEMENTASI AUGMENTASI DATA BERBASIS VARIATIONAL
AUTOENCODER UNTUK KLASIFIKASI AUTISM SPECTRUM
DISORDER MENGGUNAKAN SINYAL EEG**

SKRIPSI

**Diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Teknik**

**WENDY DHARMAWAN
2206059591**

**FAKULTAS TEKNIK
PROGRAM STUDI S1 TEKNIK KOMPUTER
DEPOK
JUNI 2026**

HALAMAN PERNYATAAN ORISINALITAS

**Skripsi ini adalah hasil karya saya sendiri,
dan semua sumber baik yang dikutip maupun dirujuk
telah saya nyatakan dengan benar.**

Nama : Wendy Dharmawan

NPM : 2206059591

Tanda Tangan :

Tanggal : 25 Juni 2026

HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL

Saya menyatakan bahwa dalam penyusunan Tugas Akhir ini, saya menggunakan teknologi Kecerdasan Buatan dengan platform Gemini dan ChatGPT untuk tujuan pemeriksaan dan perbaikan tata bahasa dan saya bertanggung jawab penuh atas keakuratan, orisinalitas, dan integritas seluruh isi Tugas Akhir ini.

Nama : Wendy Dharmawan

NPM : 2206059591

Tanda Tangan :

Tanggal : 25 Juni 2026

HALAMAN PENGESAHAN

Skripsi ini diajukan oleh :
Nama : Wendy Dharmawan
NPM : 2206059591
Program Studi : S1 Teknik Komputer
Judul Skripsi : Implementasi Augmentasi Data Berbasis Variational
Autoencoder untuk Klasifikasi Autism Spectrum Dis-
order Menggunakan Sinyal EEG

Telah berhasil dipertahankan di hadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Sarjana Teknik pada Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.

DEWAN PENGUJI

Pembimbing : Dr. Prima Dewi Purnamasari, S.T., M.Sc.

Penguji : Dr. Eng. Mia Rizkinia, S.T, M.T.

Penguji : Prof. Dr. Ir. Anak Agung Putri Ratna, M.Eng

()
()
()

Ditetapkan di : Depok

Tanggal : 25 Juni 2026

KATA PENGANTAR

Puji dan syukur Penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan rahmat-Nya lah Penulis dapat menyelesaikan Skripsi dengan judul “Implementasi Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG”. Skripsi ini Penulis laksanakan sebagai salah satu syarat dalam memperoleh gelar Sarjana Teknik pada program studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.

Penulis juga ingin menyampaikan rasa terima kasihnya kepada:

1. Dr. Prima Dewi Purnamasari, S.T., M.Sc., selaku Dosen Pembimbing Skripsi Penulis dan Ketua Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.
2. Dr. Muhammad Salman, ST., M.IT., selaku Ketua Departemen Teknik Elektro, Fakultas Teknik, Universitas Indonesia.
3. Prof. Dr.-Ing. Kalamullah Ramli, selaku Pembimbing Akademis Penulis.
4. Dr. Eng. Mia Rizkinia, S.T, M.T.dan Prof. Dr. Ir. Anak Agung Putri Ratna, M.Engselaku Dosen Penguji Skripsi Penulis.
5. Segenap dosen Departemen Teknik Elektro atas semua ilmu yang diberikan kepada Penulis.
6. Orang tua yang selalu memberikan dukungan serta doa, sehingga penulisan Skripsi dapat diselesaikan secara baik.
7. Teman-teman Teknik Komputer, selaku rekan penulis yang selalu membantu serta memberikan dukungan moril sepanjang proses kuliah serta penulisan proposal skripsi.

Penulis menyadari dan menerima bahwa Skripsi yang dibentuk ini masih jauh dari sempurna dan masih memiliki berbagai kekurangan serta kesalahan baik dari segi ilmu maupun pemahaman. Oleh karena itu, Penulis mengharapkan segala kritik dan saran yang diberikan agar ke depannya Penulis dapat menjadi lebih baik.

25 Juni 2026

Wendy Dharmawan

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas akademik Universitas Indonesia, saya yang bertanda tangan di bawah ini:

Nama : Wendy Dharmawan
NPM : 2206059591
Program Studi : S1 Teknik Komputer
Fakultas : Teknik
Jenis Karya : Skripsi

demikian pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Indonesia **Hak Bebas Royalti Noneksklusif** (*Non-exclusive Royalty Free Right*) atas karya ilmiah saya yang berjudul:

Implementasi Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi
Autism Spectrum Disorder Menggunakan Sinyal EEG

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Universitas Indonesia berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Depok
Pada tanggal : 25 Juni 2026
Yang menyatakan

(Wendy Dharmawan)
vii

ABSTRAK

Nama : Wendy Dharmawan
Program Studi : S1 Teknik Komputer
Judul : Implementasi Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG
Pembimbing : Dr. Prima Dewi Purnamasari, S.T., M.Sc.

Autism Spectrum Disorder (ASD) merupakan gangguan perkembangan saraf yang ditandai oleh hambatan dalam komunikasi sosial dan perilaku repetitif. Berbagai penelitian telah memanfaatkan sinyal electroencephalography (EEG) untuk membantu proses klasifikasi ASD, namun keterbatasan jumlah data sering menjadi kendala dalam pengembangan model pembelajaran mesin yang andal. Penelitian ini bertujuan untuk menganalisis efektivitas augmentasi data berbasis Variational Autoencoder (VAE) dalam meningkatkan performa klasifikasi ASD menggunakan sinyal EEG. Penelitian dilakukan dengan membangun model VAE untuk menghasilkan data EEG sintetis yang kemudian digunakan sebagai data augmentasi pada proses klasifikasi. Kualitas data sintetis dievaluasi menggunakan metrik Fréchet Inception Distance (FID), Sliced Wasserstein Distance (SWD), dan normalisasi Euclidean Distance (ED), sedangkan evaluasi klasifikasi dilakukan menggunakan model Deep Neural Network (DNN) dan Extreme Gradient Boosting (XGBoost). Hasil eksperimen menunjukkan bahwa data sintetis yang dihasilkan mampu mempertahankan karakteristik utama sinyal EEG serta memberikan peningkatan performa klasifikasi. Secara signifikan, penggunaan data sintetis pada model XGBoost meningkatkan akurasi dari 97,44% menjadi 99,51%, sensitivitas dari 97,24% menjadi 98,79%, spesifisitas dari 97,86% menjadi 99,86%, dan presisi dari 97,51% menjadi 99,70%. Temuan ini menunjukkan bahwa augmentasi berbasis VAE mampu memperkaya variasi data *training* dan meningkatkan kemampuan model dalam membedakan kelas ASD dan non-ASD. Penelitian ini menyimpulkan bahwa VAE merupakan pendekatan yang menjanjikan untuk mengatasi keterbatasan data EEG dan meningkatkan performa sistem klasifikasi ASD berbasis EEG.

Kata kunci: Autism Spectrum Disorder, Electroencephalography, Augmentasi Data, Variational Autoencoder, Deep Neural Network, XGBoost.

ABSTRACT

Name : Wendy Dharmawan
Study Program : S1 Teknik Komputer
Title : Analysis of Data Augmentation Using Variational Autoencoder for EEG-Based Autism Spectrum Disorder Classification
Supervisor : Dr. Prima Dewi Purnamasari, S.T., M.Sc.

Autism Spectrum Disorder (ASD) is a neurodevelopmental disorder characterized by impairments in social communication and repetitive behavioral patterns. Numerous studies have utilized electroencephalography (EEG) signals to support ASD classification; however, the limited availability of EEG data remains a major challenge in developing reliable machine learning models. This study aims to investigate the effectiveness of Variational Autoencoder (VAE)-based data augmentation in improving ASD classification performance using EEG signals. A VAE model was developed to generate synthetic EEG data, which were subsequently used as augmented samples during the classification process. The quality of the generated synthetic data was evaluated using Fréchet Inception Distance (FID), Sliced Wasserstein Distance (SWD), and normalized Euclidean Distance (ED), while classification performance was assessed using Deep Neural Network (DNN) and Extreme Gradient Boosting (XGBoost) models. Experimental results demonstrate that the synthetic data generated by the VAE preserve the main characteristics of the original EEG signals while improving classification performance. In particular, the use of synthetic data in the XGBoost model increased accuracy from 97.44% to 99.51%, sensitivity from 97.24% to 98.79%, specificity from 97.86% to 99.86%, and precision from 97.51% to 99.70%. These findings indicate that VAE-based augmentation can enrich training data diversity and enhance the model's ability to distinguish between ASD and non-ASD classes. This study concludes that VAE is a promising approach for addressing EEG data limitations and improving the performance of EEG-based ASD classification systems.

Keywords: Autism Spectrum Disorder, Electroencephalography, Data Augmentation, Variational Autoencoder, Deep Neural Network, XGBoost.

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PERNYATAAN ORISINALITAS	ii
HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL	iii
HALAMAN PENGESAHAN	iv
KATA PENGANTAR	v
HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI	vii
ABSTRAK	viii
ABSTRACT	ix
DAFTAR ISI	x
DAFTAR TABEL	xiii
DAFTAR GAMBAR	xiv
DAFTAR ALGORITMA	xvii
DAFTAR SINGKATAN	xvii
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Manfaat Penelitian	4
1.5 Ruang Lingkup Penelitian	5
1.6 Sistematika Penulisan	5
2 TINJAUAN PUSTAKA	7
2.1 Landasan Teori	7
2.1.1 Sinyal EEG	7
2.1.2 Feature Selection mRMR	12
2.1.3 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG	14
2.1.4 Augmentasi Data EEG	15
2.1.5 Model Generatif untuk Augmentasi Data	18
2.1.6 Variational Auto Encoder	20
2.1.7 Metode Evaluasi Data EEG Sintetis Model Generatif	21
2.2 Penelitian Terdahulu	22

2.2.1	Klasifikasi ASD Berbasis EEG Menggunakan Kombinasi mRMR dan XGBoost	23
2.2.2	Metode Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder	23
2.2.3	Dataset EEG yang Digunakan dalam Penelitian	24
2.3	Fokus pada Celah Penelitian	25
3	PERANCANGAN DAN IMPLEMENTASI SISTEM	27
3.1	Analisis Kebutuhan Sistem VAE untuk Augmentasi EEG	27
3.1.1	Tujuan Sistem	28
3.1.2	Kebutuhan Sistem	28
3.1.3	Batasan Sistem	28
3.2	Perancangan Arsitektur Sistem Augmentasi dan Klasifikasi EEG	29
3.2.1	Pra-Pemrosesan Dataset	30
3.2.2	Arsitektur Model VAE untuk Augmentasi Data	32
3.2.3	Arsitektur Model Klasifikasi	35
3.3	Detail Implementasi dan Teknologi pada Model Augmentasi dan Klasifikasi EEG	37
3.3.1	Teknologi dan Library	38
3.3.2	Implementasi Model Generatif Variational Autoencoder (VAE)	38
3.3.2.1	Arsitektur <i>Layer Encoder</i>	39
3.3.2.2	<i>Reparameterization Layer</i>	41
3.3.2.3	Arsitektur <i>Layer Decoder</i>	42
3.3.2.4	<i>Loss Function</i> dan Proses Training	44
3.3.2.5	Generasi Data Sintetis	46
3.3.3	Implementasi Model Klasifikasi	48
3.3.3.1	Integrasi Data Sintetis pada Model Klasifikasi	48
3.3.3.2	<i>Minimum Redundancy Maximum Relevance (mRMR)</i>	49
3.3.3.3	Model <i>XGBoost</i>	50
3.3.3.4	Model <i>Deep Neural Network</i>	50
4	EKSPERIMEN DAN ANALISIS	52
4.1	Lingkungan Training	52
4.1.1	Spesifikasi Perangkat Keras	52
4.1.2	Spesifikasi Perangkat Lunak	53
4.2	Standarisasi Pengujian Eksperimen	54
4.2.1	Konfigurasi Eksperimen	54
4.2.1.1	Konfigurasi Eksperimen Augmentasi	54
4.2.1.2	Konfigurasi Eksperimen Klasifikasi	55
4.2.2	Metrik Evaluasi	56
4.2.2.1	Metrik Evaluasi Eksperimen Augmentasi	56
4.2.2.2	Metrik Evaluasi Eksperimen Klasifikasi	57
4.3	Eksperimen dan Analisis	57

4.3.1	Eksperimen 1: Evaluasi Kemampuan Model VAE dalam Generasi Sinyal EEG Sintetis	58
4.3.2	Eksperimen 2: Evaluasi Model Klasifikasi Dengan Hanya Menggunakan Sinyal EEG Asli	66
4.3.3	Eksperimen 3: Evaluasi Model Klasifikasi Dengan Menggunakan Kombinasi Sinyal EEG Asli dan Sinyal EEG Sintetis	68
4.4	Diskusi	71
4.4.1	Analisis Komparatif terhadap Penelitian Terdahulu	71
4.4.2	Implikasi dan Arah Pengembangan Penelitian	73
5	PENUTUP	75
5.1	Kesimpulan	75
5.2	Saran	76
	DAFTAR REFERENSI	78

DAFTAR TABEL

Tabel 2.1	Pita frekuensi EEG dan karakteristiknya. Sumber: Savadi [?]]	9
Tabel 2.2	Metode augmentasi pada data <i>time-series</i> . Sumber: Rongali et al. (2024)	17
Tabel 2.3	Perbandingan karakteristik, kelebihan, dan keterbatasan beberapa model generatif utama. Sumber: Singh et al. (2025) .	19
Tabel 2.4	Metrik evaluasi data sintetis EEG. Sumber: Hartmann et al. (2018)	22
Tabel 3.1	Arsitektur <i>encoder VAE</i>	39
Tabel 3.2	Arsitektur <i>decoder VAE</i>	43
Tabel 3.3	Konfigurasi hyperparameter <i>XGBoost</i>	50
Tabel 4.1	Spesifikasi Perangkat Keras Eksperimen	52
Tabel 4.2	Spesifikasi Lingkungan Perangkat Lunak	53
Tabel 4.3	Hasil Evaluasi Kualitas Data Sintetis EEG pada Kelas Normal	59
Tabel 4.4	Hasil Evaluasi Kualitas Data Sintetis EEG pada Kelas ASD .	60
Tabel 4.5	Perbandingan fitur statistik data EEG asli antara kelas Normal dan ASD	64
Tabel 4.6	Perbandingan fitur statistik data EEG sintetis antara kelas Normal dan ASD	64
Tabel 4.7	Perbandingan fitur statistik data EEG asli dan sintetis	65
Tabel 4.8	Perbandingan performa model DNN dan XGBoost dengan data EEG asli	67
Tabel 4.9	Perbandingan performa model DNN dan XGBoost dengan kombinasi data EEG asli dan sintetis	69

DAFTAR GAMBAR

Gambar 2.1	Sistem Internasional 10–20 untuk penempatan elektroda EEG	8
Gambar 2.2	Pita frekuensi EEG pada rentang frekuensi tinggi dan rendah. Sumber: Kumar et al. (2022)	10
Gambar 2.3	Ilustrasi pengaruh berbagai jenis filter terhadap sinyal EEG. Sumber: EduRev, Filter Characteristics of Linear Systems.	11
Gambar 2.4	Bentuk-bentuk artefak pada sinyal EEG. Sumber: Kanoga dan Mitsukura (2017)	11
Gambar 2.5	Ilustrasi <i>U-shaped spectral profile</i> yang ditemukan pada pita frekuensi penderita ASD. Sumber: Wang et al. (2013)	14
Gambar 2.6	Ilustrasi umum pipeline klasifikasi ASD berbasis sinyal EEG. Sumber: Mortaga et al. (2021)	15
Gambar 2.7	Ilustrasi metode augmentasi pada data <i>time-series</i> . Sumber: Rongali et al. (2024)	16
Gambar 2.8	Arsitektur umum <i>Variational Autoencoder</i> (VAE). Sumber: Montes (2025)	20
Gambar 3.1	Pipeline klasifikasi EEG dengan augmentasi data berbasis VAE	30
Gambar 3.2	Diagram aliran proses prapemrosesan sistem	31
Gambar 3.3	Rancangan arsitektur <i>Variational Autoencoder</i> (VAE) untuk augmentasi data EEG	34
Gambar 3.4	Pipeline model klasifikasi	36
Gambar 3.5	Arsitektur <i>layer encoder</i> pada model VAE	39
Gambar 3.6	Arsitektur reparameterization layer pada model VAE	41
Gambar 3.7	Arsitektur <i>layer decoder</i> pada model VAE	42
Gambar 3.8	Diagram aliran generasi data sintetis	47
Gambar 3.9	Pipeline integrasi data sintetis pada proses klasifikasi	49
Gambar 3.10	Arsitektur model <i>Deep Neural Network</i> (DNN) yang digunakan dalam penelitian	51
Gambar 4.1	Visualisasi Domain Waktu Sinyal EEG Sintetis Label Normal	61
Gambar 4.2	Visualisasi Domain Waktu Sinyal EEG Sintetis Label ASD	61
Gambar 4.3	Visualisasi Domain Frekuensi Sinyal EEG Sintetis Label Normal	62
Gambar 4.4	Visualisasi Domain Frekuensi Sinyal EEG Sintetis Label ASD	62

DAFTAR ALGORITMA

2.1	Algoritma mRMR untuk seleksi fitur.	13
3.1	Algoritma proses konvolusi pada encoder model VAE	40
3.2	Algoritma ekspansi representasi laten pada decoder model VAE.	43
3.3	Algoritma proses rekonstruksi sinyal pada decoder model VAE.	43

DAFTAR PERSAMAAN

2.1 Optimasi Informasi Mutu	12
2.2 Evidence Lower Bound (ELBO)	20
2.3 Metode Reparameterization	21
3.1 Implementasi Reparameterization Trick	42

DAFTAR SINGKATAN

ASD	<i>Autism Spectrum Disorder</i>
BCI	<i>Brain–Computer Interface</i>
CNN	<i>Convolutional Neural Network</i>
DWT	<i>Discrete Wavelet Transform</i>
EEG	<i>Electroencephalography</i>
ELBO	<i>Evidence Lower Bound</i>
EMG	<i>Electromyogram</i>
EOG	<i>Electrooculogram</i>
FFT	<i>Fast Fourier Transform</i>
GAN	<i>Generative Adversarial Network</i>
ICA	<i>Independent Component Analysis</i>
kNN	<i>k-Nearest Neighbor</i>
KL	<i>Kullback–Leibler</i>
mRMR	<i>Minimum Redundancy Maximum Relevance</i>
PSD	<i>Power Spectral Density</i>
SNR	<i>Signal-to-Noise Ratio</i>
SVM	<i>Support Vector Machine</i>
VAE	<i>Variational Autoencoder</i>

DAFTAR ISTILAH

Alpha	Pita frekuensi alpha: komponen gelombang EEG pada rentang 8–13 Hz yang dominan pada wilayah oksipital saat kondisi rileks dengan mata tertutup.
Artefak	Komponen sinyal non-neural pada rekaman EEG yang berasal dari aktivitas fisiologis (kedipan mata, gerakan otot) maupun gangguan eksternal seperti interferensi perangkat elektronik.
Augmentasi	Augmentasi data (<i>data augmentation</i>): teknik penambahan variasi data pelatihan secara artifisial untuk meningkatkan performa model dan mengurangi <i>overfitting</i> .
ASD	Autism Spectrum Disorder: gangguan perkembangan saraf yang ditandai hambatan komunikasi, interaksi sosial, serta perilaku repetitif.
Beta	Pita frekuensi beta: komponen EEG pada rentang 13–30 Hz yang berkaitan dengan aktivitas kognitif aktif, konsentrasi, dan pemecahan masalah.
Decoder	Komponen model generatif yang memetakan variabel laten untuk merekonstruksi sinyal EEG sintetis.
Delta	Pita frekuensi delta: rentang 0.5–4 Hz yang dominan pada kondisi tidur nyenyak dan proses pemulihan fisiologis.
DNN	Deep Neural Network: jaringan saraf tiruan dalam dengan beberapa hidden layer untuk mempelajari pola kompleks.
EEG	Electroencephalography: metode perekaman aktivitas listrik otak secara non-invasif menggunakan elektroda pada kulit kepala.
ELBO	Evidence Lower Bound: fungsi objektif pada VAE yang terdiri dari reconstruction loss dan KL divergence.
Encoder	Encoder: komponen model yang memetakan data input ke ruang laten berdimensi rendah berbasis distribusi probabilistik.
FFT	Fast Fourier Transform: metode transformasi sinyal dari domain waktu ke domain frekuensi.
FID	Fréchet Inception Distance: metrik untuk mengukur kesamaan distribusi antara data asli dan data sintetis.
Gamma	Pita frekuensi gamma: sinyal EEG dengan frekuensi $> 30\text{ Hz}$ yang terkait proses kognitif tingkat tinggi.
Generalisasi	Kemampuan model mempertahankan performa pada data yang tidak terlihat selama pelatihan.
Hyperparameter	Parameter yang ditentukan sebelum pelatihan seperti learning rate atau jumlah estimators.
ICA	Independent Component Analysis: metode pemisahan sumber sinyal untuk mengurangi artefak EEG.
KL	Kullback–Leibler Divergence: regularisasi pada VAE untuk menjaga distribusi laten mendekati distribusi normal.

Latent	Latent Space: ruang representasi berdimensi rendah yang menangkap struktur penting data.
mRMR	Minimum Redundancy Maximum Relevance: metode seleksi fitur berbasis relevansi maksimum dan redundansi minimum.
Overfitting	Kondisi ketika model terlalu menyesuaikan data pelatihan sehingga menurunkan performa pada data baru.
PSD	Power Spectral Density: distribusi energi sinyal terhadap frekuensi.
Preprocessing	Pra-pemrosesan: tahap persiapan data EEG seperti filtering, normalisasi, dan segmentasi.
SWD	Sliced Wasserstein Distance: metrik untuk mengukur kesamaan distribusi data melalui proyeksi satu dimensi.
Theta	Pita frekuensi theta: rentang 4–8 Hz yang terkait memori dan kondisi mengantuk.
U-shaped	U-shaped spectral profile: pola spektral dengan peningkatan daya pada frekuensi rendah dan tinggi serta penurunan pada frekuensi menengah.
VAE	Variational Autoencoder: model generatif berbasis encoder-decoder untuk mempelajari ruang laten probabilistik.
XGBoost	Extreme Gradient Boosting: algoritma ensemble tree boosting untuk klasifikasi dan regresi yang efisien.

BAB 1

PENDAHULUAN

Autism Spectrum Disorder (ASD) merupakan gangguan neurologis yang memengaruhi komunikasi, interaksi sosial, dan perilaku individu, sehingga proses identifikasi dini memiliki peranan penting dalam penanganannya. Analisis sinyal electroencephalography (EEG) menggunakan metode machine learning mulai banyak diteliti sebagai pendekatan dalam proses klasifikasi ASD secara lebih objektif. Meskipun demikian, pengembangan model klasifikasi berbasis EEG masih menghadapi tantangan berupa keterbatasan dataset EEG yang tersedia dan tingginya variabilitas sinyal antar individu maupun antar sesi perekaman. Karakteristik tersebut menyebabkan terhambatnya proses pengembangan model klasifikasi EEG yang mampu memberikan performa secara konsisten pada data dengan karakteristik yang berbeda. Salah satu pendekatan yang mulai banyak digunakan untuk mengatasi permasalahan tersebut adalah teknik *data augmentation*, yaitu proses penambahan variasi data *training* secara artifisial, sehingga diharapkan dapat meningkatkan performa dan kemampuan generalisasi model.

Bab ini akan dimulai dengan penjelasan Latar Belakang yang memberikan konteks penting terkait penelitian ini, diikuti oleh Rumusan Masalah dan Tujuan Penelitian yang merinci fokus utama studi. Selanjutnya, akan dibahas Manfaat Penelitian dan Ruang Lingkup Penelitian untuk menjelaskan kontribusi serta batasan penelitian ini. Terakhir, Sistematika Penulisan akan menguraikan struktur keseluruhan laporan penelitian.

1.1 Latar Belakang

Autism Spectrum Disorder (ASD) merupakan gangguan neurologis yang ditandai oleh hambatan dalam komunikasi dan interaksi sosial, serta pola perilaku yang terbatas dan berulang [1], [2]. Identifikasi dan intervensi dini menjadi faktor penting dalam membantu perkembangan individu dengan ASD, namun proses diagnosis masih menghadapi berbagai tantangan karena karakteristik gejala yang heterogen dan sering kali menyerupai gangguan perkembangan lainnya [3] [4]. Kondisi tersebut mendorong berkembangnya

pendekatan diagnosis berbasis biomarker yang lebih objektif dan konsisten.

Salah satu pendekatan yang banyak diteliti adalah analisis electroencephalography (EEG) menggunakan metode machine learning, dimana dalam metode ini model dilatih menggunakan data dari subjek yang telah memperoleh diagnosis klinis berdasarkan kriteria diagnostik yang digunakan oleh penyedia dataset. Model kemudian mempelajari pola EEG yang membedakan kelompok ASD dan kelompok kontrol berdasarkan label tersebut, sehingga karakteristik yang dipelajari diasumsikan berkaitan dengan ASD sesuai dengan definisi pada dataset. Oleh karena itu, model diasumsikan mempelajari karakteristik yang berkaitan dengan ASD sesuai definisi pada dataset. Dibandingkan dengan metode lainnya, EEG memiliki keunggulan karena bersifat non-invasif, relatif lebih murah, dan memiliki resolusi temporal yang tinggi [5] [6].

Berbagai penelitian menunjukkan bahwa model machine learning mampu mengidentifikasi pola aktivitas otak yang berkaitan dengan ASD melalui sinyal EEG dengan performa klasifikasi yang cukup baik [7]. Penelitian rujukan [8] mengusulkan pendekatan klasifikasi ASD berbasis EEG menggunakan kombinasi seleksi fitur minimum Redundancy Maximum Relevance (mRMR) dan algoritma XGBoost yang menunjukkan performa klasifikasi yang baik dan konsisten.

Meskipun demikian, pengembangan model klasifikasi EEG masih menghadapi berbagai tantangan, terutama terkait keterbatasan dataset EEG yang tersedia secara publik dan telah memiliki label klinis [9]. Kualitas dataset menjadi faktor yang sangat penting karena model klasifikasi EEG mempelajari pola sinyal berdasarkan label klinis yang diberikan pada dataset. Oleh karena itu, kualitas proses akuisisi, pelabelan, dan representativitas data akan secara langsung memengaruhi karakteristik yang dipelajari model serta validitas pola yang diasosiasikan dengan ASD.

Namun, proses akuisisi data EEG umumnya membutuhkan biaya, waktu, serta keterlibatan tenaga ahli, sehingga jumlah data yang tersedia sering kali terbatas. Selain itu, data EEG memiliki variabilitas yang tinggi akibat perbedaan kondisi subjek, konfigurasi perekaman, serta keberadaan *noise* dan artefak yang dapat memengaruhi kualitas sinyal [10]. Kondisi tersebut menyulitkan pengembangan model yang mampu mempelajari pola yang representatif dan melakukan generalisasi dengan baik terhadap data baru [11].

Salah satu pendekatan yang mulai banyak diteliti untuk mengatasi keterbatasan

data EEG adalah penggunaan teknik *data augmentation*. Teknik ini bertujuan untuk meningkatkan jumlah dan keragaman data *training* secara artifisial tanpa memerlukan proses perekaman EEG tambahan. Beberapa penelitian menunjukkan bahwa penerapan *data augmentation* pada data EEG berpotensi membantu meningkatkan performa model klasifikasi serta mengurangi risiko *overfitting* pada kondisi dataset yang terbatas [12]. Namun, data sintetis yang dihasilkan perlu tetap mampu merepresentasikan karakteristik penting dari data EEG asli agar dapat memberikan manfaat terhadap performa dan kemampuan generalisasi model klasifikasi.

Penerapan augmentasi pada data EEG memiliki tantangan tersendiri karena sinyal EEG merupakan data *time series* multikanal yang bersifat non-stasioner dan memiliki rasio *signal-to-noise* yang rendah [13]. Berbeda dengan berbagai jenis data multimedia lain seperti citra, audio, atau video yang umumnya memiliki pola representasi yang lebih stabil, manipulasi pada data EEG perlu dilakukan secara hati-hati karena perubahan pada sinyal dapat memengaruhi representasi aktivitas otak yang dianalisis.

Oleh karena itu, diperlukan pendekatan augmentasi yang mampu menghasilkan data EEG sintetis dengan tetap mempertahankan karakteristik penting dari data asli. Selain meningkatkan jumlah data, pendekatan tersebut juga diharapkan dapat menghasilkan variasi data yang representatif sehingga mampu mendukung peningkatan performa dan kemampuan generalisasi model klasifikasi EEG. Namun, kualitas data sintetis yang dihasilkan serta pengaruhnya terhadap performa klasifikasi masih perlu dikaji lebih lanjut, khususnya dalam konteks klasifikasi Autism Spectrum Disorder (ASD) berbasis EEG.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, permasalahan utama dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana menghasilkan data EEG sintetis yang mampu merepresentasikan karakteristik data EEG asli untuk mengatasi keterbatasan jumlah dan variasi data?
2. Sejauh mana data sintetis yang dihasilkan mampu mempertahankan karakteristik dan distribusi sinyal EEG asli?

3. Bagaimana pengaruh penggunaan data hasil augmentasi terhadap performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD)?

1.3 Tujuan Penelitian

Selaras dengan rumusan masalah yang telah diuraikan, tujuan dari penelitian ini mencakup sebagai berikut:

1. Mengembangkan pendekatan yang sesuai untuk menghasilkan data EEG sintetis yang representatif terhadap data EEG asli.
2. Mengevaluasi sejauh mana data sintetis yang dihasilkan mampu mempertahankan karakteristik dan distribusi sinyal EEG asli.
3. Menganalisis pengaruh penggunaan data hasil augmentasi terhadap performa serta kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD).

1.4 Manfaat Penelitian

Berdasarkan latar belakang, rumusan masalah, dan tujuan penelitian yang telah diuraikan, penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Bagi Peneliti dan Pengembangan Metode:

Penelitian ini diharapkan dapat menjadi referensi dalam pengembangan dan pemanfaatan teknik *data augmentation* pada sinyal EEG, serta membuka peluang bagi pengembangan metode klasifikasi dan diagnosis di masa depan yang mampu memanfaatkan data dalam jumlah yang lebih besar dan beragam, sehingga meningkatkan robustness dan kemampuan generalisasi model.

2. Bagi Tenaga Medis dan Profesional Kesehatan:

Penelitian ini diharapkan dapat memberikan gambaran mengenai potensi pemanfaatan *machine learning* dalam analisis data EEG pada studi Autism Spectrum Disorder (ASD), maupun untuk sehingga dapat mendukung pemahaman dan penelitian lanjutan terkait pendekatan berbasis data dalam konteks klinis.

1.5 Ruang Lingkup Penelitian

Agar penelitian ini tetap terfokus, maka ruang lingkup penelitian ditetapkan sebagai berikut:

1. Dataset Penelitian: Penelitian ini menggunakan dataset EEG yang sama dengan dataset pada penelitian rujukan [8][6]. Dataset tersebut digunakan sebagai dasar dalam proses *training* model augmentasi maupun model klasifikasi sehingga hasil penelitian dapat dibandingkan secara relevan dengan penelitian sebelumnya.
2. Metode Penelitian: Tahapan *preprocessing*, klasifikasi, dan evaluasi penelitian mengacu pada metode yang digunakan dalam penelitian rujukan [8] dan [14]. Modifikasi yang dilakukan pada penelitian ini difokuskan pada penerapan metode *data augmentation* berbasis *Variational Autoencoder* (VAE) untuk menghasilkan data EEG sintetis.
3. Hasil Akhir Penelitian: Penelitian ini menghasilkan model *data augmentation* EEG berbasis *Variational Autoencoder* (VAE) untuk menghasilkan data EEG sintetis, serta mengevaluasi kualitas data yang dihasilkan dan pengaruhnya terhadap performa model klasifikasi.
4. Batasan Penelitian: Penelitian difokuskan pada analisis pengaruh penerapan *data augmentation* EEG terhadap kualitas performa model klasifikasi. Penelitian ini tidak membahas aspek perangkat keras EEG, proses akuisisi data asli, maupun tahapan penghilangan *noise* dan *artifact removal* di luar prosedur *preprocessing* yang telah ditetapkan pada penelitian rujukan.

1.6 Sistematika Penulisan

Laporan tesis ini disusun secara sistematis ke dalam lima bab utama, dengan rincian sebagai berikut:

1. Bab 1: Pendahuluan. Bab ini menyajikan gambaran umum penelitian, meliputi latar belakang yang menjelaskan pentingnya analisis sinyal EEG dalam mendukung identifikasi Autism Spectrum Disorder (ASD), rumusan masalah yang menjadi

dasar penelitian, tujuan yang ingin dicapai, manfaat penelitian, ruang lingkup penelitian, serta sistematika penulisan laporan ini.

2. Bab 2: Tinjauan Pustaka. Bab ini menguraikan landasan teoretis yang mendukung penelitian, meliputi konsep dasar sinyal EEG, metode *Minimum Redundancy Maximum Relevance* (mRMR) untuk seleksi fitur, implementasi *machine learning* dalam klasifikasi berdasarkan EEG, metode augmentasi data EEG, model *Variational AutoEncoder*, metode evaluasi data hasil augmentasi, serta kajian terhadap penelitian-penelitian sebelumnya yang bersifat relevan.
3. Bab 3: Metodologi Penelitian. Bab ini menjelaskan metode yang digunakan dalam penelitian, mencakup deskripsi dataset EEG yang digunakan, tahapan pra-pemrosesan data, penerapan teknik *data augmentation*, proses seleksi fitur menggunakan metode *mRMR*, arsitektur model augmentasi berbasis *VAE*, serta integrasi sinyal sintetis dalam proses *training* model klasifikasi.
4. Bab 4: Hasil dan Analisis. Bab ini memaparkan hasil eksperimen yang diperoleh dari proses *training* dan pengujian model. Analisis dilakukan berupa evaluasi data sintetis yang dihasilkan, serta membandingkan performa model pada skenario dengan dan tanpa penerapan *data augmentasi*, serta mengevaluasi pengaruhnya terhadap kemampuan model dalam melakukan klasifikasi data EEG.
5. Bab 5: Penutup. Bab terakhir ini berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran untuk pengembangan penelitian selanjutnya terkait analisis dan klasifikasi data EEG menggunakan metode *machine learning*.

BAB 2

TINJAUAN PUSTAKA

Bab ini menjelaskan konteks dan landasan teoretis yang mendasari penelitian mengenai analisis sinyal EEG untuk klasifikasi *Autism Spectrum Disorder* (ASD) menggunakan metode *machine learning*. Penjelasan diawali dengan pemaparan landasan teori, dilanjutkan dengan pembahasan penelitian terdahulu yang relevan, dan diakhiri dengan pembahasan mengenai celah penelitian yang menjadi dasar penelitian ini.

2.1 Landasan Teori

Bagian ini menguraikan konsep-konsep teoretis yang menjadi dasar dalam penelitian analisis sinyal EEG untuk klasifikasi Autism Spectrum Disorder (ASD). Landasan teori ini mencakup konsep dasar EEG, tahapan pemrosesan sinyal EEG, teknik seleksi fitur dalam pemrosesan, metode *machine learning* untuk klasifikasi, serta metode *data augmentation* yang digunakan dalam penelitian ini.


2.1.1 Sinyal EEG

Sinyal *electroencephalogram* (EEG) dihasilkan oleh aktivitas listrik neuron di otak yang muncul akibat aktivitas sinaptik antar neuron, sehingga potensial listrik yang dihasilkan dapat dideteksi pada permukaan kepala menggunakan elektroda. Sinyal EEG direkam sebagai perubahan tegangan terhadap waktu dengan rentang frekuensi sekitar 0,5 hingga 100 Hz dan amplitudo yang relatif rendah, umumnya berada pada kisaran 10 hingga 100 mikrovolt. Selain memiliki resolusi temporal yang tinggi, sinyal EEG juga bersifat *non-stationary*, sehingga karakteristik amplitudo dan distribusi frekuensinya dapat berubah secara dinamis seiring waktu akibat pengaruh kondisi fisiologis, tingkat kesadaran, maupun aktivitas kognitif. Aktivitas yang terekam mencerminkan berbagai proses otak, seperti fungsi kognitif, motorik, dan emosional, sehingga EEG banyak digunakan untuk mempelajari fungsi otak dan gangguan neurologis [15].

EEG biasanya direkam dalam bentuk sinyal multikanal yang diperoleh dari sejumlah

lah elektroda yang ditempatkan pada berbagai lokasi di permukaan kulit kepala. Setiap kanal merepresentasikan satu jalur perekaman sinyal yang berasal dari pasangan elektroda atau dari elektroda terhadap referensi tertentu. Setiap elektroda menangkap aktivitas listrik dari wilayah otak yang berbeda, sehingga setiap kanal mengandung informasi yang merepresentasikan aktivitas saraf pada lokasi tertentu.[13].

Penempatan elektroda EEG umumnya mengikuti standar *International 10–20 System*, yaitu protokol yang distandarisasi oleh *International Federation of Clinical Neurophysiology* (IFCN) untuk menentukan posisi elektroda pada permukaan kepala berdasarkan titik anatomi seperti nasion, inion, dan titik preauricular. Dalam sistem ini, setiap elektroda diberi kode huruf dan angka yang menunjukkan wilayah otak dan hemisfer terkait, seperti frontal (F), central (C), temporal (T), parietal (P), dan occipital (O), dengan angka ganjil untuk hemisfer kiri, angka genap untuk hemisfer kanan, serta “z” untuk posisi garis tengah kepala. Tata letak elektroda pada sistem ini ditunjukkan pada Gambar 2.1. Standarisasi ini memungkinkan perekaman EEG dilakukan secara konsisten dan dapat dibandingkan antar subjek maupun antar penelitian[16].



Gambar 2.1. Sistem Internasional 10–20 untuk penempatan elektroda EEG. Sumber: Matsuo et al. (2025)

Dalam analisis sinyal EEG, aktivitas listrik otak yang terekam dapat dianalisis melalui dua domain utama, yaitu domain waktu dan domain frekuensi. Analisis dalam domain waktu dilakukan dengan mengamati karakteristik sinyal terhadap waktu, seperti ampli-

tudo puncak, dan latensi. Sedangkan analisis dalam domain frekuensi bertujuan untuk mengidentifikasi kandungan spektral sinyal dengan memeriksa distribusi energi atau daya pada berbagai rentang frekuensi menggunakan metode transformasi spektral, seperti *Fast Fourier Transform* (FFT) maupun teknik estimasi *Power Spectral Density* (PSD) untuk mengidentifikasi aktivitas otak pada rentang frekuensi tertentu [17].


Dalam analisis spektral EEG, sinyal umumnya dibagi ke dalam beberapa segmen waktu (*epoch*) sebelum dihitung nilai *Power Spectral Density* (PSD) untuk menggambarkan distribusi daya pada setiap frekuensi. Berdasarkan karakteristik fisiologis dan kognitifnya, sinyal EEG kemudian diklasifikasikan ke dalam beberapa pita frekuensi utama seperti pada tabel 2.1.

Tabel 2.1. Pita frekuensi EEG dan karakteristiknya. Sumber: Savadi [?]]

Pita	Frekuensi (Hz)	Karakteristik
Delta	0,5–4	Dominan pada kondisi <i>deep sleep</i> dan berperan dalam proses pemulihan fisiologis serta regulasi fungsi tubuh selama tidur.
Theta	4–8	Berkaitan dengan proses pembentukan memori dan aktivitas pada sistem limbik serta hipokampus, serta muncul pada kondisi mengantuk atau relaksasi mendalam.
Alpha	8–13	Muncul pada kondisi rileks saat mata tertutup, dengan dominasi pada wilayah oksipital dan berhubungan dengan penurunan aktivitas pemrosesan sensorik.
Beta	13–30	Berkaitan dengan aktivitas kognitif aktif seperti konsentrasi, pemecahan masalah, serta aktivitas motorik.
Gamma	>30	Berhubungan dengan proses kognitif tingkat tinggi, termasuk perhatian, integrasi informasi sensorik, dan persepsi.

Melalui analisis distribusi daya pada pita frekuensi, dapat dilakukan identifikasi pola aktivitas otak yang khas serta membandingkan karakteristik sinyal EEG pada berbagai kondisi fisiologis maupun gangguan neurologis tertentu. Representasi pita frekuensi EEG sering digunakan sebagai dasar dalam proses ekstraksi fitur pada analisis sinyal EEG, misalnya melalui perhitungan *band power*, estimasi *power spectral density* (PSD), maupun

metode analisis spektral lainnya [13]. Rentang pita frekuensi EEG beserta posisinya pada spektrum frekuensi rendah hingga tinggi ditunjukkan pada ilustrasi 2.3.




Gambar 2.2. Pita frekuensi EEG pada rentang frekuensi tinggi dan rendah. Sumber: Kumar et al. (2022)

Sebelum dilakukan ekstraksi fitur dan klasifikasi, sinyal EEG umumnya melalui tahap *preprocessing* untuk meningkatkan kualitas sinyal dan mengurangi gangguan yang tidak relevan. Tahapan ini biasanya meliputi *filtering*, *artifact removal*, *baseline correction*, serta normalisasi atau standarisasi data [13].


Filtering adalah proses penyaringan sinyal untuk menghilangkan komponen frekuensi yang tidak berkaitan dengan aktivitas saraf serta mengurangi gangguan dari lingkungan seperti interferensi listrik serta gangguan yang muncul akibat pergerakan elektroda dan perubahan impedansi kulit. *Filtering* dilakukan dengan membatasi rentang frekuensi sinyal menggunakan filter tertentu. Umumnya, *band-pass filter* digunakan untuk mempertahankan frekuensi aktivitas otak, serta *notch filter* untuk mereduksi interferensi jaringan listrik. Filter tambahan seperti *high-pass filter* juga dapat digunakan untuk menghilangkan *drift* sinyal berfrekuensi sangat rendah, sedangkan *low-pass filter* digunakan untuk mereduksi komponen *noise* berfrekuensi tinggi. Pemilihan filter perlu dilakukan secara hati-hati untuk menghindari distorsi sinyal atau pergeseran fase sinyal [13]. Pengaruh

penggunaan filter terhadap sinyal EEG dapat dilihat pada ilustrasi 2.3.



Gambar 2.3. Ilustrasi pengaruh berbagai jenis filter terhadap sinyal EEG. Sumber: EduRev, Filter Characteristics of Linear Systems.

Sinyal EEG dapat terkontaminasi oleh artefak non-neural yang berasal dari aktivitas fisiologis maupun faktor eksternal. Artefak fisiologis umumnya disebabkan oleh kedipan mata dan pergerakan bola mata (*electrooculogram*) dan aktivitas otot wajah dan kepala (*electromyogram*), sedangkan artefak eksternal dapat berasal dari interferensi perangkat elektronik dan jaringan listrik. Keberadaan artefak dapat mempengaruhi kualitas sinyal, sebagaimana yang terlihat pada 2.4, sehingga berpotensi menurunkan akurasi analisis maupun kinerja sistem klasifikasi. Berbagai metode digunakan untuk mengurangi artefak pada sinyal EEG, seperti *Blind Source Separation* (BSS), *Independent Component Analysis* (ICA), serta transformasi wavelet yang memungkinkan analisis pada domain waktu dan frekuensi untuk mendeteksi artefak [13].



Gambar 2.4. Bentuk-bentuk artefak pada sinyal EEG. Sumber: Kanoga dan Mitsukura (2017)

Dalam analisis EEG berbasis *machine learning*, normalisasi atau standarisasi digunakan untuk mengurangi variasi antar kanal maupun antar subjek yang menyebabkan perbedaan skala fitur dan mempengaruhi proses *training*. Proses normalisasi digunakan untuk menyesuaikan skala fitur agar berada dalam rentang yang lebih seragam. Salah satu metode yang umum digunakan adalah *Z-score normalization*, yaitu mengurangi nilai rata-rata dan membaginya dengan standar deviasi sehingga data memiliki rata-rata nol dan variansi satu, sedangkan *min-max normalization* juga dapat dilakukan dengan men-skalakan nilai fitur ke dalam rentang tertentu, umumnya antara 0 dan 1. Proses ini memastikan kontribusi fitur lebih seimbang serta meningkatkan stabilitas dan kinerja model [13].

2.1.2 Feature Selection mRMR

Dalam aplikasi klasifikasi *machine learning*, *feature selection* merupakan langkah krusial untuk meminimalkan kesalahan klasifikasi. Secara formal, diberikan dataset D yang terdiri dari N sampel dan M fitur $X = \{x_i \mid i = 1, 2, \dots, M\}$, serta variabel target c , maka seleksi fitur bertujuan menentukan subset berdimensi lebih rendah $R^m \subset R^M$ dengan $m < M$ yang mampu merepresentasikan target secara optimal[18].

Secara umum, tujuan *feature selection* dapat diformulasikan sebagai proses optimasi untuk mencari himpunan fitur $S \subseteq X$ dengan $|S| = m$ yang memaksimalkan ketergantungan terhadap kelas target. Ketergantungan ini seringkali diukur menggunakan *mutual information* $I(S; c)$, sehingga permasalahan dapat dinyatakan sebagai:

$$\max_{S \subseteq X, |S|=m} I(S; c) \quad (2.1)$$

Penggunaan seluruh fitur tidak selalu menghasilkan performa optimal karena adanya redundansi antar fitur. Fitur dengan korelasi tinggi cenderung memberikan informasi yang berulang, sehingga diperlukan metode *feature selection* yang mempertimbangkan relevansi terhadap target sekaligus meminimalkan redundansi.

Minimum Redundancy Maximum Relevance (mRMR) merupakan teknik seleksi fitur berbasis teori informasi yang memilih subset fitur dengan relevansi tinggi terhadap target dan redundansi rendah antar fitur. Pendekatan ini efektif dalam mengurangi dimensi data tanpa mengorbankan informasi penting, sehingga meningkatkan efisiensi komputasi dan

kemampuan generalisasi model [19][20]. Proses pemilihan fitur pada metode mRMR dilakukan secara iteratif dengan mengevaluasi keseimbangan antara relevansi fitur terhadap kelas target dan redundansi antar fitur yang telah dipilih sebelumnya.

Algoritma 2.1. Algoritma mRMR untuk seleksi fitur.

```

1  # mRMR Feature Selection Algorithm
2
3  def mrmr_feature_selection(X, c, m):
4
5      S = []                # selected features
6      F = X                 # candidate features
7
8      # Select feature with maximum relevance
9      for xi in F:
10         relevance[xi] = MI(xi, c)
11
12     x_best = argmax(relevance)
13
14     S.append(x_best)
15     F.remove(x_best)
16
17     # Iterative feature selection
18     while len(S) < m:
19
20         for xj in F:
21
22             rel = MI(xj, c)
23
24             red = 0
25             for xs in S:
26                 red += MI(xj, xs)
27
28             red = red / len(S)
29
30             score[xj] = rel - red
31
32         x_best = argmax(score)
33
34         S.append(x_best)
35         F.remove(x_best)
36
37     return S

```


Algoritma 2.1 menjelaskan proses seleksi fitur menggunakan metode *Minimum Redundancy Maximum Relevance* (mRMR). Algoritma dimulai dengan memilih fitur yang memiliki nilai *mutual information* tertinggi terhadap kelas target sebagai fitur awal. Selanjutnya, fitur lain dipilih secara iteratif berdasarkan nilai *mRMR score*, yaitu selisih antara relevansi fitur terhadap target dan redundansinya terhadap fitur yang dipilih sebelumnya.

Proses ini dilakukan hingga jumlah fitur terpilih mencapai jumlah yang diinginkan.

2.1.3 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG

Dalam analisis EEG, *machine learning* digunakan untuk mengklasifikasikan pola aktivitas otak berdasarkan fitur yang diekstraksi dari sinyal EEG. Fitur tersebut dapat berasal dari domain waktu, domain frekuensi, maupun domain waktu-frekuensi, dan digunakan untuk merepresentasikan karakteristik aktivitas neural yang berkaitan dengan kondisi fisiologis atau neurologis tertentu [21]. Pendekatan ini telah digunakan pada berbagai aplikasi seperti deteksi kejang epilepsi, sistem *brain-computer interface* (BCI), serta identifikasi pola aktivitas otak pada *Autism Spectrum Disorder* (ASD) [22].


Pada studi ASD, analisis EEG dalam domain frekuensi menjadi salah satu pendekatan yang umum digunakan karena aktivitas otak dapat direpresentasikan sebagai pola osilasi pada pita frekuensi tertentu [23]. Beberapa penelitian menunjukkan bahwa individu dengan ASD cenderung memiliki peningkatan daya pada pita delta, theta, beta, dan gamma, serta penurunan pada pita alpha. Pola ini dikenal sebagai *U-shaped spectral profile* dan digunakan untuk merepresentasikan abnormalitas aktivitas neural pada ASD sebagaimana diilustrasikan pada ilustrasi 2.5. [22].



Gambar 2.5. Ilustrasi *U-shaped spectral profile* yang ditemukan pada pita frekuensi penderita ASD.
Sumber: Wang et al. (2013)

Berdasarkan fitur yang diperoleh, proses klasifikasi dilakukan menggunakan algoritma *machine learning* untuk membangun model prediksi. Berbagai metode seperti *support vector machine* (SVM), *k-nearest neighbor* (KNN), dan *random forest* telah banyak

digunakan dalam klasifikasi EEG dan menunjukkan performa yang baik dalam mengenali pola aktivitas neural yang kompleks [21]. Meskipun pendekatan *deep learning* berkembang pesat, metode *machine learning* konvensional masih relevan terutama pada kondisi data terbatas dan kebutuhan interpretabilitas model [24].



Gambar 2.6. Ilustrasi umum pipeline klasifikasi ASD berbasis sinyal EEG. Sumber: Mortaga et al. (2021)

Gambar 2.6 menunjukkan proses klasifikasi berbasis sinyal EEG pada umumnya. Pipeline diawali akuisisi sinyal EEG, dilanjutkan dengan tahap *preprocessing* untuk meningkatkan kualitas sinyal sebelum dianalisis lebih lanjut. Setelah itu, dilakukan proses ekstraksi fitur untuk memperoleh representasi informasi dari sinyal EEG yang relevan terhadap proses klasifikasi. Fitur yang diperoleh dari tahap ekstraksi kemudian digunakan sebagai masukan bagi model *machine learning* untuk mempelajari pola-pola dalam sinyal EEG dan melakukan proses klasifikasi berupa prediksi terhadap kelas atau label yang telah ditentukan sesuai dengan tujuan penelitian. Secara umum, pipeline ini bertujuan mengubah sinyal EEG mentah menjadi representasi fitur yang lebih informatif dan terstruktur sehingga dapat diproses secara efektif oleh algoritma klasifikasi.


2.1.4 Augmentasi Data EEG

Performa model *machine learning* sangat dipengaruhi oleh jumlah, kualitas, dan keragaman data *training*. Pada analisis sinyal EEG, keterbatasan data menjadi tantangan karena proses akuisisi relatif mahal, memakan waktu, serta menghasilkan data dengan variabilitas tinggi antar individu maupun sesi [25]. Variabilitas tersebut dipengaruhi oleh perbedaan perangkat, konfigurasi kanal, kondisi eksperimen, aktivitas fisiologis, dan artefak non-neural, sehingga distribusi data EEG menjadi kompleks dan tidak konsisten antar

dataset. Kondisi ini dapat menyebabkan model mengalami *overfitting* dan memiliki kemampuan generalisasi yang rendah terhadap data baru.

Untuk mengatasi permasalahan tersebut, berbagai penelitian mengusulkan penggunaan teknik *data augmentation* untuk meningkatkan jumlah dan variasi data *training* tanpa memerlukan proses perekaman tambahan [12]. Secara umum, *data augmentation* bertujuan menghasilkan sampel data baru yang tetap mempertahankan karakteristik utama data asli sehingga model dapat mempelajari representasi pola yang lebih stabil.

Pada sinyal *time-series* seperti sinyal EEG, augmentasi konvensional umumnya dilakukan melalui manipulasi langsung terhadap sinyal dalam domain waktu maupun frekuensi [26]. Pendekatan ini menghasilkan sampel baru dengan memodifikasi data asli menggunakan aturan transformasi tertentu tanpa mempelajari distribusi data secara eksplisit. Beberapa metode augmentasi yang umum digunakan pada data *time-series* meliputi *Flipping*, *Down-sampling*, *Adding Slope*, *Amplitude Adjusted Fourier Transform (AAFT)*, *Iterative Amplitude Adjusted Fourier Transform (IAAFT)*, *Amplitude-Phase Perturbation (APP)*, dan *Short-Time Fourier Transform (STFT)-based Augmentation*. Ilustrasi penerapan masing-masing metode ditunjukkan pada gambar 2.7 dengan detail implementasi yang disajikan pada tabel 2.2.



Gambar 2.7. Ilustrasi metode augmentasi pada data *time-series*. Sumber: Rongali et al. (2024)

Tabel 2.2. Metode augmentasi pada data *time-series*. Sumber: Rongali et al. (2024)

Metode	Formula	Pengaruh terhadap Data
<i>Flipping</i>	$x'(t) = -x(t)$	Membalik amplitudo sinyal terhadap sumbu horizontal sehingga pola temporal tetap terjaga tetapi orientasi sinyal berubah.
<i>Down-sampling</i>	$x'(t) = x(nt)$	Mengurangi jumlah sampel dengan faktor tertentu sehingga menghasilkan variasi resolusi temporal data.
<i>Adding Slope</i>	$x'(t) = x(t) + \alpha t$	Menambahkan tren linier pada sinyal untuk mensimulasikan perubahan gradual atau <i>drift</i> .
<i>AAFT</i>	$x'(t) = \mathcal{F}^{-1} \left(X(f) e^{j\phi_r(f)} \right)$	Menghasilkan sinyal surrogate yang mempertahankan distribusi amplitudo dan spektrum daya secara aproksimatif.
<i>IAAFT</i>	$x'(t) = \text{IAAFT}(x(t))$	Menghasilkan sinyal surrogate yang lebih akurat dalam mempertahankan distribusi amplitudo dan spektrum daya dibandingkan AAFT melalui proses iteratif.
<i>APP</i>	$X'(f) = A(f) e^{j(\phi(f) + \Delta\phi)}$	Menambahkan perturbasi amplitudo atau fase di domain frekuensi untuk menciptakan variasi sinyal yang realistis.
<i>STFT-based Augmentation</i>	$X'(m, \omega) = \text{Aug}(X(m, \omega))$	Melakukan augmentasi representasi waktu-frekuensi sehingga karakteristik lokal dimodifikasi tanpa mengubah struktur global secara signifikan.

Meskipun relatif sederhana dan mudah diterapkan, metode augmentasi konvensional memiliki keterbatasan dalam mempertahankan karakteristik kompleks sinyal EEG secara menyeluruh. Transformasi langsung terhadap sinyal berpotensi mengubah dependensi spasial maupun temporal yang penting dalam representasi aktivitas fisiologis. Selain itu, beberapa penelitian menunjukkan bahwa augmentasi sederhana tidak selalu meningkatkan performa model klasifikasi EEG secara konsisten. Oleh karena itu, penelitian lain mulai menggunakan pendekatan berbasis model generatif yang mampu mempelajari distribusi data untuk menghasilkan sampel sintesis yang lebih representatif ter-

hadap karakteristik sinyal EEG.

2.1.5 Model Generatif untuk Augmentasi Data

Model generatif merupakan pendekatan dalam *machine learning* yang mempelajari distribusi dan pola suatu dataset untuk menghasilkan sampel data baru yang memiliki karakteristik serupa dengan data asli, berbeda dengan model diskriminatif yang digunakan pada proses klasifikasi atau prediksi label [27]. Model generatif digunakan dalam berbagai aplikasi seperti sintesis gambar, rekonstruksi data (*data reconstruction*), pemrosesan suara, hingga pembuatan data sintetis untuk kebutuhan *training* model.

Data sintetis yang dihasilkan model generatif menjadi salah satu solusi terhadap berbagai permasalahan pada proses pengolahan data, seperti keterbatasan jumlah data, ketidakseimbangan kelas (*class imbalance*), serta kendala privasi dan akuisisi data [27]. Dalam konteks *machine learning*, data sintetis yang dihasilkan oleh model generatif dapat digunakan sebagai bentuk *data augmentation* untuk meningkatkan jumlah dan keragaman data *training* tanpa memerlukan proses pengumpulan data baru secara langsung. Pendekatan ini memungkinkan model mempelajari representasi data yang lebih beragam sehingga dapat membantu meningkatkan kemampuan generalisasi model.

Berbagai arsitektur model generatif telah dikembangkan dalam penelitian *deep learning*. Beberapa pendekatan yang umum digunakan meliputi *Generative Adversarial Networks* (GAN), *Variational Autoencoders* (VAE), serta model berbasis difusi (*diffusion models*). Masing-masing pendekatan memiliki mekanisme pembelajaran dan karakteristik yang berbeda dalam menghasilkan data sintetis.

Tabel 2.3. Perbandingan karakteristik, kelebihan, dan keterbatasan beberapa model generatif utama.
Sumber: Singh et al. (2025)


Model	Karakteristik Utama	Kelebihan dan Keterbatasan
GAN	Menggunakan mekanisme kompetitif antara generator dan discriminator untuk menghasilkan data sintetis.	Mampu menghasilkan data yang realistis, namun proses <i>training</i> cenderung tidak stabil dan rentan terhadap <i>mode collapse</i> .
VAE	Mempelajari distribusi laten probabilistik melalui arsitektur encoder-decoder.	Memiliki proses <i>training</i> yang lebih stabil dan mampu menghasilkan representasi laten yang terstruktur, namun kualitas data sintetis dapat lebih halus dibanding GAN.
Diffusion Model	Menghasilkan data melalui proses denoising bertahap dari distribusi acak.	Mampu menghasilkan kualitas data yang tinggi, namun memerlukan kompleksitas komputasi dan waktu <i>training</i> yang lebih besar.

Dalam analisis sinyal EEG, model generatif digunakan untuk menghasilkan data sintetis yang mengikuti distribusi statistik data asli. Pendekatan ini memungkinkan model mempelajari struktur laten dari sinyal EEG sehingga data sintetis yang dihasilkan dapat mempertahankan karakteristik temporal maupun spasial yang penting dalam proses klasifikasi. Beberapa penelitian menunjukkan bahwa penggunaan data sintetis dari model generatif dapat membantu meningkatkan performa dan kemampuan generalisasi model klasifikasi EEG, terutama pada kondisi jumlah data *training* yang terbatas [28].

Salah satu model generatif yang banyak digunakan dalam augmentasi data EEG adalah *Variational Autoencoder* (VAE). Dibandingkan GAN, VAE memiliki proses *training* yang lebih stabil dan tidak bergantung pada mekanisme adversarial yang rentan terhadap *mode collapse*. Selain itu, dibandingkan *diffusion model*, VAE umumnya memerlukan kompleksitas komputasi dan jumlah data *training* yang lebih rendah. Karakteristik tersebut menjadikan VAE lebih sesuai untuk penelitian ini yang menggunakan dataset EEG dengan jumlah data terbatas[12].

2.1.6 Variational Auto Encoder

Variational Autoencoder (VAE) merupakan salah satu model generatif berbasis *deep learning* yang digunakan untuk mempelajari representasi laten dari suatu dataset dan menghasilkan sampel data baru dengan karakteristik yang serupa dengan data asli. Berbeda dengan *autoencoder* konvensional yang berfokus pada proses kompresi dan rekonstruksi data, VAE memodelkan representasi laten sebagai distribusi probabilistik sehingga memungkinkan proses generasi data baru melalui ruang laten (*latent space*) yang dipelajari oleh model [29].



Gambar 2.8. Arsitektur umum *Variational Autoencoder* (VAE). Sumber: Montes (2025)

Arsitektur VAE terdiri atas dua komponen utama, yaitu *encoder* dan *decoder*, seperti yang diilustrasikan pada Gambar 2.8. *Encoder* bertugas memetakan data input ke representasi laten berdimensi lebih rendah dalam bentuk parameter distribusi probabilistik, yaitu nilai rata-rata (μ) dan variansi (σ). Representasi laten tersebut kemudian digunakan oleh *decoder* untuk merekonstruksi kembali data sehingga menghasilkan output yang memiliki karakteristik serupa dengan data asli.

Proses *training* VAE dilakukan menggunakan fungsi objektif *Evidence Lower Bound* (ELBO), yang terdiri atas dua komponen utama, yaitu *reconstruction loss* dan *Kullback–Leibler Divergence* (KL Divergence). *Reconstruction loss* digunakan untuk mengukur kualitas hasil rekonstruksi data, sedangkan KL Divergence berfungsi menjaga distribusi laten agar tetap mendekati distribusi normal standar. Secara matematis, fungsi objektif VAE dirumuskan sebagaimana pada persamaan 2.2:

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)] - D_{KL}(q_{\phi}(z|x) \parallel p(z)) \quad (2.2)$$

di mana $q_{\phi}(z|x)$ merepresentasikan distribusi laten yang dihasilkan oleh *encoder*, $p_{\theta}(x|z)$

merepresentasikan proses rekonstruksi oleh *decoder*, dan $p(z)$ merupakan distribusi prior pada ruang laten. Komponen pertama pada persamaan tersebut merepresentasikan kualitas rekonstruksi data, sedangkan komponen kedua berfungsi sebagai regularisasi untuk menjaga struktur distribusi laten [30].

Proses *sampling* pada ruang laten tidak dapat dilakukan secara langsung dalam proses *training* menggunakan metode *backpropagation*. Oleh karena itu, VAE menggunakan teknik yang dikenal sebagai *reparameterization trick*. Melalui teknik ini, variabel laten z dinyatakan sebagaimana yang terlihat pada persamaan 2.3.

$$z = \mu + \sigma \cdot \epsilon \quad (2.3)$$

di mana ϵ merupakan variabel acak yang diambil dari distribusi normal standar $\mathcal{N}(0,1)$. Dengan pendekatan ini, proses *sampling* dapat ditransformasikan menjadi operasi deterministik yang memungkinkan gradien tetap dapat dihitung selama proses *training* neural network [30].

2.1.7 Metode Evaluasi Data EEG Sintetis Model Generatif

Evaluasi kualitas data sintetis diperlukan untuk menilai sejauh mana sinyal EEG yang dihasilkan model generatif mampu mempertahankan karakteristik data asli. Dalam penelitian referensi [14], evaluasi dilakukan menggunakan beberapa metrik kuantitatif yang umum digunakan pada model generatif, yaitu, *Frechet Inception Distance* (FID), *Euclidean Distance* (ED), dan *Sliced Wasserstein Distance* (SWD). Definisi, formulasi matematis, serta aspek kualitas data yang dievaluasi oleh masing-masing metrik dirangkum dalam tabel 2.4.

Tabel 2.4. Metrik evaluasi data sintetis EEG. Sumber: Hartmann et al. (2018)

Metrik	Formula	Aspek yang Dievaluasi
<i>Frechet Inception Distance (FID)</i>	$\ \mu_r - \mu_g\ ^2 + \text{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$	Mengukur kesamaan distribusi fitur antara data asli dan sintetis.
<i>Euclidean Distance (ED)</i>	$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$	Mengukur kemiripan langsung antar sampel data asli dan sintetis.
<i>Sliced Wasserstein Distance (SWD)</i>	$SWD(P, Q) = \int_{\theta} W_1(P_{\theta}, Q_{\theta}) d\theta$	Mengukur kesamaan distribusi global melalui proyeksi satu dimensi.

Penelitian referensi [14] menunjukkan bahwa tidak terdapat satu metrik yang mampu merepresentasikan seluruh karakteristik kualitas sinyal EEG sintetis secara menyeluruh. Pada penelitian tersebut, nilai FID yang rendah tidak selalu menunjukkan kesamaan karakteristik spasial dan spektral terhadap data asli, sedangkan SWD dinilai lebih mampu merepresentasikan distribusi sinyal yang natural. Oleh karena itu, penggunaan beberapa metrik evaluasi secara bersamaan diperlukan untuk memperoleh penilaian kualitas data sintetis yang lebih komprehensif.

2.2 Penelitian Terdahulu

Berbagai penelitian telah mengusulkan pendekatan *machine learning* untuk klasifikasi *Autism Spectrum Disorder* (ASD) berbasis sinyal EEG dengan memanfaatkan karakteristik aktivitas neural sebagai fitur klasifikasi. Selain itu, beberapa penelitian juga menerapkan teknik augmentasi data untuk mengatasi keterbatasan jumlah data *training* dan meningkatkan performa model klasifikasi.

Tinjauan terhadap penelitian terdahulu diperlukan untuk memahami perkembangan metode klasifikasi EEG, pendekatan augmentasi data yang telah digunakan, serta keterbatasan yang masih menjadi tantangan dalam pengembangan sistem klasifikasi ASD berbasis EEG.

2.2.1 Klasifikasi ASD Berbasis EEG Menggunakan Kombinasi mRMR dan XGBoost

Pada penelitian rujukan [8], klasifikasi *Autism Spectrum Disorder* (ASD) dilakukan menggunakan sinyal EEG dengan memanfaatkan seleksi fitur dan algoritma *machine learning*. Penelitian berfokus pada penggunaan fitur domain frekuensi untuk merepresentasikan karakteristik aktivitas neural yang berkaitan dengan ASD serta meningkatkan performa klasifikasi melalui pemilihan fitur yang optimal.

Penelitian menggunakan metode *minimum Redundancy Maximum Relevance* (mRMR) untuk memilih fitur yang paling relevan dan memiliki redundansi minimum antar fitur. Sebelum proses seleksi fitur, sinyal EEG melalui tahap *preprocessing* seperti segmentasi, *filtering*, dan dekomposisi pita frekuensi. Fitur hasil seleksi kemudian digunakan sebagai masukan bagi model klasifikasi berbasis *ensemble*, yaitu XGBoost. Performa metode tersebut dibandingkan dengan model *Deep Neural Network* (DNN) sebagai metode *baseline*, sehingga peningkatan performa yang diperoleh dievaluasi berdasarkan hasil perbandingan terhadap model DNN.

Hasil penelitian menunjukkan bahwa kombinasi mRMR dan XGBoost mampu memberikan performa klasifikasi yang baik dalam membedakan individu ASD dan non-ASD. Penggunaan mRMR membantu meningkatkan kualitas fitur, sementara XGBoost memberikan kemampuan klasifikasi yang robust terhadap kompleksitas data EEG. Namun, penelitian juga menunjukkan bahwa pendekatan tersebut memiliki waktu komputasi yang lebih tinggi dibandingkan model dasar yang digunakan sebagai pembanding. Selain itu, penelitian masih dilakukan pada jumlah dataset yang relatif terbatas, sehingga kemampuan generalisasi model masih menjadi tantangan dalam pengembangan sistem klasifikasi EEG berbasis ASD.

2.2.2 Metode Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder

Pada penelitian rujukan [28], digunakan pendekatan augmentasi data berbasis *Variational Autoencoder* (VAE) untuk menghasilkan sinyal EEG sintetis pada tugas klasifikasi *motor imagery*. Penelitian memanfaatkan BCI Competition IV Dataset 2a yang terdiri dari data

EEG 22 kanal dari 9 subjek. Data EEG direpresentasikan dalam bentuk matriks dua dimensi untuk menyesuaikan penggunaan arsitektur berbasis *2D Convolutional Neural Network* (2D CNN).

Model VAE terdiri dari komponen *encoder* dan *decoder* yang digunakan untuk mempelajari representasi laten dari sinyal EEG dan merekonstruksi kembali data sintetis yang menyerupai data asli. Untuk evaluasi klasifikasi, penelitian menggunakan arsitektur EEG-Net dan membandingkan performa model yang dilatih menggunakan data asli dengan model yang dilatih menggunakan data hasil augmentasi.

Hasil penelitian menunjukkan bahwa penggunaan data sintetis dari VAE mampu meningkatkan performa klasifikasi secara signifikan, di mana akurasi meningkat dari 0.73 menjadi 0.88. Peningkatan juga terlihat pada metrik *precision*, *recall*, dan *f1-score*, yang menunjukkan bahwa data sintetis mampu memperkaya variasi data *training*.

Namun, penelitian tersebut masih berfokus pada representasi sinyal EEG dalam domain waktu dan belum mempertimbangkan karakteristik domain frekuensi secara menyeluruh. Padahal, analisis domain frekuensi memiliki peran penting dalam identifikasi pola neurofisiologis pada EEG, termasuk pada studi ASD, karena informasi aktivitas neural banyak direpresentasikan melalui distribusi daya pada pita frekuensi tertentu.

2.2.3 Dataset EEG yang Digunakan dalam Penelitian

Dataset yang digunakan dalam penelitian ini berupa sinyal *electroencephalogram* (EEG) dari studi rujukan [6], yang terdiri dari data subjek dengan dan tanpa diagnosis *Autism Spectrum Disorder* (ASD). Dataset ini digunakan karena mampu merepresentasikan karakteristik aktivitas neural yang berkaitan dengan ASD sehingga relevan untuk pengembangan model klasifikasi berbasis *machine learning*.

Data EEG dikumpulkan dari sepuluh partisipan yang terdiri dari lima anak dengan ASD berusia 6–10 tahun dan lima subjek kontrol sehat. Akuisisi dilakukan menggunakan perangkat *OpenBCI Cyton Biosensing Board* dengan 16 kanal EEG berdasarkan sistem *International 10–20 System*. Proses perekaman dilakukan tanpa stimulus eksternal dengan upaya meminimalkan distraksi partisipan untuk menjaga kualitas sinyal EEG yang diperoleh.

Setelah akuisisi, sinyal EEG melalui tahap *preprocessing* menggunakan metode

seperti *Butterworth filtering*, *Discrete Wavelet Transform* (DWT), dan *Independent Component Analysis* (ICA) untuk mengurangi artefak dan meningkatkan kualitas sinyal [8]. Selanjutnya, sinyal diproses melalui segmentasi dan dekomposisi ke dalam pita frekuensi utama seperti delta, theta, alpha, beta, dan gamma untuk proses ekstraksi fitur dan klasifikasi.

Meskipun dataset ini relevan untuk analisis ASD berbasis EEG, jumlah partisipan yang relatif kecil menjadi salah satu keterbatasan penelitian. Dataset hanya mencakup data dari sepuluh subjek sehingga berpotensi membatasi kemampuan generalisasi model serta meningkatkan risiko *overfitting*, khususnya pada model *machine learning* yang memerlukan jumlah data *training* yang lebih besar.

2.3 Fokus pada Celah Penelitian

Berdasarkan tinjauan pustaka yang telah dilakukan, terdapat celah penelitian dalam pemanfaatan teknik augmentasi data berbasis *Variational Autoencoder* (VAE) untuk analisis sinyal EEG. Beberapa penelitian sebelumnya telah menerapkan VAE untuk menghasilkan data EEG sintetis, khususnya dalam konteks tugas klasifikasi berbasis *motor imagery* menggunakan arsitektur seperti *2D Convolutional Neural Network* (CNN). Pendekatan tersebut menunjukkan bahwa data sintetis mampu meningkatkan performa model klasifikasi dengan memperkaya variasi data *training*. Meskipun demikian, fokus penelitian masih terbatas pada representasi sinyal dalam domain waktu atau spasial, tanpa mengeksplorasi secara mendalam karakteristik sinyal dalam domain frekuensi.

Di sisi lain, analisis berbasis domain frekuensi memiliki peran penting dalam studi EEG, terutama dalam mengidentifikasi pola osilasi neural yang berkaitan dengan kondisi neurologis seperti *Autism Spectrum Disorder* (ASD). Pemanfaatan data sintetis berbasis VAE pada representasi fitur frekuensi masih relatif terbatas, dan belum banyak dilakukan pengkajian terkait pengaruh augmentasi sinyal EEG terhadap kualitas fitur dan performa model klasifikasi berbasis *machine learning* konvensional.

Oleh karena itu, penelitian ini mengusulkan pendekatan yang mengintegrasikan teknik augmentasi data berbasis VAE dengan ekstraksi fitur domain frekuensi, serta memanfaatkan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) dan algoritma klasifikasi *XGBoost*. Pendekatan ini bertujuan untuk mengeksplorasi bagaimana

data sintetis yang dihasilkan pada domain frekuensi dapat meningkatkan kualitas representasi fitur serta performa klasifikasi ASD. Dengan mengisi celah ini, diharapkan penelitian ini dapat memberikan kontribusi dalam pengembangan metode klasifikasi EEG yang lebih robust dan akurat, khususnya pada kondisi dataset yang terbatas.

BAB 3

PERANCANGAN DAN IMPLEMENTASI SISTEM

Bab ini menyajikan metodologi penelitian dan perancangan teknis yang dilakukan untuk mengembangkan dan mengevaluasi sistem klasifikasi *Autism Spectrum Disorder* (ASD) berbasis sinyal EEG. Sistem yang dikembangkan pada penelitian ini bukan ditujukan untuk diimplementasikan secara langsung pada platform tertentu, melainkan sebagai sebuah lingkungan uji (*testbed*) yang terkontrol untuk mengevaluasi efektivitas pendekatan augmentasi data berbasis *Variational Autoencoder* (VAE), seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR), serta algoritma klasifikasi pada data EEG ASD.

Pembahasan pada bab ini dimulai dari Analisis Kebutuhan untuk mendefinisikan batasan masalah dan kebutuhan sistem. Fokus utama bab ini terletak pada Perancangan Arsitektur dan Alur Kerja Sistem yang menjelaskan tahapan pengolahan sinyal EEG, mulai dari prapemrosesan, augmentasi data menggunakan VAE, hingga proses klasifikasi. Arsitektur sistem divisualisasikan menggunakan diagram arsitektur dan *flowchart* untuk memberikan gambaran alur pemrosesan secara menyeluruh. Selanjutnya, bagian Detail Implementasi dan Teknologi menjabarkan realisasi arsitektur ke dalam bentuk implementasi kode dengan memanfaatkan beberapa library untuk pengolahan sinyal, pengembangan model generatif, serta proses klasifikasi. Bab ini kemudian ditutup dengan Perancangan Infrastruktur yang menjelaskan lingkungan komputasi dan *software dependencies* yang digunakan selama proses pengembangan dan pengujian model.

3.1 Analisis Kebutuhan Sistem VAE untuk Augmentasi EEG

Sebelum memulai perancangan arsitektur, tahap pertama yang dilakukan adalah menganalisis kebutuhan sistem. Analisis ini difokuskan pada kebutuhan penelitian yang berkaitan dengan pengembangan sistem klasifikasi ASD berbasis sinyal EEG dengan integrasi augmentasi data menggunakan *Variational Autoencoder* (VAE). Sistem yang dikembangkan ditujukan sebagai lingkungan uji (*testbed*) untuk mengevaluasi efektivitas augmentasi data sintetis terhadap performa model klasifikasi berbasis EEG.

3.1.1 Tujuan Sistem

Sistem dirancang untuk mengevaluasi pengaruh penggunaan data sintetis hasil augmentasi berbasis VAE terhadap performa klasifikasi ASD menggunakan sinyal EEG. Penelitian berfokus pada bagaimana data sintetis dapat meningkatkan variasi data *training* tanpa mengubah struktur utama *pipeline* klasifikasi.

3.1.2 Kebutuhan Sistem

Berdasarkan tujuan penelitian, sistem yang dirancang harus memenuhi beberapa kebutuhan berikut:

1. Sistem harus mampu melakukan preprocessing sinyal EEG dan menghasilkan representasi data yang konsisten untuk proses klasifikasi.
2. Sistem harus mampu menghasilkan sinyal EEG sintetis yang memiliki karakteristik statistik yang serupa dengan data asli tanpa hanya mereplikasi data *training* secara langsung.
3. Sistem harus mengimplementasikan model generatif berbasis *Variational Autoencoder* (VAE) untuk mempelajari distribusi laten data EEG dan menghasilkan data sintetis baru.
4. Data sintetis yang dihasilkan harus tetap kompatibel dengan *pipeline* klasifikasi berbasis ekstraksi fitur, seleksi fitur mRMR, dan klasifikasi menggunakan XGBoost maupun *Deep Neural Network*.
5. Sistem harus mampu melakukan evaluasi kualitas data sintetis menggunakan beberapa metrik evaluasi distribusi dan kemiripan data.

3.1.3 Batasan Sistem

Untuk menjaga fokus penelitian, sistem yang dikembangkan memiliki beberapa batasan sebagai berikut:


1. Dataset yang digunakan terbatas pada dataset EEG ASD yang telah dipilih pada penelitian ini.

2. Penelitian difokuskan pada augmentasi data berbasis VAE dan tidak melakukan perbandingan secara menyeluruh dengan model generatif lain seperti GAN maupun *diffusion model*.
3. Evaluasi sistem difokuskan pada kualitas data sintetis dan performa klasifikasi, bukan pada interpretasi klinis hasil diagnosis ASD.
4. Penelitian tidak membahas aspek perangkat keras akuisisi EEG maupun kualitas perangkat perekaman sinyal secara mendalam.
5. Proses *denoising*, *artifact removal*, dan teknik peningkatan kualitas sinyal lainnya tidak menjadi fokus utama penelitian dan mengikuti pendekatan prapemrosesan pada penelitian referensi yang digunakan.

3.2 Perancangan Arsitektur Sistem Augmentasi dan Klasifikasi EEG

Setelah kebutuhan fungsional sistem diuraikan, tahap selanjutnya adalah merancang arsitektur sistem sebagai representasi konseptual dari alur pemrosesan data yang akan diimplementasikan. Perancangan ini bertujuan untuk menggambarkan integrasi antar komponen dalam *pipeline*, khususnya dalam menggabungkan proses augmentasi data berbasis *Variational Autoencoder* (VAE) dengan *pipeline* klasifikasi yang telah ditentukan.

Pendekatan yang digunakan dalam penelitian ini mengadaptasi model EEG Data Augmentation using Variational Autoencoder [31] dengan melakukan penyesuaian dari implementasi berbasis representasi 2D menjadi pendekatan berbasis 1D Convolutional Neural Network (1D CNN), sehingga proses *training* model dilakukan pada setiap kanal EEG secara terpisah.



Gambar 3.1. Pipeline klasifikasi EEG dengan augmentasi data berbasis VAE


Gambar 3.1 menunjukkan alur pemrosesan data pada sistem yang dikembangkan dalam penelitian ini, yang mencakup tahap pra-pemrosesan dan ekstraksi fitur, augmentasi data menggunakan model *Variational Autoencoder* (VAE), serta proses klasifikasi. Proses dimulai dari data input berupa sinyal EEG yang melalui tahap pra-pemrosesan dan ekstraksi fitur sebelum diproses oleh model VAE untuk menghasilkan data sintetis yang memiliki karakteristik serupa dengan data asli.

Hasil tahap tersebut digunakan dalam dua skenario klasifikasi yang berbeda. Pada skenario pertama, proses klasifikasi dilakukan hanya menggunakan data asli, sedangkan pada skenario kedua, proses klasifikasi memanfaatkan kombinasi data asli dan data hasil augmentasi. Kedua skenario menggunakan kombinasi metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) algoritma klasifikasi XGBoost serta *Deep Neural Network* berdasarkan referensi penelitian sebelumnya [8]. Perbandingan kedua skenario bertujuan untuk mengevaluasi pengaruh penggunaan data sintetis terhadap performa model klasifikasi yang dihasilkan.

3.2.1 Pra-Pemrosesan Dataset

Tahap pra-pemrosesan dalam pengolahan sinyal EEG untuk memastikan bahwa data yang digunakan berada dalam kondisi yang representatif dan siap diproses oleh model. Tahap ini bertujuan untuk meningkatkan kualitas sinyal serta menyiapkan data dalam bentuk

yang terstruktur untuk diproses pada model augmentasi.



Gambar 3.2. Diagram aliran proses prapemrosesan sistem

Gambar 3.2 menggambarkan alur proses pada tahap pra-pemrosesan data EEG. Proses diawali dengan penanganan nilai yang hilang (missing values) menggunakan fungsi `dropna()` berdasarkan kelengkapan data pada setiap kanal EEG, sehingga hanya data yang memiliki informasi lengkap yang digunakan pada tahap selanjutnya.

Setelah itu, sinyal EEG dibagi menjadi beberapa segmen menggunakan metode sliding window segmentation dengan durasi 50 sekon dan overlap sebesar 50

Setiap segmen kemudian diproses menggunakan bandpass filtering berbasis Butterworth dengan rentang frekuensi 0,1–40 Hz. Proses ini bertujuan untuk mempertahankan komponen frekuensi EEG yang relevan serta mengurangi gangguan berupa low-frequency drift dan high-frequency noise yang dapat memengaruhi kualitas sinyal.

Selanjutnya dilakukan deteksi artefak untuk mengidentifikasi segmen yang terkontaminasi oleh gangguan seperti pergerakan otot, kedipan mata, atau noise lainnya. Deteksi dilakukan menggunakan dua kriteria, yaitu nilai peak-to-peak amplitude dengan ambang

batas 200 μV dan z-score thresholding dengan ambang batas lebih dari 5. Segmen yang teridentifikasi mengandung artefak kemudian dihapus pada tahap *remove bad segments* sehingga hanya segmen dengan kualitas sinyal yang baik yang dipertahankan.

Setelah proses pembersihan data selesai, dilakukan normalisasi menggunakan metode z-score normalization untuk menyeragamkan distribusi data pada setiap kanal dan meningkatkan stabilitas proses pelatihan model. Data yang telah dinormalisasi kemudian disusun ulang ke dalam bentuk tensor tiga dimensi sehingga siap digunakan pada tahap pelatihan maupun evaluasi model.


3.2.2 Arsitektur Model VAE untuk Augmentasi Data

Model *Variational Autoencoder* (VAE) digunakan sebagai metode augmentasi untuk menghasilkan sinyal EEG sintetis yang memiliki karakteristik statistik serupa dengan data asli. Penelitian ini mengadaptasi arsitektur dari penelitian [31] yang menggunakan VAE untuk menghasilkan sinyal EEG sintetis untuk tugas klasifikasi *motor imagery* dan menganalisis pengaruhnya terhadap performa klasifikasi. Beberapa penyesuaian dilakukan pada representasi data dan struktur model agar sesuai dengan kebutuhan penelitian ini. Representasi data EEG dilakukan menggunakan pendekatan *1D Convolutional Neural Network* (1D CNN) dengan pemrosesan setiap kanal EEG secara terpisah. Penyesuaian ini dilakukan berdasarkan hasil pengujian awal yang menunjukkan bahwa pendekatan multikanal belum mampu merekonstruksi detail pola temporal sinyal EEG secara optimal. Melalui pendekatan tersebut, sinyal EEG direpresentasikan sebagai deret waktu satu dimensi sehingga diharapkan model dapat mempelajari karakteristik sinyal secara lebih spesifik pada masing-masing kanal. Pendekatan ini juga mengacu pada penelitian referensi [8] yang memproses sinyal EEG per kanal, sehingga lebih sesuai dengan karakteristik data dan kompatibel dengan *pipeline* klasifikasi yang digunakan dalam penelitian ini.

Model Variational Autoencoder (VAE) yang digunakan pada penelitian ini terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*. Input berupa segmen sinyal EEG satu channel, baik sintetis maupun asli yang telah melalui alur *preprocessing* diproses oleh bagian *encoder* menggunakan beberapa lapisan *Conv1D* yang diikuti oleh *batch normalization* dan fungsi aktivasi *LeakyReLU*. Proses ini bertujuan untuk mengekstraksi representasi fitur berdimensi lebih rendah dari sinyal input. Representasi tersebut kemudian

dipetakan ke dalam dua parameter distribusi laten, yaitu *mean* (z_{mean}) dan variansi log-arithmik (z_{logvar}). Selanjutnya dilakukan proses *reparameterization* untuk menghasilkan vektor laten z , sehingga model dapat dilatih menggunakan mekanisme *backpropagation* secara *end-to-end*.

Vektor laten yang dihasilkan kemudian digunakan sebagai input bagi bagian *decoder* untuk merekonstruksi kembali sinyal EEG. Decoder terdiri dari beberapa lapisan *upsampling* dan *Conv1D* yang secara bertahap mengembalikan dimensi sinyal hingga sesuai dengan bentuk input awal. Setelah proses *training*, model dimanfaatkan untuk menghasilkan data sintetis baru dengan melakukan *sampling* acak pada ruang laten menggunakan distribusi normal standar. Vektor laten hasil *sampling* tersebut diberikan ke *decoder* untuk menghasilkan sinyal EEG sintetis yang tidak identik dengan data asli, namun tetap mempertahankan karakteristik distribusi statistiknya. Arsitektur lengkap model VAE yang digunakan ditunjukkan pada gambar 3.3.




Gambar 3.3. Rancangan arsitektur Variational Autoencoder (VAE) untuk augmentasi data EEG

Proses perhitungan parameter distribusi laten serta mekanisme *reparameterization* yang digunakan untuk menghasilkan vektor laten z dijelaskan lebih rinci pada Subbab 3.3.2.2 mengenai *Reparameterization Layer*.

Dalam proses *training*, model dioptimalkan menggunakan fungsi objektif *Evidence Lower Bound* (ELBO), yang terdiri atas dua komponen utama, yaitu *reconstruction loss* dan *Kullback-Leibler* (KL) divergence. *Reconstruction loss* digunakan untuk mengukur kemampuan *decoder* dalam merekonstruksi sinyal EEG sehingga mendekati sinyal input asli. Sementara itu, KL divergence berfungsi sebagai regularisasi yang mendorong distribusi laten yang dihasilkan *encoder*, yang direpresentasikan oleh z_{mean} dan $z_{\text{log_var}}$, agar tetap mendekati distribusi normal standar. Ruang laten yang terstruktur memungkinkan model tidak hanya merepresentasikan karakteristik data EEG secara efektif, tetapi juga menghasilkan sampel sintetis baru yang realistis melalui proses *sampling*. Detail formulasi matematis, perhitungan masing-masing komponen *loss*, serta mekanisme optimasi yang digunakan selama proses pelatihan dijelaskan lebih rinci pada Subbab 3.3.2.4 mengenai *Loss Function* dan *Proses Training*.

3.2.3 Arsitektur Model Klasifikasi

Bagian ini menjelaskan model klasifikasi yang berfungsi untuk memanfaatkan data EEG, baik asli dan sintetis untuk melakukan proses klasifikasi ASD. Model ini dirancang sebagai sebuah alur pemrosesan bertahap yang mengubah sinyal menjadi representasi fitur yang lebih informatif hingga menghasilkan keluaran kelas.



Gambar 3.4. Pipeline model klasifikasi

Berdasarkan Gambar 3.4, *pipeline* klasifikasi yang digunakan terdiri dari beberapa tahapan utama, yaitu dekomposisi frekuensi, standardisasi data, ekstraksi fitur statistik, seleksi fitur, dan klasifikasi. Pada tahap awal, sinyal EEG dipisahkan ke dalam lima pita frekuensi utama, yaitu delta, theta, alpha, beta, dan gamma untuk menangkap karakteristik aktivitas otak pada rentang frekuensi yang berbeda.

Setelah proses dekomposisi, setiap pita frekuensi distandardisasi menggunakan transformasi *z-score*. Tahapan ini bertujuan untuk menyamakan skala data antar pita frekuensi sehingga distribusi data menjadi lebih stabil dan seimbang pada proses pembelajaran model.

Tahap berikutnya adalah ekstraksi fitur statistik untuk mengubah sinyal EEG menjadi representasi numerik yang lebih terstruktur. Fitur yang dihasilkan merepresentasikan karakteristik sinyal pada masing-masing pita frekuensi dan digunakan sebagai input pada tahap klasifikasi.

Seleksi fitur dilakukan menggunakan algoritma *minimum Redundancy Maximum Relevance* (mRMR) untuk memilih fitur yang paling relevan terhadap kelas sekaligus mengurangi redundansi antar fitur. Hasil seleksi menghasilkan subset fitur yang lebih ringkas dan informatif.

Tahap akhir dilakukan menggunakan algoritma XGBoost dan *Deep Neural Network* sebagai model klasifikasi. Proses klasifikasi dilakukan pada dua skenario, yaitu menggunakan data asli dan kombinasi data asli dengan data sintetis hasil augmentasi. Kedua skenario menggunakan *pipeline* yang sama sehingga pengaruh penggunaan data sintetis dapat dianalisis secara langsung.

3.3 Detail Implementasi dan Teknologi pada Model Augmentasi dan Klasifikasi EEG

Bagian ini menjelaskan bagaimana perancangan sistem yang telah dijabarkan sebelumnya diterapkan ke dalam kode serta teknologi yang digunakan untuk mengimplementasikannya. Penjelasan pada bagian ini mencakup teknologi dan *library* yang digunakan, serta gambaran umum implementasi dari komponen utama dalam *pipeline*, termasuk pemrosesan sinyal EEG, ekstraksi dan seleksi fitur, modul augmentasi berbasis *Variational Autoencoder* (VAE), serta model klasifikasi.

3.3.1 Teknologi dan Library

Dalam penelitian ini, seluruh proses pengolahan data, *training*, dan evaluasi model dilakukan menggunakan bahasa pemrograman Python karena didukung oleh ekosistem *library* yang luas untuk kebutuhan *machine learning* dan pemrosesan sinyal. Untuk meningkatkan efisiensi komputasi, sistem memanfaatkan akselerasi GPU menggunakan CUDA Toolkit dari NVIDIA sehingga proses *training* model dan operasi numerik berskala besar dapat dilakukan dengan lebih cepat.

Library utama yang digunakan meliputi NumPy, Pandas, SciPy, dan scikit-learn. NumPy digunakan untuk komputasi numerik berbasis array dan matriks, Pandas untuk pengelolaan dataset, SciPy untuk pemrosesan sinyal EEG, sedangkan scikit-learn digunakan pada tahap *preprocessing*, ekstraksi fitur, seleksi fitur, dan evaluasi model.

Pada tahap pemodelan, digunakan XGBoost dan *Deep Neural Network* (DNN) sebagai model klasifikasi dalam penelitian ini. Implementasi model DNN serta model augmentasi *Variational Autoencoder* (VAE) dilakukan menggunakan TensorFlow dan Keras dengan dukungan akselerasi GPU untuk proses augmentasi data, sedangkan implementasi XGBoost dilakukan menggunakan library *scikit-learn* dan *XGBoost*.


Dalam implementasi *pipeline* klasifikasi, SciPy digunakan untuk proses dekomposisi frekuensi dan pemrosesan sinyal, sementara NumPy dan Pandas digunakan untuk pengelolaan data serta perhitungan fitur statistik. Fitur yang dihasilkan kemudian diseleksi menggunakan metode *minimum Redundancy Maximum Relevance* (mRMR) sebelum digunakan dalam proses *training* dan evaluasi menggunakan model XGBoost dan DNN.

3.3.2 Implementasi Model Generatif Variational Autoencoder (VAE)

Perancangan model generatif pada penelitian ini dilakukan menggunakan pendekatan *Variational Autoencoder* (VAE) yang bertujuan untuk mempelajari distribusi laten dari sinyal EEG serta menghasilkan data sintetis yang menyerupai data asli. Arsitektur model secara umum terdiri dari dua bagian utama, yaitu *encoder* dan *decoder*. Model menerima input berupa sinyal EEG satu dimensi dengan panjang 512 sampel dan satu kanal, sehingga berbentuk (512, 1). Jumlah sampel tersebut diperoleh dari proses segmentasi dengan durasi 4 detik pada frekuensi sampling 128 Hz ($4 \times 128 = 512$).

3.3.2.1 Arsitektur *Layer Encoder*

Layer encoder dirancang menggunakan beberapa lapisan *Conv1D* untuk mengekstraksi pola temporal dari sinyal EEG. Setiap lapisan menggunakan *stride* sebesar 2 untuk melakukan downsampling secara bertahap.



Gambar 3.5. Arsitektur *layer encoder* pada model VAE

Tabel 3.1. Arsitektur *encoder VAE*

Tahap	Nama Layer	Ukuran Data	Penjelasan Teknis
Input	Raw EEG	(512,1)	512 titik data (4 detik) sebagai input mentah.
L1	Conv Block 1	(256,32)	Digunakan 32 kernel untuk mengekstrak fitur temporal dasar.
L2	Conv Block 2	(128,64)	Digunakan 64 kernel untuk menangkap ritme gelombang yang lebih kompleks.
L3	Conv Block 3	(64,128)	Digunakan 128 kernel untuk mengenali <i>neural signatures</i> .
Bridge	Flatten	8192	Transformasi data 2D dari hasil ekstraksi kernel menjadi vektor 1D.
Bottleneck 1	Dense 64	64	Integrasi global: meringkas 8192 fitur menjadi 64 fitur utama.
Bottleneck 2	Latent Space 16	16	Output akhir berupa 16 nilai z_{mean} dan 16 nilai z_{latent} sebagai distribusi laten.

Sebagaimana ditunjukkan pada Gambar 3.5 dan Tabel 3.1, arsitektur *encoder* menggunakan tiga blok konvolusi dengan jumlah filter 32, 64, dan 128. Ukuran kernel yang relatif besar (15–25) dipilih untuk menangkap pola temporal EEG yang memiliki karakteristik frekuensi rendah hingga menengah. Proses downsampling dilakukan melalui stride pada setiap lapisan konvolusi, sehingga representasi semakin ringkas dan informatif.

Setiap blok konvolusi diikuti oleh Batch Normalization untuk menstabilkan distribusi aktivasi selama *training*, mempercepat konvergensi, serta mengurangi masalah internal covariate shift. Setelah normalisasi, digunakan fungsi aktivasi LeakyReLU dengan parameter 0.2, yang berarti gradien kecil sebesar 0.2 tetap dipertahankan untuk nilai negatif, sehingga menjaga aliran gradien tetap stabil.

Padding yang digunakan adalah “same”, yang menjaga ukuran temporal output tetap proporsional dengan input sebelum proses downsampling oleh stride dilakukan, sehingga informasi di tepi sinyal tetap dipertahankan secara optimal.

Dimensi laten ditetapkan sebesar 16 sebagai kompromi antara kapasitas representasi dan stabilitas *training*, sehingga model mampu menangkap struktur penting data tanpa menyebabkan overfitting atau kehilangan informasi yang signifikan.

Algoritma 3.1. Algoritma proses konvolusi pada encoder model VAE

```

1  # =====
2  # Convolution Encoder Blocks
3  # =====
4
5  for each encoder block:
6
7      for each convolution filter:
8
9          for each temporal position in feature map:
10
11              extract signal segment
12
13              multiply segment with kernel weights
14
15              sum multiplication results
16
17              store output into feature map
18
19      reduce temporal dimension using stride = 2
20
21      normalize feature map distribution
22
23      apply LeakyReLU activation


```

Berdasarkan algoritma 3.1, setiap *encoder block* memproses sinyal EEG melalui operasi konvolusi menggunakan sejumlah filter untuk mengekstraksi pola temporal dari sinyal input. Kernel konvolusi digeser sepanjang dimensi temporal sinyal untuk menghasilkan *feature map* yang merepresentasikan karakteristik penting pada setiap rentang waktu.

Setelah proses konvolusi, dilakukan reduksi dimensi temporal menggunakan *stride* sebesar 2 sehingga ukuran representasi fitur menjadi lebih kecil pada setiap blok. Hasil konvolusi kemudian dinormalisasi menggunakan Batch Normalization sebelum diterapkan fungsi aktivasi LeakyReLU untuk menjaga stabilitas distribusi aktivasi dan mempertahankan aliran gradien selama *training*.

3.3.2.2 Reparameterization Layer

Lapisan Sampling menghasilkan vektor laten z dengan menggabungkan dua parameter yang dipelajari oleh *encoder*, yaitu z_{mean} dan $z_{\text{log var}}$. Proses ini membuat representasi laten bersifat probabilistik, sehingga model tidak hanya menghasilkan satu nilai tetap, tetapi sebuah distribusi.



Gambar 3.6. Arsitektur reparameterization layer pada model VAE

Sebagaimana ditunjukkan pada Gambar 3.6, *reparameterization layer*, pada tahap ini digunakan variabel acak ϵ (*epsilon*), yang diambil dari distribusi normal standar dengan mean 0 dan variansi 1. Noise ini berfungsi untuk memperkenalkan unsur *stochastic* dalam proses *sampling*, sehingga setiap *forward pass* dapat menghasilkan representasi z yang sedikit berbeda meskipun input sama.


Nilai z dihitung menggunakan teknik *reparameterization trick*, yaitu:

$$z = z_{\text{mean}} + \exp(0.5 \cdot z_{\log \text{var}}) \cdot \epsilon \quad (3.1)$$

Faktor $\exp(0.5 \cdot z_{\log \text{var}})$ merepresentasikan standar deviasi dari distribusi yang dipelajari, sehingga noise ϵ diskalakan dengan tingkat ketidakpastian data. Pendekatan ini memungkinkan proses *sampling* tetap dapat dioptimalkan menggunakan *backpropagation*.

3.3.2.3 Arsitektur Layer Decoder

Layer decoder dirancang untuk merekonstruksi kembali representasi laten menjadi sinyal EEG dengan dimensi yang sama seperti data input. Setiap *layer* menggunakan mekanisme *upsampling* melalui *Conv1DTranspose* untuk meningkatkan dimensi temporal secara bertahap. Proses ini mengembalikan informasi yang telah dikompresi oleh *encoder* dengan mempertahankan karakteristik pola temporal sinyal EEG.



Gambar 3.7. Arsitektur *layer decoder* pada model VAE

Tabel 3.2. Arsitektur *decoder* VAE

Tahap	Nama Layer	Ukuran Data	Penjelasan Teknis
Input	Latent Vector	16	Vektor laten 16-dimensi (hasil sampling).
L4	Dense & Reshape	(64, 128)	Ekspansi awal kembali ke dimensi fitur (64 length $\times$ 128 depth).
L5 (A)	Conv1DTranspose 1	(128, 64)	64 kernel bekerja melakukan upsampling untuk memperpanjang durasi sinyal.
L5 (B)	Conv1DTranspose 2	(256, 32)	32 kernel menyusun detail bentuk gelombang EEG.
Output	Reconstruction	(512, 1)	1 kernel terakhir menggabungkan semua fitur menjadi satu sinyal utuh.

Sebagaimana ditunjukkan pada Gambar 3.7 dan Tabel 3.2, *decoder* bertugas merekonstruksi sinyal EEG dari representasi laten yang dihasilkan oleh proses *encoding*. Arsitektur *decoder* terdiri atas lapisan *dense*, proses *reshape*, serta beberapa blok *Conv1DTranspose* yang secara bertahap mengembalikan dimensi data hingga menghasilkan sinyal EEG rekonstruksi dengan ukuran yang sama seperti data input.

Algoritma 3.2. Algoritma ekspansi representasi laten pada decoder model VAE.

```

1  # =====
2  # Latent Feature Expansion
3  # =====
4
5  receive latent vector z
6
7  map latent vector into higher-dimensional representation
8
9  generate dense feature representation
10
11 reshape dense representation into feature map
12
13 prepare feature map for reconstruction process

```

Berdasarkan algoritma 3.2, proses decoder dimulai dengan mengubah vektor laten menjadi representasi berdimensi lebih tinggi menggunakan lapisan *dense*. Representasi tersebut kemudian diubah kembali ke bentuk *feature map* sehingga dapat diproses pada tahap rekonstruksi sinyal oleh blok konvolusi decoder.

Algoritma 3.3. Algoritma proses rekonstruksi sinyal pada decoder model VAE.

```

1 # =====
2 # Decoder Convolution Blocks
3 # =====
4
5 for each decoder block:
6
7     increase temporal dimension using upsampling
8
9     for each convolution filter:
10
11         for each temporal position in feature map:
12
13             extract signal segment
14
15             multiply segment with kernel weights
16
17             sum multiplication results
18
19             store output into feature map
20
21         normalize feature map distribution
22
23     apply activation function

```

Berdasarkan algoritma 3.3, setiap *decoder block* meningkatkan dimensi temporal menggunakan proses *upsampling* sebelum dilakukan operasi konvolusi untuk memben-tuk kembali pola temporal sinyal EEG. Kernel konvolusi digeser sepanjang *feature map* untuk menghasilkan representasi sinyal yang semakin mendekati bentuk asli.

Hasil konvolusi pada setiap tahap kemudian dinormalisasi menggunakan Batch Normalization sebelum diterapkan fungsi aktivasi untuk menjaga stabilitas distribusi aktivasi selama proses rekonstruksi. Pada tahap *signal reconstruction*, dilakukan konvolusi akhir pada setiap posisi temporal *feature map* untuk menghasilkan kembali sinyal EEG rekon-struksi dengan jumlah kanal yang sama seperti data input.

3.3.2.4 Loss Function dan Proses Training

Reconstruction loss digunakan untuk mengukur tingkat kemiripan antara sinyal EEG input dan hasil rekonstruksi yang dihasilkan oleh *decoder*. Pada penelitian ini, *reconstruction loss* dihitung menggunakan *Mean Squared Error* (MSE) setelah tensor input dan output rekonstruksi diubah menjadi vektor satu dimensi (*flatten*). Secara matematis, nilai MSE dapat dinyatakan sebagai:

$$L_{\text{rec}} = \frac{1}{N} \sum_{i=1}^N (x_i - \hat{x}_i)^2 \quad (3.2)$$

dengan x_i menyatakan nilai sinyal asli pada elemen ke- i , $\hat{x}_i$ menyatakan nilai hasil rekonstruksi, dan N merupakan jumlah elemen dalam satu sampel. Untuk menyesuaikan skala kontribusinya terhadap fungsi objektif total, nilai *reconstruction loss* dikalikan dengan faktor 512 sehingga diperoleh:

$$L_{\text{rec}}^* = 512 \times L_{\text{rec}} \quad (3.3)$$

KL divergence berfungsi sebagai komponen regularisasi yang mengarahkan distribusi laten yang dihasilkan oleh *encoder* agar mendekati distribusi normal standar $\mathcal{N}(0, 1)$. Pada model VAE, *encoder* tidak secara langsung menghasilkan vektor laten z , melainkan menghasilkan parameter distribusi laten berupa nilai rata-rata μ (z_mean) dan log-variansi $\log \sigma^2$ (z_log_var). Berdasarkan kedua parameter tersebut, nilai *KL divergence* dihitung untuk mengukur seberapa jauh distribusi laten yang dipelajari model menyimpang dari distribusi normal standar. Nilai *KL divergence* dirumuskan sebagai:

$$L_{\text{KL}} = -\frac{1}{2} \sum_{j=1}^d (1 + \log \sigma_j^2 - \mu_j^2 - \sigma_j^2) \quad (3.4)$$

dengan d menyatakan dimensi ruang laten. Komponen ini berfungsi sebagai regularisasi yang mendorong distribusi laten tetap mendekati distribusi normal standar sehingga ruang laten menjadi lebih terstruktur dan dapat digunakan untuk proses generasi data sintetis.

Fungsi objektif yang dioptimalkan selama proses pelatihan merupakan penjumlahan dari kedua komponen tersebut, yang secara ekuivalen merepresentasikan proses maksimalisasi *Evidence Lower Bound* (ELBO). Total loss dirumuskan sebagai:

$$L_{\text{total}} = L_{\text{rec}}^* + L_{\text{KL}} \quad (3.5)$$

Nilai *loss* kemudian dirata-ratakan terhadap seluruh sampel dalam satu *batch* dan ditambahkan sebagai *custom loss* pada model. Dengan formulasi ini, model didorong untuk menghasilkan rekonstruksi yang akurat sekaligus mempertahankan distribusi ruang laten


yang teratur.

Proses *training* dilakukan menggunakan optimizer Adam dengan *learning rate* sebesar 0,001, *batch size* 32, dan maksimum 1000 *epoch*. Selama pelatihan, parameter model diperbarui secara iteratif untuk meminimalkan fungsi objektif sehingga diperoleh representasi laten yang mampu merekonstruksi sinyal EEG dengan baik sekaligus mendukung proses generasi data sintetis.

3.3.2.5 Generasi Data Sintetis

Proses generasi data sintetis dilakukan melalui proses sampling pada ruang laten. Secara prinsip, karena distribusi laten telah dipaksa mendekati distribusi normal standar selama training, maka sampling dapat dilakukan dengan menghasilkan vektor acak dari distribusi Gaussian $\mathcal{N}(0, 1)$ dengan dimensi yang sesuai (misalnya 16 dimensi laten). Proses sampling ini dapat dilakukan secara berulang sehingga model mampu menghasilkan jumlah sampel sintetis sesuai kebutuhan proses augmentasi.

Vektor laten acak ini kemudian diberikan sebagai input ke bagian *decoder* dari model. Decoder akan memetakan representasi laten tersebut kembali ke ruang data asli, sehingga menghasilkan sampel baru yang secara statistik menyerupai data *training*. Proses ini memungkinkan model untuk menghasilkan variasi data yang tidak identik dengan data asli, namun tetap mempertahankan karakteristik distribusinya.



Gambar 3.8. Diagram aliran generasi data sintetis

Sebagaimana yang ditunjukkan oleh diagram 3.9 proses generasi data sintetis dilakukan secara terpisah untuk setiap kanal EEG dan setiap kelas data. Dengan menggunakan 16 kanal EEG serta dua kategori kelas (*normal* dan ASD), maka dibangun sebanyak 32 model VAE yang masing-masing dilatih secara spesifik terhadap distribusi data pada kanal dan kelas tertentu.

Data sintetis yang dihasilkan selanjutnya digunakan sebagai bentuk *data augmen-*

tation dalam pipeline klasifikasi. Dengan menambahkan sampel sintetis ke dalam data *training*, diharapkan model klasifikasi dapat meningkatkan kemampuan generalisasi, terutama dalam kondisi keterbatasan jumlah data asli.

3.3.3 Implementasi Model Klasifikasi

Pada bagian ini dijelaskan proses implementasi data EEG sintetis hasil augmentasi menggunakan Variational Autoencoder (VAE) ke dalam tahapan klasifikasi sesuai dengan metode yang digunakan pada penelitian acuan. Selain itu, bagian ini juga membahas konfigurasi dan parameter yang digunakan pada model klasifikasi, meliputi proses pembagian data, pemilihan fitur, serta pengaturan parameter pada algoritma Deep Neural Network (DNN) dan Extreme Gradient Boosting (XGBoost) yang digunakan untuk mengevaluasi pengaruh penambahan data sintetis terhadap performa klasifikasi ASD.


3.3.3.1 Integrasi Data Sintetis pada Model Klasifikasi

Pada proses generasi data sintetis, sebanyak 32 model VAE independen digunakan untuk menghasilkan sinyal EEG sintetis berdasarkan kombinasi 16 kanal EEG dan dua kelas data (*normal* dan ASD). Setiap model menghasilkan sinyal sintetis untuk satu kanal tertentu, kemudian seluruh kanal hasil generasi digabungkan kembali menjadi sampel EEG multikanal lengkap.

Data sintetis yang dihasilkan kemudian digabungkan dengan data EEG asli sebagai bentuk data augmentation. Dataset gabungan selanjutnya melalui tahap feature extraction untuk memperoleh representasi yang lebih informatif dari sinyal EEG. Fitur yang dihasilkan kemudian digunakan sebagai input pada tahap klasifikasi untuk mempelajari pola dalam data dan menghasilkan prediksi sesuai dengan tujuan analisis.

Sebagaimana yang ditunjukkan oleh diagram 3.9 proses generasi data sintetis dilakukan secara terpisah untuk setiap kanal EEG dan setiap kelas data. Dengan menggunakan 16 kanal EEG serta dua kategori kelas (*normal* dan ASD), maka dibangun sebanyak 32 model VAE yang masing-masing dilatih secara spesifik terhadap distribusi data pada kanal dan kelas tertentu. Terdapat perbedaan perlakuan data asli dan sintetis, yang dikarenakan model VAE dilatih menggunakan data yang telah melalui proses pra-pemrosesan. Oleh karena itu, data sintetis yang dihasilkan oleh model VAE dapat secara langsung

menuju proses feature extraction sedangkan data asli perlu melalui proses pra-pemrosesan terlebih dahulu. Perbedaan perlakuan kedua jenis data tergambar pada diagram arsitektur klasifikasi 3.4.



Gambar 3.9. Pipeline integrasi data sintesis pada proses klasifikasi

3.3.3.2 *Minimum Redundancy Maximum Relevance (mRMR)*

Minimum Redundancy Maximum Relevance (mRMR) diimplementasikan melalui *library feature_engine.selection* menggunakan kelas *mRMR*. Label kelas terlebih dahulu dikonversi ke bentuk numerik menggunakan *LabelEncoder* dari *sklearn.preprocessing* melalui operasi *fit_transform*, sehingga menghasilkan representasi biner yang dapat digunakan

dalam proses seleksi fitur.

Fitur yang digunakan berasal dari kombinasi kanal EEG dan jenis fitur hasil ekstraksi *Discrete Wavelet Transform* (DWT). Penamaan kolom dibentuk secara eksplisit melalui iterasi terhadap daftar kanal (*ch_names*) dan jenis fitur (*DWT_FEAT*), sehingga setiap fitur memiliki format *channel_feature*. Seluruh fitur kemudian dikonversi ke dalam struktur *pandas DataFrame* (*dfX*) untuk memastikan kompatibilitas dengan metode *MRMR*.

3.3.3.3 Model *XGBoost*

Model *XGBoost* pada penelitian ini menggunakan konfigurasi hyperparameter sebagaimana dalam proses *training* model untuk menghasilkan prediksi pada data uji. Konfigurasi hyperparameter *XGBoost* yang digunakan dalam penelitian ditunjukkan pada Tabel 3.3.

Tabel 3.3. Konfigurasi hyperparameter *XGBoost*


Parameter	Nilai
use_label_encoder	False
eval_metric	logloss
n_estimators	100
learning_rate	0.3
max_depth	6
subsample	1.0
colsample_bylevel	1.0
reg_alpha	0
reg_lambda	1

Pembagian data dilakukan menggunakan *train_test_split* dengan parameter *test_size=0.2*, *stratify=y_enc*, dan *random_state=42*. Model kemudian dilakukan *training* menggunakan data *training* dan digunakan untuk menghasilkan prediksi label serta probabilitas pada data *testing*. Hasil prediksi selanjutnya dievaluasi menggunakan *confusion matrix*, *classification report*, serta *ROC curve* dan *AUC score*.

3.3.3.4 Model *Deep Neural Network*

Sebagaimana ditunjukkan pada Gambar 3.10, model *Deep Neural Network* (DNN) yang digunakan dalam penelitian ini merupakan model *feedforward neural network* sederhana

yang terdiri dari tiga lapisan utama, yaitu lapisan input, satu *hidden layer*, dan lapisan output. *Hidden layer* terdiri dari 5 neuron dengan fungsi aktivasi *log-sigmoid* yang digunakan untuk memperkenalkan non-linearitas serta membatasi output neuron pada rentang (0,1). Lapisan output menggunakan fungsi aktivasi *softmax* yang menghasilkan distribusi probabilitas untuk masing-masing kelas sesuai dengan jumlah kelas ($n_classes$).



Gambar 3.10. Arsitektur model *Deep Neural Network* (DNN) yang digunakan dalam penelitian

Proses *training* model dilakukan menggunakan algoritma optimasi Adam dengan laju pembelajaran sebesar 10^{-3} dan *loss function binary crossentropy*. Model dilatih selama 100 *epoch* dengan ukuran *batch* sebesar 32, serta dilengkapi dengan mekanisme *early stopping* dan *model checkpoint* untuk mengurangi risiko *overfitting* dan mempertahankan model dengan performa terbaik selama proses *training*.

BAB 4

EKSPERIMEN DAN ANALISIS

Bab ini membahas eksperimen untuk menguji performa model klasifikasi EEG dengan augmentasi data berbasis *Variational Autoencoder* (VAE). Eksperimen difokuskan pada analisis kualitas data sintetis yang dihasilkan serta pengaruhnya terhadap performa klasifikasi Autism Spectrum Disorder (ASD). Pembahasan mencakup spesifikasi sistem yang digunakan, skenario pengujian, proses augmentasi data, serta metrik evaluasi untuk menilai kualitas data sintetis dan performa model klasifikasi.

4.1 Lingkungan Training

Bagian ini menjelaskan spesifikasi perangkat keras dan perangkat lunak yang digunakan dalam proses preprocessing sinyal EEG, training model VAE, generasi data sintetis, serta *training* dan evaluasi model klasifikasi.

4.1.1 Spesifikasi Perangkat Keras

Eksperimen dilakukan pada perangkat pribadi yang dilengkapi dengan RAM 16 GB berjenis DDR4 3200 MT/s dengan konfigurasi 2×8 GB. Proses *training* model diakselerasi menggunakan GPU NVIDIA GeForce RTX 3050 Laptop GPU dengan VRAM 4 GB, yang memungkinkan eksekusi paralel pada operasi tensor selama proses training model deep learning dan pemrosesan sinyal EEG. Sistem menggunakan prosesor Intel Core i5-12500H generasi ke-12 dengan 12 core dan 16 thread pada frekuensi dasar 3.10 GHz. Spesifikasi lengkap perangkat keras eksperimen disajikan pada Tabel 4.1.

Tabel 4.1. Spesifikasi Perangkat Keras Eksperimen

Komponen	Spesifikasi
CPU	Intel Core i5-12500H (12 Cores, 16 Threads, @ 3.10 GHz)
GPU	NVIDIA GeForce RTX 3050 Laptop GPU (4 GB VRAM)
RAM	16 GB (2×8 GB) DDR4 3200 MT/s
Arsitektur	x86_64

4.1.2 Spesifikasi Perangkat Lunak

Untuk lingkungan perangkat lunak, sistem dibangun di atas Python 3.9 dengan memanfaatkan TensorFlow (v2.10.0) sebagai framework utama dalam implementasi model *Variational Autoencoder* (VAE). Selain itu, Scikit-learn (v1.6.1), Feature-engine (v1.9.4), dan XGBoost (v2.1.4) digunakan dalam proses preprocessing, seleksi fitur, serta klasifikasi data EEG. Proses pengolahan sinyal dan ekstraksi fitur didukung oleh SciPy (v1.13.1), sedangkan pengolahan data numerik dan visualisasi dilakukan menggunakan NumPy (v1.23.5), Pandas (v2.3.3), dan Matplotlib (v3.7.3). Spesifikasi lengkap lingkungan perangkat lunak disajikan pada Tabel 4.2.

Tabel 4.2. Spesifikasi Lingkungan Perangkat Lunak

Perangkat Lunak / Library	Versi	Peran dalam Arsitektur Sistem
Python	3.9.25	Bahasa pemrograman utama yang digunakan untuk implementasi seluruh pipeline sistem.
TensorFlow	2.10.0	Implementasi dan pelatihan model VAE, termasuk encoder, decoder, dan proses optimisasi model.
Scikit-learn	1.6.1	Preprocessing data, seleksi fitur, pembagian data latih-uji, evaluasi model, serta utilitas machine learning lainnya.
XGBoost	2.1.4	Algoritma klasifikasi untuk mendeteksi kondisi epilepsi berdasarkan fitur hasil ekstraksi dan rekonstruksi sinyal EEG.
Feature-engine	1.9.4	Seleksi dan transformasi fitur pada tahap preprocessing sebelum proses klasifikasi.
SciPy	1.13.1	Pengolahan sinyal EEG dan perhitungan matematis yang mendukung ekstraksi fitur domain waktu maupun frekuensi.
NumPy	1.23.5	Operasi komputasi numerik, manipulasi array, dan representasi data EEG selama pemrosesan.
Pandas	2.3.3	Pengelolaan dataset, operasi data tabular, dan penyimpanan hasil preprocessing maupun ekstraksi fitur.
Matplotlib	3.7.3	Visualisasi sinyal EEG, kurva pelatihan model, serta penyajian hasil eksperimen dan evaluasi.

4.2 Standarisasi Pengujian Eksperimen

Bagian ini menjelaskan metrik evaluasi yang digunakan untuk menilai performa model klasifikasi serta kualitas data sintetis yang dihasilkan dalam eksperimen. Variabel kontrol diterapkan untuk menjaga konsistensi proses preprocessing, konfigurasi model, dan parameter *training* pada seluruh skenario pengujian. Variabel bebas pada penelitian ini adalah penggunaan data sintetis hasil augmentasi berbasis *Variational Autoencoder* (VAE), sedangkan variabel terikat berupa performa klasifikasi dan kualitas data sintetis yang dihasilkan.

4.2.1 Konfigurasi Eksperimen

Bagian ini menjelaskan konfigurasi eksperimen yang digunakan dalam penelitian. Konfigurasi tersebut mencakup pengaturan umum yang diterapkan untuk memastikan proses eksperimen berjalan secara konsisten dan hasil yang diperoleh dapat dievaluasi secara valid.

4.2.1.1 Konfigurasi Eksperimen Augmentasi

Berikut merupakan konfigurasi yang digunakan untuk eksperimen augmentasi sinyal EEG. Konfigurasi ini mencakup pengaturan dataset, parameter pelatihan model, serta skenario pengujian yang digunakan untuk menjaga konsistensi dan validitas hasil eksperimen.

1. Dataset: Eksperimen augmentasi menggunakan dataset EEG ASD dari penelitian [6]. Data EEG asli digunakan sebagai data masukan untuk melatih model *Variational Autoencoder* (VAE) dalam menghasilkan sinyal EEG sintetis. Sebelum digunakan pada proses *training* model VAE, sinyal EEG melalui tahapan *preprocessing* yang mengacu pada penelitian referensi [8], meliputi *filtering*, segmentasi sinyal, serta proses pengurangan artefak untuk meningkatkan kualitas sinyal EEG. Pada eksperimen augmentasi, data EEG dipisahkan berdasarkan kanal dan kelas data (NORMAL dan ASD) sebelum proses *training* model. Dengan demikian, proses augmentasi dilakukan pada 32 subset data yang berbeda yang merepresentasikan kombinasi setiap kanal dan kelas.

2. Hyperparameter: *training* model *Variational Autoencoder* (VAE) dilakukan menggunakan ukuran *batch* sebesar 32 selama 70 *epoch*. Dimensi ruang laten (*latent dimension*) yang digunakan sebesar 16 dengan optimizer *Adam* menggunakan *learning rate* sebesar 0.001, $\beta_1 = 0.5$, dan $\beta_2 = 0.999$. Fungsi *loss* menggunakan kombinasi *Mean Squared Error* (MSE) dan *Kullback-Leibler Divergence* dengan parameter $\beta = 0.5$. Pembagian data dilakukan menggunakan rasio 70% data *training*, 20% data validasi, dan 10% data *testing*.
3. Jumlah Pengulangan Eksperimen: Untuk menjamin reliabilitas hasil dan meminimalisir bias akibat inisialisasi acak, setiap eksperimen augmentasi dilakukan secara berulang dengan bobot awal model yang berbeda. Seluruh eksperimen dilakukan sebanyak lima kali pengulangan, kemudian hasil evaluasi akhir diperoleh melalui rata-rata dari seluruh pengulangan eksperimen. Pengulangan eksperimen dilakukan untuk memastikan stabilitas performa model VAE dalam menghasilkan data EEG sintetis.

4.2.1.2 Konfigurasi Eksperimen Klasifikasi

Berikut merupakan konfigurasi yang digunakan untuk eksperimen klasifikasi sinyal EEG. Konfigurasi ini mencakup pengaturan dataset, parameter pelatihan model, serta skenario pengujian yang digunakan untuk menjaga konsistensi dan validitas hasil eksperimen.

1. Dataset: Eksperimen klasifikasi menggunakan dua skenario dataset, yaitu dataset yang hanya terdiri dari data EEG asli (*real data*) dan dataset hasil augmentasi yang merupakan kombinasi data EEG asli dengan data sintetis hasil generasi model VAE. Data sintetis yang dihasilkan pada tahap augmentasi digabungkan kembali menjadi sinyal EEG multikanal, kemudian diproses menggunakan tahapan *preprocessing* yang sama dengan data EEG asli sebagaimana dijelaskan pada penelitian referensi [8] sebelum digunakan pada proses klasifikasi.
2. Hyperparameter: Eksperimen klasifikasi menggunakan dua model, yaitu model *Deep Neural Network* (DNN) sebagai model pembanding berdasarkan penelitian rujukan serta model *Extreme Gradient Boosting* (XGBoost). Model DNN dilatih menggunakan optimizer Adam dengan *learning rate* sebesar 10^{-3} , *batch size* 32,

dan maksimum 100 epoch. Selain itu, digunakan mekanisme *early stopping* dan *model checkpoint* untuk mencegah *overfitting* selama proses *training*. Sementara itu, model XGBoost menggunakan konfigurasi default dari library XGBoost dengan fungsi evaluasi *logloss* serta parameter bawaan library, termasuk jumlah *estimators*.

3. Jumlah Pengulangan Eksperimen: Untuk menjamin reliabilitas hasil dan meminimalisir bias akibat pembagian data maupun inisialisasi model secara acak, setiap eksperimen klasifikasi dilakukan sebanyak lima kali pengulangan. Selain itu, proses evaluasi model dilakukan menggunakan metode *10-fold Stratified Cross Validation*. Seluruh nilai evaluasi yang diperoleh disajikan dalam bentuk rata-rata (*mean*) dan standar deviasi (*standard deviation*) dari sepuluh fold pengujian.

4.2.2 Metrik Evaluasi

Dalam eksperimen, digunakan sejumlah metrik evaluasi untuk menilai performa model pada proses augmentasi maupun klasifikasi data EEG. Metrik evaluasi digunakan untuk menganalisis kualitas data sintetis yang dihasilkan oleh model *Variational Autoencoder* (VAE) serta mengukur performa model klasifikasi dalam membedakan kelas ASD dan NORMAL.

4.2.2.1 Metrik Evaluasi Eksperimen Augmentasi

Evaluasi pada tahap augmentasi dilakukan untuk menilai kemampuan model *Variational Autoencoder* (VAE) dalam menghasilkan sinyal EEG sintetis yang memiliki karakteristik serupa dengan data EEG asli. Evaluasi dilakukan menggunakan beberapa metrik kuantitatif yang umum digunakan pada evaluasi model generatif. Metrik evaluasi yang digunakan mengacu pada penelitian [14], meliputi *Frechet Inception Distance* (FID), *Euclidean Distance* (ED), dan *Sliced Wasserstein Distance* (SWD). Ketiga metrik tersebut digunakan untuk mengukur tingkat kemiripan distribusi, karakteristik fitur, serta kedekatan sinyal EEG sintetis terhadap data EEG asli.

4.2.2.2 Metrik Evaluasi Eksperimen Klasifikasi

Evaluasi pada tahap klasifikasi dilakukan untuk menilai performa model dalam membedakan sinyal EEG subjek ASD dan kontrol normal. Evaluasi dilakukan pada dua model klasifikasi, yaitu model *Deep Neural Network* (DNN) sebagai model pembanding berdasarkan penelitian rujukan dan model *Extreme Gradient Boosting* (XGBoost). Kedua model dievaluasi menggunakan skema *10-fold Stratified Cross Validation* untuk menjaga distribusi kelas pada setiap fold pengujian.

Metrik evaluasi yang digunakan meliputi *Precision*, *Recall (Sensitivity)*, *F1-Score*, *Accuracy*, *Specificity*, serta *Area Under Curve* (AUC). Selain itu, evaluasi juga dilakukan menggunakan *confusion matrix* untuk memperoleh nilai *True Positive* (TP), *True Negative* (TN), *False Positive* (FP), dan *False Negative* (FN) pada setiap fold pengujian. Seluruh metrik evaluasi diterapkan secara konsisten baik pada model DNN maupun model XGBoost untuk menjaga validitas komparasi performa antar model klasifikasi. Seluruh hasil evaluasi disajikan dalam bentuk rata-rata (*mean*) dan standar deviasi (*standard deviation*) dari seluruh fold untuk memberikan gambaran performa model yang lebih stabil dan representatif.

4.3 Eksperimen dan Analisis

Bagian ini menyajikan rangkaian eksperimen yang dilakukan untuk mengevaluasi efektivitas augmentasi data berbasis *Variational Autoencoder* (VAE) pada klasifikasi sinyal EEG untuk deteksi Autism Spectrum Disorder (ASD). Evaluasi dilakukan secara bertahap, dimulai dari analisis kemampuan model VAE dalam menghasilkan data EEG sintetis, dilanjutkan dengan pengujian performa model klasifikasi menggunakan data EEG asli, serta analisis pengaruh penambahan data sintetis terhadap performa klasifikasi. Penelitian ini menggunakan model *Deep Neural Network* (DNN) dan *Extreme Gradient Boosting* (XGBoost) sebagai model klasifikasi yang dibandingkan pada setiap skenario eksperimen.

4.3.1 Eksperimen 1: Evaluasi Kemampuan Model VAE dalam Generasi Sinyal EEG Sintetis

Eksperimen pertama bertujuan untuk mengevaluasi kemampuan model *Variational Autoencoder* (VAE) dalam mempelajari distribusi data EEG dan menghasilkan sinyal EEG sintetis yang memiliki karakteristik serupa dengan data asli. Evaluasi ini dilakukan sebagai tahap validasi awal untuk memastikan bahwa model VAE mampu merepresentasikan pola sinyal EEG pada masing-masing kelas dan kanal yang digunakan dalam penelitian.

Pada eksperimen ini, kualitas data sintetis dianalisis menggunakan beberapa metrik evaluasi data generatif, yaitu *Fréchet Inception Distance* (FID), *Sliced Wasserstein Distance* (SWD), dan normalisasi *Euclidean Distance* (ED). Selain evaluasi kuantitatif, dilakukan pula analisis visual pada domain waktu dan domain frekuensi untuk membandingkan karakteristik sinyal sintetis terhadap sinyal EEG asli. Untuk melengkapi evaluasi tersebut, dilakukan juga analisis terhadap beberapa fitur statistik sinyal yang digunakan pada proses klasifikasi, meliputi *mean*, *standard deviation*, *variance*, *skewness*, *kurtosis*, *amplitude*, *energy*, *RMS*, *entropy*, dan *power*, untuk menilai sejauh mana data sintetis mampu mempertahankan karakteristik distribusi statistik yang terdapat pada data EEG asli.

Eksperimen ini digunakan untuk menilai sejauh mana model VAE mampu mempertahankan karakteristik utama sinyal EEG serta menentukan kelayakan data sintetis yang dihasilkan untuk digunakan pada tahap augmentasi data dalam proses klasifikasi ASD dengan hasil evaluasi kualitas data sintetis untuk masing-masing kanal EEG pada kelas Normal dan ASD disajikan pada tabel .


Tabel 4.3. Hasil Evaluasi Kualitas Data Sintetis EEG pada Kelas Normal

Channel	ED Norm	FID	SWD
Fp1	-0.148	91.313	0.264
Fp2	0.019	60.794	0.213
F3	0.086	109.476	0.199
F4	0.037	86.644	0.172
C3	0.127	110.533	0.184
C4	0.058	95.488	0.145
P3	0.049	129.378	0.132
P4	0.145	132.878	0.147
O1	0.183	115.336	0.202
O2	0.222	118.257	0.186
F7	0.260	121.811	0.181
F8	0.271	114.876	0.169
T3	0.193	152.974	0.136
T4	0.393	180.492	0.233
T5	0.588	170.312	0.213
T6	0.531	164.081	0.235

Tabel 4.4. Hasil Evaluasi Kualitas Data Sintetis EEG pada Kelas ASD

Channel	ED Norm	FID	SWD
Fp1	0.003	34.857	0.136
Fp2	0.012	26.858	0.111
F3	0.047	49.890	0.153
F4	0.021	45.219	0.104
C3	-0.020	42.832	0.109
C4	0.014	49.008	0.118
P3	-0.026	49.183	0.113
P4	-0.029	48.179	0.084
O1	0.014	38.777	0.118
O2	0.038	33.451	0.105
F7	0.056	32.921	0.101
F8	0.052	31.354	0.107
T3	0.081	48.797	0.110
T4	0.070	50.006	0.090
T5	0.149	52.433	0.110
T6	0.120	51.330	0.108


Eksperimen pertama bertujuan untuk mengevaluasi kemampuan model *Variational Autoencoder* (VAE) dalam mempelajari distribusi sinyal EEG dan menghasilkan data sintetis yang menyerupai data asli pada masing-masing kanal EEG sebelum digunakan pada tahap klasifikasi ASD. Berdasarkan hasil evaluasi pada Tabel 4.3 dan Tabel 4.4, model VAE mampu menghasilkan sinyal sintetis yang mempertahankan pola umum sinyal EEG asli pada kedua kelas data.




Gambar 4.1. Visualisasi Domain Waktu Sinyal EEG Sintetis Label Normal



Gambar 4.2. Visualisasi Domain Waktu Sinyal EEG Sintetis Label ASD



Gambar 4.3. Visualisasi Domain Frekuensi Sinyal EEG Sintetis Label Normal



Gambar 4.4. Visualisasi Domain Frekuensi Sinyal EEG Sintetis Label ASD

Karakteristik tersebut juga terlihat pada visualisasi domain waktu (gambar 4.1 dan gambar 4.2) serta domain frekuensi (gambar 4.3 dan gambar 4.4), di mana sinyal sintetis

mampu mengikuti pola amplitudo utama serta distribusi spektral frekuensi dominan dari sinyal asli.

Secara umum, kualitas data sintetis pada kelas ASD menunjukkan hasil yang lebih baik dan lebih stabil dibandingkan kelas Normal. Hal ini ditunjukkan oleh nilai *Fréchet Inception Distance* (FID), *Sliced Wasserstein Distance* (SWD), dan normalisasi *Euclidean Distance* (ED) yang relatif lebih rendah pada sebagian besar kanal EEG kelas ASD. Kanal frontal seperti Fp2, F7, dan F8 pada kelas ASD menghasilkan nilai FID yang rendah, menunjukkan tingkat kemiripan distribusi yang tinggi terhadap data asli.

Sebaliknya, beberapa kanal pada kelas Normal, khususnya kanal temporal seperti T4, T5, dan T6, menunjukkan nilai FID dan normalisasi ED yang lebih tinggi dibandingkan kanal lainnya. Secara empiris, hal ini mengindikasikan bahwa distribusi sinyal pada kanal tersebut lebih sulit dipelajari oleh model generatif, kemungkinan akibat variasi pola sinyal dan kompleksitas distribusi yang lebih tinggi.

Selain itu, pola yang konsisten juga terlihat pada visualisasi domain frekuensi. Berdasarkan grafik PSD, sinyal sintetis umumnya mampu mengikuti distribusi spektral utama dari sinyal EEG asli. Namun, hampir seluruh model menunjukkan peningkatan komponen frekuensi di atas 40 Hz yang tidak dominan pada data asli. Setelah penerapan *low-pass filter* 40 Hz, distribusi spektral sinyal sintetis menjadi lebih mendekati data asli. Temuan ini menunjukkan bahwa model VAE berhasil mempertahankan karakteristik utama sinyal EEG, meskipun masih menghasilkan komponen frekuensi tinggi yang dapat diminimalkan melalui proses *filtering* sinyal.

Tabel 4.5. Perbandingan fitur statistik data EEG asli antara kelas Normal dan ASD

Fitur	Normal Mean	Normal SD	ASD Mean	ASD SD
Mean	-0.0000	0.0000	0.0000	0.0000
Std	1.0000	0.0000	1.0000	0.0000
Variance	1.0000	0.0000	1.0000	0.0000
Skewness	-0.0275	0.2359	-0.0627	0.3986
Kurtosis	-0.2080	0.6270	0.1878	1.1175
Amplitude	1.0000	0.0000	1.0000	0.0000
Energy	512.0000	0.0000	512.0000	0.0000
RMS	3.5451	0.1043	3.5077	0.1353
Entropy	1.0000	0.0000	1.0000	0.0000
Power	0.9689	0.0966	1.0016	0.1550

Tabel 4.6. Perbandingan fitur statistik data EEG sintetis antara kelas Normal dan ASD

Fitur	Normal Mean	Normal SD	ASD Mean	ASD SD
Mean	-0.0013	0.0267	-0.0018	0.0256
Std	0.8646	0.1005	0.9140	0.0759
Variance	0.7576	0.1713	0.8411	0.1396
Skewness	-0.0157	0.2309	-0.0337	0.2921
Kurtosis	-0.0688	0.4051	-0.0405	0.4657
Amplitude	0.8650	0.1004	0.9144	0.0759
Energy	388.2769	87.6532	431.0034	71.5142
RMS	3.5352	0.0884	3.5491	0.0906
Entropy	0.7576	0.1713	0.8411	0.1396
Power	0.7535	0.1925	0.8394	0.1854

Tabel 4.7. Perbandingan fitur statistik data EEG asli dan sintetis

Fitur	Real Mean	Real SD	Synthetic Mean	Synthetic SD
Mean	0.0000	0.0000	-0.0015	0.0261
Std	1.0000	0.0000	0.8893	0.0924
Variance	1.0000	0.0000	0.7994	0.1617
Skewness	-0.0544	0.3669	-0.0247	0.2634
Kurtosis	0.0939	1.0363	-0.0546	0.4366
Amplitude	1.0000	0.0000	0.8897	0.0923
Energy	512.0000	0.0000	409.6401	82.7897
RMS	3.5166	0.1296	3.5422	0.0897
Entropy	1.0000	0.0000	0.7994	0.1617
Power	0.9939	0.1439	0.7965	0.1938

Selain evaluasi menggunakan metrik generatif dan analisa visual, dilakukan pula analisis terhadap beberapa fitur statistik untuk membandingkan karakteristik data EEG asli dan data EEG sintetis yang dihasilkan oleh model VAE. Hasil perbandingan disajikan pada Tabel 4.5, Tabel 4.6, dan Tabel 4.7.

Berdasarkan Tabel 4.5, terdapat perbedaan karakteristik statistik antara kelompok Normal dan ASD pada data asli. Kelompok ASD menunjukkan nilai *skewness* dan *kurtosis* yang lebih tinggi dibandingkan kelompok Normal, mengindikasikan distribusi amplitudo sinyal yang lebih asimetris dan memiliki puncak distribusi yang lebih tajam. Selain itu, nilai *power* rata-rata pada kelompok ASD juga sedikit lebih tinggi dibandingkan kelompok Normal.

Karakteristik tersebut secara umum masih dapat dipertahankan pada data sintetis yang dihasilkan VAE sebagaimana ditunjukkan pada Tabel 4.6. Nilai *skewness*, *kurtosis*, *entropy*, dan *power* pada data sintetis tetap menunjukkan pola perbedaan yang konsisten antara kelas Normal dan ASD. Hal ini menunjukkan bahwa model VAE tidak hanya mempelajari bentuk sinyal secara visual, tetapi juga mampu mempertahankan sebagian karakteristik statistik yang membedakan kedua kelas.

Perbandingan antara seluruh data asli dan data sintetis pada Tabel 4.7 menunjukkan bahwa sebagian besar fitur statistik memiliki kecenderungan yang serupa. Nilai rata-rata (*mean*) kedua kelompok tetap berada di sekitar nol, sedangkan nilai *skewness* dan *kurtosis*

sintetis masih berada pada rentang yang sebanding dengan data asli. Nilai *entropy* rata-rata juga relatif dekat yang menunjukkan tingkat kompleksitas sinyal yang tetap terjaga.

Terdapat beberapa perbedaan yang menunjukkan adanya efek *smoothing* pada proses generasi data. Nilai *standard deviation*, *variance*, *amplitude*, *energy*, dan *power* pada data sintetis cenderung lebih rendah dibandingkan data asli. Penurunan ini mengindikasikan bahwa model VAE menghasilkan sinyal yang lebih teratur dan memiliki variasi amplitudo yang lebih kecil dibandingkan data asli. Fenomena tersebut juga sejalan dengan karakteristik umum VAE yang mempelajari representasi laten terstruktur melalui regularisasi *Kullback-Leibler divergence*, sehingga distribusi hasil generasi cenderung lebih halus dibandingkan distribusi data asli.

Secara keseluruhan, hasil analisis statistik menunjukkan bahwa data sintetis yang dihasilkan mampu mempertahankan karakteristik utama sinyal EEG asli baik pada tingkat distribusi maupun pola perbedaan antar kelas. Meskipun terdapat penurunan pada beberapa ukuran dispersi seperti *variance*, *energy*, dan *power*, perbedaan tersebut masih berada dalam rentang yang dapat diterima untuk tujuan augmentasi data, sehingga data sintetis yang dihasilkan dinilai cukup representatif untuk digunakan pada tahap klasifikasi ASD.

4.3.2 Eksperimen 2: Evaluasi Model Klasifikasi Dengan Hanya Menggunakan Sinyal EEG Asli

Eksperimen kedua bertujuan untuk mengevaluasi performa model klasifikasi menggunakan data EEG asli tanpa melibatkan data sintetis hasil augmentasi. Eksperimen ini dilakukan untuk memperoleh nilai performa dasar (*baseline*) yang selanjutnya digunakan sebagai acuan dalam mengevaluasi pengaruh augmentasi data sintetis pada proses klasifikasi ASD.

Pada eksperimen ini digunakan dua model klasifikasi, yaitu *Deep Neural Network* (DNN) sebagai model pembanding berdasarkan penelitian rujukan dan *Extreme Gradient Boosting* (XGBoost) sebagai model yang diusulkan. Seluruh proses *training* dan pengujian dilakukan menggunakan data EEG asli yang telah melalui tahap *preprocessing* sebagaimana dijelaskan pada bab sebelumnya. Evaluasi performa dilakukan menggunakan metrik *accuracy*, *sensitivity*, *specificity*, *precision*, *F1-score*, dan *Area Under Curve*

(AUC).

Melalui eksperimen ini, perbedaan karakteristik performa antara model DNN dan XGBoost dapat dianalisis pada kondisi tanpa augmentasi data. Hasil yang diperoleh kemudian digunakan sebagai dasar perbandingan untuk menilai sejauh mana penambahan data sintetis mampu meningkatkan performa dan kemampuan generalisasi masing-masing model klasifikasi. Hasil evaluasi eksperimen yang diperoleh disajikan pada Tabel 4.8.

Tabel 4.8. Perbandingan performa model DNN dan XGBoost dengan data EEG asli

Metrik	DNN	XGBoost
TP	115.2 ± 57.11	141.1 ± 1.43
FP	82.4 ± 58.02	3.0 ± 1.37
TN	97.6 ± 57.95	139.9 ± 1.46
FN	65.8 ± 55.98	4.1 ± 1.52
Sensitivity	0.6347 ± 0.3089	0.9724 ± 0.0101
Specificity	0.5422 ± 0.2417	0.9790 ± 0.0093
Precision	0.5412 ± 0.2384	0.9786 ± 0.0098
Accuracy	0.5893 ± 0.1865	0.9753 ± 0.0097
F1-Score	0.5689 ± 0.2423	0.9751 ± 0.0089
AUC	0.6204 ± 0.1827	0.9965 ± 0.0025

Eksperimen melibatkan dua model klasifikasi, yaitu model *Deep Neural Network* (DNN) sebagai model *baseline* berdasarkan penelitian rujukan dan model *Extreme Gradient Boosting* (XGBoost). Seluruh pengujian dilakukan menggunakan data EEG asli yang telah melalui tahap *preprocessing* sebagaimana dijelaskan pada penelitian referensi. Evaluasi performa dilakukan menggunakan metrik akurasi, sensitivitas, spesifisitas, presisi, *F1-score*, dan *Area Under Curve* (AUC). Hasil eksperimen ditunjukkan pada 4.8.

Berdasarkan hasil evaluasi, kedua model mampu melakukan klasifikasi sinyal EEG ASD dan Normal menggunakan data EEG asli. Namun, terdapat perbedaan performa

yang cukup signifikan antara model DNN dan XGBoost. Model XGBoost secara konsisten menunjukkan performa yang lebih tinggi pada hampir seluruh metrik evaluasi dibandingkan model DNN. Nilai sensitivitas, spesifisitas, presisi, *F1-score*, dan AUC yang diperoleh XGBoost menunjukkan bahwa model mampu melakukan pemisahan kelas dengan sangat baik dan stabil pada sebagian besar fold pengujian.

Sebaliknya, model DNN menunjukkan performa yang relatif lebih rendah dengan variasi hasil yang lebih besar antar fold pengujian. Hal ini terlihat dari nilai standar deviasi yang cukup tinggi pada beberapa metrik evaluasi, yang mengindikasikan bahwa performa model belum sepenuhnya stabil. Selain itu, jumlah *false positive* dan *false negative* pada model DNN juga relatif lebih tinggi dibandingkan XGBoost, sehingga kemampuan generalisasi model terhadap data EEG masih terbatas.

Perbedaan performa tersebut menunjukkan bahwa karakteristik data EEG pada penelitian ini cenderung lebih efektif dipelajari oleh model berbasis *gradient boosting* dibandingkan model DNN. Secara empiris, XGBoost memiliki kemampuan yang lebih baik dalam menangani jumlah data yang relatif terbatas serta hubungan fitur yang kompleks, sehingga menghasilkan performa klasifikasi yang lebih stabil dibandingkan DNN pada konfigurasi pengujian yang digunakan.

Secara keseluruhan, hasil eksperimen ini menunjukkan bahwa model DNN dan XGBoost memiliki karakteristik performa yang berbeda dalam melakukan klasifikasi sinyal EEG ASD menggunakan data asli. Oleh karena itu, kedua model selanjutnya digunakan pada eksperimen berikutnya untuk mengevaluasi bagaimana penggunaan data sintetis hasil augmentasi memengaruhi performa dan kemampuan generalisasi masing-masing model klasifikasi.

4.3.3 Eksperimen 3: Evaluasi Model Klasifikasi Dengan Menggunakan Kombinasi Sinyal EEG Asli dan Sinyal EEG Sintetis

Eksperimen ketiga bertujuan untuk mengevaluasi pengaruh penggunaan data sintetis hasil augmentasi *Variational Autoencoder* (VAE) terhadap performa model klasifikasi EEG. Proses klasifikasi dilakukan menggunakan kombinasi data EEG asli dan data sintetis yang dihasilkan pada tahap augmentasi untuk memperkaya jumlah serta variasi data *training*.

Sebagaimana pada eksperimen sebelumnya model klasifikasi yang digunakan adalah

Deep Neural Network (DNN) dan *Extreme Gradient Boosting* (XGBoost). Kedua model dilatih menggunakan dataset hasil kombinasi data EEG asli dan data sintetis, kemudian dievaluasi menggunakan metrik *accuracy*, *sensitivity*, *specificity*, *precision*, *F1-score*, dan *Area Under Curve* (AUC).

Hasil yang diperoleh kemudian dibandingkan dengan eksperimen sebelumnya yang hanya menggunakan data EEG asli untuk menganalisis pengaruh augmentasi data sintetis terhadap performa klasifikasi serta kemampuan generalisasi model dalam membedakan kelas ASD dan Normal. Hasil evaluasi eksperimen disajikan pada Tabel 4.9.

Tabel 4.9. Perbandingan performa model DNN dan XGBoost dengan kombinasi data EEG asli dan sintetis

Metrik	DNN	XGBoost
TP	66.84 ± 75.63	221.98 ± 1.49
FP	8.76 ± 24.24	0.68 ± 0.94
TN	581.04 ± 24.19	471.12 ± 0.92
FN	214.06 ± 75.59	2.72 ± 1.59
Sensitivity	0.2379 ± 0.2664	0.9879 ± 0.0070
Specificity	0.9852 ± 0.0407	0.9986 ± 0.0020
Precision	0.9054 ± 0.2024	0.9970 ± 0.0041
Accuracy	0.7441 ± 0.0675	0.9951 ± 0.0028
F1-Score	0.3141 ± 0.2458	0.9924 ± 0.0044
AUC	0.6181 ± 0.1474	0.9996 ± 0.0008

Hasil eksperimen menunjukkan bahwa penggunaan data sintetis memberikan pengaruh yang berbeda pada masing-masing model klasifikasi. Secara umum, augmentasi data memberikan peningkatan performa yang signifikan pada model XGBoost, namun menghasilkan perubahan karakteristik performa yang berbeda pada model DNN.

Berdasarkan hasil evaluasi pada 4.9, model XGBoost mengalami peningkatan performa pada hampir seluruh metrik evaluasi setelah penambahan data sintetis. Nilai sensitivitas meningkat dari 0.9724 menjadi 0.9879, sedangkan nilai presisi meningkat dari

0.9786 menjadi 0.9970. Selain itu, nilai AUC juga meningkat dari 0.9965 menjadi 0.9996. Peningkatan tersebut menunjukkan bahwa data sintetis yang dihasilkan mampu membantu model XGBoost mempelajari distribusi data EEG dengan lebih baik serta meningkatkan kemampuan generalisasi model terhadap kedua kelas data.

Sebaliknya, model DNN menunjukkan perubahan performa yang tidak sepenuhnya konsisten setelah penggunaan data sintetis. Meskipun nilai presisi meningkat secara signifikan dari 0.5412 menjadi 0.9054, nilai sensitivitas justru mengalami penurunan yang cukup besar dari 0.6347 menjadi 0.2379. Penurunan sensitivitas tersebut juga diikuti oleh penurunan nilai F1-score dari 0.5689 menjadi 0.3141, sementara nilai AUC relatif tidak mengalami perubahan yang signifikan, yaitu dari 0.6204 menjadi 0.6181.

Secara empiris, kondisi tersebut mengindikasikan bahwa model DNN lebih sering memprediksi kelas Normal dibandingkan kelas ASD setelah proses augmentasi dilakukan. Akibatnya, jumlah *false positive* berhasil ditekan sehingga nilai presisi dan spesifisitas meningkat, namun di sisi lain jumlah *false negative* meningkat sehingga sensitivitas mengalami penurunan. Hal ini menunjukkan bahwa penambahan data sintetis tidak selalu meningkatkan kemampuan model DNN dalam mengenali pola ASD secara seimbang.

Perbedaan respons kedua model terhadap augmentasi kemungkinan berkaitan dengan karakteristik arsitektur masing-masing model. Model XGBoost cenderung lebih robust terhadap perubahan distribusi data dan lebih efektif dalam memanfaatkan tambahan variasi fitur dari data sintetis. Sebaliknya, model DNN lebih sensitif terhadap kualitas dan distribusi data augmentasi, terutama ketika kualitas data sintetis antar kelas tidak sepenuhnya seimbang. Pada eksperimen sebelumnya, kualitas data sintetis pada kelas Normal menunjukkan deviasi distribusi yang lebih besar dibandingkan kelas ASD. Kondisi ini kemungkinan turut memengaruhi proses pembelajaran model DNN sehingga distribusi keputusan model menjadi kurang seimbang setelah augmentasi dilakukan.

Meskipun demikian, hasil eksperimen menunjukkan bahwa augmentasi berbasis model generatif tetap memiliki potensi dalam meningkatkan performa klasifikasi EEG, terutama pada model berbasis *gradient boosting* seperti XGBoost. Temuan ini juga menunjukkan bahwa efektivitas data sintetis sangat dipengaruhi oleh karakteristik model klasifikasi yang digunakan serta kualitas distribusi data sintetis yang dihasilkan oleh

model augmentasi.

4.4 Diskusi

Bagian ini membahas hasil penelitian yang telah diperoleh dengan mengaitkannya pada tujuan penelitian serta temuan dari penelitian terdahulu. Pembahasan difokuskan pada hubungan antara kualitas data sintetis yang dihasilkan oleh model *Variational Autoencoder* (VAE) dan performa model klasifikasi, perbedaan respons model DNN dan XGBoost terhadap augmentasi data, serta faktor-faktor yang memengaruhi efektivitas penggunaan data sintetis pada klasifikasi ASD berbasis EEG. Selain itu, hasil penelitian dibandingkan dengan beberapa penelitian sebelumnya untuk mengidentifikasi kesesuaian maupun perbedaan temuan, serta untuk memberikan gambaran mengenai implikasi dan arah pengembangan penelitian pada bidang augmentasi data EEG dan klasifikasi ASD.

4.4.1 Analisis Komparatif terhadap Penelitian Terdahulu

Hasil penelitian ini menunjukkan kesesuaian dengan penelitian terdahulu baik dari sisi performa model klasifikasi maupun efektivitas augmentasi data berbasis *Variational Autoencoder* (VAE). Pada penelitian rujukan [8], model XGBoost terbukti memberikan performa yang jauh lebih baik dibandingkan model ANN pada klasifikasi ASD berbasis EEG, dengan nilai AUC sebesar 0.9963 ± 0.0027 dan *F1-score* sebesar 0.9743 ± 0.0093 , sedangkan model ANN hanya memperoleh AUC sebesar 0.6160 ± 0.1861 dan *F1-score* sebesar 0.5638 ± 0.2469 . Temuan yang hampir identik juga diperoleh pada penelitian ini. Pada pengujian menggunakan data EEG asli, model XGBoost menghasilkan AUC sebesar 0.9965 ± 0.0025 dan *F1-score* sebesar 0.9751 ± 0.0089 , sedangkan model DNN memperoleh AUC sebesar 0.6204 ± 0.1827 dan *F1-score* sebesar 0.5689 ± 0.2423 . Kemiripan hasil tersebut menunjukkan bahwa metodologi klasifikasi yang digunakan pada penelitian ini berhasil mereproduksi karakteristik performa yang dilaporkan pada penelitian rujukan.

Selain membandingkan performa model klasifikasi, penelitian ini juga memperluas studi sebelumnya melalui penerapan augmentasi data berbasis VAE. Penelitian [28] menunjukkan bahwa data sintetis yang dihasilkan oleh VAE mampu meningkatkan performa klasifikasi EEG pada tugas *motor imagery*. Temuan pada penelitian ini menunjukkan ke-

cenderung yang serupa pada model XGBoost. Setelah penambahan data sintetis, nilai AUC meningkat dari 0.9965 menjadi 0.9996 dan *F1-score* meningkat dari 0.9751 menjadi 0.9924. Hasil tersebut menunjukkan bahwa data sintetis yang dihasilkan masih mampu mempertahankan informasi diskriminatif yang relevan sehingga dapat dimanfaatkan secara efektif oleh model klasifikasi.

Namun demikian, manfaat augmentasi tidak muncul secara konsisten pada seluruh model klasifikasi. Pada model DNN, meskipun nilai presisi meningkat dari 0.5412 menjadi 0.9054, nilai sensitivitas menurun dari 0.6347 menjadi 0.2379 dan *F1-score* menurun dari 0.5689 menjadi 0.3141. Analisis matriks konfusi menunjukkan bahwa jumlah *false positive* menurun secara signifikan dari 82.4 menjadi 8.76, tetapi jumlah *false negative* meningkat dari 65.8 menjadi 214.06. Kondisi ini menunjukkan bahwa setelah augmentasi dilakukan, model DNN menjadi lebih cenderung memprediksi kelas Normal sehingga kemampuan mendeteksi ASD menurun.

Perbedaan tersebut kemungkinan berkaitan dengan kualitas data sintetis yang dihasilkan. Pada eksperimen sebelumnya, data sintetis kelas ASD memiliki nilai ED, FID, dan SWD yang lebih rendah dibandingkan kelas Normal, yang menunjukkan bahwa distribusi data sintetis masih memiliki perbedaan yang lebih besar terhadap data asli. Hasil analisis statistik menunjukkan bahwa sinyal ASD memiliki distribusi yang lebih kompleks, ditandai oleh nilai skewness dan kurtosis yang lebih tinggi. Karakteristik tersebut dapat menyebabkan model VAE lebih sulit mempelajari distribusi data ASD secara optimal. Temuan ini mengindikasikan bahwa kualitas data sintetis yang dihasilkan VAE tidak selalu sama untuk setiap kelas dan turut dipengaruhi oleh karakteristik data asli yang digunakan sebagai sumber pembelajaran.

Selain itu, respons terhadap data sintetis juga dipengaruhi oleh karakteristik model klasifikasi. XGBoost tetap menunjukkan peningkatan performa setelah augmentasi, sedangkan DNN mengalami penurunan sensitivitas yang cukup besar. Hal ini sejalan dengan karakteristik XGBoost yang relatif lebih robust terhadap variasi data pada dataset berukuran terbatas [32]. Pada penelitian ini, proses klasifikasi dilakukan menggunakan fitur-fitur hasil ekstraksi yang telah diseleksi menggunakan metode mRMR, sehingga menghasilkan representasi fitur yang lebih relevan dan minim redundansi. Representasi semacam ini umumnya sesuai dengan karakteristik model berbasis *tree ensemble*, yang

diketahui mampu memanfaatkan hubungan antar fitur secara efektif [33]. Sebaliknya, DNN cenderung lebih sensitif terhadap kualitas data dan pergeseran distribusi data pelatihan. Hal tersebut tercermin pada hasil eksperimen, di mana model DNN mengalami penurunan sensitivitas dan *F1-score* setelah augmentasi dilakukan, sedangkan model XGBoost tetap menunjukkan peningkatan performa pada hampir seluruh metrik evaluasi.

Secara keseluruhan, hasil penelitian ini mendukung temuan penelitian terdahulu mengenai keunggulan XGBoost untuk klasifikasi ASD berbasis EEG serta potensi VAE sebagai metode augmentasi data EEG. Di sisi lain, penelitian ini menunjukkan bahwa keberhasilan augmentasi tidak hanya bergantung pada model generatif yang digunakan, tetapi juga pada kualitas data sintetis yang dihasilkan serta karakteristik model klasifikasi yang memanfaatkan data tersebut.

4.4.2 Implikasi dan Arah Pengembangan Penelitian

Hasil penelitian ini menunjukkan beberapa peluang pengembangan untuk diteliti lebih lanjut. Salah satu temuan utama adalah adanya perbedaan kualitas data sintetis antar kelas dan kanal EEG. Temuan tersebut mengindikasikan bahwa karakteristik distribusi data asli kemungkinan memiliki pengaruh terhadap kemampuan model VAE dalam mempelajari representasi laten dan menghasilkan data sintetis yang berkualitas. Oleh karena itu, hubungan antara kompleksitas distribusi data EEG dan kualitas hasil augmentasi menjadi aspek yang menarik untuk dieksplorasi pada penelitian berikutnya.

Selain itu, hasil eksperimen menunjukkan bahwa peningkatan kualitas distribusi data sintetis tidak selalu berbanding lurus dengan peningkatan performa seluruh model klasifikasi. Pada penelitian ini, model XGBoost mampu memanfaatkan data sintetis secara efektif, sedangkan model DNN menunjukkan respons yang berbeda terhadap penambahan data hasil augmentasi. Temuan tersebut menunjukkan bahwa interaksi antara karakteristik data sintetis dan mekanisme pembelajaran model klasifikasi masih memerlukan kajian yang lebih mendalam.

Dari sisi evaluasi, hasil penelitian juga menunjukkan bahwa metrik distribusi seperti FID, SWD, normalisasi ED, maupun perbandingan pilihan fitur mampu memberikan indikasi kemiripan antara data sintetis dan data asli. Namun demikian, hubungan antara nilai metrik tersebut dengan manfaat praktis data sintetis terhadap performa klasi-

fikasi masih belum sepenuhnya dipahami. Kondisi ini membuka peluang untuk mengembangkan pendekatan evaluasi yang mampu menghubungkan kualitas generasi dengan kegunaan data sintetis pada tugas klasifikasi EEG secara lebih langsung.

Penelitian ini juga menunjukkan bahwa augmentasi berbasis VAE memiliki potensi untuk mendukung pengembangan sistem klasifikasi ASD berbasis EEG. Meskipun demikian, ruang pengembangan masih terbuka untuk mengeksplorasi pendekatan generatif yang lebih beragam serta memahami kondisi-kondisi tertentu di mana augmentasi dapat memberikan manfaat yang optimal terhadap proses klasifikasi.

BAB 5

PENUTUP

Bab ini menyajikan kesimpulan yang diperoleh berdasarkan hasil penelitian serta saran untuk pengembangan penelitian selanjutnya. Kesimpulan disusun untuk menjawab rumusan masalah yang telah ditetapkan, sedangkan saran diberikan berdasarkan keterbatasan dan temuan yang diperoleh selama penelitian.

5.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan analisis eksperimental terhadap penggunaan augmentasi data berbasis Variational Autoencoder (VAE) untuk klasifikasi Autism Spectrum Disorder (ASD) menggunakan sinyal EEG, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Penelitian ini menunjukkan bahwa pendekatan augmentasi data berbasis *Variational Autoencoder* (VAE) dapat digunakan sebagai salah satu alternatif untuk mengatasi keterbatasan jumlah dan variasi data pada klasifikasi ASD berbasis EEG. Melalui proses pembelajaran distribusi data, VAE mampu menghasilkan sampel baru yang memperluas keragaman data *training* tanpa memerlukan proses akuisisi data EEG tambahan yang umumnya memerlukan biaya, waktu, dan keterlibatan tenaga ahli.
2. Kualitas data sintetis yang dihasilkan tidak sepenuhnya seragam pada seluruh kanal dan kelas data. Perbedaan tersebut mengindikasikan bahwa karakteristik distribusi data pada masing-masing kanal dan kelas dapat memengaruhi kemampuan model VAE dalam merepresentasikan pola sinyal EEG. Meskipun demikian, data sintetis yang dihasilkan masih mampu mempertahankan karakteristik utama sinyal EEG baik pada domain waktu maupun domain frekuensi, sehingga menunjukkan bahwa model generatif mampu menangkap pola penting yang terdapat pada data asli.
3. Pengaruh data sintetis terhadap performa klasifikasi tidak hanya ditentukan oleh

kualitas hasil generasi, tetapi juga oleh karakteristik model klasifikasi yang digunakan. Model XGBoost dengan mRmR mampu memanfaatkan tambahan variasi data yang diberikan oleh proses augmentasi secara lebih efektif dan menunjukkan peningkatan performa yang relatif konsisten. Sebaliknya, model DNN menunjukkan sensitivitas yang lebih tinggi terhadap perubahan distribusi data sehingga manfaat augmentasi tidak selalu muncul secara merata pada seluruh metrik evaluasi.

4. Secara keseluruhan, hasil penelitian menunjukkan bahwa efektivitas augmentasi data EEG berbasis model generatif dipengaruhi oleh kualitas data asli, kemampuan model generatif dalam merepresentasikan distribusi data, serta karakteristik algoritma klasifikasi yang digunakan. Meskipun peningkatan performa belum terlihat secara konsisten pada seluruh model, pendekatan augmentasi berbasis VAE tetap menunjukkan potensi dalam mendukung pengembangan sistem klasifikasi ASD berbasis EEG yang lebih robust terhadap keterbatasan data.

5.2 Saran

Berdasarkan temuan dan keterbatasan yang dihadapi selama penelitian ini, beberapa saran untuk penelitian selanjutnya diajukan guna meningkatkan kualitas data sintetis yang dihasilkan serta efektivitas pemanfaatannya pada klasifikasi *Autism Spectrum Disorder* (ASD) berbasis sinyal EEG:

1. Penelitian selanjutnya dapat mengeksplorasi penggunaan model klasifikasi yang lebih kompleks dan memiliki kapasitas pembelajaran yang lebih tinggi, seperti Transformer atau arsitektur *deep learning* lainnya. Model dengan kebutuhan data yang lebih besar berpotensi memperoleh manfaat yang lebih signifikan dari penambahan data sintetis sehingga efektivitas augmentasi dapat dievaluasi secara lebih komprehensif.
2. Penelitian selanjutnya dapat menganalisis pengaruh kualitas, karakteristik, dan jumlah data asli terhadap performa model VAE dalam menghasilkan data sintetis. Analisis tersebut dapat memberikan pemahaman yang lebih mendalam mengenai

hubungan antara kualitas data masukan dan kualitas data sintetis yang dihasilkan sehingga faktor-faktor yang memengaruhi keberhasilan proses augmentasi dapat diidentifikasi dengan lebih baik.

3. Penelitian selanjutnya dapat mengevaluasi pengaruh rasio data sintetis terhadap data asli secara lebih sistematis. Pengujian dengan berbagai jumlah data sintetis diperlukan untuk mengetahui titik optimal penggunaan data augmentasi serta memahami hubungan antara jumlah data sintetis dan performa model klasifikasi.
4. Penelitian selanjutnya dapat membandingkan pendekatan augmentasi berbasis VAE dengan metode generatif lainnya, seperti *Generative Adversarial Network* (GAN), *Diffusion Model*, maupun variasi arsitektur VAE yang lebih kompleks. Perbandingan tersebut dapat memberikan gambaran yang lebih menyeluruh mengenai metode augmentasi yang paling efektif untuk menghasilkan data EEG sintetis dengan kualitas yang baik.
5. Penelitian selanjutnya dapat mengembangkan metode evaluasi kualitas data sintetis yang tidak hanya berfokus pada kemiripan distribusi statistik, tetapi juga mempertimbangkan karakteristik fisiologis dan relevansi klinis sinyal EEG. Pendekatan evaluasi yang lebih komprehensif diharapkan dapat memberikan gambaran yang lebih akurat mengenai kualitas dan kegunaan data sintetis pada aplikasi klasifikasi ASD berbasis EEG.

DAFTAR REFERENSI

- [1] National Center for Biotechnology Information, “Autism spectrum disorder,” [Online]. Available: <https://www.ncbi.nlm.nih.gov/books/NBK525976/>, 2023.
- [2] American Psychiatric Association, *Diagnostic and Statistical Manual of Mental Disorders (DSM-5)*, 5th ed. Arlington, VA, USA: American Psychiatric Association, 2013, [Online]. Available: <https://www.psychiatry.org/psychiatrists/practice/dsm>.
- [3] Y. Hus and O. Segal, “Challenges surrounding the diagnosis of autism in children,” 2021, [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8654688/>.
- [4] S. Bose and P. Seth, “Screening of autism spectrum disorder using machine learning approach in accordance with dsm-5,” in *2023 7th International Conference on Electronics, Materials Engineering & Nano-Technology (IEMENTech)*, 2023, [Online]. Available: <https://doi.org/10.1109/IEMENTech60402.2023.10423494>.
- [5] C. Clairmont, J. Wang, S. Tariq, H. T. Sherman, M. Zhao, and X.-J. Kong, “The value of brain imaging and electrophysiological testing for early screening of autism spectrum disorder: A systematic review,” 2022, [Online]. Available: <https://doi.org/10.3389/fnins.2021.812946>.
- [6] M. Melinda, P. D. Purnamasari, F. Fahmi, E. P. Sinulingga, M. Mulyadi, Y. Away, Y. Yunidar, and F. H. Juwono, “A comprehensive eeg dataset and performance assessment for autism spectrum disorder,” 2025, [Online]. Available: <https://doi.org/10.1038/s41598-025-34981>.
- [7] O. Gurau, W. J. Bosl, and C. R. Newton, “How useful is electroencephalography in the diagnosis of autism spectrum disorders and the delineation of subtypes: A systematic review,” 2017, [Online]. Available: <https://doi.org/10.3389/fpsyt.2017.00121>.

- [8] P. D. Purnamasari, A. A. P. Ratna, M. Melinda, F. Fahmi, F. H. Juwono, Y. Away, N. Li, R. Yan, and S. Gazali, “Enhancing clinical transparency in asd detection: An eeg analysis approach with mrmr and xgboost,” 2025, under review.
- [9] R. Lyu, “Deep learning approaches for eeg-based healthcare applications: A comprehensive review,” 2026, [Online]. Available: <https://doi.org/10.3389/fnhum.2025.1689073>.
- [10] X. Jiang, G. B. Bian, and Z. Tian, “Removal of artifacts from eeg signals: A review,” 2019, [Online]. Available: <https://doi.org/10.3390/s19050987>.
- [11] M. Tabejamaat, H. Mohammadzade, F. Negin, and F. Bremond, “Eeg classification with limited data: A deep clustering approach,” 2025, [Online]. Available: <https://doi.org/10.1016/j.patcog.2024.110934>.
- [12] C. Rommel, J. Paillard, T. Moreau, and A. Gramfort, “Data augmentation for learning predictive models on eeg: A systematic comparison,” 2022, [Online]. Available: <https://doi.org/10.48550/arXiv.2206.14483>.
- [13] S. Savadi, “A comprehensive review of feature extraction and classification techniques in eeg signal analysis,” 2025, [Online]. Available: <http://www.ijceronline.com/>.
- [14] K. G. Hartmann, R. T. Schirrmeister, and T. Ball, “Eeg-gan: Generative adversarial networks for electroencephalographic (eeg) brain signals,” 2018, [Online]. Available: <https://doi.org/10.48550/arXiv.1806.01875>.
- [15] W. Kong and X. Jin, “Basics of eeg signals,” in *Brain Fingerprint Identification*. Springer, Singapore, 2025, [Online]. Available: https://doi.org/10.1007/978-981-96-4512-1_2.
- [16] S. Beniczky and D. L. Schomer, “Electroencephalography: Basic biophysical and technological aspects important for clinical applications,” 2020, [Online]. Available: <https://doi.org/10.1684/epd.2020.1217>.

- [17] E. Ignatious, S. Azam, M. Jonkman, and F. D. Boer, "Frequency and time domain analysis of eeg-based auditory evoked potentials to detect binaural hearing in noise," 2023, [Online]. Available: <https://doi.org/10.3390/jcm12134487>.
- [18] H. Peng, F. Long, and C. Ding, "Feature selection based on mutual information criteria of max-dependency, max-relevance, and min-redundancy," 2005, [Online]. Available: <https://doi.org/10.1109/TPAMI.2005.159>.
- [19] B. Gholami, M. H. Behboudi, M. G. Mahjani, and A. Khadem, "Diagnosis of sleep apnea syndrome from eeg signals using different entropy measures," in *2021 7th International Conference on Signal Processing and Intelligent Systems (ICSPIS)*, 2021, [Online]. Available: <https://doi.org/10.1109/ICSPIS54653.2021.9729367>.
- [20] C.-T. Hsieh and Y.-H. Huang, "Tsmrmr feature selection method for detecting sleep apnea episodes based on eeg signals," in *2024 IEEE-EMBS Conference on Biomedical Engineering and Sciences (IECBES)*, 2024, [Online]. Available: <https://doi.org/10.1109/IECBES61011.2024.10991314>.
- [21] A. D. Giacomo, R. Palmieri, E. F. Russo, I. Pizzolorusso, R. Brandi, F. Magistro, M. G. D. Cesare, S. Quattrocchi, D. Cardone, D. Perpetuini, and A. Merla, "Machine learning and deep learning applied to eeg and fnirs for early autism spectrum disorder diagnosis: A systematic review," 2026, [Online]. Available: <https://doi.org/10.3389/fpsy.2026.1668914>.
- [22] J. Wang, J. Barstein, L. E. Ethridge, M. W. Mosconi, Y. Takarae, and J. A. Sweeney, "Resting-state eeg abnormalities in autism spectrum disorders," 2013, [Online]. Available: <https://doi.org/10.1186/1866-1955-5-24>.
- [23] L. B. Ribeiro and M. da Silva Filho, "Systematic review on eeg analysis to diagnose and treat autism by evaluating functional connectivity and spectral power," 2023, [Online]. Available: <https://doi.org/10.2147/NDT.S394363>.
- [24] F. J. Ramírez-Arias, E. E. García-Guerrero, E. Tlelo-Cuautle, J. M. Colores-Vargas, E. García-Canseco, O. R. López-Bonilla, G. M. Galindo-Aldana, and E. Inzunza-

- González, “Evaluation of machine learning algorithms for classification of eeg signals,” 2022, [Online]. Available: <https://doi.org/10.3390/technologies10040079>.
- [25] L. Xu, M. Xu, Y. Ke, X. An, S. Liu, and D. Ming, “Cross-dataset variability problem in eeg decoding with deep learning,” 2020, [Online]. Available: <https://doi.org/10.3389/fnhum.2020.00103>.
- [26] Q. Wen, L. Sun, F. Yang, X. Song, J. Gao, X. Wang, and H. Xu, “Time series data augmentation for deep learning: A survey,” 2021, [Online]. Available: <https://arxiv.org/abs/2002.12478>.
- [27] M. Goyal and Q. H. Mahmoud, “A systematic review of synthetic data generation techniques using generative ai,” 2024, [Online]. Available: <https://www.mdpi.com/2079-9292/13/17/3509>.
- [28] G. Bao, B. Yan, L. Tong, J. Shu, L. Wang, K. Yang, and Y. Zeng, “Data augmentation for eeg-based emotion recognition using generative adversarial networks,” 2021, [Online]. Available: <https://doi.org/10.3389/fncom.2021.723843>.
- [29] Y. Yao, X. Wang, X. Hao, H. Sun, R. Dong, and Y. Li, “Trans-cvae-gan: Transformer-based cvae-gan for high-fidelity eeg signal generation,” 2025, [Online]. Available: <https://doi.org/10.3390/bioengineering12101028>.
- [30] D. P. Kingma and M. Welling, “Auto-encoding variational bayes,” 2014, [Online]. Available: <https://doi.org/10.48550/arXiv.1312.6114>.
- [31] A. Vasarkar, “Eeg data augmentation using variational autoencoder,” [Online]. Available: <https://github.com/arkanivasarkar/EEG-Data-Augmentation-using-Variational-Autoencoder>.
- [32] T. Chen and C. Guestrin, “Xgboost: A scalable tree boosting system,” 2016, [Online]. Available: <https://arxiv.org/abs/1603.02754>.
- [33] R. Shwartz-Ziv and A. Armon, “Tabular data: Deep learning is not all you need,” 2022, [Online]. Available: <https://arxiv.org/abs/2106.03253>.

- [34] D. T. Kertapati, “Anak-anak luar biasa,” 2023, [Online]. Available: https://kemkes.go.id/app_asset/file_content_download/171090786265fa61d67ff2e9.83516065.pdf.
- [35] “Burden and inequality of autism spectrum disorders in global, east asian, and south-east asian regions, 1990–2021,” 2021, [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/40819035/>.
- [36] A. Adhikary, “Identification of novel diagnostic neuroimaging biomarkers for autism spectrum disorder through convolutional neural network-based analysis of functional, structural, and diffusion tensor imaging data towards enhanced autism diagnosis,” 2024, [Online]. Available: <https://doi.org/10.48550/arXiv.2305.18841>.
- [37] S. Saha and M. Baumert, “Intra- and inter-subject variability in eeg-based sensorimotor brain computer interface: A review,” 2020, [Online]. Available: <https://doi.org/10.3389/fncom.2019.00087>.
- [38] G. M. Rojas, C. Alvarez, C. E. Montoya, M. de la Iglesia-Vayá, J. E. Cisternas, and M. Gálvez, “Study of resting-state functional connectivity networks using eeg electrodes position as seed,” 2018, [Online]. Available: <https://doi.org/10.3389/fnins.2018.00235>.
- [39] C. Ahuja and D. Sethia, “Harnessing few-shot learning for eeg signal classification: A survey of state-of-the-art techniques and future directions,” 2024, [Online]. Available: <https://doi.org/10.3389/fnhum.2024.1421922>.
- [40] A. Singh, N. K. Chatta, Y. Vagula, A. Ehtesham, S. Kumar, and T. T. Khoei, “A taxonomy of generative models with a focus on diffusion models and denoising techniques,” 2025, [Online]. Available: <https://www.mdpi.com/2079-9292/15/6/1293>.