



UNIVERSITAS INDONESIA

**ANALISIS AUGMENTASI DATA BERBASIS VARIATIONAL
AUTOENCODER UNTUK KLASIFIKASI AUTISM SPECTRUM
DISORDER MENGGUNAKAN SINYAL EEG**

SKRIPSI

**WENDY DHARMAWAN
2206059591**

**FAKULTAS TEKNIK
PROGRAM STUDI S1 TEKNIK KOMPUTER
DEPOK
2025**



UNIVERSITAS INDONESIA

**ANALISIS AUGMENTASI DATA BERBASIS VARIATIONAL
AUTOENCODER UNTUK KLASIFIKASI AUTISM SPECTRUM
DISORDER MENGGUNAKAN SINYAL EEG**

SKRIPSI

**Diajukan sebagai salah satu syarat untuk memperoleh gelar
Sarjana Teknik**

**WENDY DHARMAWAN
2206059591**

**FAKULTAS TEKNIK
PROGRAM STUDI S1 TEKNIK KOMPUTER
DEPOK
JULI 2025**

HALAMAN PERNYATAAN ORISINALITAS

**Skripsi ini adalah hasil karya saya sendiri,
dan semua sumber baik yang dikutip maupun dirujuk
telah saya nyatakan dengan benar.**

Nama : Wendy Dharmawan

NPM : 2206059591

Tanda Tangan :

Tanggal : 25 Juli 2025

HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL

Saya menyatakan bahwa dalam penyusunan Tugas Akhir ini, saya menggunakan teknologi Kecerdasan Buatan dengan platform Gemini dan ChatGPT untuk tujuan pemeriksaan dan perbaikan tata bahasa dan saya bertanggung jawab penuh atas keakuratan, orisinalitas, dan integritas seluruh isi Tugas Akhir ini.

Nama : Wendy Dharmawan

NPM : 2206059591

Tanda Tangan :

Tanggal : 25 Juli 2025

HALAMAN PENGESAHAN

Skripsi ini diajukan oleh :
Nama : Wendy Dharmawan
NPM : 2206059591
Program Studi : S1 Teknik Komputer
Judul Skripsi : Analisis Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG

Telah berhasil dipertahankan di hadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Sarjana Teknik pada Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.

DEWAN PENGUJI

Pembimbing : [Nama Dosen Pembimbing] ()
Penguji : [Nama Dosen Penguji 1] ()
Penguji : [Nama Dosen Penguji 2] ()
Penguji : [Nama Dosen Penguji 3] ()

Ditetapkan di : Depok
Tanggal : 1 Agustus 2025

KATA PENGANTAR

Puji dan syukur Penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan rahmat-Nya lah Penulis dapat menyelesaikan Skripsi dengan judul “Analisis Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG”. Skripsi ini Penulis laksanakan sebagai salah satu syarat dalam memperoleh gelar Sarjana Teknik pada program studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.

Penulis juga ingin menyampaikan rasa terima kasihnya kepada:

1. [Nama Dosen Pembimbing], selaku Dosen Pembimbing Skripsi Penulis.
2. [Nama Ketua Departemen], selaku Ketua Departemen Teknik Elektro, Fakultas Teknik, Universitas Indonesia.
3. [Nama Ketua Prodi], selaku Kepala Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.
4. [Nama Dosen Pembimbing Akademis], selaku Pembimbing Akademis Penulis.
5. [Nama Dosen Penguji 1], [Nama Dosen Penguji 2] dan [Nama Dosen Penguji 3] selaku Dosen Penguji Skripsi Penulis.
6. Segenap dosen Departemen Teknik Elektro atas semua ilmu yang diberikan kepada Penulis.
7. Orang tua yang selalu memberikan dukungan serta doa, sehingga penulisan Skripsi dapat diselesaikan secara baik.
8. Teman-teman Teknik Komputer, selaku rekan penulis yang selalu membantu serta memberikan dukungan moril sepanjang proses kuliah serta penulisan proposal skripsi.

Penulis menyadari dan menerima bahwa Skripsi yang dibentuk ini masih jauh dari sempurna dan masih memiliki berbagai kekurangan serta kesalahan baik dari segi ilmu maupun pemahaman. Oleh karena itu, Penulis mengharapkan segala kritik dan saran yang diberikan agar ke depannya Penulis dapat menjadi lebih baik.

25 Juli 2025

Wendy Dharmawan

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas akademik Universitas Indonesia, saya yang bertanda tangan di bawah ini:

Nama : Wendy Dharmawan
NPM : 2206059591
Program Studi : S1 Teknik Komputer
Fakultas : Teknik
Jenis Karya : Skripsi

demikian pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Indonesia **Hak Bebas Royalti Noneksklusif** (*Non-exclusive Royalty Free Right*) atas karya ilmiah saya yang berjudul:

Analisis Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Universitas Indonesia berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyataan ini saya buat dengan sebenarnya.

Dibuat di : Depok
Pada tanggal : 25 Juli 2025
Yang menyatakan

(Wendy Dharmawan)
vii

ABSTRAK

Nama : Wendy Dharmawan
Program Studi : S1 Teknik Komputer
Judul : Analisis Augmentasi Data Berbasis Variational Autoencoder untuk Klasifikasi Autism Spectrum Disorder Menggunakan Sinyal EEG
Pembimbing : [Nama Dosen Pembimbing]

Kata kunci: sistem informasi akademik, manajemen tugas akhir, templat $\text{\LaTeX}$, evaluasi usabilitas, rekayasa perangkat lunak.

ABSTRACT

Name : Wendy Dharmawan
Study Program : S1 Teknik Komputer
Title : Analysis of Data Augmentation Using Variational Autoencoder for EEG-Based Autism Spectrum Disorder Classification
Supervisor : [Nama Dosen Pembimbing]

Keywords: academic information system, thesis management, L^AT_EX template, usability evaluation, software engineering.

DAFTAR ISI

HALAMAN JUDUL	i
HALAMAN PERNYATAAN ORISINALITAS	ii
HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL	iii
HALAMAN PENGESAHAN	iv
KATA PENGANTAR	v
HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI	vii
ABSTRAK	viii
ABSTRACT	ix
DAFTAR ISI	x
DAFTAR TABEL	xii
DAFTAR GAMBAR	xiii
DAFTAR KODE PROGRAM	xiv
DAFTAR SINGKATAN	xiv
1 PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	3
1.3 Tujuan Penelitian	4
1.4 Manfaat Penelitian	4
1.5 Ruang Lingkup Penelitian	5
1.6 Sistematika Penulisan	6
2 TINJAUAN PUSTAKA	8
2.1 Landasan Teori	8
2.1.1 Sinyal EEG	8
2.1.2 Feature Selection mRMR	13
2.1.3 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG	15
2.1.4 Augmentasi Data EEG	16
2.1.5 Model Generatif untuk Augmentasi Data	18
2.1.6 Variational Auto Encoder	20
2.1.7 Metode Evaluasi Data Sintetis Sinyal EEG	22
2.2 Penelitian Terdahulu	23

2.2.1	Klasifikasi ASD Berbasis EEG Menggunakan mRMR dan XGBoost	23
2.2.2	Metode Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder	24
2.2.3	Dataset EEG yang Digunakan	24
2.3	Fokus pada Celah Penelitian	25
3	PERANCANGAN DAN IMPLEMENTASI SISTEM	27
3.1	Analisis Kebutuhan Sistem	27
3.1.1	Tujuan Sistem	28
3.1.2	Kebutuhan Sistem	28
3.1.3	Batasan Sistem	28
3.2	Perancangan Arsitektur Sistem	29
3.2.1	Pra-Pemrosesan Dataset	31
3.2.2	Arsitektur Model VAE untuk Augmentasi Data	32
3.2.3	Arsitektur Model Klasifikasi	34
3.3	Detail Implementasi dan Teknologi	36
3.3.1	Teknologi dan Library	37
3.3.2	Implementasi Model Generatif Variational Autoencoder (VAE) . .	37
3.3.3	Implementasi Model Klasifikasi	42
4	PENUTUP	44
4.1	Kesimpulan	44
4.2	Pengembangan Lanjutan	46
	DAFTAR PUSTAKA	48
	DAFTAR PUSTAKA	48

DAFTAR TABEL

Tabel 2.1	Pita frekuensi EEG dan karakteristiknya	10
Tabel 2.2	Metode augmentasi konvensional pada data <i>time-series</i> . . .	18
Tabel 2.3	Perbandingan beberapa model generatif	19
Tabel 2.4	Metrik evaluasi data sintetis EEG	22
Tabel 3.1	Konfigurasi Parameter <i>XGBoost</i>	43

DAFTAR GAMBAR

Gambar 2.1	Sistem Internasional 10–20 untuk Penempatan Elektroda EEG	9
Gambar 2.2	Pita Frekuensi EEG pada Rentang Frekuensi Tinggi dan Rendah	11
Gambar 2.3	Ilustrasi pengaruh berbagai jenis filter terhadap sinyal EEG	12
Gambar 2.4	Bentuk-Bentuk Artefak pada Sinyal EEG	12
Gambar 2.5	Ilustrasi <i>U-shaped spectral profile</i> yang ditemukan pada pita frekuensi penderita ASD	15
Gambar 2.6	Ilustrasi umum pipeline klasifikasi ASD berbasis sinyal EEG	16
Gambar 2.7	Ilustrasi Metode Augmentasi Konvensional pada Data <i>Time-Series</i>	17
Gambar 2.8	Arsitektur umum <i>Variational Autoencoder</i> (VAE)	20
Gambar 3.1	Diagram aliran data pada sistem	30
Gambar 3.2	Diagram aliran proses prapemrosesan sistem	31
Gambar 3.3	Diagram Model VAE untuk Augmentasi EEG	33
Gambar 3.4	Diagram Model Klasifikasi	35
Gambar 3.5	Diagram Aliran Layer <i>Encoder</i> pada Model VAE	38
Gambar 3.6	Diagram aliran Reparameterization Layer	39
Gambar 3.7	Diagram aliran Decoder Layer	41
Gambar 4.1	Perbandingan sampel sinyal EEG asli dan sintetis pada channel Fp1 dalam domain waktu	46
Gambar 4.2	Perbandingan PSD antara sampel sinyal asli dan sintetis pada channel Fp1	46

DAFTAR SINGKATAN

ASD	<i>Autism Spectrum Disorder</i>
BCI	<i>Brain–Computer Interface</i>
CNN	<i>Convolutional Neural Network</i>
DWT	<i>Discrete Wavelet Transform</i>
EEG	<i>Electroencephalography</i>
ELBO	<i>Evidence Lower Bound</i>
EMG	<i>Electromyogram</i>
EOG	<i>Electrooculogram</i>
FFT	<i>Fast Fourier Transform</i>
GAN	<i>Generative Adversarial Network</i>
ICA	<i>Independent Component Analysis</i>
kNN	<i>k-Nearest Neighbor</i>
KL	<i>Kullback–Leibler</i>
mRMR	<i>Minimum Redundancy Maximum Relevance</i>
PSD	<i>Power Spectral Density</i>
SNR	<i>Signal-to-Noise Ratio</i>
SVM	<i>Support Vector Machine</i>
VAE	<i>Variational Autoencoder</i>

BAB 1

PENDAHULUAN

Autism Spectrum Disorder (ASD) merupakan gangguan neurologis yang memengaruhi komunikasi, interaksi sosial, dan perilaku individu, sehingga proses identifikasi dini memiliki peranan penting dalam penanganannya. Analisis sinyal electroencephalography (EEG) menggunakan metode machine learning mulai banyak diteliti sebagai pendekatan dalam proses klasifikasi ASD secara lebih objektif. Meskipun demikian, pengembangan model klasifikasi berbasis EEG masih menghadapi tantangan berupa keterbatasan dataset EEG yang tersedia dan tingginya variabilitas sinyal antar individu maupun antar sesi perekaman. Karakteristik tersebut menyebabkan terhambatnya proses pengembangan model klasifikasi EEG yang mampu memberikan performa secara konsisten pada data dengan karakteristik yang berbeda. Salah satu pendekatan yang mulai banyak digunakan untuk mengatasi permasalahan tersebut adalah teknik *data augmentation*, yaitu proses penambahan variasi data *training* secara artifisial, sehingga diharapkan dapat meningkatkan performa dan kemampuan generalisasi model.

Bab ini akan dimulai dengan penjelasan Latar Belakang yang memberikan konteks penting terkait penelitian ini, diikuti oleh Rumusan Masalah dan Tujuan Penelitian yang merinci fokus utama studi. Selanjutnya, akan dibahas Manfaat Penelitian dan Ruang Lingkup Penelitian untuk menjelaskan kontribusi serta batasan penelitian ini. Terakhir, Sistematika Penulisan akan menguraikan struktur keseluruhan laporan penelitian.

1.1 Latar Belakang

Autism Spectrum Disorder (ASD) merupakan gangguan neurologis yang ditandai oleh hambatan dalam komunikasi dan interaksi sosial, serta pola perilaku yang terbatas dan berulang [1], [2]. Identifikasi dan intervensi dini menjadi faktor penting dalam membantu perkembangan individu dengan ASD, namun proses diagnosis masih menghadapi berbagai tantangan karena karakteristik gejala yang heterogen dan sering kali menyerupai gangguan perkembangan lainnya [3] [4]. Kondisi tersebut mendorong berkembangnya

pendekatan diagnosis berbasis biomarker yang lebih objektif dan konsisten.

Salah satu pendekatan yang banyak diteliti adalah analisis electroencephalography (EEG) menggunakan metode machine learning. Dibandingkan dengan metode lainnya, EEG memiliki keunggulan karena bersifat non-invasif, relatif lebih murah, dan memiliki resolusi temporal yang tinggi [5] [6]. Berbagai penelitian menunjukkan bahwa model machine learning mampu mengidentifikasi pola aktivitas otak yang berkaitan dengan ASD melalui sinyal EEG dengan performa klasifikasi yang cukup baik [7]. Penelitian rujukan [8] mengusulkan pendekatan klasifikasi ASD berbasis EEG menggunakan kombinasi seleksi fitur minimum Redundancy Maximum Relevance (mRMR) dan algoritma XGBoost yang menunjukkan performa klasifikasi yang baik dan konsisten.

Meskipun demikian, pengembangan model klasifikasi EEG masih menghadapi berbagai tantangan, terutama terkait keterbatasan dataset EEG yang tersedia secara publik dan telah memiliki label klinis [9]. Proses akuisisi dan pelabelan data EEG umumnya membutuhkan biaya, waktu, serta keterlibatan tenaga ahli, sehingga jumlah data yang tersedia sering kali terbatas. Keterbatasan dataset ini dapat meningkatkan risiko overfitting pada proses training model machine learning dan membatasi kemampuan model dalam melakukan generalisasi terhadap data baru [10]. Selain itu, sinyal EEG juga rentan terhadap berbagai artefak, seperti gerakan otot, kedipan mata, maupun gangguan pada perangkat perekaman yang dapat memengaruhi kualitas sinyal [11]. Keberadaan artefak tersebut menyebabkan proses analisis EEG menjadi lebih sulit karena sinyal yang diperoleh tidak selalu merepresentasikan aktivitas otak yang sebenarnya.

Salah satu pendekatan yang mulai banyak diteliti untuk mengatasi keterbatasan dataset EEG adalah penggunaan teknik data augmentation. Teknik ini bertujuan untuk meningkatkan jumlah dan variasi data training secara artifisial sehingga model dapat mempelajari representasi fitur yang lebih beragam. Beberapa penelitian menunjukkan bahwa penerapan data augmentation pada data EEG dapat membantu meningkatkan performa model klasifikasi dan mengurangi risiko overfitting pada kondisi dataset yang terbatas [12].

Penerapan augmentasi pada data EEG memiliki tantangan tersendiri karena sinyal EEG merupakan data *time series* multikanal yang bersifat non-stasioner dan memiliki rasio *signal-to-noise* yang rendah [13]. Berbeda dengan berbagai jenis data multimedia

lain seperti citra, audio, atau video yang umumnya memiliki pola representasi yang lebih stabil, manipulasi pada data EEG perlu dilakukan secara hati-hati karena perubahan pada sinyal dapat memengaruhi representasi aktivitas otak yang dianalisis. Pendekatan augmentasi data konvensional pada data *time series* umumnya dilakukan melalui transformasi sederhana seperti penambahan *noise*, pergeseran waktu, atau manipulasi amplitudo. Namun, pada data EEG, transformasi tersebut berpotensi mengubah karakteristik temporal dan spasial yang digunakan dalam proses analisis maupun klasifikasi sinyal [14].

Seiring dengan perkembangan deep learning, pendekatan berbasis model generatif seperti Variational Autoencoder (VAE) mulai digunakan untuk menghasilkan data EEG sintetis yang lebih representatif. Model VAE mempelajari distribusi laten dari data EEG sehingga mampu menghasilkan sampel baru yang berbeda namun tetap mempertahankan karakteristik statistik dari data asli. Pendekatan generatif memiliki potensi untuk menghasilkan variasi data yang lebih realistis dibandingkan metode augmentasi konvensional [14]. Meskipun demikian, pemanfaatan data sintetis berbasis model generatif pada klasifikasi EEG, khususnya dalam konteks Autism Spectrum Disorder (ASD), masih memerlukan kajian lebih lanjut untuk memahami pengaruhnya terhadap performa dan kemampuan generalisasi model klasifikasi.

Berdasarkan permasalahan tersebut, penelitian ini bertujuan untuk mengeksplorasi penggunaan teknik data augmentation berbasis Variational Autoencoder (VAE) untuk menghasilkan data EEG sintetis dan menganalisis pengaruhnya terhadap performa model klasifikasi ASD berbasis EEG. Penelitian dilakukan dengan mengimplementasikan pendekatan klasifikasi EEG menggunakan seleksi fitur mRMR dan algoritma XGBoost berdasarkan penelitian rujukan [8], kemudian mengevaluasi perbedaan performa model sebelum dan sesudah penerapan data augmentasi.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, permasalahan utama dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana pendekatan yang dapat digunakan untuk mengatasi keterbatasan jumlah dan variasi data pada sinyal EEG dalam konteks klasifikasi Autism Spectrum

Disorder (ASD)?

2. Bagaimana pendekatan tersebut dapat dirancang dan diintegrasikan ke dalam pipeline pemrosesan data EEG untuk mendukung proses klasifikasi?
3. Bagaimana pengaruh penambahan atau peningkatan variasi data terhadap performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD)?

1.3 Tujuan Penelitian

Selaras dengan rumusan masalah yang telah diuraikan, tujuan dari penelitian ini mencakup sebagai berikut:

1. Mengidentifikasi dan mengeksplorasi pendekatan yang dapat digunakan untuk mengatasi keterbatasan jumlah dan variasi data pada sinyal EEG dalam klasifikasi Autism Spectrum Disorder (ASD).
2. Merancang dan mengintegrasikan pendekatan tersebut ke dalam pipeline pemrosesan data EEG untuk mendukung proses klasifikasi.
3. Menganalisis pengaruh penambahan atau peningkatan variasi data terhadap performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD).

1.4 Manfaat Penelitian

Berdasarkan latar belakang, rumusan masalah, dan tujuan penelitian yang telah diuraikan, penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. Bagi Peneliti dan Pengembangan Metode:

Penelitian ini diharapkan dapat menjadi referensi dalam pengembangan dan pemanfaatan teknik *data augmentation* pada sinyal EEG, serta membuka peluang bagi pengembangan metode klasifikasi dan diagnosis di masa depan yang mampu memanfaatkan data dalam jumlah yang lebih besar dan beragam, sehingga meningkatkan robustness dan kemampuan generalisasi model.

2. Bagi Tenaga Medis dan Profesional Kesehatan:

Penelitian ini diharapkan dapat memberikan gambaran mengenai potensi pemanfaatan *machine learning* dalam analisis data EEG pada studi Autism Spectrum Disorder (ASD), maupun untuk sehingga dapat mendukung pemahaman dan penelitian lanjutan terkait pendekatan berbasis data dalam konteks klinis.

1.5 Ruang Lingkup Penelitian

Agar penelitian ini tetap terfokus, maka ruang lingkup penelitian ditetapkan sebagai berikut:

1. **Dataset Penelitian:** Penelitian ini menggunakan dataset EEG yang sama dengan dataset pada penelitian rujukan [8][6]. Dataset tersebut digunakan sebagai dasar dalam proses pelatihan model augmentasi maupun model klasifikasi sehingga hasil penelitian dapat dibandingkan secara relevan dengan penelitian sebelumnya.
2. **Metode Preprocessing Data:** Tahapan *preprocessing* data EEG mengikuti prosedur yang digunakan pada penelitian rujukan [8]. Proses ini mencakup tahapan pengolahan data yang diperlukan sebelum proses seleksi fitur, augmentasi data, dan klasifikasi dilakukan.
3. **Metode Augmentasi dan Klasifikasi:** Penelitian ini menerapkan metode *data augmentation* berbasis *Variational Autoencoder* (VAE) untuk menghasilkan data EEG sintetis. Selanjutnya, proses klasifikasi dilakukan menggunakan pendekatan yang mengacu pada penelitian rujukan [8], yaitu kombinasi seleksi fitur *mRMR* dan model klasifikasi *XGBoost*.
4. **Metode Evaluasi:** Evaluasi penelitian dilakukan dengan membandingkan performa model klasifikasi pada data tanpa augmentasi dan dengan augmentasi. Penilaian kualitas data sintetis serta performa klasifikasi mengacu pada metode evaluasi yang digunakan dalam penelitian rujukan [15].
5. **Hasil Akhir Penelitian:** Penelitian ini menghasilkan model *data augmentation* EEG berbasis *Variational Autoencoder* (VAE) yang dapat digunakan untuk meng-

hasilkan data EEG sintetis guna mendukung peningkatan performa model klasifikasi.

6. **Batasan Penelitian:** Penelitian difokuskan pada analisis pengaruh penerapan *data augmentation* EEG terhadap kualitas performa model klasifikasi. Penelitian ini tidak membahas aspek perangkat keras EEG, proses akuisisi data asli, maupun tahapan penghilangan *noise* dan *artifact removal* di luar prosedur *preprocessing* yang telah ditetapkan pada penelitian rujukan.

1.6 Sistematika Penulisan

Laporan tesis ini disusun secara sistematis ke dalam lima bab utama, dengan rincian sebagai berikut:

1. **Bab 1: Pendahuluan.** Bab ini menyajikan gambaran umum penelitian, meliputi latar belakang yang menjelaskan pentingnya analisis sinyal EEG dalam mendukung identifikasi Autism Spectrum Disorder (ASD), rumusan masalah yang menjadi dasar penelitian, tujuan yang ingin dicapai, manfaat penelitian, ruang lingkup penelitian, serta sistematika penulisan laporan ini.
2. **Bab 2: Tinjauan Pustaka.** Bab ini menguraikan landasan teoretis yang mendukung penelitian, meliputi konsep dasar sinyal EEG, metode ekstraksi dan seleksi fitur pada data EEG, metode *Minimum Redundancy Maximum Relevance* (mRMR), implementasi *machine learning* dalam klasifikasi berdasarkan EEG, metode augmentasi data EEG, model *Variational AutoEncoder*, serta kajian terhadap penelitian-penelitian sebelumnya yang bersifat relevan.
3. **Bab 3: Metodologi Penelitian.** Bab ini menjelaskan metode yang digunakan dalam penelitian, mencakup deskripsi dataset EEG yang digunakan, tahapan pra-pemrosesan data, penerapan teknik *data augmentation*, proses seleksi fitur menggunakan metode *mRMR*, arsitektur model augmentasi berbasis *VAE*, serta konfigurasi *training* model klasifikasi menggunakan *XGBoost*.
4. **Bab 4: Hasil dan Analisis.** Bab ini memaparkan hasil eksperimen yang diperoleh dari proses *training* dan pengujian model. Analisis dilakukan untuk membanding-

kan performa model pada skenario dengan dan tanpa penerapan *data augmentasi*, serta mengevaluasi pengaruhnya terhadap kemampuan model dalam melakukan klasifikasi data EEG.

5. **Bab 5: Penutup.** Bab terakhir ini berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran untuk pengembangan penelitian selanjutnya terkait analisis dan klasifikasi data EEG menggunakan metode *machine learning* .

BAB 2

TINJAUAN PUSTAKA

Bab ini menjelaskan konteks dan landasan teoretis yang mendasari penelitian mengenai analisis sinyal EEG untuk klasifikasi *Autism Spectrum Disorder* (ASD) menggunakan metode *machine learning*. Penjelasan diawali dengan pemaparan landasan teori, dilanjutkan dengan pembahasan penelitian terdahulu yang relevan, dan diakhiri dengan pembahasan mengenai celah penelitian yang menjadi dasar penelitian ini.

2.1 Landasan Teori


Bagian ini menguraikan konsep-konsep teoretis yang menjadi dasar dalam penelitian analisis sinyal EEG untuk klasifikasi Autism Spectrum Disorder (ASD). Landasan teori ini mencakup konsep dasar EEG, tahapan pemrosesan sinyal EEG, teknik seleksi fitur dalam pemrosesan, metode *machine learning* untuk klasifikasi, serta metode *data augmentation* yang digunakan dalam penelitian ini.

2.1.1 Sinyal EEG

Sinyal *electroencephalogram* (EEG) dihasilkan oleh aktivitas listrik neuron di otak yang muncul akibat aktivitas sinaptik antar neuron, sehingga potensial listrik yang dihasilkan dapat dideteksi pada permukaan kepala menggunakan elektroda. Sinyal EEG direkam sebagai perubahan tegangan terhadap waktu dengan rentang frekuensi sekitar 0,5 hingga 100 Hz dan amplitudo yang relatif rendah, umumnya berada pada kisaran 10 hingga 100 mikrovolt. Selain memiliki resolusi temporal yang tinggi, sinyal EEG juga bersifat *non-stationary*, sehingga karakteristik amplitudo dan distribusi frekuensinya dapat berubah secara dinamis seiring waktu akibat pengaruh kondisi fisiologis, tingkat kesadaran, maupun aktivitas kognitif. Aktivitas yang terekam mencerminkan berbagai proses otak, seperti fungsi kognitif, motorik, dan emosional, sehingga EEG banyak digunakan untuk mempelajari fungsi otak dan gangguan neurologis [16].

EEG biasanya direkam dalam bentuk sinyal multikanal yang diperoleh dari sejumlah

lah elektroda yang ditempatkan pada berbagai lokasi di permukaan kulit kepala. Setiap kanal merepresentasikan satu jalur perekaman sinyal yang berasal dari pasangan elektroda atau dari elektroda terhadap referensi tertentu. Setiap elektroda menangkap aktivitas listrik dari wilayah otak yang berbeda, sehingga setiap kanal mengandung informasi yang merepresentasikan aktivitas saraf pada lokasi tertentu.[13].



Gambar 2.1. Sistem Internasional 10–20 untuk Penempatan Elektroda EEG

Penempatan elektroda EEG umumnya mengikuti standar International *10–20 System*, yaitu protokol yang distandarisasi oleh *International Federation of Clinical Neurophysiology* (IFCN) untuk menentukan posisi elektroda pada permukaan kepala berdasarkan titik anatomi seperti nasion, inion, dan titik preauricular. Dalam sistem ini, setiap elektroda diberi kode huruf dan angka yang menunjukkan wilayah otak dan hemisfer terkait, seperti frontal (F), central (C), temporal (T), parietal (P), dan occipital (O), dengan angka ganjil untuk hemisfer kiri, angka genap untuk hemisfer kanan, serta “z” untuk posisi garis tengah kepala. Standarisasi ini memungkinkan perekaman EEG dilakukan secara konsisten dan dapat dibandingkan antar subjek maupun antar penelitian[17].

Dalam analisis sinyal EEG, aktivitas listrik otak yang terekam dapat dianalisis melalui dua domain utama, yaitu domain waktu dan domain frekuensi. Analisis dalam domain waktu dilakukan dengan mengamati karakteristik sinyal terhadap waktu, seperti amplitudo puncak, dan latensi. Sedangkan analisis dalam domain frekuensi bertujuan untuk


mengidentifikasi kandungan spektral sinyal dengan memeriksa distribusi energi atau daya pada berbagai rentang frekuensi menggunakan metode transformasi spektral, seperti *Fast Fourier Transform* (FFT) maupun teknik estimasi *Power Spectral Density* (PSD) untuk mengidentifikasi aktivitas otak pada rentang frekuensi tertentu [18].

Dalam analisis spektral EEG, sinyal umumnya dibagi ke dalam beberapa segmen waktu (*epoch*) sebelum dihitung nilai *Power Spectral Density* (PSD) untuk menggambarkan distribusi daya pada setiap frekuensi. Berdasarkan karakteristik fisiologis dan kognitifnya, sinyal EEG kemudian diklasifikasikan ke dalam beberapa pita frekuensi utama sebagai berikut.

Tabel 2.1. Pita frekuensi EEG dan karakteristiknya

Pita	Frekuensi (Hz)	Karakteristik
Delta	0,5–4	Dominan pada kondisi <i>deep sleep</i> dan berperan dalam proses pemulihan fisiologis serta regulasi fungsi tubuh selama tidur.
Theta	4–8	Berkaitan dengan proses pembentukan memori dan aktivitas pada sistem limbik serta hipokampus, serta muncul pada kondisi mengantuk atau relaksasi mendalam.
Alpha	8–13	Muncul pada kondisi rileks saat mata tertutup, dengan dominasi pada wilayah oksipital dan berhubungan dengan penurunan aktivitas pemrosesan sensorik.
Beta	13–30	Berkaitan dengan aktivitas kognitif aktif seperti konsentrasi, pemecahan masalah, serta aktivitas motorik.
Gamma	>30	Berhubungan dengan proses kognitif tingkat tinggi, termasuk perhatian, integrasi informasi sensorik, dan persepsi.


Melalui analisis distribusi daya pada pita frekuensi, dapat dilakukan identifikasi pola aktivitas otak yang khas serta membandingkan karakteristik sinyal EEG pada berbagai kondisi fisiologis maupun gangguan neurologis tertentu. Representasi pita frekuensi EEG sering digunakan sebagai dasar dalam proses ekstraksi fitur pada analisis sinyal EEG, misalnya melalui perhitungan *band power*, estimasi *power spectral density* (PSD), maupun metode analisis spektral lainnya [13].



Gambar 2.2. Pita Frekuensi EEG pada Rentang Frekuensi Tinggi dan Rendah


Sebelum dilakukan ekstraksi fitur dan klasifikasi, sinyal EEG umumnya melalui tahap *preprocessing* untuk meningkatkan kualitas sinyal dan mengurangi gangguan yang tidak relevan. Tahapan ini biasanya meliputi *filtering*, *artifact removal*, *baseline correction*, serta normalisasi atau standarisasi data [13].

Filtering adalah proses penyaringan sinyal untuk menghilangkan komponen frekuensi yang tidak berkaitan dengan aktivitas saraf serta mengurangi gangguan dari lingkungan seperti interferensi listrik serta gangguan yang muncul akibat pergerakan elektroda dan perubahan impedansi kulit. *Filtering* dilakukan dengan membatasi rentang frekuensi sinyal menggunakan filter tertentu. Umumnya, *band-pass filter* digunakan untuk mempertahankan frekuensi aktivitas otak, serta *notch filter* untuk mereduksi interferensi jaringan listrik. Filter tambahan seperti *high-pass filter* juga dapat digunakan untuk menghilangkan *drift* sinyal berfrekuensi sangat rendah, sedangkan *low-pass filter* digunakan untuk mereduksi komponen *noise* berfrekuensi tinggi. Pemilihan filter perlu dilakukan secara hati-hati untuk menghindari distorsi sinyal atau pergeseran fase sinyal [13]. Pengaruh penggunaan filter terhadap sinyal EEG dapat dilihat pada ilustrasi berikut.



Gambar 2.3. Ilustrasi pengaruh berbagai jenis filter terhadap sinyal EEG

Sinyal EEG dapat terkontaminasi oleh artefak non-neural yang berasal dari aktivitas fisiologis maupun faktor eksternal. Artefak fisiologis umumnya disebabkan oleh kedipan mata dan pergerakan bola mata (*electrooculogram*), aktivitas otot wajah dan kepala (*electromyogram*), serta pergerakan tubuh selama proses perekaman, sedangkan artefak eksternal dapat berasal dari interferensi perangkat elektronik dan jaringan listrik. Keberadaan artefak dapat mempengaruhi kualitas sinyal dan berpotensi menurunkan akurasi analisis maupun kinerja sistem klasifikasi. Berbagai metode digunakan untuk mengurangi artefak pada sinyal EEG, seperti *Blind Source Separation* (BSS), *Independent Component Analysis* (ICA), serta transformasi wavelet yang memungkinkan analisis pada domain waktu dan frekuensi untuk mendeteksi artefak [13].



Gambar 2.4. Bentuk-Bentuk Artefak pada Sinyal EEG

Dalam analisis EEG berbasis *machine learning*, normalisasi atau standarisasi digunakan untuk mengurangi variasi antar kanal maupun antar subjek yang menyebabkan perbedaan skala fitur dan mempengaruhi proses *training*. Proses normalisasi digunakan untuk menyesuaikan skala fitur agar berada dalam rentang yang lebih seragam. Salah satu metode yang umum digunakan adalah *Z-score normalization*, yaitu mengurangi nilai rata-rata dan membaginya dengan standar deviasi sehingga data memiliki rata-rata nol dan variansi satu, sedangkan *min-max normalization* juga dapat dilakukan dengan men-skalakan nilai fitur ke dalam rentang tertentu, umumnya antara 0 dan 1. Proses ini memastikan kontribusi fitur lebih seimbang serta meningkatkan stabilitas dan kinerja model [13].

2.1.2 Feature Selection mRMR

Dalam aplikasi klasifikasi *machine learning*, *feature selection* merupakan langkah krusial untuk meminimalkan kesalahan klasifikasi. Secara formal, diberikan dataset D yang terdiri dari N sampel dan M fitur $X = \{x_i \mid i = 1, 2, \dots, M\}$, serta variabel target c , maka seleksi fitur bertujuan menentukan subset berdimensi lebih rendah $R^m \subset R^M$ dengan $m < M$ yang mampu merepresentasikan target secara optimal[19].

Secara umum, tujuan *feature selection* dapat diformulasikan sebagai proses optimasi untuk mencari himpunan fitur $S \subseteq X$ dengan $|S| = m$ yang memaksimalkan ketergantungan terhadap kelas target. Ketergantungan ini seringkali diukur menggunakan *mutual information* $I(S; c)$, sehingga permasalahan dapat dinyatakan sebagai:

$$\max_{S \subseteq X, |S|=m} I(S; c) \quad (2.1)$$

Penggunaan seluruh fitur tidak selalu menghasilkan performa optimal karena adanya redundansi antar fitur. Fitur dengan korelasi tinggi cenderung memberikan informasi yang berulang, sehingga diperlukan metode *feature selection* yang mempertimbangkan relevansi terhadap target sekaligus meminimalkan redundansi.

Minimum Redundancy Maximum Relevance (mRMR) merupakan teknik seleksi fitur berbasis teori informasi yang memilih subset fitur dengan relevansi tinggi terhadap target dan redundansi rendah antar fitur. Pendekatan ini efektif dalam mengurangi dimensi data tanpa mengorbankan informasi penting, sehingga meningkatkan efisiensi komputasi dan

kemampuan generalisasi model [20][21]. Proses pemilihan fitur pada metode mRMR dilakukan secara iteratif dengan mengevaluasi keseimbangan antara relevansi fitur terhadap kelas target dan redundansi antar fitur yang telah dipilih sebelumnya.

Listing 2.1. Pseudocode algoritma mRMR untuk seleksi fitur.

```

1  # mRMR Feature Selection Algorithm
2
3  def mrmr_feature_selection(X, c, m):
4
5      S = []                # selected features
6      F = X                # candidate features
7
8      # Select feature with maximum relevance
9      for xi in F:
10         relevance[xi] = MI(xi, c)
11
12     x_best = argmax(relevance)
13
14     S.append(x_best)
15     F.remove(x_best)
16
17     # Iterative feature selection
18     while len(S) < m:
19
20         for xj in F:
21
22             rel = MI(xj, c)
23
24             red = 0
25             for xs in S:
26                 red += MI(xj, xs)
27
28             red = red / len(S)
29
30             score[xj] = rel - red
31
32         x_best = argmax(score)
33
34         S.append(x_best)
35         F.remove(x_best)
36
37     return S

```

Kode 2.1 menjelaskan proses seleksi fitur menggunakan metode *Minimum Redundancy Maximum Relevance* (mRMR). Algoritma dimulai dengan memilih fitur yang memiliki nilai *mutual information* tertinggi terhadap kelas target sebagai fitur awal. Selanjutnya, fitur lain dipilih secara iteratif berdasarkan nilai *mRMR score*, yaitu selisih antara relevansi fitur terhadap target dan redundansinya terhadap fitur yang dipilih sebelumnya. Proses ini dilakukan hingga jumlah fitur terpilih mencapai jumlah yang diinginkan.

2.1.3 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG

Dalam analisis EEG, *machine learning* digunakan untuk mengklasifikasikan pola aktivitas otak berdasarkan fitur yang diekstraksi dari sinyal EEG. Fitur tersebut dapat berasal dari domain waktu, domain frekuensi, maupun domain waktu-frekuensi, dan digunakan untuk merepresentasikan karakteristik aktivitas neural yang berkaitan dengan kondisi fisiologis atau neurologis tertentu [22]. Pendekatan ini telah digunakan pada berbagai aplikasi seperti deteksi kejang epilepsi, sistem *brain-computer interface* (BCI), serta identifikasi pola aktivitas otak pada *Autism Spectrum Disorder* (ASD) [23].

Pada studi ASD, analisis EEG dalam domain frekuensi menjadi salah satu pendekatan yang umum digunakan karena aktivitas otak dapat direpresentasikan sebagai pola osilasi pada pita frekuensi tertentu [24]. Beberapa penelitian menunjukkan bahwa individu dengan ASD cenderung memiliki peningkatan daya pada pita delta, theta, beta, dan gamma, serta penurunan pada pita alpha. Pola ini dikenal sebagai *U-shaped spectral profile* dan digunakan untuk merepresentasikan abnormalitas aktivitas neural pada ASD [23].





Figure 1 Illustration of the U-shaped profile of abnormal power pattern in autism spectrum disorders (ASD).

Gambar 2.5. Ilustrasi *U-shaped spectral profile* yang ditemukan pada pita frekuensi penderita ASD

Berdasarkan fitur yang diperoleh, proses klasifikasi dilakukan menggunakan algoritma *machine learning* untuk membangun model prediksi. Berbagai metode seperti *support vector machine* (SVM), *k-nearest neighbor* (KNN), dan *random forest* telah banyak digunakan dalam klasifikasi EEG dan menunjukkan performa yang baik dalam mengenali pola aktivitas neural yang kompleks [22]. Meskipun pendekatan *deep learning* berkembang pesat, metode *machine learning* konvensional masih relevan terutama pada kondisi

data terbatas dan kebutuhan interpretabilitas model [25].



Gambar 2.6. Ilustrasi umum pipeline klasifikasi ASD berbasis sinyal EEG

Gambar ?? menunjukkan proses klasifikasi berbasis sinyal EEG pada umumnya. Pipeline diawali akuisisi sinyal EEG, dilanjutkan dengan tahap *preprocessing* untuk meningkatkan kualitas sinyal sebelum dianalisis lebih lanjut. Setelah itu, dilakukan proses ekstraksi fitur untuk memperoleh representasi informasi dari sinyal EEG yang relevan terhadap proses klasifikasi. Fitur yang telah diperoleh kemudian digunakan sebagai input bagi model *machine learning* untuk mempelajari pola aktivitas otak dan melakukan klasifikasi antara individu ASD dan non-ASD. Secara umum, pipeline ini bertujuan untuk mengubah sinyal EEG mentah menjadi representasi data yang dapat diproses oleh model klasifikasi dalam mendeteksi pola neurofisiologis yang berkaitan dengan ASD.


2.1.4 Augmentasi Data EEG

Performa model *machine learning* sangat dipengaruhi oleh jumlah, kualitas, dan keragaman data *training*. Pada analisis sinyal EEG, keterbatasan data menjadi tantangan karena proses akuisisi relatif mahal, memakan waktu, serta menghasilkan data dengan variabilitas tinggi antar individu maupun sesi [26]. Variabilitas tersebut dipengaruhi oleh perbedaan perangkat, konfigurasi kanal, kondisi eksperimen, aktivitas fisiologis, dan artefak

non-neural, sehingga distribusi data EEG menjadi kompleks dan tidak konsisten antar dataset. Kondisi ini dapat menyebabkan model mengalami *overfitting* dan memiliki kemampuan generalisasi yang rendah terhadap data baru.

Untuk mengatasi permasalahan tersebut, berbagai penelitian mengusulkan penggunaan teknik *data augmentation* untuk meningkatkan jumlah dan variasi data *training* tanpa memerlukan proses perekaman tambahan [12]. Secara umum, *data augmentation* bertujuan menghasilkan sampel data baru yang tetap mempertahankan karakteristik utama data asli sehingga model dapat mempelajari representasi pola yang lebih stabil.

Pada sinyal *time-series* seperti sinyal EEG, augmentasi konvensional umumnya dilakukan melalui manipulasi langsung terhadap sinyal dalam domain waktu maupun frekuensi [27]. Pendekatan ini menghasilkan sampel baru dengan memodifikasi data asli menggunakan aturan transformasi tertentu tanpa mempelajari distribusi data secara eksplisit. Beberapa metode yang umum digunakan meliputi *Noise Injection*, *Smoothing*, *Time Warping*, dan *Trend Shifting*. Ilustrasi penerapan metode-metode tersebut dapat dilihat pada Gambar 2.8.



Gambar 2.7. Ilustrasi Metode Augmentasi Konvensional pada Data *Time-Series*

Karakteristik umum dari masing-masing metode augmentasi konvensional dapat dijelaskan pada Tabel 2.2.

Tabel 2.2. Metode augmentasi konvensional pada data *time-series*

Metode	Formula	Pengaruh terhadap Data
<i>Noise Injection</i>	$x'(t) = x(t) + \epsilon$	Menambahkan <i>noise</i> acak untuk meningkatkan variasi data.
<i>Smoothing</i>	$x'(t) = \frac{1}{k} \sum_{i=0}^{k-1} x(t-i)$	Menghaluskan sinyal dengan mengurangi fluktuasi frekuensi tinggi.
<i>Time Warping</i>	$x'(t) = x(\phi(t))$	Mengubah skala waktu sinyal untuk menghasilkan variasi temporal data.
<i>Trend Shifting</i>	$x'(t) = x(t) + \alpha t$	Menambahkan perubahan tren gradual pada sinyal untuk memperkaya variasi distribusi data.

Meskipun relatif sederhana dan mudah diterapkan, metode augmentasi konvensional memiliki keterbatasan dalam mempertahankan karakteristik kompleks sinyal EEG secara menyeluruh. Transformasi langsung terhadap sinyal berpotensi mengubah dependensi spasial maupun temporal yang penting dalam representasi aktivitas fisiologis. Selain itu, beberapa penelitian menunjukkan bahwa augmentasi sederhana tidak selalu meningkatkan performa model klasifikasi EEG secara konsisten. Oleh karena itu, penelitian lain mulai menggunakan pendekatan berbasis model generatif yang mampu mempelajari distribusi data untuk menghasilkan sampel sintetis yang lebih representatif terhadap karakteristik sinyal EEG.

2.1.5 Model Generatif untuk Augmentasi Data

Model generatif merupakan pendekatan dalam *machine learning* yang mempelajari distribusi dan pola suatu dataset untuk menghasilkan sampel data baru yang memiliki karakteristik serupa dengan data asli, berbeda dengan model diskriminatif yang digunakan pada proses klasifikasi atau prediksi label [28]. Model generatif digunakan dalam berbagai aplikasi seperti sintesis gambar, rekonstruksi data (*data reconstruction*), pemrosesan suara, hingga pembuatan data sintetis untuk kebutuhan pelatihan model.

Data sintetis yang dihasilkan model generatif menjadi salah satu solusi terhadap

berbagai permasalahan pada proses pengolahan data, seperti keterbatasan jumlah data, ketidakseimbangan kelas (*class imbalance*), serta kendala privasi dan akuisisi data [28]. Dalam konteks *machine learning*, data sintetis yang dihasilkan oleh model generatif dapat digunakan sebagai bentuk *data augmentation* untuk meningkatkan jumlah dan keragaman data *training* tanpa memerlukan proses pengumpulan data baru secara langsung. Pendekatan ini memungkinkan model mempelajari representasi data yang lebih beragam sehingga dapat membantu meningkatkan kemampuan generalisasi model.

Berbagai arsitektur model generatif telah dikembangkan dalam penelitian *deep learning*. Beberapa pendekatan yang umum digunakan meliputi *Generative Adversarial Networks* (GAN), *Variational Autoencoders* (VAE), serta model berbasis difusi (*diffusion models*). Masing-masing pendekatan memiliki mekanisme pembelajaran dan karakteristik yang berbeda dalam menghasilkan data sintetis.

Tabel 2.3. Perbandingan beberapa model generatif

Model	Karakteristik Utama	Kelebihan dan Keterbatasan
GAN	Menggunakan mekanisme kompetitif antara generator dan discriminator untuk menghasilkan data sintetis.	Mampu menghasilkan data yang realistis, namun proses <i>training</i> cenderung tidak stabil dan rentan terhadap <i>mode collapse</i> .
VAE	Mempelajari distribusi laten probabilistik melalui arsitektur encoder-decoder.	Memiliki proses <i>training</i> yang lebih stabil dan mampu menghasilkan representasi laten yang terstruktur, namun kualitas data sintetis dapat lebih halus dibanding GAN.
Diffusion Model	Menghasilkan data melalui proses denoising bertahap dari distribusi acak.	Mampu menghasilkan kualitas data yang tinggi, namun memerlukan kompleksitas komputasi dan waktu <i>training</i> yang lebih besar.


Dalam analisis sinyal EEG, model generatif digunakan untuk menghasilkan data sintetis yang mengikuti distribusi statistik data asli. Pendekatan ini memungkinkan model mempelajari struktur laten dari sinyal EEG sehingga data sintetis yang dihasilkan dapat mempertahankan karakteristik temporal maupun spasial yang penting dalam proses

klasifikasi. Beberapa penelitian menunjukkan bahwa penggunaan data sintetis dari model generatif dapat membantu meningkatkan performa dan kemampuan generalisasi model klasifikasi EEG, terutama pada kondisi jumlah data *training* yang terbatas [14].

Salah satu model generatif yang banyak digunakan dalam augmentasi data EEG adalah *Variational Autoencoder* (VAE). Dibandingkan GAN, VAE memiliki proses *training* yang lebih stabil dan tidak bergantung pada mekanisme adversarial yang rentan terhadap *mode collapse*. Selain itu, dibandingkan *diffusion model*, VAE umumnya memerlukan kompleksitas komputasi dan jumlah data *training* yang lebih rendah. Karakteristik tersebut menjadikan VAE lebih sesuai untuk penelitian ini yang menggunakan dataset EEG dengan jumlah data terbatas[12].

2.1.6 Variational Auto Encoder

Variational Autoencoder (VAE) merupakan salah satu model generatif berbasis *deep learning* yang digunakan untuk mempelajari representasi laten dari suatu dataset dan menghasilkan sampel data baru dengan karakteristik yang serupa dengan data asli. Berbeda dengan *autoencoder* konvensional yang berfokus pada proses kompresi dan rekonstruksi data, VAE memodelkan representasi laten sebagai distribusi probabilitas sehingga memungkinkan proses generasi data baru melalui ruang laten (*latent space*) yang dipelajari oleh model [29].



Gambar 2.8. Arsitektur umum *Variational Autoencoder* (VAE)

Arsitektur VAE terdiri atas dua komponen utama, yaitu *encoder* dan *decoder*, seperti

yang diilustrasikan pada Gambar ???. *Encoder* bertugas memetakan data input ke representasi laten berdimensi lebih rendah dalam bentuk parameter distribusi probabilistik, yaitu nilai rata-rata (μ) dan variansi (σ). Representasi laten tersebut kemudian digunakan oleh *decoder* untuk merekonstruksi kembali data sehingga menghasilkan output yang memiliki karakteristik serupa dengan data asli.

Proses *training* VAE dilakukan menggunakan fungsi objektif *Evidence Lower Bound* (ELBO), yang terdiri atas dua komponen utama, yaitu *reconstruction loss* dan *Kullback-Leibler Divergence* (KL Divergence). *Reconstruction loss* digunakan untuk mengukur kualitas hasil rekonstruksi data, sedangkan KL Divergence berfungsi menjaga distribusi laten agar tetap mendekati distribusi normal standar. Secara matematis, fungsi objektif VAE dapat dinyatakan sebagai berikut:

$$\mathcal{L}(\theta, \phi; x) = \mathbb{E}_{q_{\phi}(z|x)}[\log p_{\theta}(x|z)] - D_{KL}(q_{\phi}(z|x) \parallel p(z))$$

di mana $q_{\phi}(z|x)$ merepresentasikan distribusi laten yang dihasilkan oleh *encoder*, $p_{\theta}(x|z)$ merepresentasikan proses rekonstruksi oleh *decoder*, dan $p(z)$ merupakan distribusi prior pada ruang laten. Komponen pertama pada persamaan tersebut merepresentasikan kualitas rekonstruksi data, sedangkan komponen kedua berfungsi sebagai regularisasi untuk menjaga struktur distribusi laten [30].

Proses *sampling* pada ruang laten tidak dapat dilakukan secara langsung dalam proses *training* menggunakan metode *backpropagation*. Oleh karena itu, VAE menggunakan teknik yang dikenal sebagai *reparameterization trick*. Melalui teknik ini, variabel laten z dinyatakan sebagai:

$$z = \mu + \sigma \cdot \epsilon$$

di mana ϵ merupakan variabel acak yang diambil dari distribusi normal standar $\mathcal{N}(0, 1)$. Dengan pendekatan ini, proses *sampling* dapat ditransformasikan menjadi operasi deterministik yang memungkinkan gradien tetap dapat dihitung selama proses *training* neural network [30].

2.1.7 Metode Evaluasi Data Sintetis Sinyal EEG

Evaluasi kualitas data sintetis diperlukan untuk menilai sejauh mana sinyal EEG yang dihasilkan model generatif mampu mempertahankan karakteristik data asli. Dalam penelitian referensi [15], evaluasi dilakukan menggunakan beberapa metrik kuantitatif yang umum digunakan pada model generatif, yaitu *Inception Score* (IS), *Frechet Inception Distance* (FID), *Euclidean Distance* (ED), dan *Sliced Wasserstein Distance* (SWD). Masing-masing metrik digunakan untuk mengevaluasi aspek yang berbeda, seperti kualitas distribusi, keberagaman sampel, serta kemiripan antara data sintetis dan data asli.

Tabel 2.4. Metrik evaluasi data sintetis EEG

Metrik	Formula	Aspek yang Dievaluasi
IS	$\exp(\mathbb{E}_x[D_{KL}(p(y x) \parallel p(y))])$	Mengukur kualitas dan keberagaman sampel sintetis berdasarkan distribusi prediksi model klasifikasi.
FID	$\ \mu_r - \mu_g\ ^2 + Tr(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$	Mengukur kesamaan distribusi fitur antara data asli dan sintetis.
ED	$d(x, y) = \sqrt{\sum_{i=1}^n (x_i - y_i)^2}$	Mengukur kemiripan langsung antar sampel data asli dan sintetis.
SWD	$SWD(P, Q) = \int_{\theta} W_1(P_{\theta}, Q_{\theta}) d\theta$	Mengukur kesamaan distribusi global melalui proyeksi satu dimensi.

Namun demikian, penelitian referensi [15] menunjukkan bahwa tidak terdapat satu metrik yang mampu merepresentasikan seluruh karakteristik kualitas sinyal EEG sintetis secara menyeluruh. Pada penelitian tersebut, nilai FID yang rendah tidak selalu menunjukkan kesamaan karakteristik spasial dan spektral terhadap data asli, sedangkan SWD dinilai lebih mampu merepresentasikan distribusi sinyal yang natural. Oleh karena itu,

penggunaan beberapa metrik evaluasi secara bersamaan diperlukan untuk memperoleh penilaian kualitas data sintetis yang lebih komprehensif.

2.2 Penelitian Terdahulu

Berbagai penelitian telah mengusulkan pendekatan *machine learning* untuk klasifikasi *Autism Spectrum Disorder* (ASD) berbasis sinyal EEG dengan memanfaatkan karakteristik aktivitas neural sebagai fitur klasifikasi. Selain itu, beberapa penelitian juga menerapkan teknik augmentasi data untuk mengatasi keterbatasan jumlah data *training* dan meningkatkan performa model klasifikasi.

Tinjauan terhadap penelitian terdahulu diperlukan untuk memahami perkembangan metode klasifikasi EEG, pendekatan augmentasi data yang telah digunakan, serta keterbatasan yang masih menjadi tantangan dalam pengembangan sistem klasifikasi ASD berbasis EEG.

2.2.1 Klasifikasi ASD Berbasis EEG Menggunakan mRMR dan XGBoost

Pada penelitian rujukan [8], klasifikasi *Autism Spectrum Disorder* (ASD) dilakukan menggunakan sinyal EEG dengan memanfaatkan seleksi fitur dan algoritma *machine learning*. Penelitian berfokus pada penggunaan fitur domain frekuensi untuk merepresentasikan karakteristik aktivitas neural yang berkaitan dengan ASD serta meningkatkan performa klasifikasi melalui pemilihan fitur yang optimal.

Penelitian menggunakan metode *minimum Redundancy Maximum Relevance* (mRMR) untuk memilih fitur yang paling relevan dan memiliki redundansi minimum antar fitur. Sebelum proses seleksi fitur, sinyal EEG melalui tahap *preprocessing* seperti segmentasi, *filtering*, dan dekomposisi pita frekuensi. Fitur hasil seleksi kemudian digunakan sebagai masukan bagi model klasifikasi berbasis *ensemble*, yaitu XGBoost.

Hasil penelitian menunjukkan bahwa kombinasi mRMR dan XGBoost mampu memberikan performa klasifikasi yang baik dalam membedakan individu ASD dan non-ASD. Penggunaan mRMR membantu meningkatkan kualitas fitur, sementara XGBoost memberikan kemampuan klasifikasi yang robust terhadap kompleksitas data EEG. Namun, penelitian juga menunjukkan bahwa pendekatan tersebut memiliki waktu komputasi yang

lebih tinggi dibandingkan model dasar yang digunakan sebagai pembanding. Selain itu, penelitian masih dilakukan pada jumlah dataset yang relatif terbatas, sehingga kemampuan generalisasi model masih menjadi tantangan dalam pengembangan sistem klasifikasi EEG berbasis ASD.

2.2.2 Metode Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder

Pada penelitian referensi [14], digunakan pendekatan augmentasi data berbasis *Variational Autoencoder* (VAE) untuk menghasilkan sinyal EEG sintetis pada tugas klasifikasi *motor imagery*. Penelitian memanfaatkan BCI Competition IV Dataset 2a yang terdiri dari data EEG 22 kanal dari 9 subjek. Data EEG direpresentasikan dalam bentuk matriks dua dimensi untuk menyesuaikan penggunaan arsitektur berbasis *2D Convolutional Neural Network* (2D CNN).

Model VAE terdiri dari komponen *encoder* dan *decoder* yang digunakan untuk mempelajari representasi laten dari sinyal EEG dan merekonstruksi kembali data sintetis yang menyerupai data asli. Untuk evaluasi klasifikasi, penelitian menggunakan arsitektur EEG-Net dan membandingkan performa model yang dilatih menggunakan data asli dengan model yang dilatih menggunakan data hasil augmentasi.

Hasil penelitian menunjukkan bahwa penggunaan data sintetis dari VAE mampu meningkatkan performa klasifikasi secara signifikan, di mana akurasi meningkat dari 0.73 menjadi 0.88. Peningkatan juga terlihat pada metrik *precision*, *recall*, dan *f1-score*, yang menunjukkan bahwa data sintetis mampu memperkaya variasi data *training*.

Namun, penelitian tersebut masih berfokus pada representasi sinyal EEG dalam domain waktu dan belum mempertimbangkan karakteristik domain frekuensi secara menyeluruh. Padahal, analisis domain frekuensi memiliki peran penting dalam identifikasi pola neurofisiologis pada EEG, termasuk pada studi ASD, karena informasi aktivitas neural banyak direpresentasikan melalui distribusi daya pada pita frekuensi tertentu.

2.2.3 Dataset EEG yang Digunakan

Dataset yang digunakan dalam penelitian ini berupa sinyal *electroencephalogram* (EEG) dari studi rujukan [6], yang terdiri dari data subjek dengan dan tanpa diagnosis *Autism*

Spectrum Disorder (ASD). Dataset ini digunakan karena mampu merepresentasikan karakteristik aktivitas neural yang berkaitan dengan ASD sehingga relevan untuk pengembangan model klasifikasi berbasis *machine learning*.

Data EEG dikumpulkan dari sepuluh partisipan yang terdiri dari lima anak dengan ASD berusia 6–10 tahun dan lima subjek kontrol sehat. Akuisisi dilakukan menggunakan perangkat *OpenBCI Cyton Biosensing Board* dengan 16 kanal EEG berdasarkan sistem *International 10–20 System*. Proses perekaman dilakukan tanpa stimulus eksternal dengan upaya meminimalkan distraksi partisipan untuk menjaga kualitas sinyal EEG yang diperoleh.

Setelah akuisisi, sinyal EEG melalui tahap *preprocessing* menggunakan metode seperti *Butterworth filtering*, *Discrete Wavelet Transform* (DWT), dan *Independent Component Analysis* (ICA) untuk mengurangi artefak dan meningkatkan kualitas sinyal [8]. Selanjutnya, sinyal diproses melalui segmentasi dan dekomposisi ke dalam pita frekuensi utama seperti delta, theta, alpha, beta, dan gamma untuk proses ekstraksi fitur dan klasifikasi.

Meskipun dataset ini relevan untuk analisis ASD berbasis EEG, jumlah partisipan yang relatif kecil menjadi salah satu keterbatasan penelitian. Dataset hanya mencakup data dari sepuluh subjek sehingga berpotensi membatasi kemampuan generalisasi model serta meningkatkan risiko *overfitting*, khususnya pada model *machine learning* yang memerlukan jumlah data *training* yang lebih besar.

2.3 Fokus pada Celah Penelitian

Berdasarkan tinjauan pustaka yang telah dilakukan, terdapat celah penelitian dalam pemanfaatan teknik augmentasi data berbasis *Variational Autoencoder* (VAE) untuk analisis sinyal EEG. Beberapa penelitian sebelumnya telah menerapkan VAE untuk menghasilkan data EEG sintetis, khususnya dalam konteks tugas klasifikasi berbasis *motor imagery* menggunakan arsitektur seperti *2D Convolutional Neural Network* (CNN). Pendekatan tersebut menunjukkan bahwa data sintetis mampu meningkatkan performa model klasifikasi dengan memperkaya variasi data *training*. Meskipun demikian, fokus penelitian masih terbatas pada representasi sinyal dalam domain waktu atau spasial, tanpa mengeksplorasi secara mendalam karakteristik sinyal dalam domain frekuensi.

Di sisi lain, analisis berbasis domain frekuensi memiliki peran penting dalam studi EEG, terutama dalam mengidentifikasi pola osilasi neural yang berkaitan dengan kondisi neurologis seperti *Autism Spectrum Disorder* (ASD). Pemanfaatan data sintetis berbasis VAE pada representasi fitur frekuensi masih relatif terbatas, dan belum banyak dilakukan pengkajian terkait pengaruh augmentasi sinyal EEG terhadap kualitas fitur dan performa model klasifikasi berbasis *machine learning* konvensional.

Oleh karena itu, penelitian ini mengusulkan pendekatan yang mengintegrasikan teknik augmentasi data berbasis VAE dengan ekstraksi fitur domain frekuensi, serta memanfaatkan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) dan algoritma klasifikasi *XGBoost*. Pendekatan ini bertujuan untuk mengeksplorasi bagaimana data sintetis yang dihasilkan pada domain frekuensi dapat meningkatkan kualitas representasi fitur serta performa klasifikasi ASD. Dengan mengisi celah ini, diharapkan penelitian ini dapat memberikan kontribusi dalam pengembangan metode klasifikasi EEG yang lebih robust dan akurat, khususnya pada kondisi dataset yang terbatas.

BAB 3

PERANCANGAN DAN IMPLEMENTASI SISTEM

Bab ini menyajikan metodologi penelitian dan perancangan teknis yang dilakukan untuk mengembangkan dan mengevaluasi sistem klasifikasi *Autism Spectrum Disorder* (ASD) berbasis sinyal EEG. Sistem yang dikembangkan pada penelitian ini bukan ditujukan untuk diimplementasikan secara langsung pada platform tertentu, melainkan sebagai sebuah lingkungan uji (*testbed*) yang terkontrol untuk mengevaluasi efektivitas pendekatan augmentasi data berbasis *Variational Autoencoder* (VAE), seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR), serta algoritma klasifikasi XGBoost pada data EEG ASD.

Pembahasan pada bab ini dimulai dari Analisis Kebutuhan untuk mendefinisikan batasan masalah dan kebutuhan sistem. Fokus utama bab ini terletak pada Perancangan Arsitektur dan Alur Kerja Sistem yang menjelaskan tahapan pengolahan sinyal EEG, mulai dari prapemrosesan, augmentasi data menggunakan VAE, hingga proses klasifikasi. Arsitektur sistem divisualisasikan menggunakan diagram arsitektur dan *flowchart* untuk memberikan gambaran alur pemrosesan secara menyeluruh. Selanjutnya, bagian Detail Implementasi dan Teknologi menjabarkan realisasi arsitektur ke dalam bentuk implementasi kode dengan memanfaatkan beberapa library untuk pengolahan sinyal, pengembangan model generatif, serta proses klasifikasi. Bab ini kemudian ditutup dengan Perancangan Infrastruktur yang menjelaskan lingkungan komputasi dan *software dependencies* yang digunakan selama proses pengembangan dan pengujian model.

3.1 Analisis Kebutuhan Sistem

Sebelum memulai perancangan arsitektur, tahap pertama yang dilakukan adalah menganalisis kebutuhan sistem. Analisis ini difokuskan pada kebutuhan penelitian yang berkaitan dengan pengembangan sistem klasifikasi ASD berbasis sinyal EEG dengan integrasi augmentasi data menggunakan *Variational Autoencoder* (VAE). Sistem yang dikembangkan ditujukan sebagai lingkungan uji (*testbed*) untuk mengevaluasi efektivitas augmentasi data sintetis terhadap performa model klasifikasi berbasis EEG.

3.1.1 Tujuan Sistem

Sistem dirancang untuk mengevaluasi pengaruh penggunaan data sintetis hasil augmentasi berbasis VAE terhadap performa klasifikasi ASD menggunakan sinyal EEG. Penelitian berfokus pada bagaimana data sintetis dapat meningkatkan variasi data *training* tanpa mengubah struktur utama *pipeline* klasifikasi.

3.1.2 Kebutuhan Sistem

Berdasarkan tujuan penelitian, sistem yang dirancang harus memenuhi beberapa kebutuhan berikut:

1. Sistem harus mampu melakukan preprocessing sinyal EEG dan menghasilkan representasi data yang konsisten untuk proses klasifikasi.
2. Sistem harus mampu menghasilkan sinyal EEG sintetis yang memiliki karakteristik statistik yang serupa dengan data asli tanpa hanya mereplikasi data *training* secara langsung.
3. Sistem harus mengimplementasikan model generatif berbasis *Variational Autoencoder* (VAE) untuk mempelajari distribusi laten data EEG dan menghasilkan data sintetis baru.
4. Data sintetis yang dihasilkan harus tetap kompatibel dengan *pipeline* klasifikasi berbasis ekstraksi fitur, seleksi fitur mRMR, dan klasifikasi menggunakan XGBoost.
5. Sistem harus mampu melakukan evaluasi kualitas data sintetis menggunakan beberapa metrik evaluasi distribusi dan kemiripan data.

3.1.3 Batasan Sistem

Untuk menjaga fokus penelitian, sistem yang dikembangkan memiliki beberapa batasan sebagai berikut:

1. Dataset yang digunakan terbatas pada dataset EEG ASD yang telah dipilih pada penelitian ini.

2. Penelitian difokuskan pada augmentasi data berbasis VAE dan tidak melakukan perbandingan secara menyeluruh dengan model generatif lain seperti GAN maupun *diffusion model*.
3. Evaluasi sistem difokuskan pada kualitas data sintetis dan performa klasifikasi, bukan pada interpretasi klinis hasil diagnosis ASD.
4. Penelitian tidak membahas aspek perangkat keras akuisisi EEG maupun kualitas perangkat perekaman sinyal secara mendalam.
5. Proses *denoising*, *artifact removal*, dan teknik peningkatan kualitas sinyal lainnya tidak menjadi fokus utama penelitian dan mengikuti pendekatan prapemrosesan pada penelitian referensi yang digunakan.


3.2 Perancangan Arsitektur Sistem

Setelah kebutuhan fungsional sistem diuraikan, tahap selanjutnya adalah merancang arsitektur sistem sebagai representasi konseptual dari alur pemrosesan data yang akan diimplementasikan. Perancangan ini bertujuan untuk menggambarkan integrasi antar komponen dalam *pipeline*, khususnya dalam menggabungkan proses augmentasi data berbasis *Variational Autoencoder* (VAE) dengan *pipeline* klasifikasi yang telah ditentukan.

Pendekatan yang digunakan dalam penelitian ini mengadaptasi model *EEG Data Augmentation using Variational Autoencoder* [31] dengan beberapa penyesuaian pada arsitektur dan representasi data. Berbeda dengan implementasi awal yang memproses sinyal EEG dalam bentuk multikanal dua dimensi, penelitian ini menggunakan pendekatan berbasis *1D Convolutional Neural Network* (1D CNN) dengan pemrosesan setiap kanal EEG secara terpisah.

Penyesuaian ini dilakukan berdasarkan hasil pengujian awal yang menunjukkan bahwa pendekatan multikanal belum mampu merekonstruksi detail karakteristik sinyal EEG secara optimal, khususnya pada pola temporal tiap kanal. Oleh karena itu, sinyal EEG direpresentasikan sebagai deret waktu satu dimensi agar model dapat mempelajari karakteristik sinyal secara lebih spesifik pada masing-masing kanal. Pendekatan ini juga mengacu pada penelitian referensi [8] yang memproses sinyal EEG per kanal, sehingga

lebih sesuai dengan karakteristik data dan kompatibel dengan *pipeline* klasifikasi yang digunakan dalam penelitian ini.



Gambar 3.1. Diagram aliran data pada sistem


Gambar 3.1 menunjukkan alur pemrosesan data pada sistem yang dikembangkan dalam penelitian ini, yang mencakup tahap pra-pemrosesan dan ekstraksi fitur, augmentasi data menggunakan model *Variational Autoencoder* (VAE), serta proses klasifikasi. Proses dimulai dari data input berupa sinyal EEG yang melalui tahap pra-pemrosesan dan ekstraksi fitur sebelum diproses oleh model VAE untuk menghasilkan data sintetis yang memiliki karakteristik serupa dengan data asli.

Hasil tahap tersebut digunakan dalam dua skenario klasifikasi yang berbeda. Pada skenario pertama, proses klasifikasi dilakukan hanya menggunakan data asli, sedangkan pada skenario kedua, proses klasifikasi memanfaatkan kombinasi data asli dan data hasil augmentasi. Kedua skenario menggunakan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) dan algoritma klasifikasi XGBoost berdasarkan referensi

penelitian sebelumnya [8]. Perbandingan kedua skenario bertujuan untuk mengevaluasi pengaruh penggunaan data sintetis terhadap performa model klasifikasi yang dihasilkan.

3.2.1 Pra-Pemrosesan Dataset

Tahap pra-pemrosesan dalam pengolahan sinyal EEG untuk memastikan bahwa data yang digunakan berada dalam kondisi yang representatif dan siap diproses oleh model. Tahap ini bertujuan untuk meningkatkan kualitas sinyal serta menyiapkan data dalam bentuk yang terstruktur untuk diproses pada model augmentasi.



Gambar 3.2. Diagram aliran proses prapemrosesan sistem

Gambar 3.2 menggambarkan alur proses pada tahap pra-pemrosesan data. Sinyal EEG mentah terlebih dahulu dibersihkan dari nilai yang hilang. Selanjutnya, sinyal dibagi ke


dalam segmen-segmen dengan durasi tertentu menggunakan pendekatan *sliding window* dengan overlap, sehingga memungkinkan penangkapan karakteristik temporal dari aktivitas neural. Setiap segmen kemudian diproses menggunakan *bandpass filter* berbasis Butterworth untuk mempertahankan komponen frekuensi yang relevan serta mengurangi gangguan seperti *low-frequency drift* dan *high-frequency noise*.

Setelah proses penyaringan, dilakukan tahap seleksi segmen untuk mengidentifikasi dan mengeliminasi artefak berdasarkan kriteria amplitudo dan distribusi statistik, seperti nilai *peak-to-peak* dan *z-score*. Tahap ini bertujuan untuk memastikan bahwa hanya segmen sinyal yang berkualitas baik yang digunakan dalam proses selanjutnya.

Selanjutnya, dilakukan normalisasi menggunakan metode *z-score normalization* untuk menyeragamkan distribusi data dan meningkatkan stabilitas proses *training*. Data kemudian dipisahkan menjadi data *training* dan validasi, serta disusun ulang ke dalam bentuk tensor tiga dimensi agar sesuai dengan kebutuhan arsitektur *1D Convolutional Neural Network*.

3.2.2 Arsitektur Model VAE untuk Augmentasi Data

Model *Variational Autoencoder* (VAE) digunakan sebagai metode augmentasi untuk menghasilkan sinyal EEG sintetis yang memiliki karakteristik statistik serupa dengan data asli. Penelitian ini mengadaptasi arsitektur dari penelitian [31] dengan beberapa penyesuaian pada representasi data dan struktur model. Berbeda dengan pendekatan awal yang menggunakan representasi multikanal dua dimensi berbasis *2D Convolutional Neural Network*, penelitian ini menggunakan pendekatan *1D Convolutional Neural Network* (1D CNN) dengan pemrosesan setiap kanal EEG secara terpisah. Penyesuaian ini dilakukan berdasarkan hasil pengujian awal yang menunjukkan bahwa pendekatan multikanal belum mampu merekonstruksi detail pola temporal sinyal EEG secara optimal. Selain itu, dimensi ruang laten juga ditingkatkan untuk memperbesar kapasitas model dalam menangkap variasi pola sinyal EEG.



Gambar 3.3. Diagram Model VAE untuk Augmentasi EEG


Seperti ditunjukkan pada Gambar 3.4, model terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*. Input berupa segmen sinyal EEG satu dimensi diproses oleh bagian *encoder* menggunakan beberapa lapisan *Conv1D* yang diikuti oleh *batch normalization* dan fungsi aktivasi *LeakyReLU*. Proses ini bertujuan untuk mengekstraksi representasi fitur berdimensi lebih rendah dari sinyal input. Representasi tersebut kemudian dipetakan ke dalam dua parameter distribusi laten, yaitu *mean* (z_{mean}) dan variansi log-arithmik (z_{logvar}). Selanjutnya dilakukan proses *reparameterization* untuk menghasilkan vektor laten z , sehingga model dapat dilatih menggunakan mekanisme *backpropagation* secara *end-to-end*.

Vektor laten yang dihasilkan kemudian digunakan sebagai input bagi bagian *decoder* untuk merekonstruksi kembali sinyal EEG. Decoder terdiri dari beberapa lapisan *upsampling* dan *Conv1D* yang secara bertahap mengembalikan dimensi sinyal hingga sesuai dengan bentuk input awal. Setelah proses *training*, model dimanfaatkan untuk menghasilkan data sintetis baru dengan melakukan *sampling* acak pada ruang laten menggunakan distribusi normal standar. Vektor laten hasil *sampling* tersebut diberikan ke *decoder* untuk menghasilkan sinyal EEG sintetis yang tidak identik dengan data asli, namun tetap mempertahankan karakteristik distribusi statistiknya.

Dalam proses *training*, model dioptimalkan menggunakan kombinasi *reconstruction loss* dan *Kullback-Leibler (KL) divergence*. *Reconstruction loss* digunakan untuk mengukur perbedaan antara sinyal input dan hasil rekonstruksi, sedangkan KL divergence berfungsi untuk menjaga distribusi ruang laten tetap mendekati distribusi normal standar. Kombinasi kedua komponen tersebut digunakan sebagai fungsi objektif dalam proses optimasi model.

3.2.3 Arsitektur Model Klasifikasi

Pipeline klasifikasi yang digunakan terdiri dari beberapa tahapan utama, yaitu dekomposisi frekuensi, standardisasi data, ekstraksi fitur statistik, seleksi fitur, serta klasifikasi. Tahapan awal dilakukan dengan memisahkan sinyal EEG ke dalam lima pita frekuensi utama, yaitu delta, theta, alpha, beta, dan gamma. Pemisahan ini bertujuan untuk menangkap karakteristik aktivitas otak pada rentang frekuensi yang berbeda, sehingga informasi yang diperoleh menjadi lebih representatif terhadap kondisi neurologis yang



Gambar 3.4. Diagram Model Klasifikasi

diamati dan lebih mudah dianalisis pada tahap selanjutnya.

Setelah proses dekomposisi, setiap pita frekuensi distandardisasi menggunakan transformasi *z-score*. Tahapan ini bertujuan untuk menormalkan distribusi data sehingga memiliki skala yang sebanding antar pita frekuensi, serta mencegah dominasi fitur tertentu dalam proses pembelajaran model sehingga setiap pita frekuensi dapat berkontribusi secara proporsional dalam pembentukan fitur.

Tahap berikutnya adalah ekstraksi fitur statistik, yang bertujuan untuk mengubah sinyal EEG yang bersifat kontinu menjadi representasi numerik yang terstruktur. Fitur yang dihasilkan mencerminkan karakteristik distribusi, variabilitas, dan kompleksitas sinyal pada masing-masing pita frekuensi. Proses ini menghasilkan himpunan fitur berdimensi tinggi yang mampu merepresentasikan pola sinyal secara komprehensif, sehingga menjadi dasar penting dalam proses klasifikasi.

Seleksi fitur dilakukan menggunakan metode *minimum Redundancy Maximum Relevance* (mRMR), yang bertujuan untuk memilih fitur yang paling relevan terhadap label kelas sekaligus meminimalkan redundansi antar fitur. Pendekatan ini menghasilkan subset fitur yang lebih ringkas, efisien, dan tetap informatif untuk digunakan pada tahap klasifikasi.

Tahap akhir dari *pipeline* adalah proses klasifikasi menggunakan algoritma XGBoost. Model ini membangun ensemble pohon keputusan secara bertahap untuk menangkap hubungan non-linear antar fitur secara efektif. Dalam penelitian ini, proses klasifikasi dilakukan dalam dua skenario, yaitu menggunakan data asli serta menggunakan kombinasi data asli dan data sintetis yang diperoleh dari model augmentasi. Kedua skenario diproses menggunakan *pipeline* yang sama, sehingga perbedaan performa yang dihasilkan dapat secara langsung dianalisis sebagai dampak dari penggunaan data hasil augmentasi.

3.3 Detail Implementasi dan Teknologi

Bagian ini menjelaskan bagaimana perancangan sistem yang telah dijabarkan sebelumnya diterapkan ke dalam kode serta teknologi yang digunakan untuk mengimplementasikannya. Penjelasan pada bagian ini mencakup teknologi dan *library* yang digunakan, serta gambaran umum implementasi dari komponen utama dalam *pipeline*, termasuk pemrosesan sinyal EEG, ekstraksi dan seleksi fitur, modul augmentasi berbasis *Variational Au-*

toencoder (VAE), serta model klasifikasi.

3.3.1 Teknologi dan Library

Dalam penelitian ini, seluruh proses pengolahan data, *training*, dan evaluasi model dilakukan menggunakan bahasa pemrograman Python. Pemilihan Python didasarkan pada ekosistem library yang luas serta kemampuannya dalam mendukung pengembangan sistem berbasis *machine learning* dan pemrosesan sinyal secara efisien. Untuk mempercepat komputasi, sistem ini memanfaatkan akselerasi GPU dengan bantuan CUDA Toolkit dari NVIDIA, sehingga operasi numerik berskala besar seperti *training* model dan komputasi matriks dapat dilakukan dengan lebih efisien.

Library utama yang digunakan dalam pengembangan sistem ini meliputi NumPy, Pandas, SciPy, dan scikit-learn. NumPy berperan sebagai backend komputasi numerik untuk operasi berbasis array dan matriks, sementara Pandas digunakan untuk pengelolaan dan manipulasi dataset. SciPy menyediakan fungsi *signal processing* yang mendukung proses pemrosesan sinyal EEG, sedangkan scikit-learn digunakan untuk kebutuhan preprocessing data, ekstraksi fitur, serta evaluasi model melalui berbagai metrik yang tersedia.

Untuk tahap pemodelan, digunakan XGBoost sebagai algoritma klasifikasi berbasis *gradient boosting* yang efisien dan mampu menangani data berdimensi tinggi serta hubungan non-linear. Selain itu, PyTorch digunakan sebagai framework *deep learning* untuk membangun model generatif berbasis Variational Autoencoder (VAE), yang memungkinkan proses augmentasi data dilakukan secara fleksibel dengan dukungan akselerasi GPU.

Dalam implementasi pipeline klasifikasi, beberapa library juga berperan dalam tahap ekstraksi dan pemrosesan fitur. SciPy digunakan untuk pemrosesan sinyal dan dekomposisi frekuensi, sementara NumPy dan Pandas mendukung perhitungan serta pengelolaan fitur statistik. Untuk seleksi fitur, digunakan scikit-learn sebagai dasar implementasi metode mRMR, sebelum fitur terpilih digunakan dalam proses pelatihan dan prediksi menggunakan XGBoost.


3.3.2 Implementasi Model Generatif Variational Autoencoder (VAE)

Perancangan model generatif pada penelitian ini dilakukan menggunakan pendekatan *Variational Autoencoder* (VAE) yang bertujuan untuk mempelajari distribusi laten dari

sinyal EEG serta menghasilkan data sintetis yang menyerupai data asli. Arsitektur model secara umum terdiri dari dua bagian utama, yaitu *encoder* dan *decoder*.

Model menerima input berupa sinyal EEG satu dimensi dengan panjang 512 sampel dan satu kanal, sehingga berbentuk $(512, 1)$. Panjang sinyal ini diperoleh dari proses segmentasi dengan durasi 4 detik pada frekuensi sampling 128 Hz.

Arsitektur Layer *Encoder* dirancang menggunakan beberapa lapisan *Conv1D* untuk mengekstraksi pola temporal dari sinyal EEG. Setiap lapisan menggunakan *stride* sebesar 2 untuk melakukan downsampling secara bertahap.



Gambar 3.5. Diagram Aliran Layer *Encoder* pada Model VAE

Encoder menggunakan tiga blok konvolusi dengan jumlah filter 32, 64, dan 128. Ukuran kernel yang relatif besar (15–25) dipilih untuk menangkap pola temporal EEG yang memiliki karakteristik frekuensi rendah hingga menengah. Proses downsampling dilakukan melalui stride pada setiap lapisan konvolusi, sehingga menghasilkan reduksi dimensi bertahap dari 512 menjadi 64, yang membuat representasi semakin ringkas dan informatif.


Setiap blok konvolusi diikuti oleh Batch Normalization untuk menstabilkan distribusi

aktivasi selama pelatihan, mempercepat konvergensi, serta mengurangi masalah internal covariate shift. Setelah normalisasi, digunakan fungsi aktivasi LeakyReLU dengan parameter 0.2, yang berarti gradien kecil sebesar 0.2 tetap dipertahankan untuk nilai negatif, sehingga mencegah masalah “dying ReLU” dan menjaga aliran gradien tetap stabil.

Padding yang digunakan adalah “same”, yang menjaga ukuran temporal output tetap proporsional dengan input sebelum proses downsampling oleh stride dilakukan, sehingga informasi di tepi sinyal tetap dipertahankan secara optimal.

Dimensi laten ditetapkan sebesar 16 sebagai kompromi antara kapasitas representasi dan stabilitas pelatihan, sehingga model mampu menangkap struktur penting data tanpa menyebabkan overfitting atau kehilangan informasi yang signifikan.

Reparameterization Layer digunakan untuk memungkinkan proses pelatihan berbasis gradien.



Gambar 3.6. Diagram aliran Reparameterization Layer

Lapisan Sampling menghasilkan vektor laten z dengan menggabungkan dua parameter yang dipelajari oleh *encoder*, yaitu z_{mean} dan $z_{\text{log var}}$. Proses ini digunakan untuk membuat representasi laten bersifat probabilistik, sehingga model tidak hanya menghasilkan satu nilai tetap, tetapi sebuah distribusi.

Pada tahap ini digunakan variabel acak ϵ (epsilon), yang diambil dari distribusi normal standar dengan mean 0 dan variansi 1. Noise ini berfungsi untuk memperkenalkan unsur stochastic dalam proses sampling, sehingga setiap forward pass dapat menghasilkan representasi z yang sedikit berbeda meskipun input sama.

Nilai z dihitung menggunakan teknik reparameterization trick, yaitu: $z = z_{\text{mean}} + \exp(0.5 \cdot z_{\text{log var}}) \cdot \epsilon$

Faktor $\exp(0.5 \cdot z_{\log \text{ var}})$ merepresentasikan standar deviasi dari distribusi yang dipelajari, sehingga noise ϵ diskalakan sesuai dengan tingkat ketidakpastian data. Pendekatan ini memungkinkan proses sampling tetap dapat dioptimalkan menggunakan backpropagation, karena operasi acak dipisahkan dari parameter yang dipelajari.


Arsitektur Decoder menggunakan tiga tahap *upsampling* dengan jumlah filter 128, 64, dan 32. Ukuran kernel yang relatif besar (15–25) dipilih untuk mempertahankan pola temporal EEG yang memiliki karakteristik frekuensi rendah hingga menengah. Proses *upsampling* dilakukan pada setiap tahap untuk meningkatkan dimensi sinyal secara bertahap dari 64 menjadi 512, sehingga memungkinkan rekonstruksi struktur temporal secara progresif.

Setiap tahap *upsampling* diikuti oleh lapisan konvolusi yang berfungsi untuk memperhalus dan membentuk kembali fitur hasil interpolasi, sehingga informasi yang dihasilkan tidak bersifat kasar atau terdistorsi. Struktur jumlah filter disusun secara terbalik dari encoder, sehingga representasi fitur secara bertahap dikurangi kompleksitasnya seiring dengan peningkatan resolusi sinyal.

Setiap lapisan konvolusi diikuti oleh Batch Normalization untuk menstabilkan distribusi aktivasi selama proses rekonstruksi, membantu menjaga konsistensi output, serta mengurangi potensi ketidakstabilan selama propagasi. Setelah normalisasi, digunakan fungsi aktivasi ReLU yang memberikan non-linearitas yang cukup untuk memodelkan hubungan kompleks tanpa menghambat proses generasi sinyal.

Padding yang digunakan adalah “same”, yang menjaga ukuran temporal output tetap proporsional setelah setiap operasi konvolusi, sehingga perubahan dimensi hanya dipengaruhi oleh proses *upsampling*. Hal ini memastikan bahwa informasi pada bagian tepi sinyal tetap dipertahankan selama proses rekonstruksi.

Lapisan akhir menggunakan konvolusi dengan satu filter untuk menghasilkan sinyal output dengan jumlah kanal yang sesuai dengan data asli, sehingga hasil rekonstruksi dapat langsung dibandingkan dengan input awal dalam proses pembelajaran.



Gambar 3.7. Diagram aliran Decoder Layer

Fungsi Loss dan Proses Training didasarkan pada kombinasi *reconstruction loss* dan *Kullback-Leibler (KL) divergence*, yang merupakan komponen utama dalam *Variational Autoencoder (VAE)*.

Reconstruction loss dihitung menggunakan *Mean Squared Error (MSE)* antara input dan output rekonstruksi. Sebelum perhitungan, kedua tensor diubah menjadi vektor satu dimensi (*flatten*) untuk menyederhanakan komputasi. Nilai loss kemudian dikalikan dengan faktor 512 untuk menyesuaikan skala kontribusinya terhadap total loss, sehingga model lebih fokus dalam mempertahankan kemiripan antara data asli dan hasil rekonstruksi.

KL divergence digunakan untuk mengukur perbedaan antara distribusi laten yang dipelajari dengan distribusi normal standar $\mathcal{N}(0, 1)$. Perhitungan dilakukan menggunakan parameter μ (z_mean) dan $\log \sigma^2$ (z_log_var), kemudian dijumlahkan pada setiap dimensi laten dan dikalikan dengan faktor -0.5 . Komponen ini berfungsi sebagai regularisasi agar ruang laten tetap terstruktur dan tidak menyimpang.

Total loss diperoleh dengan menjumlahkan kedua komponen tersebut, kemudian dirata-ratakan terhadap batch dan ditambahkan sebagai *custom loss* pada model.

Pelatihan dilakukan menggunakan optimizer Adam dengan *learning rate* 0.001, *batch size* 32, dan maksimum 1000 epoch.

Generasi Data Sintetis dilakukan melalui proses sampling pada ruang laten. Secara prinsip, karena distribusi laten telah dipaksa mendekati distribusi normal standar selama training, maka sampling dapat dilakukan dengan menghasilkan vektor acak dari distribusi Gaussian $\mathcal{N}(0, 1)$ dengan dimensi yang sesuai (misalnya 16 dimensi laten).

Vektor laten acak ini kemudian diberikan sebagai input ke bagian *decoder* dari model. Decoder akan memetakan representasi laten tersebut kembali ke ruang data asli, sehingga menghasilkan sampel baru yang secara statistik menyerupai data pelatihan. Proses ini memungkinkan model untuk menghasilkan variasi data yang tidak identik dengan data asli, namun tetap mempertahankan karakteristik distribusinya.

Data sintetis yang dihasilkan selanjutnya digunakan sebagai bentuk *data augmentation* dalam pipeline klasifikasi. Dengan menambahkan sampel sintetis ke dalam data pelatihan, diharapkan model klasifikasi dapat meningkatkan kemampuan generalisasi, terutama dalam kondisi keterbatasan jumlah data asli.

3.3.3 Implementasi Model Klasifikasi

Minimum Redundancy Maximum Relevance (mRMR) diimplementasikan melalui *library feature_engine.selection* melalui kelas *MRMR*. Label kelas terlebih dahulu dikonversi ke bentuk numerik menggunakan *LabelEncoder* dari *sklearn.preprocessing* melalui operasi *fit_transform*, sehingga menghasilkan representasi biner yang dapat digunakan

dalam proses seleksi fitur.

Fitur yang digunakan berasal dari kombinasi kanal EEG dan jenis fitur hasil ekstraksi *Discrete Wavelet Transform* (DWT). Penamaan kolom dibentuk secara eksplisit melalui iterasi terhadap daftar kanal (*ch_names*) dan jenis fitur (*DWT_FEAT*), sehingga setiap fitur memiliki format *channel_feature*. Seluruh fitur kemudian dikonversi ke dalam struktur *pandas DataFrame* (*dfX*) untuk memastikan kompatibilitas dengan metode *MRMR*.

Tabel 3.1. Konfigurasi Parameter *XGBoost*

Parameter	Nilai
use_label_encoder	False
eval_metric	logloss
n_estimators	100
learning_rate	0.3
max_depth	6
subsample	1.0
colsample_bylevel	1.0
reg_alpha	0
reg_lambda	1

Model *XGBoost* Model *XGBoost* pada penelitian ini menggunakan konfigurasi parameter sebagaimana ditunjukkan pada Tabel di atas. Parameter tersebut digunakan dalam proses *training* model untuk menghasilkan prediksi pada data uji.

Pembagian data dilakukan menggunakan *train_test_split* dengan parameter *test_size=0.2*, *stratify=y_enc*, dan *random_state=42*. Model kemudian dilakukan *training* menggunakan data *training* dan digunakan untuk menghasilkan prediksi label serta probabilitas pada data *testing*. Hasil prediksi selanjutnya dievaluasi menggunakan *confusion matrix*, *classification report*, serta *ROC curve* dan *AUC score*.

BAB 4

PENUTUP

4.1 Kesimpulan

Berdasarkan pemaparan teori serta perancangan metode yang telah dilakukan, dapat ditarik beberapa kesimpulan terkait konsep, pendekatan, dan arsitektur sistem yang diusulkan dalam penelitian ini. Kesimpulan yang diperoleh mencakup hasil analisis terhadap pendekatan yang diusulkan dalam meningkatkan representasi data EEG untuk mendukung proses klasifikasi ASD, sebagai berikut:


1. Diagnosis dini *Autism Spectrum Disorder* (ASD) merupakan aspek penting dalam mendukung intervensi yang lebih efektif. Analisis sinyal EEG sebagai metode non-invasif menjadi pendekatan yang menjanjikan dan terus berkembang untuk analisis aktivitas otak dalam konteks ASD, baik dalam domain waktu maupun frekuensi.
2. Representasi sinyal EEG pada domain frekuensi, seperti distribusi daya pada pita frekuensi dapat dimanfaatkan untuk merepresentasikan pola aktivitas otak yang relevan, yang kemudian dimodelkan menggunakan pendekatan *machine learning*. Pada penelitian ini, digunakan model *Extreme Gradient Boosting* (XGBoost) dengan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) berdasarkan penelitian rujukan untuk memperoleh fitur yang informatif dan meminimalkan redundansi.
3. Ketersediaan dataset pada analisis EEG masih menjadi tantangan utama dalam penerapan *machine learning* karena proses akuisisi yang mahal dan kompleks, serta tingginya variabilitas data. Variabilitas ini muncul akibat perbedaan antar subjek, kondisi perekaman, konfigurasi perangkat, jumlah kanal, serta keberadaan artefak seperti gerakan otot dan kedipan mata, yang menyebabkan distribusi data menjadi tidak konsisten dan menyulitkan proses generalisasi model.
4. Metode augmentasi data, yaitu metode membuat data dengan representasi statistik yang serupa berdasarkan data yang sudah ada dapat digunakan untuk mengatasi

masalah overfitting model karena keterbatasan dataset. Metode augmentasi yang digunakan dalam penelitian ini adalah *Variational Autoencoder* (VAE), yang dipilih karena mampu memodelkan distribusi laten data secara probabilistik dan menghasilkan sampel sintetis yang menyerupai data asli, sehingga lebih sesuai dibandingkan metode augmentasi konvensional yang berpotensi mengganggu karakteristik sinyal EEG.


5. Pipeline penelitian ini mencakup tahapan prapemrosesan, augmentasi data, seleksi fitur menggunakan mRMR, dan klasifikasi dengan XGBoost. Augmentasi dilakukan menggunakan VAE untuk menghasilkan data sintetis yang kemudian digabungkan dengan data asli. Pelatihan model dilakukan dalam dua skenario, yaitu menggunakan data asli saja dan menggunakan kombinasi data asli dan hasil augmentasi, sehingga perbandingan kinerja model dapat dilakukan untuk mengevaluasi pengaruh augmentasi sinyal EEG.
6. Evaluasi kualitas data sintetis mengacu pada metrik kuantitatif yang umum digunakan pada model generatif, yaitu *Inception Score* (IS), *Frechet Inception Distance* (FID), *Euclidean Distance* (ED), dan *Sliced Wasserstein Distance* (SWD). Metrik-metrik ini digunakan untuk menilai kesamaan distribusi, keberagaman sampel, serta kemampuan model dalam menghasilkan data yang tidak hanya mereplikasi data pelatihan, sehingga memberikan evaluasi yang lebih komprehensif terhadap kualitas sinyal EEG sintetis.
7. Penelitian ini secara khusus mengisi celah penelitian melalui integrasi augmentasi data berbasis VAE dengan representasi fitur domain frekuensi yang berbeda dengan pendekatan yang berfokus pada domain waktu atau spasial pada penelitian yang ada. Metode yang diusulkan memanfaatkan karakteristik frekuensi sinyal EEG sebagai dasar pembelajaran distribusi laten, sehingga data sintetis yang dihasilkan tetap mempertahankan pola osilasi neural yang relevan. Pendekatan yang diusulkan dapat meningkatkan variabilitas data *training* sehingga berpotensi menghasilkan model klasifikasi ASD yang lebih robust, khususnya pada kondisi dataset yang terbatas dan memiliki variabilitas tinggi.

4.2 Pengembangan Lanjutan

Pada tahap saat ini, model generatif yang dikembangkan telah mampu menghasilkan data sintetis dengan tingkat kesesuaian yang baik terhadap data asli. Hal ini ditunjukkan melalui hasil evaluasi menggunakan metrik yang telah dibahas sebelumnya, yaitu *Inception Score* (IS), *Frechet Inception Distance* (FID), *Euclidean Distance* (ED), dan *Sliced Wasserstein Distance* (SWD), di mana nilai yang diperoleh menunjukkan kualitas distribusi dan keberagaman sampel yang memadai.



Gambar 4.1. Perbandingan sampel sinyal EEG asli dan sintetis pada channel Fp1 dalam domain waktu



Gambar 4.2. Perbandingan PSD antara sampel sinyal asli dan sintetis pada channel Fp1

Meskipun demikian, pengembangan lebih lanjut masih diperlukan, khususnya dalam mengintegrasikan hasil augmentasi secara optimal ke dalam pipeline klasifikasi serta melakukan evaluasi eksperimental terhadap peningkatan performa model. Selain itu, eksplorasi terhadap variasi arsitektur model generatif, tuning hiperparameter, serta pengujian pada dataset yang lebih beragam dapat dilakukan untuk meningkatkan kualitas data sintetis dan stabilitas model secara keseluruhan.

DAFTAR PUSTAKA

- [1] National Center for Biotechnology Information, “Autism spectrum disorder,” [Online]. Available: <https://www.ncbi.nlm.nih.gov/books/NBK525976/>, 2023.
- [2] American Psychiatric Association, *Diagnostic and Statistical Manual of Mental Disorders (DSM-5)*, 5th ed. Arlington, VA, USA: American Psychiatric Association, 2013, [Online]. Available: <https://www.psychiatry.org/psychiatrists/practice/dsm>.
- [3] Y. Hus and O. Segal, “Challenges surrounding the diagnosis of autism in children,” 2021, [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC8654688/>.
- [4] S. Bose and P. Seth, “Screening of autism spectrum disorder using machine learning approach in accordance with dsm-5,” in *2023 7th International Conference on Electronics, Materials Engineering & Nano-Technology (IEMENTech)*, 2023, [Online]. Available: <https://doi.org/10.1109/IEMENTech60402.2023.10423494>.
- [5] C. Clairmont, J. Wang, S. Tariq, H. T. Sherman, M. Zhao, and X.-J. Kong, “The value of brain imaging and electrophysiological testing for early screening of autism spectrum disorder: A systematic review,” 2022, [Online]. Available: <https://doi.org/10.3389/fnins.2021.812946>.
- [6] M. Melinda, P. D. Purnamasari, F. Fahmi, E. P. Sinulingga, M. Mulyadi, Y. Away, Y. Yunidar, and F. H. Juwono, “A comprehensive eeg dataset and performance assessment for autism spectrum disorder,” 2025, [Online]. Available: <https://doi.org/10.1038/s41598-025-34981>.
- [7] O. Gurau, W. J. Bosl, and C. R. Newton, “How useful is electroencephalography in the diagnosis of autism spectrum disorders and the delineation of subtypes: A systematic review,” 2017, [Online]. Available: <https://doi.org/10.3389/fpsy.2017.00121>.

- [8] P. D. Purnamasari, A. A. P. Ratna, M. Melinda, F. Fahmi, F. H. Juwono, Y. Away, N. Li, R. Yan, and S. Gazali, "Enhancing clinical transparency in asd detection: An eeg analysis approach with mrmr and xgboost," 2025, under review.
- [9] R. Lyu, "Deep learning approaches for eeg-based healthcare applications: A comprehensive review," 2026, [Online]. Available: <https://doi.org/10.3389/fnhum.2025.1689073>.
- [10] M. Tabejamaat, H. Mohammadzade, F. Negin, and F. Bremond, "Eeg classification with limited data: A deep clustering approach," 2025, [Online]. Available: <https://doi.org/10.1016/j.patcog.2024.110934>.
- [11] X. Jiang, G. B. Bian, and Z. Tian, "Removal of artifacts from eeg signals: A review," 2019, [Online]. Available: <https://doi.org/10.3390/s19050987>.
- [12] C. Rommel, J. Paillard, T. Moreau, and A. Gramfort, "Data augmentation for learning predictive models on eeg: A systematic comparison," 2022, [Online]. Available: <https://doi.org/10.48550/arXiv.2206.14483>.
- [13] S. Savadi, "A comprehensive review of feature extraction and classification techniques in eeg signal analysis," 2025, [Online]. Available: <http://www.ijceronline.com/>.
- [14] G. Bao, B. Yan, L. Tong, J. Shu, L. Wang, K. Yang, and Y. Zeng, "Data augmentation for eeg-based emotion recognition using generative adversarial networks," 2021, [Online]. Available: <https://doi.org/10.3389/fncom.2021.723843>.
- [15] K. G. Hartmann, R. T. Schirrmeister, and T. Ball, "Eeg-gan: Generative adversarial networks for electroencephalographic (eeg) brain signals," 2018, [Online]. Available: <https://doi.org/10.48550/arXiv.1806.01875>.
- [16] W. Kong and X. Jin, "Basics of eeg signals," in *Brain Fingerprint Identification*. Springer, Singapore, 2025, [Online]. Available: https://doi.org/10.1007/978-981-96-4512-1_2.

- [17] S. Beniczky and D. L. Schomer, "Electroencephalography: Basic biophysical and technological aspects important for clinical applications," 2020, [Online]. Available: <https://doi.org/10.1684/epd.2020.1217>.
- [18] E. Ignatious, S. Azam, M. Jonkman, and F. D. Boer, "Frequency and time domain analysis of eeg-based auditory evoked potentials to detect binaural hearing in noise," 2023, [Online]. Available: <https://doi.org/10.3390/jcm12134487>.
- [19] H. Peng, F. Long, and C. Ding, "Feature selection based on mutual information criteria of max-dependency, max-relevance, and min-redundancy," 2005, [Online]. Available: <https://doi.org/10.1109/TPAMI.2005.159>.
- [20] B. Gholami, M. H. Behboudi, M. G. Mahjani, and A. Khadem, "Diagnosis of sleep apnea syndrome from eeg signals using different entropy measures," in *2021 7th International Conference on Signal Processing and Intelligent Systems (ICSPIS)*, 2021, [Online]. Available: <https://doi.org/10.1109/ICSPIS54653.2021.9729367>.
- [21] C.-T. Hsieh and Y.-H. Huang, "Tsmrmr feature selection method for detecting sleep apnea episodes based on eeg signals," in *2024 IEEE-EMBS Conference on Biomedical Engineering and Sciences (IECBES)*, 2024, [Online]. Available: <https://doi.org/10.1109/IECBES61011.2024.10991314>.
- [22] A. D. Giacomo, R. Palmieri, E. F. Russo, I. Pizzolorusso, R. Brandi, F. Magistro, M. G. D. Cesare, S. Quattrocelli, D. Cardone, D. Perpetuini, and A. Merla, "Machine learning and deep learning applied to eeg and fnirs for early autism spectrum disorder diagnosis: A systematic review," 2026, [Online]. Available: <https://doi.org/10.3389/fpsy.2026.1668914>.
- [23] J. Wang, J. Barstein, L. E. Ethridge, M. W. Mosconi, Y. Takarae, and J. A. Sweeney, "Resting-state eeg abnormalities in autism spectrum disorders," 2013, [Online]. Available: <https://doi.org/10.1186/1866-1955-5-24>.
- [24] L. B. Ribeiro and M. da Silva Filho, "Systematic review on eeg analysis to diagnose and treat autism by evaluating functional connectivity and spectral power," 2023, [Online]. Available: <https://doi.org/10.2147/NDT.S394363>.

- [25] F. J. Ramírez-Arias, E. E. García-Guerrero, E. Tlelo-Cuautle, J. M. Colores-Vargas, E. García-Canseco, O. R. López-Bonilla, G. M. Galindo-Aldana, and E. Inzunza-González, “Evaluation of machine learning algorithms for classification of eeg signals,” 2022, [Online]. Available: <https://doi.org/10.3390/technologies10040079>.
- [26] L. Xu, M. Xu, Y. Ke, X. An, S. Liu, and D. Ming, “Cross-dataset variability problem in eeg decoding with deep learning,” 2020, [Online]. Available: <https://doi.org/10.3389/fnhum.2020.00103>.
- [27] W.-H. Kim, G.-W. Kim, J. Ahn, and K. Chung, “Time-series data augmentation for improving multi-class classification performance,” 2024, [Online]. Available: https://ijaseit.insightsociety.org/index.php?option=com_content&view=article&id=9&Itemid=1&article_id=20546.
- [28] M. Goyal and Q. H. Mahmoud, “A systematic review of synthetic data generation techniques using generative ai,” 2024, [Online]. Available: <https://www.mdpi.com/2079-9292/13/17/3509>.
- [29] Y. Yao, X. Wang, X. Hao, H. Sun, R. Dong, and Y. Li, “Trans-cvae-gan: Transformer-based cvae-gan for high-fidelity eeg signal generation,” 2025, [Online]. Available: <https://doi.org/10.3390/bioengineering12101028>.
- [30] D. P. Kingma and M. Welling, “Auto-encoding variational bayes,” 2014, [Online]. Available: <https://doi.org/10.48550/arXiv.1312.6114>.
- [31] A. Vasarkar, “Eeg data augmentation using variational autoencoder,” [Online]. Available: <https://github.com/arkanivasarkar/EEG-Data-Augmentation-using-Variational-Autoencoder>.
- [32] D. T. Kertapati, “Anak-anak luar biasa,” 2023, [Online]. Available: https://kemkes.go.id/app_asset/file_content_download/171090786265fa61d67ff2e9.83516065.pdf.
- [33] “Burden and inequality of autism spectrum disorders in global, east asian, and south-east asian regions, 1990–2021,” 2021, [Online]. Available: <https://pubmed.ncbi.nlm.nih.gov/40819035/>.

- [34] A. Adhikary, “Identification of novel diagnostic neuroimaging biomarkers for autism spectrum disorder through convolutional neural network-based analysis of functional, structural, and diffusion tensor imaging data towards enhanced autism diagnosis,” 2024, [Online]. Available: <https://doi.org/10.48550/arXiv.2305.18841>.
- [35] S. Saha and M. Baumert, “Intra- and inter-subject variability in eeg-based sensorimotor brain computer interface: A review,” 2020, [Online]. Available: <https://doi.org/10.3389/fncom.2019.00087>.
- [36] G. M. Rojas, C. Alvarez, C. E. Montoya, M. de la Iglesia-Vayá, J. E. Cisternas, and M. Gálvez, “Study of resting-state functional connectivity networks using eeg electrodes position as seed,” 2018, [Online]. Available: <https://doi.org/10.3389/fnins.2018.00235>.
- [37] C. Ahuja and D. Sethia, “Harnessing few-shot learning for eeg signal classification: A survey of state-of-the-art techniques and future directions,” 2024, [Online]. Available: <https://doi.org/10.3389/fnhum.2024.1421922>.