UNIVERSITAS INDONESIA

RANCANG BANGUN SISTEM PENGELOLAAN TUGAS AKHIR BERBASIS WEB UNTUK MAHASISWA TEKNIK KOMPUTER UNIVERSITAS INDONESIA

SKRIPSI

WENDY DHARMAWAN
2206059591

FAKULTAS TEKNIK
PROGRAM STUDI S1 TEKNIK KOMPUTER
DEPOK
2025

UNIVERSITAS INDONESIA

RANCANG BANGUN SISTEM PENGELOLAAN TUGAS AKHIR BERBASIS WEB UNTUK MAHASISWA TEKNIK KOMPUTER UNIVERSITAS INDONESIA

SKRIPSI
Diajukan sebagai salah satu syarat untuk memperoleh gelar Sarjana Teknik

WENDY DHARMAWAN
2206059591

FAKULTAS TEKNIK
PROGRAM STUDI S1 TEKNIK KOMPUTER
DEPOK
JULI 2025

HALAMAN PERNYATAAN ORISINALITAS

Skripsi ini adalah hasil karya saya sendiri,

dan semua sumber baik yang dikutip maupun dirujuk

telah saya nyatakan dengan benar.

Nama	:	**Wendy Dharmawan**
NPM	:	**2206059591**
Tanda Tangan	:	
Tanggal	:	**25 Juli 2025**

HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL

Saya menyatakan bahwa dalam penyusunan Tugas Akhir ini, saya menggunakan teknologi Keceradasan Buatan dengan platform Gemini dan ChatGPT untuk tujuan pemeriksaan dan perbaikan tata bahasa dan saya bertanggung jawab penuh atas keakuratan, orisinalitas, dan integritas seluruh isi Tugas Akhir ini.

Nama	:	**Wendy Dharmawan**
NPM	:	**2206059591**
Tanda Tangan	:	
Tanggal	:	**25 Juli 2025**

HALAMAN PENGESAHAN

Skripsi ini diajukan oleh	:	
Nama	:	Wendy Dharmawan
NPM	:	2206059591
Program Studi	:	S1 Teknik Komputer
Judul Skripsi	:	Rancang Bangun Sistem Pengelolaan Tugas Akhir Berbasis Web untuk Mahasiswa Teknik Komputer Universitas Indonesia

Telah berhasil dipertahankan di hadapan Dewan Penguji dan diterima sebagai bagian persyaratan yang diperlukan untuk memperoleh gelar Sarjana Teknik pada Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.

DEWAN PENGUJI

Pembimbing	:	[Nama Dosen Pembimbing]	(	)
Penguji	:	[Nama Dosen Penguji 1]	(	)
Penguji	:	[Nama Dosen Penguji 2]	(	)
Penguji	:	[Nama Dosen Penguji 3]	(	)

Ditetapkan di	:	Depok
Tanggal	:	1 Agustus 2025

KATA PENGANTAR

Puji dan syukur Penulis panjatkan kepada Tuhan Yang Maha Esa atas berkat dan rahmat-Nya lah Penulis dapat menyelesaikan Skripsi dengan judul "Rancang Bangun Sistem Pengelolaan Tugas Akhir Berbasis Web untuk Mahasiswa Teknik Komputer Universitas Indonesia". Skripsi ini Penulis laksanakan sebagai salah satu syarat dalam memperoleh gelar Sarjana Teknik pada program studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.

Penulis juga ingin menyampaikan rasa terima kasihnya kepada:

1. [Nama Dosen Pembimbing], selaku Dosen Pembimbing SkripsiPenulis.
2. [Nama Ketua Departemen], selaku Ketua Departemen Teknik Elektro, Fakultas Teknik, Universitas Indonesia.
3. [Nama Ketua Prodi], selaku Kepala Program Studi S1 Teknik Komputer, Fakultas Teknik, Universitas Indonesia.
4. [Nama Dosen Pembimbing Akademis], selaku Pembimbing Akademis Penulis.
5. [Nama Dosen Penguji 1], [Nama Dosen Penguji 2] dan [Nama Dosen Penguji 3] selaku Dosen Penguji SkripsiP̃enulis.
6. Segenap dosen Departemen Teknik Elektro atas semua ilmu yang diberikan kepada Penulis.
7. Orang tua yang selalu memberikan dukungan serta doa, sehingga penulisan Skripsi dapat diselesaikan secara baik.
8. Teman-teman Teknik Komputer, selaku rekan penulis yang selalu membantu serta memberikan dukungan moril sepanjang proses kuliah serta penulisan proposal skripsi.

Penulis menyadari dan menerima bahwa Skripsi yang dibentuk ini masih jauh dari sempurna dan masih memiliki berbagai kekurangan serta kesalahan baik dari segi ilmu maupun pemahaman. Oleh karena itu, Penulis mengharapkan segala kritik dan saran yang diberikan agar ke depannya Penulis dapat menjadi lebih baik.

25 Juli 2025

Wendy Dharmawan

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI TUGAS AKHIR UNTUK KEPENTINGAN AKADEMIS

Sebagai sivitas akademik Universitas Indonesia, saya yang bertanda tangan di bawah ini:

Nama	:	Wendy Dharmawan
NPM	:	2206059591
Program Studi	:	S1 Teknik Komputer
Fakultas	:	Teknik
Jenis Karya	:	Skripsi

demi pengembangan ilmu pengetahuan, menyetujui untuk memberikan kepada Universitas Indonesia **Hak Bebas Royalti Noneksklusif (*Non-exclusive Royalty Free Right*)** atas karya ilmiah saya yang berjudul:

Rancang Bangun Sistem Pengelolaan Tugas Akhir Berbasis Web untuk Mahasiswa Teknik Komputer Universitas Indonesia

beserta perangkat yang ada (jika diperlukan). Dengan Hak Bebas Royalti Noneksklusif ini Universitas Indonesia berhak menyimpan, mengalihmedia/formatkan, mengelola dalam bentuk pangkalan data (*database*), merawat, dan memublikasikan tugas akhir saya selama tetap mencantumkan nama saya sebagai penulis/pencipta dan sebagai pemilik Hak Cipta.

Demikian pernyatan ini saya buat dengan sebenarnya.

Dibuat di : Depok

Pada tanggal : 25 Juli 2025

Yang menyatakan

(Wendy Dharmawan)

ABSTRAK

Nama	:	Wendy Dharmawan
Program Studi	:	S1 Teknik Komputer
Judul	:	Rancang Bangun Sistem Pengelolaan Tugas Akhir Berbasis Web untuk Mahasiswa Teknik Komputer Universitas Indonesia
Pembimbing	:	[Nama Dosen Pembimbing]

Proses pengerjaan Tugas Akhir di Program Studi Teknik Komputer Universitas Indonesia (PSTK UI) menghadapi tantangan ganda, yaitu inefisiensi pada alur kerja administrasi yang masih berjalan semi-manual serta rendahnya tingkat kepatuhan mahasiswa terhadap format penulisan yang baku. Penelitian ini bertujuan untuk merancang, membangun, dan mengevaluasi sebuah solusi terpadu bernama D'Office, yang terdiri dari sistem pengelolaan tugas akhir berbasis web dan sebuah templat penulisan berbasis LaTeX. Sebuah purwarupa fungsional dikembangkan dan dievaluasi melalui metodologi eksperimen campuran yang melibatkan 24 partisipan (mahasiswa dan dosen), dengan membandingkan kelompok kontrol (proses manual) dengan kelompok eksperimen (menggunakan solusi D'Office). Metrik kuantitatif yang diukur meliputi Waktu Pengerjaan Tugas (ToT), Tingkat Keberhasilan Tugas (TSR), Skor Kepatuhan Format, dan Skor Skala Kebergunaan Sistem (SUS), yang didukung oleh data kualitatif dari wawancara. Hasil pengujian menunjukkan bahwa sistem D'Office berhasil mengurangi ToT rata-rata sebesar 76% dan meningkatkan TSR hingga 100% pada tugas-tugas kunci. Penggunaan templat LaTeX meningkatkan Skor Kepatuhan Format secara signifikan dari 74.0 menjadi 97.5. Selain itu, sistem D'Office memperoleh skor SUS "*Excellent*" sebesar 85.5 dan umpan balik kualitatif yang sangat positif dari pengguna. Solusi terpadu D'Office terbukti efektif dalam meningkatkan efisiensi proses administrasi dan kualitas format penulisan tugas akhir, serta memberikan pengalaman pengguna yang sangat memuaskan.

Kata kunci: sistem informasi akademik, manajemen tugas akhir, templat LaTeX, evaluasi usabilitas, rekayasa perangkat lunak.

ABSTRACT

Name	:	Wendy Dharmawan
Study Program	:	S1 Teknik Komputer
Title	:	Development of a Web-Based Thesis Management System for Computer Engineering Students at the University of Indonesia
Supervisor	:	[Nama Dosen Pembimbing]

The thesis completion process at the Department of Computer Engineering, Universitas Indonesia, faces dual challenges: inefficiencies in the semi-manual administrative workflow and low student compliance with standardized writing formats. This research aims to design, build, and evaluate an integrated solution named D'Office, which consists of a web-based thesis management system and a LaTeX-based writing template. A functional prototype was developed and evaluated through a mixed-methods experiment involving 24 participants (students and lecturers), comparing a control group (manual process) with an experimental group (using the D'Office solution). Quantitative metrics, including Time on Task (ToT), Task Success Rate (TSR), Formatting Compliance Score, and System Usability Scale (SUS) score, were measured, supported by qualitative data from interviews. The results show that the D'Office system successfully reduced the average ToT by 76% and increased the TSR to 100% on key tasks. The use of the LaTeX template significantly improved the Formatting Compliance Score from 74.0 to 97.5. Furthermore, the D'Office system achieved an "Excellent" SUS score of 85.5 and received overwhelmingly positive qualitative feedback from users. The integrated D'Office solution is proven to be effective in enhancing the efficiency of the administrative process and the quality of thesis formatting, while providing a highly satisfactory user experience.

Keywords: academic information system, thesis management, LaTeX template, usability evaluation, software engineering.

DAFTAR ISI

HALAMAN JUDUL . . . . . **i**

HALAMAN PERNYATAAN ORISINALITAS . . . . . **ii**

HALAMAN PERNYATAAN PENGGUNAAN KECERDASAN ARTIFISIAL . **iii**

HALAMAN PENGESAHAN . . . . . **iv**

KATA PENGANTAR . . . . . **v**

HALAMAN PERNYATAAN PERSETUJUAN PUBLIKASI . . . . . **vii**

ABSTRAK . . . . . **viii**

ABSTRACT . . . . . **ix**

DAFTAR ISI . . . . . **x**

DAFTAR TABEL . . . . . **xii**

DAFTAR GAMBAR . . . . . **xiii**

DAFTAR PERSAMAAN . . . . . **xiv**

DAFTAR NOTASI . . . . . **xv**

DAFTAR KODE PROGRAM . . . . . **xvi**

DAFTAR SINGKATAN . . . . . **xvii**

1 PENDAHULUAN **1**
- 1.1 Latar Belakang 1
- 1.2 Rumusan Masalah 5
- 1.3 Tujuan Penelitian 5
- 1.4 Manfaat Penelitian 6
- 1.5 Ruang Lingkup Penelitian 6
- 1.6 Sistematika Penulisan 7

2 TINJAUAN PUSTAKA **9**
- 2.1 Landasan Teori 9
  - 2.1.1 Sinyal EEG 9
  - 2.1.2 Akuisisi Sinyal EEG 11
  - 2.1.3 Prapemrosesan Sinyal EEG 13
  - 2.1.4 Feature Selection mRMR 17
  - 2.1.5 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG 18

2.1.6 Augmentasi Data EEG 20
2.1.7 Variational Auto Encoder 22
2.2 Penelitian Terdahulu 24
2.2.1 Klasifikasi ASD Berbasis EEG Menggunakan mRMR dan XGBoost 24
2.2.2 Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder 25
2.2.3 Dataset yang Digunakan 26
2.3 Fokus pada Celah Penelitian 28

3 PERANCANGAN DAN IMPLEMENTASI SISTEM DAN TEMPLAT . . . 29
3.1 Analisis Kebutuhan Sistem 30
3.2 Perancangan Arsitektur Sistem 31
3.2.1 Pra-Pemrosesan Dataset 33
3.2.2 Arsitektur Model VAE 34
3.2.3 Arsitektur Model Klasifikasi 36
3.3 Detail Implementasi dan Teknologi 38
3.3.1 Teknologi dan Library 38
3.3.2 Implementasi Model Generatif Variational Autoencoder (VAE) . . 39

DAFTAR REFERENSI 43

DAFTAR TABEL

DAFTAR GAMBAR

Gambar 2.1 Sistem Internasional 10–20 untuk Penempatan Elektroda EEG 12
Gambar 2.2 Pita Frekuensi EEG pada Rentang Frekuensi Tinggi dan Rendah 15
Gambar 2.3 Bentuk-Bentuk Artefak pada Sinyal EEG 16

Gambar 3.1 Diagram aliran data pada sistem 32
Gambar 3.2 Diagram aliran proses prapemrosesan sistem 33
Gambar 3.3 Diagram arsitektur model Variational Autoencoder (VAE) . . 35
Gambar 3.4 Arsitektur model Variational Autoencoder (VAE) 39

DAFTAR PERSAMAAN

DAFTAR NOTASI

g	Konstanta percepatan gravitasi (9.8 m/s^2)
v_0	Kecepatan awal benda
α	Koefisien alpha
Σ	Notasi untuk penjumlahan (sigma)

DAFTAR KODE PROGRAM

DAFTAR SINGKATAN

API	*Application Programming Interface*
DTE	Departemen Teknik Elektro
HCI	*Human Computer Interaction*
IMK	Interaksi Manusia dan Komputer
ITB	Institut Teknologi Bandung
MVC	*Model-View-Controller*
ORM	*Eloquent Object-Relational Mapper*
PDF	*Portable Document Format*
PRG	*Post/Redirect/Get*
PSTK UI	Program Studi Teknik Komputer, Universitas Indonesia
SDLC	*System Development Life Cycle*
SIAK-NG	Sistem Informasi Akademik *Next-Generation*
SKS	Satuan Kredit Semester
SQL	Structured Query Language
SSD	*Solid State Drive*
SUS	*System Usability Scale*
TA	Tugas Akhir
ToT	*Time on Task*
TSR	*Task Success Rate*
TTFB	*Time to First Byte*
UGM	Universitas Gadjah Mada
UI	Universitas Indonesia
UI/UX	*User Interface/Experience*
UML	*Unified Modeling Language*
UX	*User Experience*

BAB 1
PENDAHULUAN

Autism Spectrum Disorder (ASD) merupakan salah satu kondisi yang berkaitan dengan fungsi dan perkembangan sistem saraf manusia, yang berdampak pada berbagai aspek kehidupan individu, khususnya dalam komunikasi, interaksi sosial, dan perilaku. Proses identifikasi ASD secara dini masih menjadi tantangan karena metode diagnosis yang ada sering kali bergantung pada observasi klinis yang memerlukan waktu dan evaluasi yang mendalam. Dalam beberapa tahun terakhir, pemanfaatan sinyal electroencephalography (EEG) dan teknik machine learning mulai banyak dieksplorasi sebagai pendekatan alternatif untuk membantu proses identifikasi ASD secara lebih objektif. Meskipun demikian, penelitian berbasis EEG masih menghadapi berbagai kendala, seperti keterbatasan dataset dan tingginya variabilitas sinyal, yang dapat memengaruhi performa model klasifikasi. Oleh karena itu, teknik *data augmentation* mulai diteliti sebagai salah satu pendekatan untuk meningkatkan variasi data pelatihan serta membantu meningkatkan kemampuan generalisasi model.

Bab ini akan dimulai dengan penjelasan Latar Belakang yang memberikan konteks penting terkait penelitian ini, diikuti oleh Rumusan Masalah dan Tujuan Penelitian yang merinci fokus utama studi. Selanjutnya, akan dibahas Manfaat Penelitian dan Ruang Lingkup Penelitian untuk menjelaskan kontribusi serta batasan penelitian ini. Terakhir, Sistematika Penulisan akan menguraikan struktur keseluruhan laporan penelitian.

1.1 Latar Belakang

Autism Spectrum Disorder (ASD) merupakan gangguan neurologis yang ditandai oleh ketidakmampuan yang persisten dalam komunikasi sosial dan interaksi sosial, serta pola perilaku, minat, atau aktivitas yang terbatas dan berulang [1], [2]. Gejala umumnya muncul sejak masa anak-anak, dengan tingkat keparahan yang bervariasi sehingga menimbulkan karakteristik yang beragam pada setiap individu [1]. ASD memengaruhi berbagai aspek dari individu, diantaranya kemampuan sosial, akademik, dan okupasional,

serta berlangsung seumur hidup [1]. Oleh karena itu, identifikasi dan intervensi sejak dini menjadi faktor yang sangat penting untuk meminimalkan hambatan perkembangan jangka panjang dan memperbaiki kualitas hidup individu dengan ASD [1].

Saat ini di Indonesia, jumlah penyandang ASD diperkirakan berjumlah sebanyak 2,4 juta orang, dengan pertambahan sebanyak 500 penyandang baru per tahunnya[3]. Tingkat prevalensi Autism Spectrum Disorder (ASD) di Indonesia dilaporkan relatif lebih rendah dibandingkan dengan beberapa negara di kawasan Asia. Meskipun demikian, perbedaan angka prevalensi antarwilayah sering kali dipengaruhi oleh variasi dalam sistem diagnosis, pelaporan, serta tingkat kesadaran masyarakat, sehingga penguatan skrining dan intervensi dini, pengembangan sistem informasi kesehatan, serta pengurangan stigma sosial perlu menjadi prioritas untuk meningkatkan identifikasi dan penanganan ASD secara lebih efektif[4].

Diagnosa ASD yang akurat masih menjadi tantangan yang signifikan. Hal ini disebabkan oleh sifat heterogen dari ASD, dengan variasi gejala yang luas serta perbedaan tingkat keparahan pada setiap individu. Selain itu, proses diagnosis juga menjadi lebih sulit karena gejala ASD sering kali menyerupai atau muncul bersamaan dengan gangguan perkembangan lainnya, sehingga memerlukan evaluasi yang lebih menyeluruh dan instrumen penilaian yang tepat, serta prosedur diagnosis klinis yang umumnya memerlukan waktu yang cukup lama dan sering kali hanya dilakukan ketika terdapat indikasi kuat adanya perkembangan ASD[5][6]. Metode yang saat ini menjadi standar emas, Autism Diagnostic Observation Schedule, Second Edition (ADOS-2) masih memiliki beberapa kelemahan, seperti evaluasi yang subjektif dan ketidakmampuan membedakan varietas keterbatasan dalam membedakan tingkat keparahan gejala secara akurat, serta kemampuan deteksi dini yang masih kurang memadai karena metode ini pada umumnya menilai kondisi yang telah muncul pada anak[7]. Keterbatasan ini menuntut pengembangan metode yang lebih objektif dan konsisten, sehingga proses identifikasi dapat dilakukan dengan tingkat reliabilitas yang lebih tinggi

Untuk menjawab tantangan tersebut, berbagai penelitian mulai mengeksplorasi pendekatan berbasis data dalam proses identifikasi ASD. Penilaian ASD masih menghadapi berbagai kendala, di antaranya keterbatasan dataset pencitraan medis yang tersedia secara publik serta dominasi metode diagnosis konvensional yang bergantung pada observasi

klinis, sehingga berpotensi menimbulkan variasi hasil diagnosis antar klinisi[7]. Oleh karena itu, pendekatan berbasis biomarker mulai diteliti untuk meningkatkan objektivitas dalam proses identifikasi ASD. Sejumlah penelitian telah mengeksplorasi biomarker neurologis dan fisiologis seperti Magnetic Resonance Imaging (MRI), functional MRI (fMRI), functional near-infrared spectroscopy (fNIRS), serta biomarker genetik dan perilaku. Meskipun menunjukkan potensi dalam mengidentifikasi perbedaan struktur dan aktivitas otak pada individu dengan ASD, metode-metode tersebut masih memiliki keterbatasan, seperti biaya yang tinggi dan kebutuhan peralatan khusus. Oleh karena itu, electroencephalography (EEG) mulai banyak dieksplorasi sebagai biomarker alternatif karena bersifat non-invasif, relatif lebih murah, memiliki resolusi temporal yang tinggi, serta dapat digunakan secara luas dalam lingkungan klinis dan pada berbagai kelompok usia untuk memperoleh pengukuran aktivitas otak secara berulang [8], [9].

Perkembangan pesat dalam bidang machine learning telah membuka peluang baru dalam analisis sinyal neurofisiologis untuk membantu proses identifikasi gangguan neurologis, termasuk ASD. Teknik machine learning memungkinkan peneliti untuk mengekstraksi pola kompleks dari sinyal electroencephalography (EEG) yang sulit diidentifikasi melalui analisis konvensional. Pendekatan ini umumnya melibatkan beberapa tahapan pemrosesan, mulai dari akuisisi sinyal EEG, preprocessing, ekstraksi fitur, hingga proses klasifikasi menggunakan algoritma pembelajaran mesin seperti Support Vector Machine (SVM), k-Nearest Neighbor (kNN), dan Random Forest. Berbagai penelitian menunjukkan bahwa model machine learning yang diterapkan pada data EEG mampu mengidentifikasi perbedaan pola aktivitas otak antara individu dengan ASD dan individu dengan perkembangan tipikal, serta mencapai tingkat akurasi yang tinggi dalam proses klasifikasi.[10][11]. Draft penelitian [1x] mengusulkan pendekatan klasifikasi ASD berbasis EEG yang lebih optimal dan interpretable dengan mengombinasikan seleksi fitur minimum Redundancy Maximum Relevance (mRMR) dan algoritma XGBoost. Pendekatan yang diusulkan menunjukkan kinerja yang sangat baik, dengan tingkat akurasi yang tinggi dan konsisten pada berbagai skenario pengujian, sehingga dapat dikatakan mampu mencapai hasil klasifikasi yang baik untuk mendukung proses identifikasi ASD secara lebih andal.

Meskipun electroencephalography (EEG) menunjukkan potensi sebagai biomarker

dalam identifikasi ASD, penelitian berbasis EEG masih menghadapi sejumlah tantangan yang signifikan. Salah satu kendala utama yang ada adalah keterbatasan ketersediaan dataset EEG yang berlabel secara klinis dan dapat diakses secara publik[12]. Keterbatasan jumlah dan variasi partisipan pada dataset EEG dapat meningkatkan risiko overfitting dalam proses pelatihan model pembelajaran mesin, yang pada akhirnya dapat membatasi kemampuan model untuk melakukan generalisasi terhadap populasi yang lebih luas [13]. Variasi data EEG dapat berupa perbedaan protokol pengambilan data, seperti variasi jumlah kanal EEG, konfigurasi elektroda, perangkat perekaman, serta kondisi eksperimen, juga menyebabkan perbedaan karakteristik sinyal antar dataset[14]. Variabilitas sinyal EEG juga dapat berupa perbedaan antar individu, yang dipengaruhi oleh kondisi neurologis dan aktivitas yang dilakukan selama proses perekaman[15]. Data EEG juga rentan terhadap berbagai artefak yang dapat mengkontaminasi sinyal, seperti gerakan otot, kedipan mata, atau gangguan pada perangkat perekaman. Keberadaan artefak tersebut dapat memengaruhi kualitas sinyal yang diperoleh dan berpotensi menimbulkan pola yang tidak merepresentasikan aktivitas otak yang sebenarnya[16]. Kombinasi dari keterbatasan dataset, keberadaan artefak pada sinyal, serta tingginya variabilitas data menyebabkan pengembangan model yang mampu melakukan klasifikasi secara konsisten menjadi lebih sulit, terutama ketika model diharapkan dapat diterapkan secara lebih luas pada data EEG dari berbagai sumber dan kondisi perekaman yang berbeda.

Salah satu pendekatan yang mulai banyak diteliti untuk mengatasi keterbatasan dataset EEG adalah penggunaan teknik data augmentation. Teknik ini bertujuan untuk memperluas jumlah data pelatihan secara artifisial dengan menghasilkan variasi baru dari data yang sudah ada, sehingga model dapat mempelajari representasi fitur yang lebih beragam. Beberapa penelitian menunjukkan bahwa penerapan augmentasi data dapat membantu meningkatkan performa model klasifikasi EEG serta mengurangi risiko overfitting pada kondisi dataset yang terbatas [17]. Pendekatan augmentasi konvensional umumnya dilakukan melalui transformasi sederhana pada sinyal, seperti penambahan noise, pergeseran waktu, atau manipulasi amplitudo. Namun, metode tersebut sering kali memiliki keterbatasan dalam mempertahankan karakteristik kompleks dari sinyal EEG. Seiring dengan perkembangan metode deep learning, pendekatan berbasis model generatif seperti Variational Autoencoder (VAE) mulai banyak digunakan untuk menghasilkan data sin-

tetis yang lebih representatif. Model ini mempelajari distribusi laten dari data EEG dan memungkinkan proses generasi sampel baru yang mempertahankan karakteristik statistik dari data asli. Oleh karena itu, penggunaan data sintetis berbasis model generatif memiliki potensi yang lebih besar dalam meningkatkan kualitas dataset dibandingkan metode augmentasi konvensional[18]. Meskipun demikian, pemanfaatan data sintetis dalam analisis EEG, khususnya untuk klasifikasi Autism Spectrum Disorder (ASD), masih memerlukan kajian lebih lanjut untuk memahami dampaknya terhadap performa dan kemampuan generalisasi model. Oleh karena itu, penelitian ini bertujuan untuk mengeksplorasi penggunaan teknik augmentasi data berbasis model generatif dalam meningkatkan performa model klasifikasi EEG, serta mengevaluasi sejauh mana data sintetis yang dihasilkan dapat merepresentasikan karakteristik sinyal EEG yang relevan dengan kondisi ASD.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah dijelaskan, permasalahan utama dalam penelitian ini dirumuskan sebagai berikut:

1. Bagaimana teknik data augmentation pada sinyal EEG yang telah dikembangkan dalam penelitian sebelumnya dapat diidentifikasi dan dipilih untuk digunakan dalam klasifikasi EEG untuk klasifikasi ASD?

2. Bagaimana teknik data augmentation dapat diterapkan dalam pipeline pemrosesan data EEG, khususnya terkait tahap penerapannya terhadap proses preprocessing berdasarkan arsitektur yang diusulkan pada draft paper penelitian [1x]?

3. Sejauh mana penggunaan data augmentation memengaruhi performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD)?

1.3 Tujuan Penelitian

Selaras dengan rumusan masalah yang telah diuraikan, tujuan dari penelitian ini mencakup sebagai berikut:

1. Mengidentifikasi dan memilih teknik data augmentation pada sinyal EEG yang relevan berdasarkan penelitian yang telah ada untuk digunakan dalam proses klasifikasi EEG untuk klasifikasi ASD.

2. Menerapkan teknik data augmentation dalam pipeline pemrosesan data EEG berdasarkan arsitektur draft penelitian rujukan [1x] serta mengevaluasi penerapannya terhadap tahapan preprocessing.

3. Menganaalisis pengaruh penggunaan data augmentation terhadap performa dan kemampuan generalisasi model klasifikasi EEG dalam mendeteksi pola yang berkaitan dengan Autism Spectrum Disorder (ASD).

1.4 Manfaat Penelitian

Berdasarkan latar belakang, rumusan masalah, dan tujuan penelitian yang telah diuraikan, penelitian ini diharapkan memberikan manfaat sebagai berikut:

1. **Bagi Peneliti di Bidang Terkait:**
   Penelitian ini diharapkan dapat menjadi referensi bagi peneliti di bidang Artificial Intelligence dan analisis sinyal EEG, khususnya dalam pengembangan metode pembelajaran mesin untuk analisis data EEG pada studi Autism Spectrum Disorder (ASD). Hasil penelitian ini dapat digunakan sebagai dasar untuk penelitian lanjutan dalam pengembangan model analisis EEG yang lebih efektif.

2. **Bagi Tenaga Medis dan Profesional Kesehatan**
   Penelitian ini diharapkan dapat memberikan gambaran mengenai potensi pemanfaatan teknologi Artificial Intelligence dalam analisis data EEG pada studi Autism Spectrum Disorder (ASD), sehingga dapat mendukung penelitian lanjutan maupun pengembangan alat bantu yang dapat membantu proses evaluasi klinis.

1.5 Ruang Lingkup Penelitian

Agar penelitian ini tetap terfokus, maka ditetapkan beberapa batasan masalah sebagai berikut:

1. **Arsitektur Dasar dan Implementasi Model:** Penelitian ini akan merekonstruksi pendekatan analisis EEG yang diusulkan pada penelitian rujukan[1x], yaitu metode analisis EEG yang memanfaatkan seleksi fitur *mRMR* serta model klasifikasi *XGBoost*. Penelitian ini bertujuan untuk mengimplementasikan kembali pendekatan tersebut sebagai dasar eksperimen.

2. **Dataset dan Variasi Data:** Penelitian ini menggunakan dataset EEG yang sama dengan penelitian rujukan. Variasi dalam penelitian ini terletak pada keterlibatan teknik *data augmentasi* yang dihasilkan berdasarkan data asli yang akan digunakan dan dianalisis pengaruhnya terhadap performa model dalam proses klasifikasi.

3. **Proses Training Model Augmentasi:** Model augmentasi akan dilatih menggunakan metode VAE dengan mengacu pada pendekatan pada penelitian rujukan[], disertai penyesuaian arsitektur model untuk mengakomodasi perubahan dimensi data yang digunakan untuk proses training model.

4. **Proses Training Model Klasifikasi:** Model klasifikasi akan dilatih menggunakan prosedur pelatihan berdasarkan penilitan rujukan [1x] tanpa melakukan modifikasi terhadap struktur model maupun proses *fine-tuning* tambahan di luar skenario eksperimen yang dirancang.

5. **Evaluasi dan Analisis Hasil:** Evaluasi penelitian difokuskan pada perbandingan performa model yang dilatih dengan dan tanpa penerapan *data augmentasi*. Analisis akan mencakup pengamatan terhadap metrik performa klasifikasi untuk menilai pengaruh variasi data terhadap hasil model.

6. **Platform Eksekusi:** Seluruh proses pelatihan, pengujian, dan analisis model akan dijalankan menggunakan komputasi klasik dengan memanfaatkan CPU dan/atau GPU.

1.6 Sistematika Penulisan

Laporan tesis ini disusun secara sistematis ke dalam lima bab utama, dengan rincian sebagai berikut:

1. **Bab 1: Pendahuluan.** Bab ini menyajikan gambaran umum penelitian, meliputi latar belakang yang menjelaskan pentingnya analisis sinyal EEG dalam mendukung identifikasi Autism Spectrum Disorder (ASD), rumusan masalah yang menjadi dasar penelitian, tujuan yang ingin dicapai, manfaat penelitian, ruang lingkup penelitian, serta sistematika penulisan laporan ini.

2. **Bab 2: Tinjauan Pustaka.** Bab ini menguraikan landasan teoretis yang mendukung penelitian, meliputi konsep dasar sinyal EEG, metode ekstraksi dan seleksi fitur pada data EEG, metode *Minimum Redundancy Maximum Relevance* (mRMR), algoritma klasifikasi *XGBoost*, serta kajian terhadap penelitian-penelitian sebelumnya yang relevan.

3. **Bab 3: Metodologi Penelitian.** Bab ini menjelaskan metode yang digunakan dalam penelitian, mencakup deskripsi dataset EEG yang digunakan, tahapan prapemrosesan data, penerapan teknik *data augmentasi*, proses seleksi fitur menggunakan metode *mRMR*, serta proses pelatihan model klasifikasi menggunakan *XGBoost*.

4. **Bab 4: Hasil dan Analisis.** Bab ini memaparkan hasil eksperimen yang diperoleh dari proses pelatihan dan pengujian model. Analisis dilakukan untuk membandingkan performa model pada skenario dengan dan tanpa penerapan *data augmentasi*, serta mengevaluasi pengaruhnya terhadap kemampuan model dalam melakukan klasifikasi data EEG.

5. **Bab 5: Penutup.** Bab terakhir ini berisi kesimpulan dari hasil penelitian yang telah dilakukan serta saran untuk pengembangan penelitian selanjutnya terkait analisis dan klasifikasi data EEG menggunakan metode pembelajaran mesin.

BAB 2
TINJAUAN PUSTAKA

Bab ini menjelaskan konteks dan landasan teoretis yang mendasari penelitian mengenai analisis sinyal EEG untuk klasifikasi Autism Spectrum Disorder (ASD) menggunakan metode machine learning. Penjelasan diawali dengan pemaparan landasan teori yang mencakup konsep dasar sinyal EEG, tahapan pemrosesan dan analisis data EEG, serta metode klasifikasi yang digunakan dalam penelitian ini. Selanjutnya, bab ini membahas penelitian-penelitian terdahulu yang relevan dengan analisis EEG dan penerapan teknik data augmentation. Bab ini kemudian diakhiri dengan pembahasan mengenai celah penelitian yang menjadi dasar dilakukannya penelitian ini.

2.1 Landasan Teori

Bagian ini menguraikan konsep-konsep teoretis yang menjadi dasar dalam penelitian analisis sinyal EEG untuk klasifikasi Autism Spectrum Disorder (ASD). Landasan teori ini mencakup konsep dasar EEG, tahapan pemrosesan sinyal EEG, teknik seleksi fitur dalam pemrosesan, metode *machine learning* untuk klasifikasi, serta metode *data augmentation* yang digunakan dalam penelitian ini.

2.1.1 Sinyal EEG

Sinyal electroencephalogram (EEG) dihasilkan oleh aktivitas listrik neuron di dalam otak. Neuron saling berkomunikasi melalui proses transmisi sinaptik yang menghasilkan impuls listrik kecil yang menyebar melalui jaringan otak. Ketika sekelompok besar neuron mengalami aktivasi secara sinkron, potensial listrik yang dihasilkan dapat dideteksi pada permukaan permukaan kepala menggunakan elektroda. Sinyal EEG direkam sebagai perubahan tegangan terhadap waktu dengan rentang frekuensi yang umumnya berada pada kisaran 0,5 hingga 100 Hz. Aktivitas yang terekam pada sinyal EEG dipengaruhi oleh berbagai proses aktivitas otak, seperti proses kognitif, fungsi motorik, serta kondisi emosional, sehingga EEG banyak dimanfaatkan sebagai alat untuk mempelajari fungsi otak

maupun berbagai gangguan neurologis[19].

Sinyal EEG memiliki amplitudo yang relatif kecil, umumnya berada pada kisaran sekitar 10 hingga 100 mikrovolt. Amplitudo yang rendah ini menyebabkan sinyal EEG sangat sensitif terhadap berbagai sumber gangguan selama proses perekaman. Gangguan tersebut dapat berasal dari aktivitas fisiologis tubuh maupun dari lingkungan sekitar. Artefak fisiologis yang muncul seringkali disebabkan oleh pergerakan mata (electrooculogram atau EOG), aktivitas otot wajah dan kepala (electromyogram atau EMG), serta kedipan mata. Selain itu, interferensi listrik dari perangkat elektronik atau jaringan listrik juga dapat mempengaruhi kualitas sinyal yang direkam. Oleh karena itu, data EEG umumnya memerlukan tahapan prapemrosesan seperti penyaringan sinyal dan penghapusan artefak untuk meningkatkan kualitas sinyal sebelum dilakukan analisis lebih lanjut[20].

Sinyal EEG bersifat tidak stasioner (non-stationary), artinya pola dan karakteristik statistiknya tidak konstan terhadap waktu. Perubahan ini dipengaruhi oleh berbagai faktor, termasuk kondisi fisiologis individu, tingkat kesadaran, serta aktivitas kognitif yang sedang berlangsung. Variasi tersebut menyebabkan pola amplitudo maupun distribusi frekuensi sinyal EEG dapat berubah secara dinamis selama proses perekaman. Sifat non-stationary ini menyebabkan proses analisis sinyal EEG lebih kompleks dibandingkan sinyal yang bersifat stasioner, sehingga dalam banyak penelitian diperlukan metode analisis yang mampu menangkap perubahan karakteristik sinyal dari waktu ke waktu[20].

Dalam penelitian EEG, pengumpulan data umumnya dilakukan menggunakan desain eksperimen atau protokol stimulasi yang terstandarisasi untuk mengamati aktivitas listrik otak pada berbagai kondisi. Secara umum, pembangkitan sinyal EEG dalam penelitian dapat diklasifikasikan menjadi dua jenis utama berdasarkan sumber aktivasinya, yaitu stimulus eksogen dan aktivasi endogen. Stimulus eksogen berasal dari rangsangan eksternal dari lingkungan, seperti rangsangan visual, auditori, atau taktil, yang diterima oleh sistem sensorik dan memicu respons saraf yang kemudian terekam sebagai aktivitas listrik pada EEG. Sebaliknya, aktivasi endogen tidak bergantung pada rangsangan eksternal, melainkan muncul dari proses mental internal individu, seperti imajinasi gerakan (motor imagery), respons emosional, pemusatan perhatian, atau aktivitas kognitif lainnya yang menghasilkan sinyal EEG secara spontan[19][21].

2.1.2 Akuisisi Sinyal EEG

EEG biasanya direkam dalam bentuk sinyal multikanal yang diperoleh dari sejumlah elektroda yang ditempatkan pada berbagai lokasi di permukaan kulit kepala. Setiap kanal merepresentasikan satu jalur perekaman sinyal yang berasal dari pasangan elektroda atau dari elektroda terhadap referensi tertentu. Setiap elektroda menangkap aktivitas listrik dari wilayah otak yang berbeda, sehingga setiap kanal mengandung informasi yang merepresentasikan aktivitas saraf pada lokasi tertentu. Oleh karena itu, data multikanal yang dihasilkan dapat menggambarkan aktivitas otak di berbagai bagian otak secara bersamaan. Oleh karena itu, data multikanal yang dihasilkan dapat menggambarkan aktivitas otak di berbagai bagian otak secara bersamaan. Representasi ini memungkinkan peneliti untuk melakukan analisis spasial, yaitu berdasarkan perbedaan lokasi aktivitas otak, maupun spatio-temporal, yaitu berdasarkan perubahan aktivitas otak terhadap lokasi dan waktu, serta mengidentifikasi pola aktivitas yang muncul pada wilayah tertentu atau hubungan aktivitas antar wilayah otak [20].

Untuk memastikan konsistensi dan keterbandingan data antar penelitian, penempatan elektroda EEG umumnya mengikuti sistem standar yang dikenal sebagai International *10–20 System*. Sistem ini merupakan protokol penempatan elektroda yang distandarisasi oleh *International Federation of Clinical Neurophysiology* (IFCN) untuk menentukan posisi elektroda pada permukaan kepala secara sistematis. Dalam sistem ini, penentuan posisi elektroda didasarkan pada pengukuran jarak antara beberapa titik anatomi utama pada kepala, yaitu nasion (bagian depan kepala), inion (bagian belakang kepala), serta titik preauricular (area di depan telinga) pada kedua sisi kepala. Berdasarkan titik-titik referensi tersebut, permukaan kepala dibagi menjadi beberapa posisi proporsional untuk memastikan representasi perekaman yang mencukupi terhadap berbagai wilayah otak. Setiap elektroda dalam sistem ini diberi nama yang terdiri dari huruf dan angka, di mana huruf menunjukkan wilayah anatomi relatif pada permukaan kepala, seperti frontal (F), central (C), temporal (T), parietal (P), dan occipital (O), sedangkan angka menunjukkan hemisfer atau belahan otak, dengan angka ganjil untuk hemisfer kiri dan angka genap untuk hemisfer kanan. Angka yang lebih kecil menunjukkan posisi yang lebih dekat dengan garis tengah kepala, sedangkan angka yang lebih besar menunjukkan posisi yang lebih lateral. Elektroda yang terletak tepat pada garis tengah kepala ditandai dengan huruf “z”

(*zero*). Standarisasi ini memungkinkan proses perekaman EEG dilakukan secara konsisten sehingga distribusi aktivitas otak dapat dibandingkan secara lebih konsisten antar subjek maupun antar studi penelitian [22][23].

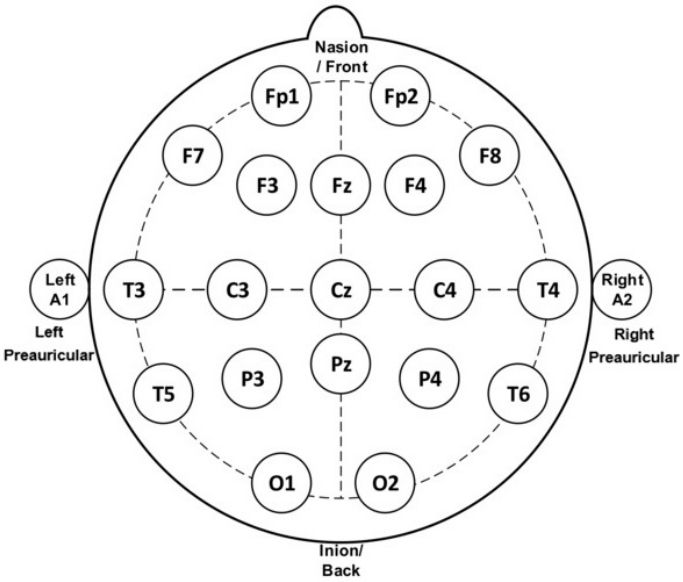

Gambar 2.1. Sistem Internasional 10–20 untuk Penempatan Elektroda EEG

Selain konfigurasi penempatan elektroda, proses akuisisi sinyal EEG juga melibatkan tahapan konversi sinyal analog menjadi sinyal digital agar dapat diproses oleh sistem komputer. Aktivitas listrik otak yang direkam oleh elektroda pada awalnya berupa sinyal analog dengan perubahan tegangan yang berlangsung secara kontinu terhadap waktu. Untuk memungkinkan penyimpanan dan analisis secara digital, sinyal analog tersebut dikonversi menjadi serangkaian nilai numerik melalui proses digitalisasi menggunakan konverter analog-ke-digital (*analog-to-digital converter* atau ADC). Dalam proses ini, tegangan sinyal pada setiap kanal EEG diukur secara berkala dalam interval waktu singkat yang disebut *sampel* yang kemudian dapat disimpan dalam bentuk data digital [23].

Frekuensi pengambilan sampel atau *sampling frequency* menentukan seberapa sering tegangan sinyal diukur dalam satu detik. Resolusi temporal dari sinyal EEG yang direkam sangat bergantung pada frekuensi sampling yang digunakan. Berdasarkan prinsip teorema Nyquist, frekuensi sampling harus setidaknya dua kali lebih besar dari frekuensi tertinggi dari sinyal yang ingin direkam agar bentuk sinyal dapat direpresentasikan secara akurat. Dalam praktik klinis, aktivitas listrik otak yang relevan untuk interpretasi

EEG umumnya berada pada rentang frekuensi sekitar 0,1 hingga 70 Hz. Oleh karena itu, standar minimal frekuensi sampling yang direkomendasikan untuk perekaman EEG klinis adalah sekitar 128 Hz. Meskipun demikian, penggunaan frekuensi sampling yang lebih tinggi seringkali lebih direkomendasikan karena dapat memberikan resolusi temporal yang lebih baik serta menghasilkan representasi sinyal yang lebih akurat. Perangkat EEG modern umumnya mampu melakukan perekaman denganfrekuensi sampling yang lebih besar atau sama dengan 256 Hz [23].

2.1.3 Prapemrosesan Sinyal EEG

Dalam analisis sinyal EEG, aktivitas listrik otak yang terekam dapat dianalisis melalui beberapa pendekatan yang berbeda. Secara umum, analisis EEG dilakukan dalam dua domain utama, yaitu domain waktu (time domain) dan domain frekuensi (frequency domain). Analisis dalam domain waktu dilakukan dengan mengamati karakteristik sinyal terhadap waktu, seperti amplitudo puncak, latensi, serta perbedaan latensi antar komponen sinyal yang muncul pada kondisi tertentu. Sementara itu, analisis dalam domain frekuensi bertujuan untuk mengidentifikasi kandungan spektral sinyal dengan memeriksa distribusi energi atau daya pada berbagai rentang frekuensi menggunakan metode transformasi spektral, seperti *Fast Fourier Transform* (FFT) maupun teknik estimasi *Power Spectral Density* (PSD). Pola osilasi dan aktivitas otak pada rentang frekuensi tertentu dapat diidentifikasi melalui metode analisis tersebut [21].

Dalam praktik analisis spektral EEG, sinyal yang telah direkam biasanya terlebih dahulu dibagi ke dalam beberapa segmen waktu atau epoch sebelum dilakukan perhitungan spektrum. Setiap epoch kemudian dianalisis untuk memperoleh nilai *Power Spectral Density* (PSD) yang menggambarkan distribusi daya sinyal pada setiap frekuensi. Nilai PSD yang dihasilkan dari seluruh epoch seringkali dirata-ratakan untuk setiap kanal dan subjek sehingga diperoleh representasi spektral yang lebih stabil. Setelah distribusi spektrum sinyal diperoleh, analisis selanjutnya umumnya dilakukan dengan membagi rentang frekuensi EEG ke dalam beberapa pita frekuensi tertentu yang disebut (*frequency bands*). Pembagian ini bertujuan untuk mempermudah interpretasi aktivitas listrik otak karena setiap rentang frekuensi diketahui berkaitan dengan kondisi fisiologis dan kognitif yang berbeda. Secara umum, sinyal EEG diklasifikasikan ke dalam lima pita frekuensi

utama sebagai berikut:

- **Delta (±0,5–4 Hz)**: Pita frekuensi delta umumnya muncul secara dominan pada kondisi tidur nyenyak (*deep sleep*) atau keadaan tidak sadar. Aktivitas delta sering dikaitkan dengan proses pemulihan fisiologis dan regulasi fungsi tubuh selama fase tidur nyenyak.
- **Theta (±4–8 Hz)**: Aktivitas theta biasanya muncul pada kondisi mengantuk, tahap awal tidur, serta pada beberapa aktivitas mental tertentu seperti meditasi dan proses pembentukan memori. Gelombang theta juga sering dikaitkan dengan aktivitas pada sistem limbik dan hipokampus.
- **Alpha (±8–13 Hz)**: Gelombang alpha umumnya terlihat ketika individu berada dalam keadaan rileks namun tetap terjaga, terutama ketika mata tertutup dan rangsangan visual berkurang. Aktivitas alpha sering ditemukan pada wilayah oksipital dan dianggap berkaitan dengan kondisi relaksasi serta pengolahan informasi sensorik yang minimal.
- **Beta (±13–30 Hz)**: Pita frekuensi beta umumnya berkaitan dengan kondisi kewaspadaan, aktivitas kognitif aktif, pemecahan masalah, serta aktivitas motorik. Gelombang beta sering meningkat ketika individu sedang berpikir secara intens atau melakukan aktivitas yang memerlukan konsentrasi.
- **Gamma (>±30 Hz)**: Aktivitas gamma berada pada rentang frekuensi tinggi dan sering dikaitkan dengan proses kognitif tingkat lanjut, seperti perhatian, integrasi informasi sensorik, serta proses memori dan persepsi.

Melalui analisis distribusi daya pada setiap pita frekuensi tersebut, peneliti dapat mengidentifikasi pola aktivitas otak yang khas serta membandingkan karakteristik sinyal EEG pada berbagai kondisi fisiologis maupun gangguan neurologis tertentu. Oleh karena itu, representasi pita frekuensi EEG sering digunakan sebagai dasar dalam proses ekstraksi fitur pada analisis sinyal EEG, misalnya melalui perhitungan *band power*, estimasi *power spectral density* (PSD), maupun metode analisis spektral lainnya [20].

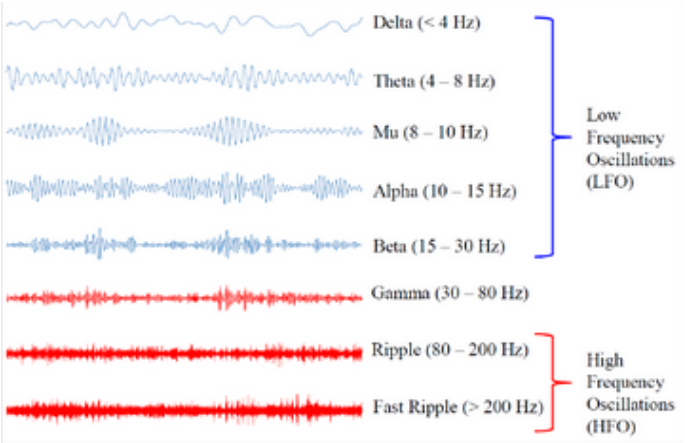

Gambar 2.2. Pita Frekuensi EEG pada Rentang Frekuensi Tinggi dan Rendah

Sebelum dilakukan proses ekstraksi fitur maupun klasifikasi, sinyal EEG umumnya melalui beberapa tahapan prapemrosesan (*preprocessing*). Tahapan ini bertujuan untuk meningkatkan kualitas sinyal dengan mengurangi komponen gangguan yang tidak relevan serta menyiapkan data agar lebih sesuai untuk proses analisis komputasional. Dalam praktik analisis EEG, berbagai teknik prapemrosesan telah dikembangkan untuk memperbaiki kualitas sinyal yang direkam. Secara umum, teknik-teknik tersebut meliputi penyaringan sinyal (*filtering*), penghapusan artefak (*artifact removal*), koreksi baseline (*baseline correction*), serta normalisasi atau standarisasi data. Setiap teknik memiliki tujuan yang berbeda dalam meningkatkan kualitas dan konsistensi data EEG sebelum dilakukan analisis lebih lanjut[20].

Salah satu tahap prapemrosesan yang paling umum diterapkan adalah penyaringan sinyal (*filtering*). Proses ini bertujuan untuk menghilangkan komponen frekuensi yang tidak berkaitan dengan aktivitas saraf serta mengurangi pengaruh gangguan dari lingkungan sekitar. Sinyal EEG yang direkam sering mengandung berbagai jenis gangguan, seperti interferensi listrik dari jaringan listrik, *DC offset*, yaitu kondisi di mana terdapat komponen tegangan konstan yang menyebabkan sinyal bergeser dari garis dasar (baseline), serta drift frekuensi rendah, yaitu kondisi di mana terjadi perubahan sinyal secara perlahan dalam jangka waktu tertentu akibat faktor seperti pergerakan elektroda atau perubahan impedansi kulit. Oleh karena itu, proses penyaringan biasanya dilakukan dengan membatasi rentang frekuensi sinyal yang dianalisis menggunakan filter tertentu. Dalam banyak penelitian, *band-pass filter* digunakan untuk mempertahankan komponen

frekuensi yang berkaitan dengan aktivitas otak, biasanya pada rentang sekitar 0,5 hingga 70 Hz. Selain itu, *notch filter* sering diterapkan pada frekuensi 50 Hz atau 60 Hz untuk menekan interferensi dari jaringan listrik. Filter tambahan seperti *high-pass filter* juga dapat digunakan untuk menghilangkan drift sinyal berfrekuensi sangat rendah, sedangkan *low-pass filter* digunakan untuk mereduksi komponen noise berfrekuensi tinggi. Perancangan filter perlu dilakukan secara hati-hati karena konfigurasi filter yang tidak tepat dapat menyebabkan distorsi sinyal atau pergeseran fase, terutama pada analisis yang berfokus pada karakteristik temporal sinyal [20].

Selain gangguan frekuensi, sinyal EEG juga sering terkontaminasi oleh artefak non-neural yang berasal dari aktivitas fisiologis maupun faktor eksternal. Artefak tersebut dapat disebabkan oleh kedipan mata, pergerakan bola mata, aktivitas otot wajah dan kepala, serta pergerakan tubuh selama proses perekaman. Keberadaan artefak dapat mempengaruhi kualitas sinyal dan berpotensi menurunkan akurasi analisis maupun kinerja sistem klasifikasi. Oleh karena itu, berbagai metode telah dikembangkan untuk mengidentifikasi dan mengurangi pengaruh artefak pada data EEG, seperti *Blind Source Separation* (BSS), yaitu pendekatan yang bertujuan memisahkan sinyal campuran menjadi beberapa sumber penyusun tanpa informasi awal mengenai sumber tersebut, *Independent Component Analysis* (ICA), yang memisahkan sinyal EEG menjadi beberapa komponen yang secara statistik independen sehingga komponen yang berkaitan dengan artefak dapat diidentifikasi dan dipisahkan dari komponen yang merepresentasikan aktivitas saraf, serta transformasi wavelet, yaitu metode yang memungkinkan analisis sinyal secara simultan pada domain waktu dan frekuensi sehingga memudahkan identifikasi artefak yang bersifat temporer maupun non-stasioner [20].

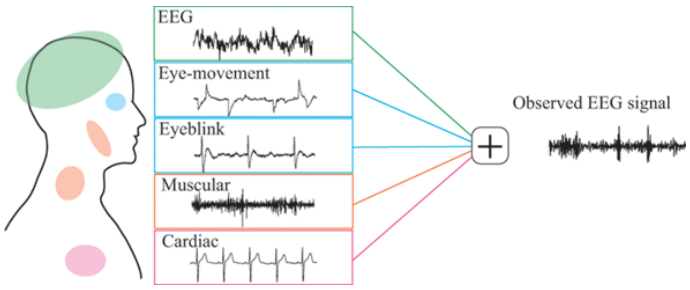

Gambar 2.3. Bentuk-Bentuk Artefak pada Sinyal EEG

Dalam analisis EEG berbasis *machine learning*, normalisasi atau standarisasi data sering diterapkan untuk mengurangi variasi antar kanal maupun antar subjek. Variasi tersebut dapat menyebabkan perbedaan skala pada fitur yang diekstraksi dari sinyal EEG sehingga dapat mempengaruhi proses *training* model. Oleh karena itu, proses normalisasi digunakan untuk menyesuaikan skala fitur agar berada dalam rentang yang lebih seragam. Salah satu metode yang umum digunakan adalah *z-score normalization*, yaitu dengan mengurangkan nilai rata-rata dan membaginya dengan standar deviasi sehingga data memiliki rata-rata nol dan variansi satu. Metode lain yang juga sering digunakan adalah *min-max normalization*, yang menskalakan nilai fitur ke dalam rentang tertentu, biasanya antara 0 dan 1. Penerapan normalisasi atau standarisasi membantu memastikan bahwa setiap fitur memiliki pengaruh yang lebih seimbang dalam proses *training* model serta dapat meningkatkan stabilitas dan kinerja algoritma klasifikasi yang digunakan [20].

2.1.4 Feature Selection mRMR

Dalam banyak aplikasi klasifikasi, identifikasi fitur-fitur yang paling merepresentasikan data observasi, atau yang dikenal sebagai proses *feature selection*, merupakan langkah yang krusial untuk meminimalkan kesalahan klasifikasi. Secara formal, diberikan suatu dataset D yang terdiri dari N sampel dan M fitur $X = \{x_i \mid i = 1, 2, \ldots, M\}$, serta variabel target klasifikasi c, sehingga permasalahan seleksi fitur adalah menentukan subset fitur berdimensi lebih rendah $R^m \subset R^M$ dengan $m < M$ yang mampu merepresentasikan karakteristik variabel target secara optimal.

Secara umum, tujuan *feature selection* dapat diformulasikan sebagai proses optimasi untuk mencari himpunan fitur $S \subseteq X$ dengan $|S| = m$ yang memaksimalkan ketergantungan terhadap kelas target. Ketergantungan ini seringkali diukur menggunakan *mutual information* $I(S;c)$, sehingga permasalahan dapat dinyatakan sebagai:

$$\max_{S \subseteq X, |S|=m} I(S;c) \tag{2.1}$$

Namun, penggunaan seluruh fitur yang tersedia tidak selalu menghasilkan performa yang optimal karena adanya redundansi informasi antar fitur. Fitur-fitur yang memiliki korelasi tinggi cenderung memberikan informasi yang berulang dan tidak menambah

kontribusi signifikan dalam proses klasifikasi. Oleh karena itu, diperlukan metode *feature selection* yang tidak hanya mempertimbangkan relevansi terhadap target, tetapi juga meminimalkan redundansi antar fitur[24].

Salah satu pendekatan yang banyak digunakan adalah *minimum Redundancy Maximum Relevance* (mRMR), yaitu teknik seleksi fitur berbasis teori informasi yang bertujuan untuk memilih subset fitur dengan tingkat relevansi yang tinggi terhadap variabel target, sekaligus memiliki redundansi yang rendah antar fitur. Relevansi umumnya diukur menggunakan *mutual information* antara fitur dan label kelas, sedangkan redundansi diukur berdasarkan keterkaitan antar fitur. Dengan demikian, mRMR menghasilkan subset fitur yang informatif dan tidak saling tumpang tindih dalam merepresentasikan informasi.

Pendekatan ini terbukti efektif dalam berbagai penelitian karena mampu mengurangi dimensi data tanpa mengorbankan informasi penting yang dibutuhkan untuk proses klasifikasi. Dengan menyeimbangkan antara relevansi dan redundansi, mRMR dapat meningkatkan efisiensi komputasi, serta meningkatkan kemampuan generalisasi model. Oleh karena itu, metode *minimum Redundancy Maximum Relevance* (mRMR) digunakan untuk menghilangkan fitur yang tidak relevan sekaligus memilih subset fitur yang optimal dan efisien [25][2x]

2.1.5 Machine Learning untuk Klasifikasi ASD Berdasarkan Sinyal EEG

Dalam *machine learning*, klasifikasi merupakan proses pemetaan data masukan ke dalam kategori atau kelas tertentu berdasarkan pola yang dipelajari dari data *training*. Pada analisis EEG, proses klasifikasi umumnya dilakukan dengan menggunakan fitur-fitur yang diekstraksi dari sinyal EEG, seperti fitur dalam domain waktu, domain frekuensi, maupun domain waktu-frekuensi. Fitur-fitur tersebut merepresentasikan karakteristik aktivitas otak yang relevan terhadap kondisi fisiologis atau kognitif tertentu. Melalui proses klasifikasi, model diharapkan mampu mengidentifikasi pola tersebut secara akurat pada data baru.

Sinyal EEG telah banyak digunakan dalam berbagai tugas klasifikasi untuk mengidentifikasi kondisi kognitif dan neurologis berdasarkan pola aktivitas otak, diantaranya dalam tugas motorik, deteksi kejang epilepsi, dan penerapan dalam sistem *brain–computer in-*

terface (BCI) [26]. Sinyal EEG juga dimanfaatkan untuk mengidentifikasi pola aktivitas otak yang berkaitan dengan *Autism Spectrum Disorder* (ASD), dimana perbedaan karakteristik aktivitas neurofisiologis antara individu ASD dan individu dengan perkembangan tipikal memungkinkan penggunaan EEG sebagai data dalam proses klasifikasi kondisi tersebut[10].

Salah satu pendekatan yang banyak digunakan dalam tugas klasifikasi adalah analisis dalam domain frekuensi. Analisis dalam domain frekuensi merupakan pendekatan yang umum digunakan dalam studi EEG untuk mengkaji gangguan *Autism Spectrum Disorder* (ASD), karena aktivitas otak dapat direpresentasikan sebagai pola osilasi yang terdistribusi pada pita frekuensi tertentu. Pita frekuensi EEG diketahui memiliki keterkaitan erat dengan berbagai proses kognitif dan fungsi neural, sehingga analisis spektral menjadi pendekatan yang informatif dalam mengungkap karakteristik aktivitas neurofisiologis. Pendekatan ini juga memungkinkan pengukuran distribusi daya sinyal pada setiap pita frekuensi, sehingga aktivitas neural dapat dianalisis secara lebih terstruktur.

Dalam konteks ASD, studi EEG berbasis analisis spektral menunjukkan adanya pola abnormalitas yang relatif konsisten pada berbagai pita frekuensi. Individu dengan ASD cenderung menunjukkan peningkatan daya pada pita frekuensi rendah (delta dan theta) serta frekuensi tinggi (beta dan gamma), disertai dengan penurunan daya pada pita frekuensi menengah (alpha). Pola ini membentuk karakteristik profil spektral berbentuk U (*U-shaped profile*) yang mencerminkan adanya gangguan dalam mekanisme neurofisiologis yang mendasari aktivitas otak. Oleh karena itu, representasi dalam domain frekuensi menjadi relevan dalam analisis dan klasifikasi ASD, karena mampu menyoroti perbedaan distribusi aktivitas neural yang tidak mudah diamati dalam domain waktu [26].

Berdasarkan representasi fitur yang diperoleh, proses klasifikasi selanjutnya dilakukan menggunakan algoritma *machine learning* untuk membangun model prediksi. Berbagai metode klasifikasi, seperti *support vector machine* (SVM), *k-nearest neighbor* (KNN), dan *random forest*, telah banyak digunakan dalam analisis sinyal EEG dan menunjukkan kinerja yang baik dalam mengidentifikasi pola aktivitas neural yang kompleks[10]. Meskipun pendekatan *deep learning* juga berkembang pesat dalam beberapa tahun terakhir, metode *machine learning* konvensional tetap menjadi pilihan yang efektif, khususnya pada kondisi data yang terbatas dan kebutuhan interpretabilitas model[27].

Lebih lanjut, pendekatan berbasis algoritma *ensemble* seperti *Extreme Gradient Boosting* (XGBoost) telah menunjukkan performa yang handal dalam tugas klasifikasi sinyal EEG, terutama pada skenario yang memanfaatkan representasi fitur dalam domain frekuensi. Berdasarkan penelitian yang telah ada[1x], penerapan algoritma XGBoost dalam klasifikasi ASD menghasilkan performa yang cukup handal, dengan kemampuan dalam menangkap hubungan non-linear serta meningkatkan akurasi klasifikasi melalui mekanisme *boosting* secara iteratif untuk menghasilkan model yang lebih kuat.

2.1.6 Augmentasi Data EEG

Dalam penelitian berbasis *machine learning*, ketersediaan data dalam jumlah yang memadai merupakan faktor penting dalam proses *training* model. Namun demikian, pada analisis sinyal EEG, pengumpulan dataset berskala besar seringkali menjadi tantangan. Proses perekaman EEG cenderung mahal dan memakan waktu, serta menghasilkan data dengan variabilitas yang tinggi antar individu maupun antar sesi perekaman. Variasi ini dapat disebabkan oleh berbagai faktor, seperti perbedaan konfigurasi perangkat EEG, jumlah kanal yang digunakan, kondisi eksperimen, serta keberadaan artefak yang berasal dari aktivitas non-neural seperti gerakan otot, kedipan mata, maupun gangguan lingkungan. Variabilitas tersebut menyebabkan distribusi data EEG menjadi kompleks dan seringkali tidak konsisten antar dataset [14].

Keterbatasan jumlah data serta kompleksitas karakteristik sinyal EEG dapat menyebabkan model *machine learning* mengalami masalah *overfitting*, di mana model mampu mempelajari pola yang sangat spesifik terhadap data *training* namun memiliki kemampuan generalisasi yang rendah terhadap data baru. Oleh karena itu, berbagai penelitian mengusulkan penggunaan teknik *data augmentation* untuk meningkatkan jumlah dan keragaman data *training* tanpa harus melakukan perekaman sinyal EEG tambahan. Secara umum, *data augmentation* bertujuan untuk menghasilkan sampel data baru yang memiliki karakteristik statistik yang serupa dengan data asli, sehingga model *machine learning* dapat mempelajari representasi pola yang lebih stabil [17]. Untuk sinyal EEG, teknik *data augmentation* dapat dilakukan melalui berbagai pendekatan. Beberapa metode sederhana meliputi manipulasi sinyal dalam domain waktu atau frekuensi, seperti *noise injection*, *time shifting*, maupun transformasi spektral. Pendekatan-pendekatan ini umumnya

dilakukan dengan mentransformasikan data asli untuk menghasilkan sampel baru yang memiliki distribusi yang serupa dengan data awal.

Namun demikian, metode augmentasi konvensional memiliki keterbatasan ketika diterapkan pada sinyal EEG. Penambahan *noise* pada sinyal EEG berpotensi mengubah amplitudo serta distribusi data asli, sehingga dapat mengganggu representasi karakteristik sinyal. Selain itu, teknik seperti *time shifting* juga dapat mengubah informasi temporal yang penting, terutama ketika pola waktu memiliki keterkaitan langsung dengan aktivitas fisiologis tertentu. Beberapa penelitian juga menunjukkan bahwa augmentasi sederhana tidak selalu meningkatkan performa model klasifikasi, bahkan dalam beberapa kasus dapat menyebabkan penurunan kinerja model. Oleh karena itu, pendekatan berbasis model generatif mulai banyak dikembangkan untuk menghasilkan data EEG sintetis yang lebih mampu mempertahankan karakteristik kompleks sinyal, termasuk dependensi spasial dan temporal pada data multikanal, sehingga menghasilkan representasi data yang lebih realistis dan informatif [28].

Model generatif berbasis *deep learning*, seperti *Generative Adversarial Networks* (GAN) dan *Variational Autoencoders* (VAE), telah banyak digunakan untuk menghasilkan sinyal EEG sintetis yang mengikuti distribusi statistik dari data asli. Pendekatan ini memungkinkan model untuk mempelajari struktur laten dari sinyal EEG dan kemudian menghasilkan sampel baru yang memiliki karakteristik yang serupa dengan data *training*. Beberapa penelitian menunjukkan bahwa penggunaan data sintetis yang dihasilkan oleh model generatif dapat meningkatkan performa model klasifikasi EEG, terutama pada kondisi di mana jumlah data *training* terbatas [28].

Dibandingkan dengan model generatif lainnya, *Variational Autoencoder* (VAE) merupakan model generatif probabilistik yang mampu memodelkan distribusi laten data dan menghasilkan sampel secara terkontrol. Pendekatan ini memungkinkan pembelajaran representasi laten yang kontinu dan terstruktur, sehingga sesuai untuk menangani data berdimensi tinggi seperti sinyal EEG. Dalam konteks EEG, penggunaan VAE didorong oleh kemampuannya dalam memodelkan distribusi sinyal neural yang kompleks, sehingga mampu merepresentasikan karakteristik statistik data secara lebih komprehensif. Dengan demikian, VAE menjadi pendekatan yang relevan untuk menghasilkan data sintetis yang mampu mempertahankan karakteristik sinyal EEG, sehingga dapat dimanfaatkan untuk

meningkatkan kualitas dan keragaman data *training* dalam proses klasifikasi[29].

2.1.7 Variational Auto Encoder

Variational Autoencoder (VAE) merupakan salah satu model generatif berbasis *deep learning* yang banyak digunakan untuk mempelajari representasi laten dari suatu dataset dan menghasilkan sampel data baru yang memiliki karakteristik statistik yang serupa dengan data asli. Model ini merupakan pengembangan dari *autoencoder* tradisional dengan pendekatan probabilistik, di mana representasi laten dimodelkan sebagai distribusi probabilitas sehingga memungkinkan proses generasi data baru melalui ruang laten (*latent space*) yang dipelajari oleh model, berbeda dengan *autoencoder* konvensional yang berfokus pada kompresi dan rekonstruksi data [30].

Secara umum, arsitektur VAE terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*. Bagian *encoder* bertugas memetakan data masukan x ke dalam representasi laten z yang memiliki dimensi lebih rendah. Namun berbeda dengan *autoencoder* biasa yang menghasilkan representasi deterministik, VAE memodelkan representasi laten tersebut sebagai distribusi probabilistik, yang mengikuti distribusi normal multivariat. Oleh karena itu, *encoder* tidak hanya menghasilkan satu vektor representasi laten, tetapi juga dua parameter distribusi, yaitu nilai rata-rata (μ) dan variansi (σ), yang mendeskripsikan distribusi probabilistik dari variabel laten tersebut [30].

Setelah distribusi laten diperoleh, proses berikutnya adalah melakukan *sampling* dari distribusi tersebut untuk menghasilkan vektor laten z yang kemudian diberikan sebagai masukan kepada bagian *decoder*. Decoder berfungsi untuk merekonstruksi kembali data dari representasi laten tersebut sehingga menghasilkan data keluaran $\hat{x}$ yang diharapkan memiliki karakteristik yang serupa dengan data asli x. Dengan mekanisme ini, model tidak hanya mempelajari bagaimana merekonstruksi data, tetapi juga mempelajari struktur distribusi laten dari dataset yang digunakan[30].

Proses *training* VAE dilakukan dengan memaksimalkan fungsi objektif yang dikenal sebagai *Evidence Lower Bound* (ELBO). Fungsi ini terdiri dari dua komponen utama, yaitu *reconstruction loss* dan *regularization loss*. *Reconstruction loss* mengukur sejauh mana data hasil rekonstruksi $\hat{x}$ mendekati data asli x, sehingga model terdorong untuk mempertahankan informasi penting dari data masukan. Sementara itu, komponen regu-

larisasi diukur menggunakan *Kullback–Leibler Divergence* (KL Divergence), yang bertujuan untuk memastikan bahwa distribusi laten yang dipelajari oleh model tetap mendekati distribusi yang telah ditentukan sebelumnya, biasanya berupa distribusi normal standar.

Secara matematis, fungsi objektif VAE dapat dinyatakan sebagai berikut:

$$\mathcal{L}(\theta,\phi;x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)] - D_{KL}(q_\phi(z|x) \parallel p(z))$$

di mana $q_\phi(z|x)$ merepresentasikan distribusi laten yang dihasilkan oleh *encoder*, $p_\theta(x|z)$ merepresentasikan proses rekonstruksi oleh *decoder*, dan $p(z)$ merupakan distribusi prior pada ruang laten. Komponen pertama pada persamaan tersebut merepresentasikan kualitas rekonstruksi data, sedangkan komponen kedua berfungsi sebagai regularisasi untuk menjaga struktur distribusi laten[30].

Dalam implementasinya, proses *sampling* pada ruang laten tidak dapat dilakukan secara langsung dalam proses *training* menggunakan metode *backpropagation*. Oleh karena itu, VAE menggunakan teknik yang dikenal sebagai *reparameterization trick*. Melalui teknik ini, variabel laten z dinyatakan sebagai:

$$z = \mu + \sigma \cdot \varepsilon$$

di mana ε merupakan variabel acak yang diambil dari distribusi normal standar $\mathcal{N}(0,1)$. Dengan pendekatan ini, proses *sampling* dapat ditransformasikan menjadi operasi deterministik yang memungkinkan gradien tetap dapat dihitung selama proses *training* neural network [30].

Kemampuan VAE dalam mempelajari representasi laten dari data menjadikannya sangat sesuai untuk digunakan sebagai model generatif dalam berbagai aplikasi, termasuk augmentasi data. Dengan mempelajari distribusi laten dari dataset *training*, model dapat menghasilkan sampel sintetis baru yang memiliki karakteristik statistik yang serupa dengan data asli. Hal ini sangat bermanfaat pada dataset yang memiliki jumlah sampel terbatas, seperti pada penelitian berbasis sinyal EEG, di mana proses akuisisi data seringkali memerlukan prosedur eksperimen yang kompleks.

Dalam kasus analisis sinyal EEG, penggunaan VAE memungkinkan model untuk mempelajari pola spasial dan temporal dari sinyal EEG secara lebih komprehensif. Sete-

lah model dilatih menggunakan dataset EEG yang tersedia, representasi laten yang dihasilkan dapat digunakan untuk menghasilkan sinyal EEG sintetis yang tetap mempertahankan karakteristik distribusi dari data asli. Model VAE menjadi salah satu pendekatan yang banyak digunakan dalam penelitian augmentasi data EEG untuk meningkatkan performa sistem klasifikasi berbasis *machine learning*[17].

2.2 Penelitian Terdahulu

Selain membahas konsep-konsep dasar yang relevan dengan penelitian ini, penting juga untuk meninjau beberapa penelitian terdahulu yang berkaitan dengan klasifikasi Autism Spectrum Disorder (ASD) berbasis sinyal EEG. Seiring dengan berkembangnya pendekatan machine learning dalam analisis sinyal EEG, berbagai metode telah diusulkan untuk mengidentifikasi pola aktivitas neural yang berkaitan dengan ASD. Salah satu pendekatan yang cukup menonjol adalah penggunaan kombinasi teknik seleksi fitur dan algoritma klasifikasi berbasis ensemble learning.

Selain membahas pendekatan klasifikasi berbasis EEG, perlu juga dilakukan tinjauan terhadap penerapan augmentasi data dalam penelitian terdahulu sebagai upaya mengatasi keterbatasan jumlah data. Sejumlah penelitian menunjukkan bahwa augmentasi data dapat meningkatkan performa model klasifikasi dengan memperkaya variasi data pelatihan serta mengurangi risiko *overfitting*. Namun, efektivitas teknik augmentasi sangat bergantung pada metode yang digunakan dan kesesuaiannya dengan karakteristik sinyal EEG. Pendekatan berbasis *Variational Autoencoder* (VAE) dinilai sesuai karena kemampuannya dalam memodelkan distribusi data dan menghasilkan representasi laten yang mampu mempertahankan karakteristik kompleks sinyal EEG.

Kedua pendekatan ini menjadi landasan penting dalam pengembangan metode augmentasi data yang lebih efektif untuk meningkatkan performa model klasifikasi EEG.

2.2.1 Klasifikasi ASD Berbasis EEG Menggunakan mRMR dan XGBoost

Pada draft penelitian oleh [XX], dilakukan analisis klasifikasi *Autism Spectrum Disorder* (ASD) menggunakan sinyal EEG dengan memanfaatkan teknik seleksi fitur dan algoritma *machine learning*. Selain membangun model klasifikasi, penelitian ini juga mengem-

bangkan model deskriptif untuk mengidentifikasi dan memahami karakteristik pola aktivitas neural yang membedakan individu dengan ASD dan individu dengan perkembangan tipikal. Penelitian ini berfokus pada pemanfaatan fitur berbasis domain frekuensi untuk merepresentasikan karakteristik aktivitas neural yang relevan dengan kondisi ASD, serta menekankan pentingnya pemilihan fitur yang optimal untuk meningkatkan performa dan interpretabilitas model klasifikasi.

Penelitian menggunakan pendekatan seleksi fitur berbasis *minimum Redundancy Maximum Relevance* (mRMR) untuk mengidentifikasi fitur yang paling informatif sekaligus meminimalkan redundansi antar fitur. Sebelum proses seleksi fitur, sinyal EEG melalui tahap prapemrosesan yang meliputi segmentasi, (*filtering*), serta dekomposisi ke dalam pita frekuensi untuk menghasilkan representasi fitur yang lebih stabil dan terstruktur. Fitur yang telah diseleksi kemudian digunakan sebagai masukan bagi model klasifikasi berbasis *ensemble*, yaitu XGBoost, di mana pendekatan ini dibandingkan dengan metode dasar berbasis *Discrete Wavelet Transform* (DWT), ekstraksi fitur *Shannon entropy*, dan klasifikasi menggunakan *Artificial Neural Network* (ANN).

Hasil eksperimen menunjukkan bahwa pendekatan yang diusulkan mampu menghasilkan performa klasifikasi yang cukup baik dalam membedakan individu dengan ASD dan individu dengan perkembangan tipikal. Penggunaan mRMR terbukti dapat meningkatkan kualitas fitur yang digunakan, sementara XGBoost memberikan kemampuan klasifikasi yang robust terhadap kompleksitas data EEG. Temuan ini menunjukkan bahwa kombinasi seleksi fitur dan algoritma *ensemble* memiliki potensi yang signifikan dalam meningkatkan akurasi serta kemampuan generalisasi model dalam klasifikasi ASD berbasis sinyal EEG.

2.2.2 Augmentasi Data pada Sinyal EEG Menggunakan Variational Autoencoder

Pada penelitian referensi [XX], diusulkan pendekatan augmentasi data untuk sinyal EEG menggunakan model generatif berbasis *Variational Autoencoder* (VAE). Implementasi yang digunakan dalam penelitian ini mengadaptasi metode yang diperkenalkan dalam studi referensi [XX], yang memanfaatkan VAE untuk mempelajari distribusi laten dari sinyal EEG dan menghasilkan sampel sintetis yang menyerupai data asli. Dataset yang digunakan berasal dari BCI Competition IV Dataset 2a, yang terdiri dari data EEG 22

kanal dari 9 subjek dengan empat kelas tugas *motor imagery*, sehingga digunakan dalam tugas klasifikasi *motor imagery*. Dalam implementasinya, data EEG diolah dalam bentuk yang sesuai untuk pemanfaatan arsitektur *2D Convolutional Neural Network* (2D CNN), sehingga direpresentasikan dalam bentuk matriks dua dimensi.

Dari sisi arsitektur, model yang digunakan terdiri dari dua komponen utama, yaitu *encoder* dan *decoder*, yang dilatih secara end-to-end untuk merekonstruksi sinyal EEG melalui representasi laten berdimensi rendah. *Encoder* memetakan sinyal EEG ke dalam distribusi probabilistik yang direpresentasikan oleh parameter *mean* dan variansi, sementara *decoder* menghasilkan kembali sinyal berdasarkan sampel dari ruang laten tersebut melalui mekanisme *reparameterization*. Selain itu, dalam tahap evaluasi, digunakan arsitektur *EEGNet* sebagai model klasifikasi berbasis CNN yang dirancang khusus untuk sinyal EEG. Dua model EEGNet dilatih secara terpisah menggunakan data asli dan data hasil augmentasi untuk membandingkan pengaruh penggunaan data sintetis terhadap performa klasifikasi.

Hasil penelitian menunjukkan bahwa penggunaan data sintetis yang dihasilkan oleh VAE mampu meningkatkan performa model klasifikasi *motor imagery* secara signifikan. Model yang dilatih menggunakan data asli memperoleh akurasi sebesar 0.73, sedangkan model yang dilatih menggunakan data hasil augmentasi mencapai akurasi sebesar 0.88. Peningkatan ini juga tercermin pada metrik *precision*, *recall*, dan *f1-score* pada sebagian besar kelas, yang menunjukkan bahwa data sintetis mampu memperkaya variasi data *training* dan membantu model dalam menangkap pola yang lebih representatif. Temuan ini menunjukkan bahwa pendekatan generatif berbasis VAE memiliki potensi yang signifikan dalam meningkatkan kinerja sistem klasifikasi berbasis sinyal EEG, yang dalam kasus ini berfokus pada klasifikasi *motor imagery*.

2.2.3 Dataset yang Digunakan

Dataset yang digunakan dalam penelitian ini berupa sinyal *electroencephalogram* (EEG) yang diperoleh dari subjek dengan dan tanpa diagnosis *Autism Spectrum Disorder* (ASD). Data ini dipilih karena mampu merepresentasikan aktivitas neural yang berkaitan dengan kondisi ASD, sehingga relevan untuk digunakan dalam pengembangan dan evaluasi model klasifikasi berbasis *machine learning*.

Data EEG dikumpulkan dari sepuluh partisipan yang terdiri dari lima anak dengan diagnosis ASD berusia 6–10 tahun serta lima subjek kontrol sehat berusia di atas 17 tahun. Proses akuisisi dilakukan menggunakan 16 kanal EEG yang ditempatkan berdasarkan sistem standar *International 10–20 System*, yaitu pada posisi Fp1, Fp2, F3, F4, F7, F8, C3, C4, T3, T4, T5, T6, P3, P4, O1, dan O2. Perekaman dilakukan dalam kondisi terkontrol untuk memastikan kenyamanan partisipan, pada rentang waktu 09.00–12.00 demi tetap menjaga subjek berada dalam kondisi sadar dan rileks. Setiap sesi perekaman berlangsung sekitar 15 menit untuk delapan kanal dan diulang hingga mencakup seluruh 16 kanal, sehingga total durasi perekaman mencapai sekitar 40 menit, dengan tambahan waktu sekitar 10 menit untuk pemasangan elektroda.

Akuisisi data dilakukan menggunakan perangkat *OpenBCI Cyton Biosensing Board*, yang mendukung perekaman hingga delapan kanal EEG per sesi. Sistem ini dilengkapi dengan *USB dongle* untuk transmisi data secara nirkabel ke komputer, serta menggunakan baterai 3.7V sebagai sumber daya. Elektroda ditempatkan menggunakan *EEG cap* dengan bantuan gel konduktif untuk meningkatkan kualitas kontak dan meminimalkan gangguan sinyal. Perangkat ini memiliki rasio *signal-to-noise ratio* (SNR) sebesar 121 dB serta resolusi tegangan sebesar 0.298 μV, sehingga mampu merekam sinyal EEG dengan tingkat presisi yang tinggi. Data yang diperoleh divisualisasikan dan direkam menggunakan perangkat lunak *OpenBCI GUI* serta *library BrainFlow* untuk keperluan pemrosesan lebih lanjut.

Lingkungan perekaman juga dirancang untuk meminimalkan gangguan eksternal, dengan konfigurasi ruangan yang mengarahkan partisipan menghadap dinding kosong guna mengurangi distraksi visual. Setelah proses akuisisi, sinyal EEG melalui tahap prapemrosesan untuk meningkatkan kualitas data. Dalam penelitian terkait [XX], beberapa metode seperti *Butterworth filtering*, *Discrete Wavelet Transform* (DWT), dan *Independent Component Analysis* (ICA) digunakan untuk mengurangi artefak dan meningkatkan kejernihan sinyal. Di antara metode tersebut, ICA menunjukkan performa yang paling efektif dalam meningkatkan kualitas sinyal, khususnya dalam meningkatkan nilai SNR serta mempertahankan karakteristik penting sinyal EEG yang relevan untuk analisis lebih lanjut.

Selanjutnya, sinyal EEG yang telah diproses digunakan dalam tahap segmentasi dan

ekstraksi fitur, khususnya melalui dekomposisi ke dalam pita frekuensi utama (delta, theta, alpha, beta, dan gamma). Karakteristik dataset yang memiliki dimensi fitur tinggi serta jumlah sampel yang relatif terbatas menjadikannya menantang dalam proses pemodelan, sehingga sesuai untuk mengevaluasi kinerja metode klasifikasi serta efektivitas pendekatan augmentasi data yang digunakan dalam penelitian ini.

2.3 Fokus pada Celah Penelitian

Berdasarkan tinjauan pustaka yang telah dilakukan, terdapat celah penelitian dalam pemanfaatan teknik augmentasi data berbasis *Variational Autoencoder* (VAE) untuk analisis sinyal EEG. Beberapa penelitian sebelumnya telah menerapkan VAE untuk menghasilkan data EEG sintetis, khususnya dalam konteks tugas klasifikasi berbasis *motor imagery* menggunakan arsitektur seperti *2D Convolutional Neural Network* (CNN). Pendekatan tersebut menunjukkan bahwa data sintetis mampu meningkatkan performa model klasifikasi dengan memperkaya variasi data *training*. Meskipun demikian, fokus penelitian masih terbatas pada representasi sinyal dalam domain waktu atau spasial, tanpa mengeksplorasi secara mendalam karakteristik sinyal dalam domain frekuensi.

Di sisi lain, analisis berbasis domain frekuensi memiliki peran penting dalam studi EEG, terutama dalam mengidentifikasi pola osilasi neural yang berkaitan dengan kondisi neurologis seperti *Autism Spectrum Disorder* (ASD). Pemanfaatan data sintetis berbasis VAE pada representasi fitur frekuensi masih relatif terbatas, dan belum banyak dilakukan pengkajian terkait pengaruh augmentasi sinyal EEG terhadap kualitas fitur dan performa model klasifikasi berbasis *machine learning* konvensional.

Oleh karena itu, penelitian ini mengusulkan pendekatan yang mengintegrasikan teknik augmentasi data berbasis VAE dengan ekstraksi fitur domain frekuensi, serta memanfaatkan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) dan algoritma klasifikasi *XGBoost*. Pendekatan ini bertujuan untuk mengeksplorasi bagaimana data sintetis yang dihasilkan pada domain frekuensi dapat meningkatkan kualitas representasi fitur serta performa klasifikasi ASD. Dengan mengisi celah ini, diharapkan penelitian ini dapat memberikan kontribusi dalam pengembangan metode klasifikasi EEG yang lebih robust dan akurat, khususnya pada kondisi dataset yang terbatas.

BAB 3
PERANCANGAN DAN IMPLEMENTASI SISTEM DAN TEMPLAT

Bab ini menyajikan metodologi penelitian serta perancangan teknis yang dilakukan untuk mengembangkan dan mengevaluasi sistem klasifikasi *Autism Spectrum Disorder* (ASD) berbasis sinyal EEG. Sistem yang dikembangkan dalam penelitian ini difokuskan sebagai sebuah lingkungan uji (*testbed*) yang terkontrol untuk mengevaluasi efektivitas pendekatan yang diusulkan, khususnya integrasi antara augmentasi data berbasis *Variational Autoencoder* (VAE), seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR), dan algoritma klasifikasi *XGBoost*.

Pembahasan pada bab ini diawali dengan Analisis Kebutuhan yang bertujuan untuk mendefinisikan batasan masalah serta spesifikasi sistem. Fokus utama bab ini terletak pada Perancangan Arsitektur dan Alur Kerja Sistem, yang menguraikan tahapan pengolahan sinyal EEG secara menyeluruh. Proses dimulai dari tahap prapemrosesan sinyal, dilanjutkan dengan dekomposisi frekuensi dan ekstraksi fitur statistik, kemudian dilakukan augmentasi data menggunakan model VAE. Model VAE yang digunakan diimplementasikan dalam bentuk *encoder-decoder neural network* yang dilatih untuk merekonstruksi sinyal EEG melalui representasi laten, sehingga mampu menghasilkan data sintetis yang mempertahankan karakteristik distribusi data asli. Data hasil augmentasi selanjutnya digabungkan dengan data asli sebelum dilakukan seleksi fitur menggunakan mRMR dan klasifikasi menggunakan XGBoost. Alur ini divisualisasikan menggunakan diagram arsitektur dan flowchart untuk memberikan gambaran sistem secara komprehensif.

Selanjutnya, bagian Detail Implementasi dan Teknologi menjelaskan realisasi arsitektur ke dalam bentuk implementasi kode. Model VAE dikembangkan menggunakan pustaka *deep learning* (seperti TensorFlow atau PyTorch) dengan mekanisme *reparameterization trick* untuk memungkinkan proses *training* berbasis *backpropagation*. Selain itu, digunakan pustaka seperti *NumPy* dan *SciPy* untuk pengolahan sinyal, serta *scikit-learn* dan *XGBoost* untuk proses seleksi fitur dan klasifikasi. Bab ini kemudian ditutup dengan Perancangan Infrastruktur yang memaparkan konfigurasi lingkungan komputasi, dependensi perangkat lunak, serta spesifikasi perangkat keras yang digunakan dalam proses

training dan evaluasi model.

3.1 Analisis Kebutuhan Sistem

Sebelum memulai perancangan arsitektur, tahap pertama yang perlu dilakukan adalah menganalisis kebutuhan sistem. Untuk menjaga fokus penelitian dan tidak memperluas pembahasan, analisis kebutuhan ini difokuskan pada kebutuhan fungsional yang berkaitan dengan perancangan arsitektur sistem serta tujuan utama penelitian. Berbeda dengan penelitian yang berfokus pada pengembangan model klasifikasi, penelitian ini menitikberatkan pada integrasi proses augmentasi data ke dalam *pipeline* klasifikasi yang telah ada.

Secara khusus, sistem yang dirancang harus mampu mengakomodasi alur pemrosesan data EEG secara terstruktur, mulai dari tahap preprocessing hingga sintesis data baru menggunakan model generatif, serta memastikan bahwa data yang dihasilkan tetap kompatibel dengan *pipeline* klasifikasi. Oleh karena itu, kebutuhan fungsional yang didefinisikan berfokus pada integrasi antar komponen dalam *pipeline*, bukan pada perancangan model klasifikasi itu sendiri.

Berdasarkan penjabaran tersebut, didefinisikan beberapa kebutuhan fungsional utama yang harus dipenuhi dalam perancangan arsitektur sistem pada penelitian ini:

1. **Arsitektur *pipeline* Augmentasi EEG**

   Sistem harus dirancang sebagai *pipeline* terstruktur yang mencakup tahapan preprocessing sinyal EEG, dekomposisi frekuensi, dan ekstraksi fitur sebagai representasi data. Tahapan ini harus mampu menghasilkan representasi data yang terstandarisasi dan siap digunakan sebagai masukan bagi modul augmentasi, sehingga proses *training* distribusi data dapat dilakukan secara optimal.

2. **Karakteristik dan Mekanisme Model Generatif (VAE)**

   Keseluruhan sistem harus mengimplementasikan modul augmentasi berbasis model generatif berupa *Variational Autoencoder* (VAE) yang mampu mempelajari distribusi laten dari data EEG. Model ini harus mampu menghasilkan sampel data sintetik baru yang diharapkan tetap mempertahankan karakteristik penting dari data

asli. Modul augmentasi ini harus dirancang secara modular sehingga dapat diintegrasikan maupun dilepas dari *pipeline* klasifikasi tanpa memerlukan perubahan signifikan pada struktur sistem utama.

3. **Kesesuaian dan Konsistensi dengan *pipeline* Klasifikasi**
   Sistem dan proses augmentasi harus mempertahankan kompatibilitas dengan *pipeline* klasifikasi yang digunakan, yaitu seleksi fitur berbasis *minimum Redundancy Maximum Relevance* (mRMR) dan model klasifikasi XGBoost. Data asli dan data sintetis harus memiliki format serta representasi fitur yang konsisten setelah melalui tahapan preprocessing dan ekstraksi fitur, sehingga keduanya dapat diproses secara langsung tanpa memerlukan perubahan pada struktur arsitektur utama.

3.2 Perancangan Arsitektur Sistem

Setelah kebutuhan fungsional sistem diuraikan, tahap selanjutnya adalah merancang arsitektur sistem sebagai representasi konseptual dari alur pemrosesan data yang akan diimplementasikan. Perancangan ini bertujuan untuk menggambarkan integrasi antar komponen dalam *pipeline*, khususnya dalam menggabungkan proses augmentasi data berbasis *Variational Autoencoder* (VAE) dengan *pipeline* klasifikasi yang telah ditentukan.

Secara umum, arsitektur sistem yang dirancang mencakup keseluruhan alur pemrosesan sinyal EEG, mulai dari tahap prapemrosesan hingga klasifikasi. Untuk mempermudah pemahaman, sistem dibagi menjadi tiga komponen utama, yaitu tahap prapemrosesan dan ekstraksi fitur, model augmentasi data berbasis VAE, serta tahap klasifikasi.

Pendekatan yang digunakan dalam penelitian ini mengadaptasi model *EEG Data Augmentation using Variational Autoencoder* [XX], yaitu suatu model generatif berbasis VAE yang dirancang untuk menghasilkan data EEG sintetis yang menyerupai karakteristik data asli. Model ini pada dasarnya terdiri dari komponen *encoder* dan *decoder* yang dilatih secara end-to-end untuk merekonstruksi sinyal melalui representasi laten probabilistik.

Dalam implementasinya, arsitektur awal model tersebut mengalami penyesuaian untuk menyesuaikan dengan kebutuhan penelitian. Secara khusus, dimensi data dan struktur jaringan dimodifikasi dari pendekatan awal menjadi berbasis *1D Convolutional Neural Network* (1D CNN). Ketetapan didasarkan pada penelitian referensi [XX] yang mem-

proses sinyal EEG sebagai kanal terpisah dalam domain satu dimensi, sehingga lebih sesuai dengan karakteristik data serta kompatibel dengan *pipeline* klasifikasi yang digunakan. Dengan demikian, arsitektur yang diusulkan tetap mempertahankan prinsip dasar VAE, namun diadaptasi agar selaras dengan representasi data dan kebutuhan integrasi sistem dalam penelitian ini.

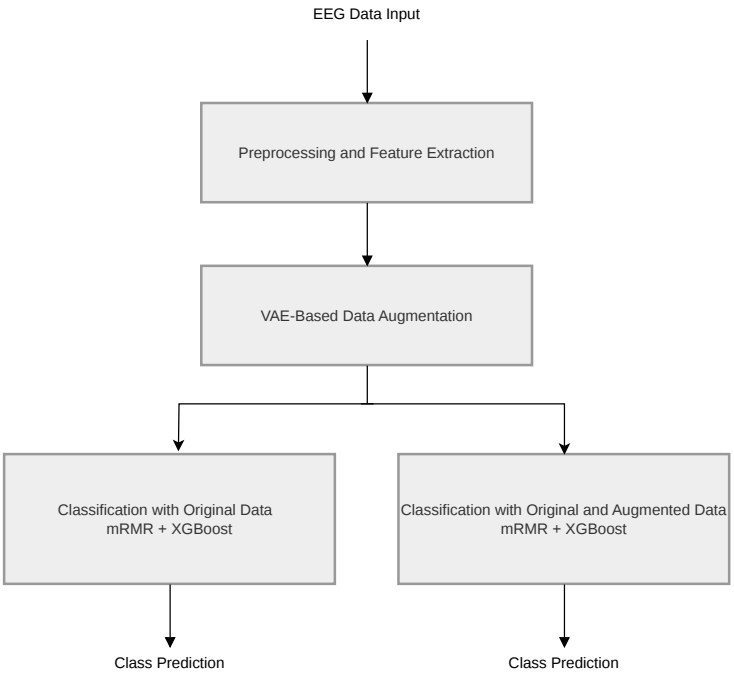

Gambar 3.1. Diagram aliran data pada sistem

Gambar 3.1 menunjukkan alur pemrosesan data pada sistem yang dikembangkan dalam penelitian ini. Proses dimulai dari data masukan berupa sinyal EEG yang terlebih dahulu melalui tahap pra-pemrosesan dan ekstraksi fitur untuk meningkatkan kualitas sinyal serta memperoleh representasi yang relevan. Data hasil pra-pemrosesan tersebut kemudian diproses pada tahap augmentasi menggunakan model *Variational Autoencoder* (VAE), yang bertujuan untuk menghasilkan data sintetis yang memiliki karakteristik serupa dengan data asli.

Selanjutnya, hasil dari tahap tersebut digunakan dalam dua skenario klasifikasi yang berbeda. Pada skenario pertama, proses klasifikasi dilakukan hanya menggunakan data asli, sedangkan pada skenario kedua, proses klasifikasi memanfaatkan kombinasi data

asli dan data hasil augmentasi. Kedua skenario tersebut menggunakan metode seleksi fitur *minimum Redundancy Maximum Relevance* (mRMR) serta algoritma klasifikasi XGBoost berdasarkan referensi penelitian sebelumnya [xx]. Perbandingan antara kedua skenario ini bertujuan untuk mengevaluasi pengaruh penggunaan data sintetis terhadap performa model klasifikasi yang dihasilkan.

3.2.1 Pra-Pemrosesan Dataset

Tahap pra-pemrosesan data merupakan komponen penting dalam pengolahan sinyal EEG untuk memastikan bahwa data yang digunakan berada dalam kondisi yang representatif dan siap diproses oleh model. Pada penelitian ini, tahap pra-pemrosesan bertujuan untuk meningkatkan kualitas sinyal serta menyiapkan data dalam bentuk yang terstruktur untuk tahap selanjutnya.

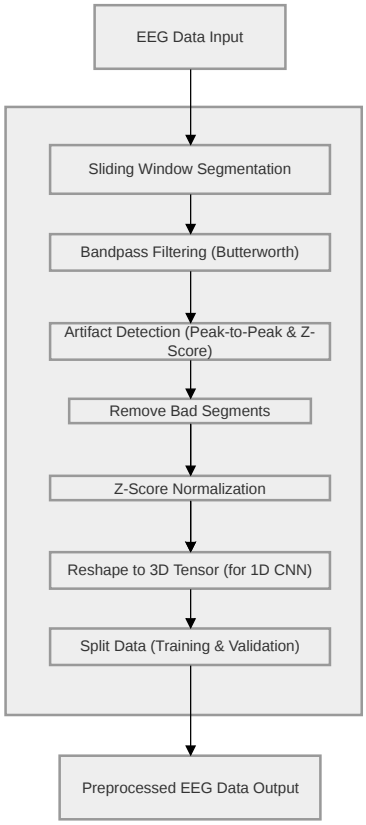

Gambar 3.2. Diagram aliran proses prapemrosesan sistem

Selanjutnya, secara lebih rinci, Gambar 3.2 menggambarkan alur proses pada tahap

pra-pemrosesan data. Sinyal EEG mentah terlebih dahulu dibersihkan dari nilai yang hilang. Selanjutnya, sinyal dibagi ke dalam segmen-segmen dengan durasi tertentu menggunakan pendekatan *sliding window* dengan overlap, sehingga memungkinkan penangkapan karakteristik temporal dari aktivitas neural. Setiap segmen kemudian diproses menggunakan *bandpass filter* berbasis Butterworth untuk mempertahankan komponen frekuensi yang relevan serta mengurangi gangguan seperti *low-frequency drift* dan *high-frequency noise*.

Setelah proses penyaringan, dilakukan tahap seleksi segmen untuk mengidentifikasi dan mengeliminasi artefak berdasarkan kriteria amplitudo dan distribusi statistik, seperti nilai *peak-to-peak* dan *z-score*. Tahap ini bertujuan untuk memastikan bahwa hanya segmen sinyal yang berkualitas baik yang digunakan dalam proses selanjutnya.

Selanjutnya, dilakukan proses normalisasi terhadap setiap segmen sinyal menggunakan metode *z-score normalization*, yaitu dengan mengurangi nilai rata-rata dan membaginya dengan simpangan baku pada masing-masing sampel. Proses ini bertujuan untuk menyeragamkan distribusi data, mengurangi variasi antar sampel, serta meningkatkan stabilitas dalam proses *training* model, khususnya pada tahap augmentasi menggunakan VAE. Data yang telah dinormalisasi kemudian dipisahkan menjadi data *training* dan validasi, serta disusun ulang ke dalam bentuk tensor tiga dimensi agar sesuai dengan kebutuhan arsitektur *1D Convolutional Neural Network*.

3.2.2 Arsitektur Model VAE

Model *Variational Autoencoder* (VAE) menjadi komponen utama dalam arsitektur sistem yang digunakan untuk melakukan augmentasi data sinyal EEG. Pada penelitian referensi [XX], arsitektur VAE yang digunakan berbasis *2D Convolutional Neural Network* (2D CNN), yaitu data EEG direpresentasikan dalam bentuk dua dimensi dengan mempertimbangkan hubungan spasial antar kanal. Namun demikian, dalam penelitian ini dilakukan penyesuaian arsitektur menjadi berbasis *1D Convolutional Neural Network* (1D CNN). Perubahan ini dilakukan untuk menyesuaikan dengan pendekatan klasifikasi yang digunakan, di mana sinyal EEG diproses sebagai deret waktu satu dimensi pada setiap kanal secara terpisah. Selain itu, dimensi ruang laten juga ditingkatkan untuk meningkatkan kapasitas model dalam menangkap variasi pola sinyal EEG.

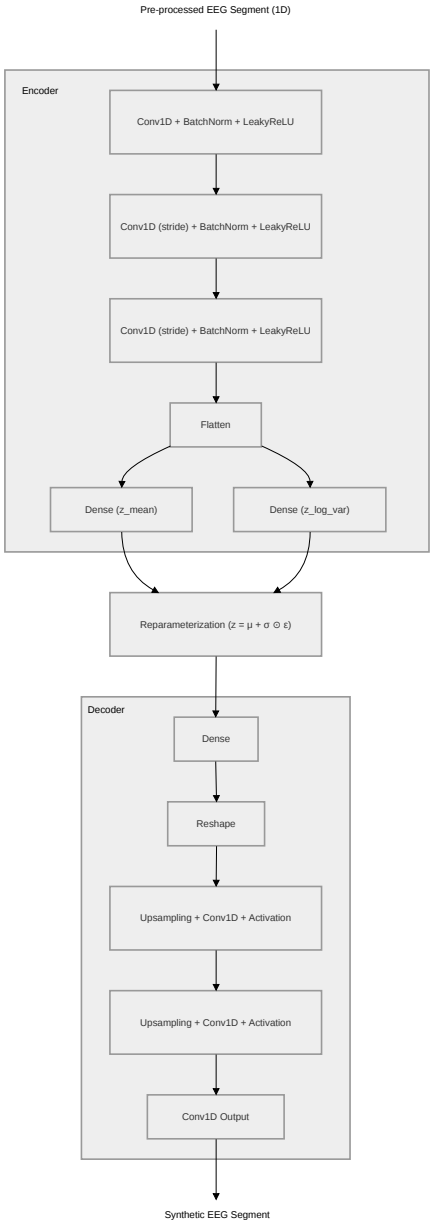

Gambar 3.3. Diagram arsitektur model Variational Autoencoder (VAE)

Pada prosesnya, data input berupa segmen sinyal EEG satu dimensi terlebih dahulu diproses oleh bagian *encoder*. Bagian ini terdiri dari beberapa lapisan *convolutional* satu dimensi yang diikuti oleh *batch normalization* dan fungsi aktivasi *LeakyReLU*. Setiap lapisan *convolutional* menggunakan *stride* tertentu untuk melakukan reduksi dimensi secara progresif, sehingga menghasilkan representasi fitur berdimensi lebih rendah. Representasi ini kemudian diratakan (*flatten*) dan dipetakan ke dalam dua parameter distribusi

laten, yaitu *mean* (z_{mean}) dan variansi logaritmik ($z_{\text{log_var}}$) menggunakan lapisan *dense*. Selanjutnya, dilakukan proses *reparameterization*, di mana vektor laten z dihasilkan dengan mengombinasikan kedua parameter tersebut dengan variabel acak yang mengikuti distribusi normal standar. Mekanisme ini memungkinkan proses *training* model tetap dapat dilakukan melalui *backpropagation* secara *end-to-end*.

Vektor laten yang dihasilkan kemudian menjadi input bagi bagian *decoder*, yang bertugas untuk merekonstruksi kembali sinyal EEG. Proses rekonstruksi diawali dengan lapisan *dense* yang diikuti dengan proses *reshape* untuk membentuk kembali struktur data. Selanjutnya, digunakan serangkaian operasi *upsampling* yang dikombinasikan dengan lapisan *convolutional* satu dimensi dan fungsi aktivasi untuk meningkatkan dimensi data secara bertahap. Lapisan akhir berupa *convolutional* satu dimensi menghasilkan sinyal output yang memiliki dimensi yang sama dengan input awal.

Selain digunakan untuk rekonstruksi, model yang telah melalui tahap *training* juga dimanfaatkan untuk menghasilkan data sintetis baru. Proses ini dilakukan dengan melakukan sampling secara acak pada ruang laten menggunakan distribusi normal standar, yang kemudian diberikan sebagai input ke bagian *decoder*. Melalui mekanisme ini, *decoder* dapat menghasilkan sinyal EEG sintetis yang memiliki karakteristik statistik yang menyerupai data asli, sehingga dapat digunakan sebagai data tambahan dalam proses augmentasi.

Dalam proses *training*, model VAE dioptimalkan menggunakan *loss function* gabungan yang terdiri dari dua komponen utama, yaitu *reconstruction loss* dan *Kullback-Leibler* (KL) divergence. *Reconstruction loss* mengukur perbedaan antara sinyal input dan hasil rekonstruksi, sedangkan KL divergence mengatur distribusi laten agar mendekati distribusi normal standar. Kedua komponen ini dihitung berdasarkan output dari *decoder* serta parameter distribusi laten (z_{mean} dan $z_{\text{log_var}}$), kemudian digabungkan untuk menghasilkan total *loss* yang digunakan dalam proses optimasi model.

3.2.3 Arsitektur Model Klasifikasi

Pipeline klasifikasi yang digunakan terdiri dari beberapa tahapan utama, yaitu dekomposisi frekuensi, standardisasi data, ekstraksi fitur statistik, seleksi fitur, serta klasifikasi. Tahapan awal dilakukan dengan memisahkan sinyal EEG ke dalam lima pita frekuensi

utama, yaitu delta, theta, alpha, beta, dan gamma. Pemisahan ini bertujuan untuk menangkap karakteristik aktivitas otak pada rentang frekuensi yang berbeda, sehingga informasi yang diperoleh menjadi lebih representatif terhadap kondisi neurologis yang diamati dan lebih mudah dianalisis pada tahap selanjutnya.

Setelah proses dekomposisi, setiap pita frekuensi distandardisasi menggunakan transformasi *z-score*. Tahapan ini bertujuan untuk menormalkan distribusi data sehingga memiliki skala yang sebanding antar pita frekuensi, serta mencegah dominasi fitur tertentu dalam proses pembelajaran model. Dengan demikian, representasi data yang dihasilkan menjadi lebih seimbang, sehingga setiap pita frekuensi dapat berkontribusi secara proporsional dalam pembentukan fitur.

Tahap berikutnya adalah ekstraksi fitur statistik, yang bertujuan untuk mengubah sinyal EEG yang bersifat kontinu menjadi representasi numerik yang terstruktur. Fitur yang dihasilkan mencerminkan karakteristik distribusi, variabilitas, dan kompleksitas sinyal pada masing-masing pita frekuensi. Proses ini menghasilkan himpunan fitur berdimensi tinggi yang mampu merepresentasikan pola sinyal secara komprehensif, sehingga menjadi dasar penting dalam proses klasifikasi.

Seleksi fitur dilakukan menggunakan metode *minimum Redundancy Maximum Relevance* (mRMR), yang bertujuan untuk memilih fitur yang paling relevan terhadap label kelas sekaligus meminimalkan redundansi antar fitur. Dengan pendekatan ini, fitur yang dipilih tidak hanya memiliki hubungan kuat dengan target klasifikasi, tetapi juga saling melengkapi satu sama lain. Hasilnya adalah subset fitur yang lebih ringkas, efisien, dan tetap informatif untuk digunakan pada tahap klasifikasi.

Tahap akhir dari *pipeline* adalah proses klasifikasi menggunakan algoritma XGBoost. Model ini membangun ensemble pohon keputusan secara bertahap untuk menangkap hubungan non-linear antar fitur secara efektif. Dalam penelitian ini, proses klasifikasi dilakukan dalam dua skenario, yaitu menggunakan data asli serta menggunakan kombinasi data asli dan data sintetis yang diperoleh dari model augmentasi. Kedua skenario diproses menggunakan *pipeline* yang sama, sehingga perbedaan performa yang dihasilkan dapat secara langsung dianalisis sebagai dampak dari penggunaan data hasil augmentasi.

3.3 Detail Implementasi dan Teknologi

Bagian ini menjelaskan bagaimana perancangan sistem yang telah dijabarkan sebelumnya diterapkan ke dalam kode serta teknologi yang digunakan untuk mengimplementasikannya. Penjelasan pada bagian ini mencakup teknologi dan *library* yang digunakan, serta gambaran umum implementasi dari komponen utama dalam *pipeline*, termasuk pemrosesan sinyal EEG, ekstraksi dan seleksi fitur, modul augmentasi berbasis *Variational Autoencoder* (VAE), serta model klasifikasi.

3.3.1 Teknologi dan Library

Dalam penelitian ini, seluruh proses pengolahan data, *training*, dan evaluasi model dilakukan menggunakan bahasa pemrograman Python. Pemilihan Python didasarkan pada ekosistem library yang luas serta kemampuannya dalam mendukung pengembangan sistem berbasis *machine learning* dan pemrosesan sinyal secara efisien. Untuk mempercepat komputasi, sistem ini memanfaatkan akselerasi GPU dengan bantuan CUDA Toolkit dari NVIDIA, sehingga operasi numerik berskala besar seperti *training* model dan komputasi matriks dapat dilakukan dengan lebih efisien.

Library utama yang digunakan dalam pengembangan sistem ini meliputi NumPy, Pandas, SciPy, dan scikit-learn. NumPy berperan sebagai backend komputasi numerik untuk operasi berbasis array dan matriks, sementara Pandas digunakan untuk pengelolaan dan manipulasi dataset. SciPy menyediakan fungsi *signal processing* yang mendukung proses pemrosesan sinyal EEG, sedangkan scikit-learn digunakan untuk kebutuhan preprocessing data, ekstraksi fitur, serta evaluasi model melalui berbagai metrik yang tersedia.

Untuk tahap pemodelan, digunakan XGBoost sebagai algoritma klasifikasi berbasis *gradient boosting* yang efisien dan mampu menangani data berdimensi tinggi serta hubungan non-linear. Selain itu, PyTorch digunakan sebagai framework *deep learning* untuk membangun model generatif berbasis Variational Autoencoder (VAE), yang memungkinkan proses augmentasi data dilakukan secara fleksibel dengan dukungan akselerasi GPU.

Dalam implementasi pipeline klasifikasi, beberapa library juga berperan dalam tahap ekstraksi dan pemrosesan fitur. SciPy digunakan untuk pemrosesan sinyal dan dekomposisi frekuensi, sementara NumPy dan Pandas mendukung perhitungan serta pengelo-

laan fitur statistik. Untuk seleksi fitur, digunakan scikit-learn sebagai dasar implementasi metode mRMR, sebelum fitur terpilih digunakan dalam proses pelatihan dan prediksi menggunakan XGBoost.

3.3.2 Implementasi Model Generatif Variational Autoencoder (VAE)

Perancangan model generatif pada penelitian ini dilakukan menggunakan pendekatan *Variational Autoencoder* (VAE) yang bertujuan untuk mempelajari distribusi laten dari sinyal EEG serta menghasilkan data sintetis yang menyerupai data asli. Arsitektur model secara umum terdiri dari dua bagian utama, yaitu encoder dan decoder.

TEMP FILL IN THE BLOCK DIAGRAM

Gambar 3.4. Arsitektur model Variational Autoencoder (VAE)

Model menerima input berupa sinyal EEG satu dimensi dengan panjang 512 sampel dan satu kanal, sehingga berbentuk $(512, 1)$. Panjang sinyal ini diperoleh dari proses segmentasi dengan durasi 4 detik pada frekuensi sampling 128 Hz.

Arsitektur Encoder Encoder dirancang menggunakan beberapa lapisan *Conv1D* untuk mengekstraksi pola temporal dari sinyal EEG. Setiap lapisan menggunakan *stride* sebesar 2 untuk melakukan downsampling secara bertahap.

```
inputs = Input(shape=(512, 1))
x = Conv1D(32, 25, strides=2, padding='same')(inputs)
x = BatchNormalization()(x)
x = LeakyReLU(0.2)(x)

x = Conv1D(64, 25, strides=2, padding='same')(x)
x = BatchNormalization()(x)
x = LeakyReLU(0.2)(x)

x = Conv1D(128, 15, strides=2, padding='same')(x)
x = BatchNormalization()(x)
```

```
x = LeakyReLU(0.2)(x)

x = Flatten()(x)
x = Dense(64, activation='relu')(x)

z_mean = Dense(16)(x)
z_log_var = Dense(16)(x)
```

Encoder menggunakan tiga blok konvolusi dengan jumlah filter 32, 64, dan 128. Ukuran kernel yang relatif besar (15–25) dipilih untuk menangkap pola temporal EEG yang memiliki karakteristik frekuensi rendah hingga menengah. Proses downsampling menghasilkan reduksi dimensi bertahap dari 512 menjadi 64, sehingga representasi menjadi lebih ringkas.

Dimensi laten ditetapkan sebesar 16 sebagai kompromi antara kapasitas representasi dan stabilitas pelatihan.

Lapisan Reparameterization Untuk memungkinkan proses pelatihan berbasis gradien, digunakan teknik *reparameterization trick*.

```
class Sampling(layers.Layer):
    def call(self, inputs):
        z_mean, z_log_var = inputs
        epsilon = tf.random.normal(shape=tf.shape(z_mean))
        return z_mean + tf.exp(0.5 * z_log_var) * epsilon

z = Sampling()([z_mean, z_log_var])
```

Lapisan ini menghasilkan vektor laten z dengan menambahkan noise acak terhadap distribusi yang dipelajari, sehingga model tetap bersifat probabilistik.

Arsitektur Decoder Decoder berfungsi untuk merekonstruksi kembali sinyal EEG dari representasi laten.

```
latent_inputs = Input(shape=(16,))
x = Dense(64 * 128, activation='relu')(latent_inputs)
x = Reshape((64, 128))(x)

x = UpSampling1D(2)(x)
x = Conv1D(128, 15, padding='same', activation='relu')(x)
x = BatchNormalization()(x)

x = UpSampling1D(2)(x)
x = Conv1D(64, 25, padding='same', activation='relu')(x)
x = BatchNormalization()(x)

x = UpSampling1D(2)(x)
x = Conv1D(32, 25, padding='same', activation='relu')(x)
x = BatchNormalization()(x)

outputs = Conv1D(1, 3, padding='same')(x)
```

Decoder menggunakan tiga tahap *upsampling* untuk mengembalikan dimensi sinyal ke ukuran awal. Struktur filter disusun secara terbalik dari encoder untuk menjaga konsistensi representasi.

Fungsi Loss dan Training Model dilatih menggunakan kombinasi *reconstruction loss* dan *Kullback-Leibler divergence*.

```
reconstruction_loss = mse(K.flatten(inputs), K.flatten(outputs))
reconstruction_loss *= 512

kl_loss = 1 + z_log_var - K.square(z_mean) - K.exp(z_log_var)
kl_loss = -0.5 * K.sum(kl_loss, axis=-1)

vae_loss = K.mean(reconstruction_loss + kl_loss)
vae.add_loss(vae_loss)
```

Reconstruction loss memastikan hasil rekonstruksi mendekati data asli, sedangkan *KL divergence* menjaga distribusi laten tetap mendekati distribusi normal.

Pelatihan dilakukan menggunakan optimizer Adam dengan *learning rate* sebesar 0.001, batch size 32, dan maksimum 1000 epoch.

Generasi Data Sintetis Setelah model dilatih, data sintetis dihasilkan dengan melakukan sampling dari distribusi laten.

```
z = np.random.normal(size=(N, 16))
synthetic_data = decoder.predict(z)
```

Data sintetis yang dihasilkan kemudian digunakan sebagai tambahan data pelatihan dalam pipeline klasifikasi untuk mengevaluasi pengaruh augmentasi terhadap performa model.

DAFTAR REFERENSI